



Relatório Parcial 2

Período

01 de julho de 2025 a 30 de junho de 2026

Pesquisador Responsável

Prof. Dr. José Mario De Martino

martino@unicamp.br

Depto. de Engenharia de Computação e Automação

Faculdade de Engenharia Elétrica e de Computação

Universidade Estadual de Campinas

Instituição Sede

Universidade Estadual de Campinas - UNICAMP



Direitos da Pessoa com Deficiência

Secretaria dos



SÃO PAULO
GOVERNO DO ESTADO
SÃO PAULO SÃO TODOS



1 Identificação do Projeto

Processo Fapesp	2024/00914-7
Título	Centro de Ciência para o Desenvolvimento Tecnologia Assistiva e Acessibilidade em Libras (CCD-TAAL)
Pesquisador Responsável	Prof. Dr. José Mario de Martino (FEEC/UNICAMP)
Pesquisador Responsável da Instituição Parceira	Edilson de Andrade (SeDPeD)
Pesquisadores Principais	Prof. Dr. Felipe Venâncio Barbosa (FFLCH/USP) Prof. Dr. Hélio Pedrini (IC/UNICAMP) Prof. Dr. Vagner Luiz Gava (IPT)
Pesquisadores Associados	Prof. Dra. Sylvia Lia Grespan Neves (FE/USP) Angelina da Silva Inacio (IPT) Fábio Rogério Lins Pereira de Souza (IPT) Felipe Augusto Frazão Kleine (IPT)
Bolsistas Acadêmicos FAPESP	Dr. Guilherme Vieira Leite (PD) José Carlos Ferreira (DR) Calebe do Nascimento de Souza (IC) Guilherme Galvão de Oliveira Pinto (IC) Gustavo Borba da Silva (IC) Isabela Gomes Pereira (IC)
Bolsistas TT-4A FAPESP	Ângelo Brandão Benetti Isabela Cristina Barbieri Natalia Najyme de Melo Afonso Thyago de Souza Santos
Bolsistas PRP UNICAMP	Dra. Maria Cristina Oliveira Souza Dra. Tatiana de Lourdes Massaro
Bolsistas BAS UNICAMP	Jhonatan Valentim Nunes Calixto João Vitor Gonçalves da Costa Leonardo Domingos da Luz Matheus de Oliveira e Almeida Níque Emília Bomfim Souza Santos Rafael Henrique Rabelo
Período do Relatório	1º de julho de 2025 a 30 de junho de 2026
Data de Início do Projeto	1º de julho de 2024
Data de Término do Projeto	30 de junho de 2029

2 Resumo do Projeto

O Centro de Ciência para o Desenvolvimento - Tecnologia Assistiva e Acessibilidade em Libras (CCD-TAAL) é uma articulação multidisciplinar envolvendo pesquisadores da Universidade Estadual de Campinas, da Universidade de São Paulo e do Instituto de Pesquisas Tecnológicas, em parceria com a Secretaria Estadual dos Direitos da Pessoa com Deficiência. O CCD-TAAL busca avançar no desenvolvimento de soluções que reduzam as barreiras de comunicação entre a comunidade surda e a ouvinte.

O CCD-TAAL se propõe a enfrentar esse desafio, com foco no desenvolvimento de abordagens para a tradução automática da Língua Brasileira de Sinais (Libras) para o português e vice-versa, explorando modernas técnicas de aprendizado de máquina baseadas em redes neurais profundas. Essa missão está alinhada ao tema estratégico proposto na Chamada da FAPESP, que busca um projeto de pesquisa em inteligência artificial voltado à acessibilidade da Libras.

3 Objetivos e Plano de Trabalho Propostos

O CCD-TAAL objetiva o desenvolvimento de sistemas de tradução automática de português para Libras e de Libras para português, explorando as mais atuais e promissoras abordagens de tradução automática entre línguas orais e de reconhecimento de atividade humana. Atualmente, tais abordagens são baseadas em dados (*data-driven*) e se apoiam em técnicas de aprendizado de máquina.

A estratégia condutora do projeto baseia-se na adaptação de abordagens SOTA (*State-of-the-Art*) de tradução automática entre línguas orais e de reconhecimento de atividade humana. Essa adaptação passa pelo estudo, experimentação e avaliação de arquiteturas promissoras de aprendizado profundo (*Deep Learning*). Contudo, como Libras é uma língua com recursos computacionais limitados (*Under-Resourced Language*)¹, a carência de dados enseja a investigação, também a ser explorada no projeto, de abordagens de transferência de conhecimento (*transfer learning*) para mitigar o problema. Estratégias de transferência de conhecimento têm sido aplicadas com sucesso à tradução entre línguas orais com recursos computacionais limitados. Entretanto, mesmo com a aplicação de estratégias de transferência de conhecimento, ainda são necessários ajustes no modelo pré-treinado com dados das línguas envolvidas. Faz parte do método de desenvolvimento do projeto a definição de um protocolo de construção e de estabelecimento de uma base de dados, ou corpus paralelo, para permitir o treinamento dos modelos computacionais.

Além dos dois objetivos principais de pesquisa mencionados acima, o projeto prevê também a definição e a implementação de provas de conceito de aplicativos para apoiar a comunicação entre surdos e ouvintes, utilizando as soluções desenvolvidas. Ainda no escopo do projeto, esses aplicativos serão desenvolvidos com forte apoio e interação com a Secretaria de Estado dos Direitos da Pessoa com Deficiência e avaliados em ambiente controlado de laboratório e em campo.

Em síntese, os objetivos do projeto CCD-TAAL apresentados na proposta do projeto são:

- Desenvolver abordagens baseadas em aprendizado de máquina para a superação dos desafios tecnocientíficos envolvidos na tradução automática de português escrito para Libras;
- Desenvolver abordagens baseadas em aprendizado de máquina para a superação dos desafios tecnocientíficos envolvidos na tradução automática de Libras para português escrito;
- Desenvolver abordagens para o reconhecimento da Libras em imagem e vídeo explorando modelos e técnicas computacionais baseadas em aprendizado de máquina;
- Desenvolver e refinar abordagens para a síntese de avatares sinalizantes realistas 3D e avatares videorealistas;

¹Uma língua com recursos computacionais limitados carece de dados que possam ser usados para o treinamento de modelos computacionais baseados em aprendizado de máquina.

- Construir uma base de dados (*dataset*) ampla e aberta que sirva de subsídio para as pesquisas do CCD-TAAL e de outros grupos de pesquisa do Estado, do País e do exterior;
- Desenvolver aplicativos utilizando as abordagens de tradução automática desenvolvidas que contribuam para reduzir as barreiras comunicacionais e de acesso a conteúdos digitais escritos enfrentadas pelos surdos;
- Pesquisar os impactos e o potencial das tecnologias de tradução automática entre Libras e português em contextos sociais como educação e saúde, para aumentar a acessibilidade e potencializar as políticas públicas de inclusão voltadas à comunidade surda;
- Contribuir com o estudo, o desenvolvimento e a difusão da Língua Brasileira de Sinais;
- Contribuir para a formação de pesquisadores e profissionais nas áreas de competência técnica e científica do CCD-TAAL.




Figura 1: Focos de Pesquisa e Desenvolvimento do CCD-TAAL.

A Figura 1 apresenta os focos de pesquisa e desenvolvimento do CCD-TAAL, representados por retângulos com bordas arredondadas. Os elementos gráficos à esquerda da figura, com aparência de filme, representam vídeos e/ou animações com conteúdo em Libras. Os retângulos com canto dobrado representam informação em formato escrito. O elemento cilíndrico representa a base de dados a ser construída para alimentar os algoritmos de aprendizado de máquina. Essa base será composta por, entre outros elementos, vídeos, anotações por glosa, dados de captura de movimento (MoCap - *Motion Capture*) e metadados para complementar e caracterizar a informação e permitir a indexação, busca e recuperação de dados. As setas representam o fluxo de informação entre os vários componentes da figura.

O método a ser utilizado no desenvolvimento do projeto pode ser resumido nas seguintes atividades:

- A1 Reuniões dos Pesquisadores Principais.** Reuniões semestrais para o acompanhamento e alinhamento das atividades executadas e a serem executadas. O projeto prevê a realização de reuniões de alinhamento semestrais com a participação dos Pesquisadores Principais. Essas reuniões têm como objetivo disseminar, entre os membros do CCD-TAAL, as atividades desenvolvidas e os resultados parciais alcançados no semestre anterior, e planejar as atividades para o semestre seguinte.

- A2 **Oficinas de Trabalho.** Anualmente, será realizada oficina de trabalho para a apresentação e discussão de detalhes técnicos das atividades desenvolvidas e a serem desenvolvidas. Durante as Oficinas, os Pesquisadores Principais, Pesquisadores Associados e bolsistas apresentarão seus trabalhos. Cada oficina contará também com um palestrante convidado, preferencialmente internacional, não participante do projeto.
- A3 **Estabelecimento de Formalismo de Anotação por Glosas.** A estratégia para a representação escrita da Libras, processável por computador e a ser explorada no projeto, será baseada na anotação com glosas. Para tanto, é necessária a definição de um formalismo que permita a anotação de sinais lexicais, parcialmente lexicais e não lexicais, incluindo expressões faciais e outros aspectos não-manuais. As glosas serão utilizadas para anotar vídeos com conteúdo em Libras, controlar avatares sinalizantes e permitir a aplicação de técnicas de aprendizado de máquina para a tradução automática.
- A4 **Construção de Base de Dados.** Construção de base de dados (*dataset*) para o treinamento, validação, teste e avaliação de modelos de aprendizado de máquina. A construção de uma base de dados que constitua um corpus paralelo português-Libras é um passo fundamental para desenvolver sistemas de aprendizado de máquina capazes de realizar a tradução entre as duas línguas. Os principais passos a serem adotados na coleta desses dados incluem: (i) elaboração e aprovação do projeto junto ao Comitê de Ética em Pesquisa (CEP) da instituição-sede; (ii) recrutamento de voluntários; (iii) seleção do material para a formação da base de dados. Inicialmente, duas classes de material serão consideradas: livros didáticos do ensino fundamental e procedimento de anamnese², (iv) tradução do material selecionado por intérpretes/tradutores para a representação por glosas, (v) gravação em vídeos e dados de captura de movimento da sinalização do material traduzido, (vi) anotação ELAN [2] dos vídeos e associação a metadados, incluindo os dados de captura de movimento, (vii) análise linguística dos vídeos e dados de captura de movimento da sinalização e (viii) armazenamento e organização da base de dados para permitir buscas e edições.
- A5 **Reconhecimento de Libras Vídeo-para-Glosa (*Sign2Gloss*).** Desenvolvimento de modelos baseados em técnicas de aprendizado de máquina para o reconhecimento de Libras Vídeo-para-Glosa, incluindo aspectos manuais e não manuais da Libras. Com a base de dados coletada neste projeto, serão desenvolvidos e treinados modelos de aprendizado profundo. Inicialmente, os dados específicos de língua de sinais, enriquecidos com anotações por glosas correspondentes aos sinais e informações sobre o contexto linguístico e dependências espaço-temporais, servirão como fonte de treinamento para modelos envolvendo *Transformers* e GNNs. Essa abordagem visa não apenas a capacitar o modelo a identificar e transcrever os sinais com precisão, mas também a garantir a sincronização eficaz entre as informações visuais e linguísticas.
- A6 **Tradução Glosa-para-Texto (*Gloss2Text*).** O foco desta atividade é desenvolver modelos baseados em técnicas de aprendizado de máquina para a tradução automática Glosa-para-Texto, explorando arquiteturas SOTA desenvolvidas para a tradução entre línguas orais e escritas. Tais modelos atualmente se baseiam em arquitetura codificador-decodificador associada a mecanismo de atenção do tipo *Transformers*.

²A anamnese é a coleta da história clínica do paciente, podendo ser considerada uma das etapas mais importantes na prática dos profissionais de saúde. Nessa etapa, o paciente é entrevistado para o levantamento e compreensão de sua doença e possíveis causas [1].

- A7 **Tradução de Libras Vídeopara-Texto (*Sign2Text*)**. Desenvolvimento de modelos baseados em técnicas de aprendizado de máquina para o reconhecimento de Libras Vídeopara-Texto, incluindo seus aspectos manuais e não-manuais da Libras, explorando a estratégia fim-a-fim (*end-to-end*). Esta atividade visa a conversão da informação da sinalização presente em imagens e vídeos diretamente para texto em português em um único passo, sem passar por uma representação intermediária baseada em glosas. Da mesma forma que a atividade anterior, modelos de aprendizado profundo serão projetados e treinados.
- A8 **Tradução Texto-para-Glosa (*Text2Gloss*)**. Esta atividade é voltada ao desenvolvimento de modelos baseados em técnicas de aprendizado de máquina para a tradução automática de Texto-para-Glosa. Como na atividade anterior, serão exploradas e avaliadas arquiteturas de estado da arte voltadas à tradução automática entre línguas orais/escritas.
- A9 **Conversão Glosa-para-Vídeo (*Gloss2Sign*) e Síntese de Avatar Sinalizante 3D**. Desenvolvimento e refinamento de abordagem voltada à síntese de avatar sinalizante tridimensional realista.
- A10 **Conversão Glosa-para-Vídeo (*Gloss2Sign*) e Síntese de Avatar Sinalizante Videorealista**. Desenvolvimento de uma abordagem voltada à síntese de animações de avatar videorealistas, explorando redes neurais generativas.
- A11 **Desenvolvimento de Aplicativos**. Projeto e implementação de aplicativos, utilizando as tecnologias de tradução desenvolvidas, voltados à inserção social, educacional e laboral dos Surdos.
- A12 **Avaliação de Abordagens de Reconhecimento/Tradução de Libras**. A atividade é voltada à definição e aplicação de protocolos e ferramentas para avaliar e comparar a qualidade e generalidade das abordagens de reconhecimento/tradução da Libras desenvolvidas. As avaliações e comparações a serem realizadas envolvem as abordagens Vídeopara-Glosa, acopladas à tradução Glosa-para-Texto e Vídeopara-Texto, que serão exploradas.
- A13 **Avaliação de Abordagens de Tradução de Texto-para-Glosa e vice-versa**. O foco da atividade é a definição e aplicação de protocolos e ferramentas para avaliar e comparar a qualidade e generalidade das abordagens de tradução automática de texto em português para representação por glosa e vice-versa. As avaliações e comparações envolvem as abordagens de tradução Texto-para-Glosa e Glosa-para-Texto que serão estudadas.
- A14 **Avaliação Avatares**. Definição e aplicação de protocolo para avaliar e comparar a qualidade do avatar 3D e avatar videorealista. Nesta atividade, será desenvolvida também uma avaliação comparativa da interação entre usuário e avatar versus intérprete humano, através de técnicas de rastreamento ocular. Os dados dessa comparação trarão informações sobre a percepção e esforço cognitivo de partes específicas do avatar, como as configurações de mãos, expressões não manuais e amplitude da permanência do contato. Ainda nesta atividade será desenvolvida a avaliação humana focalizando a fluência e adequação do resultado da tradução. Serão desenvolvidos instrumentos de mensuração da percepção dos usuários sobre a usabilidade, a inteligibilidade e a acessibilidade.
- A15 **Avaliação de Aplicativos**. Definição e aplicação de protocolos para avaliar os aplicativos desenvolvidos para a inserção social, educacional e laboral dos Surdos. Será realizada a testagem empírica com usuários surdos, em contextos educacionais e da área da saúde.

Tabela 1: Cronograma de Execução.

Atividade	Ano 1				Ano 2				Ano 3				Ano 4				Ano 5			
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
A1																				
A2																				
A3																				
A4																				
A5																				
A6																				
A7																				
A8																				
A9																				
A10																				
A11																				
A12																				
A13																				
A14																				
A15																				

4 Atividades Realizadas e Resultados Alcançados

Uma descrição das atividades realizadas no período coberto por este relatório é apresentada a seguir.

- A1 Reuniões dos Pesquisadores Principais:** Para tornar o acompanhamento do projeto mais efetivo e dinâmico, as reuniões de acompanhamento, inicialmente previstas para ocorrerem semestralmente, passaram a ser realizadas semanalmente. Participam dessas reuniões todos os integrantes do projeto, incluindo pesquisadores principais, pesquisadores associados, bolsistas e colaboradores. Durante os encontros, são apresentados e discutidos os resultados e as atividades desenvolvidas na semana anterior, o planejamento das atividades da semana seguinte e eventuais dificuldades encontradas na execução do projeto.
- A2 Oficinas de Trabalho:** Esforços foram empenhados para convidar participantes internacionais para as oficinas. Entretanto, ainda não foi possível alinhar a disponibilidade e sincronizar a agenda de convidados para participar da oficina presencial e da visita ao CCD-TAAL. A atividade possível foi uma conversa remota com a Profa. Dra. Lorna Quandt, pesquisadora da área de neurociência cognitiva, psicologia da linguagem e tecnologias para línguas de sinais, que atua como professora e pesquisadora na Gallaudet University, universidade norte-americana reconhecida internacionalmente por sua atuação junto à comunidade surda. Também estabelecemos contato com a Profa. Dra. Liona Paulus e os pesquisadores Maria Kopf e Julian Bleicken da Universidade de Hamburgo, Alemanha, vinculados ao *Institut für Deutsche Gebärdensprache und Kommunikation Gehörloser* (IDGS). A Profa. Paulus é linguista surda especializada em línguas de sinais, estudos surdos e interpretação entre línguas de sinais e língua oral. A pesquisadora Maria Kopf atua principalmente em questões associadas a recursos linguísticos para línguas de sinais, corpora anotados, documentação linguística e infraestrutura de dados para pesquisa. Julian Bleicken integra a equipe responsável pelo desenvolvimento e manutenção do DGS Corpus (Corpus de Língua de Sinais

Alemã), um relevante corpus de língua de sinais que contém centenas de horas de gravações e extensas anotações linguísticas. Uma conversa remota com o grupo da Profa. Paulus deverá ocorrer em julho próximo após o período de férias de seus membros.

A3 Estabelecimento de Formalismo de Anotação por Glosas: Ao longo dos dois primeiros anos do projeto, foi conduzido um trabalho colaborativo envolvendo intérpretes e participantes surdos para o desenvolvimento de um formalismo multicamada de anotação por glosas para a Libras. A partir de setembro de 2024, foram realizadas diversas reuniões no âmbito do CCD-TAAL com o objetivo de definir um esquema de anotação adequado ao treinamento e à avaliação de modelos de aprendizado de máquina. Nessas reuniões, foram discutidos os princípios conceituais da anotação, as convenções a serem adotadas e a estrutura das camadas de anotação necessárias para representar as características multiarticulatórias e parcialmente simultâneas da Libras, incluindo mãos, corpo, face, boca e olhos. Também foram consideradas as demandas das estratégias de tradução automática previstas no projeto. O formalismo resultante estabelece um protocolo para a tradução e a anotação de vídeos em Libras, visando garantir consistência linguística e adequação às aplicações computacionais desenvolvidas no projeto. A versão atual desse formalismo é apresentada no Anexo 1.

A4 Construção de Base de Dados: A construção de bases de dados (datasets) para o treinamento de modelos neurais envolve desafios significativos relacionados aos custos de gravação, anotação e validação dos dados. Por esse motivo, é comum que esses conjuntos sejam desenvolvidos com restrições de domínio linguístico, limitando-se a temas, contextos comunicativos, vocabulários ou tipos específicos de interação. Essa estratégia reduz a complexidade da coleta e da anotação, permite controlar o vocabulário empregado e facilita a obtenção de múltiplas ocorrências de cada unidade linguística, tornando viáveis o treinamento, a validação e a avaliação dos modelos.

No âmbito do CCD-TAAL, estão em desenvolvimento três conjuntos de dados voltados à pesquisa em tradução automática envolvendo Libras: (i) anamnese médica, (ii) interação entre passageiros e condutores em veículos e (iii) comunicação em restaurantes universitários.

A anamnese é a coleta da história clínica do paciente e pode ser considerada uma das etapas mais importantes na prática dos profissionais de saúde. Nessa etapa, o paciente é entrevistado para o levantamento e compreensão de sua doença e possíveis causas [1]. No domínio da anamnese médica, foram elaboradas 4.357 sentenças em português, abrangendo tanto as falas do médico quanto as do paciente. Essas sentenças estão sendo traduzidas para Libras por intérpretes surdos e ouvintes participantes do projeto. O processo de tradução envolve análise, discussão e validação coletiva em reuniões da equipe. Após a definição da versão considerada mais adequada, é produzido um vídeo de referência que orienta as etapas subsequentes de aquisição de dados. Cada sentença é registrada em dois momentos distintos. Em um dos momentos, o sinalizante é gravado simultaneamente por quatro câmeras convencionais RGB posicionadas à sua frente. No outro momento, são capturados dados corporais e faciais por meio de um sistema de captura de movimento (Motion Capture – MoCap). Esses dados são utilizados para a geração de animações de avatares tridimensionais. Os vídeos RGB são anotados utilizando o formalismo descrito no Anexo 1 com o auxílio do software ELAN [2]. As animações dos avatares também serão anotadas, possibilitando seu uso como dados de treinamento, validação e teste de modelos neurais.

A Tabela 2 apresenta os dados registrados e gerados até o momento. Na tabela, são apresentadas

as quantidades relacionadas a:

- **Sentenças em português:** conjunto de sentenças geradas a partir de simulações de diálogos possíveis entre médico e paciente no contexto da anamnese. Essas sentenças são expressas em forma textual.
- **Sentenças em português traduzidas para Libras:** sentenças originalmente em português traduzidas para Libras e expressas por meio de um vídeo de referência.
- **Sentenças distintas gravadas em vídeo:** coleção de vídeos com conteúdo em Libras de sentenças distintas.
- **Sentenças gravadas em vídeo:** conjunto total de sentenças gravadas em vídeo, podendo haver repetições de sentenças, contemplando diferentes sinalizadores e diferentes posicionamentos das câmeras.
- **Sentenças distintas gravadas com MoCap:** dados de MoCap de sentenças distintas.
- **Sentenças gravadas em MoCap:** total de sentenças gravadas com dados de Mocap, incluindo repetições.
- **Animações geradas:** conjunto de animações geradas a partir dos dados de MoCap.
- **Sentenças distintas anotadas no ELAN:** conjunto de arquivos de anotação de vídeos contendo sentenças distintas. A anotação seguirá o formalismo apresentado no Anexo 1.
- **Sentenças anotadas no ELAN:** arquivos de anotação de vídeos de todas as sentenças, incluindo as repetições.

O segundo conjunto de dados é voltado à interação entre passageiro e condutor no interior de veículos e está sendo desenvolvido no contexto do projeto UNITY, cooperação Brasil–Alemanha financiada pela FAPESP (Processo 2024/23068-4). O projeto tem como objetivo ampliar a acessibilidade de pessoas surdas aos sistemas de transporte multimodais. Inicialmente, foram definidas 127 sentenças em português representativas de interações típicas entre passageiros e condutores. A primeira campanha de aquisição de dados foi realizada na UNICAMP com a participação de pesquisadores alemães, utilizando três veículos distintos (Jeep Compass, Nissan March e Renault Megane) e três intérpretes de Libras. A coleta empregou uma câmera RGB FLIR, uma câmera tridimensional Time-of-Flight (ToF) e a câmera de um tablet, permitindo a captura simultânea de imagens RGB, profundidade e nuvens de pontos. Todas as gravações foram realizadas durante o dia e em condições climáticas favoráveis. Resultados parciais dessa atividade foram consolidados no artigo apresentado no Anexo 2.

Posteriormente, o conjunto de dados foi ampliado para 1.349 sentenças em português. Essas sentenças estão sendo traduzidas para Libras e registradas com quatro câmeras RGB convencionais, com diferentes sinalizadores e diferentes posicionamentos dos sinalizadores: em pé e sentado. De forma semelhante ao conjunto de anamnese, também são coletados dados corporais e faciais por MoCap para a geração de animações de avatares tridimensionais.

A Tabela 2 apresenta os dados registrados e gerados até o momento para este conjunto de dados.

O terceiro conjunto de dados destina-se ao desenvolvimento de soluções de acessibilidade Web baseadas em avatares tridimensionais sinalizadores. Como prova de conceito, foi escolhido o domínio de restaurantes universitários. O protótipo produzido já foi integrado às páginas Web

Tabela 2: Conjuntos de dados em construção.

Domínio	Tipo de Dados	Total
Anamnese	Sentenças em português (texto)	4.357
	Sentenças em português traduzidas para Libras (vídeo de referência)	444
	Sentenças distintas gravadas em vídeo (vídeo)	344
	Sentenças gravadas em vídeo (vídeo)	1.376
	Sentenças distintas gravadas com MoCap (dados de MoCap)	441
	Sentenças gravadas em MoCap (dados de MoCap)	441
	Animações geradas (animação)	18
	Sentenças distintas anotadas no ELAN (anotação)	0
	Sentenças anotadas no ELAN (anotação)	0
Interação Veículo	Sentenças em português (texto)	1.349
	Sentenças em português traduzidas para Libras (vídeo de referência)	1.075
	Sentenças distintas gravadas em vídeo (vídeo)	1.046
	Sentenças gravadas em vídeo (vídeo)	10.496
	Sentenças distintas gravadas com MoCap (dados de MoCap)	1.021
	Sentenças gravadas em MoCap (dados de MoCap)	1.021
	Animações geradas (animação)	92
	Sentenças distintas anotadas no ELAN (anotação)	0
	Sentenças anotadas no ELAN (anotação)	0
Cardápio	Sentenças em português (texto)	960
	Sentenças em português traduzidas para Libras (vídeo de referência)	0
	Sentenças distintas gravadas com MoCap (dados de MoCap)	960
	Sentenças gravadas em MoCap (dados de MoCap)	960
	Animações geradas (animação)	758
	Sentenças distintas anotadas no ELAN (anotação)	0
	Sentenças anotadas no ELAN (anotação)	0

dos restaurantes universitários da UNICAMP. A interface do protótipo permite ao usuário ativar ou desativar o avatar, ajustar sua posição na tela e controlar a velocidade da sinalização. Uma demonstração da solução pode ser visualizada em vídeo ([clique aqui para ver](#)). Além de apoiar iniciativas de acessibilidade na Web, esse conjunto de dados também será utilizado para o treinamento, validação e teste de modelos neurais de tradução automática.

Assim como nos demais domínios, foram realizadas sessões de captura de movimento corporal e facial com sinalizadores fluentes em Libras. Após a aquisição, para a geração de animações, os movimentos capturados são transferidos para o esqueleto de um avatar virtual, estabelecendo uma correspondência direta entre os movimentos do sinalizante e os do avatar.

Para associar os dados de movimento às unidades linguísticas correspondentes, cada sessão é renderizada como um vídeo animado do avatar e anotada com o software ELAN. As anotações são sincronizadas com os dados de MoCap, permitindo a extração automática de segmentos correspondentes a sinais específicos. Esses segmentos são associados às respectivas glosas e armazenados em uma base de movimentos, possibilitando sua recuperação e reutilização em processos de síntese concatenativa de Libras [3]. O Anexo 6 apresenta aspectos do desenvolvimento da abordagem baseada em síntese concatenativa de sinais.

A Tabela 2 apresenta os dados registrados e gerados até o momento também para este conjunto de dados.

A5 Reconhecimento de Libras Vídeo-para-Glosa (*Sign2Gloss*): Como parte desta atividade, foi implementada a abordagem proposta no artigo [4], baseada em arquitetura *Transformer* para reconhecimento e tradução de línguas de sinais. Um dos principais diferenciais dessa abordagem é o treinamento multitarefa, no qual as tarefas de reconhecimento de sinais (*Sign2Gloss*) e tradução (*Gloss2Text*) são aprendidas de forma conjunta, em vez de serem tratadas como problemas independentes. Durante o treinamento, o modelo aprende simultaneamente a produzir sequências de glosas e sentenças na língua alvo por meio de uma função de custo que combina os erros das duas tarefas. Essa estratégia permite que o conhecimento adquirido durante o reconhecimento contribua para a tradução, favorecendo a aprendizagem de representações internas robustas e linguisticamente informadas. A arquitetura é composta por um extrator visual baseado em rede neural convolucional, responsável por gerar representações dos quadros do vídeo, seguido por um *encoder Transformer*, que modela as dependências temporais dessas representações, e por módulos de decodificação dedicados às tarefas de reconhecimento e tradução.

Para avaliar o modelo, os autores conduziram experimentos utilizando o conjunto de dados RWTH-PHOENIX-Weather 2014T, um dos principais conjuntos de dados da área, composto por vídeos na Língua de Sinais Alemã (DGS), acompanhados de anotações de glosas e traduções para o alemão escrito. Os resultados demonstraram ganhos, em comparação com métodos anteriores, tanto na tarefa de reconhecimento quanto na de tradução. Em reconhecimento contínuo de língua de sinais, o modelo obteve reduções na taxa de erro de palavras (Word Error Rate – WER) [5], enquanto, na tradução, alcançou melhorias em métricas automáticas de avaliação, como BLEU [6].

O modelo neural para reconhecimento de língua de sinais implementado no âmbito do CCD-TAAL foi validado e testado no mesmo conjunto de dados utilizado na implementação original. Na tarefa de reconhecimento (*Sign2Gloss*), o modelo alcançou WER de 42,92, valor compatível com os resultados reportados no trabalho original. Esse mesmo experimento foi replicado no *cluster* de computação de alto desempenho (HPC) da Technische Hochschule Ingolstadt (THI), com o propósito de avaliar comparativamente a eficiência computacional entre as infraestruturas disponíveis. O modelo alcançou um desempenho estatisticamente similar, registrando uma WER de 45,08. Contudo, evidenciou-se um ganho computacional expressivo na infraestrutura alemã: o tempo total necessário para o treinamento foi reduzido para apenas 40 minutos, em contraste com as 16 horas demandadas pelos equipamentos locais utilizados no Brasil. Essa implementação estabelece uma base para futuras adaptações à Libras e aos conjuntos de dados em desenvolvimento no âmbito do CCD-TAAL.

A6 Tradução Glosa-para-Texto (*Gloss2Text*): Parte da solução proposta em [7] e implementada no âmbito do CCD-TAAL também suporta a tarefa de tradução de Glosa-para-Texto. O modelo implementado como parte desta atividade apresentou as seguintes métricas de desempenho para a tarefa de tradução Glosa-para-Texto: BLEU-1 48,90, BLEU-2 36,88, BLEU-3 29,45 e BLEU-4 24,54. Novamente o experimento foi executado no *cluster* da THI, obtendo resultados similares, porém, em menor tempo: BLEU-1 45,60, BLEU-2 31,80, BLEU-3 24,18, BLEU-4 19,46. Tais valores são compatíveis com os resultados apresentados no artigo de referência.

Foram conduzidos experimentos baseados em [8] e [9], que apresentam abordagens para o processamento de arquivos gerados pelo software ELAN para o seu uso como base de dados para o treinamento de modelos neurais. Os trabalhos citados têm como foco a tradução de glosas de

múltiplas camadas, e discorrem sobre as dificuldades em acessar os corpora disponíveis e sua escassez e também métricas de avaliação da tradução.

As etapas realizadas relativas às glosas de múltiplas camadas dos experimentos até o momento foram: a busca de bases de dados que incluam anotações de glosas em múltiplas camadas (preferencialmente em formato criado pelo ELAN) e a adaptação e execução dos códigos-fonte disponibilizados pelos autores – gerando, respectivamente, novos *datasets* em formato de texto e JSON com as glosas realinhadas e reagrupadas de maneira mais apropriada para o treinamento de modelos.

- A7 **Tradução de Libras Vídeo-para-Texto (*Sign2Text*)**: O encadeamento da implementação, envolvendo as atividades 5 e 6, resulta em um modelo de tradução Vídeo-para-Texto. Os desenvolvimentos realizados no âmbito do CCD-TAAL também estabelecem um modelo de tradução Vídeo-para-Texto a ser refinado e adaptado para Libras.

Na literatura revisada, focada na tradução direta de vídeos em texto, o *framework* de referência Uni-Sign [10] destacou-se por seu pipeline robusto. Esse pipeline parte da extração de poses corporais, faciais e das mãos por meio da ferramenta RTMPose, exportando-as em séries temporais de grafos, processando-as em seguida através de Redes Neurais Convolucionais de Grafos Espaço-Temporais (ST-GCNs) para gerar embeddings semânticos e, por fim, decodificando os embeddings obtidos com o modelo de linguagem mT5-base para gerar a tradução em texto final.

A partir dessa fundamentação teórica, foi realizada uma análise experimental para validar empiricamente e reproduzir a arquitetura do *framework* estudado, com testes em vídeos selecionados. O MediaPipe foi utilizado no lugar do RTMPose, obtendo a mesma qualidade das informações exportadas em grafos. Também foram realizadas avaliações com GCNs e ST-GCNs, utilizando a arquitetura proposta no código-fonte original do *framework* Uni-Sign e obtendo os *embeddings* esperados para a tradução pelo mT5-base.

- A8 **Tradução Texto-para-Glosa (*Text2Gloss*)**: Como parte desta atividade, foi implementada uma abordagem de mapeamento Texto-para-Glossa baseada no *fine-tuning* do modelo de tradução automática multilíngue mBART [11]. O mBART, abreviação de *multilingual Bidirectional and Auto-Regressive Transformer*, emprega a arquitetura *Transformer* padrão de Vaswani [12]. O modelo combina um *encoder* bidirecional, eficiente na compreensão textual, junto com um *decoder* autotregressivo, eficaz na geração contínua de textos. Esse modelo passa por um pré-treinamento não supervisionado, em que seu objetivo é a reconstrução de documentos corrompidos por mascaramentos de *tokens* e permutações aleatórias de sentenças [13]. Ao tentar reconstruir textos fortemente corrompidos, o modelo é forçado a desenvolver uma compreensão gramatical robusta do idioma. Esse conhecimento linguístico adquirido torna o mBART competente em tarefas de tradução automática. No contexto específico da conversão Texto-para-Glossa, o pré-treinamento do mBART em *corpora* multilíngues de larga escala permite ao *encoder* obter uma profunda compreensão semântica e sintática da língua oral. O conhecimento é transferido para a tarefa de mapeamento Texto-para-Glossa por meio do *fine-tuning*, etapa na qual a rede é treinada para converter sentenças em língua falada em sequências de glosas. O fato das glosas serem baseadas no vocabulário da língua oral permite que o modelo aproveite as representações lexicais já aprendidas.

A implementação realizada no âmbito do CCD-TAAL foi testada e avaliada nos conjuntos de

dados Phoenix-14T e VLibrasBD [14], alcançando pontuações BLEU-4 de 25,51 e 41,12, respectivamente.

A9 Conversão Glossa-para-Vídeo (*Gloss2Sign*) e Síntese de Avatar Sinalizante 3D: Até o momento, foram geradas 1.018 animações de um avatar tridimensional sinalizador, sendo 18 relacionadas ao conjunto de dados de anamnese, 92 ao conjunto de dados de interação entre passageiro e condutor, 758 ao conjunto de dados de acessibilidade Web dos restaurantes universitários da UNICAMP e 150 relacionadas a pesquisas complementares e textos institucionais do projeto.

As animações serão usadas para apresentar visualmente o resultado final da tradução para a língua de sinais, explorando a abordagem concatenativa descrita em [15]. Adicionalmente, as animações também serão utilizadas para auxiliar no treinamento de modelos neurais, fornecendo dados sintéticos para ampliar o conjunto de dados de treinamento

Originalmente desenvolvida para síntese de fala, a abordagem concatenativa gera novas expressões por meio da seleção e concatenação de segmentos previamente armazenados em uma base de dados [16, 17]. Aplicada à Libras, essa estratégia utiliza fragmentos de movimento obtidos por captura de movimento (Motion Capture – MoCap). A partir de uma sequência de glosas, o sistema recupera segmentos correspondentes da base de dados, seleciona as instâncias mais adequadas e as combina para produzir novas animações. Como os movimentos são derivados de performances humanas reais, a síntese preserva características cinemáticas e temporais difíceis de reproduzir por meio de técnicas procedurais ou puramente neurais.

Os dados utilizados na construção da base de movimentos, contendo os segmentos a serem concatenados, são obtidos em sessões de MoCap com sinalizadores fluentes em Libras. Simultaneamente, expressões faciais e outros aspectos não manuais foram registrados por uma câmera acoplada à cabeça do informante. Posteriormente, técnicas de visão computacional são empregadas para extrair parâmetros faciais relevantes e sincronizá-los com os dados corporais, permitindo a reconstrução integrada dos componentes manuais e não manuais da sinalização.

O *pipeline* de síntese concatenativa implementado consiste em quatro etapas: seleção de fragmentos, geração de conteúdo, suavização de transições e síntese de animação. Partindo de uma sequência de glosas, o sistema recupera fragmentos de movimento armazenados em uma base de dados, seleciona as instâncias mais compatíveis, gera transições suaves entre fragmentos consecutivos e, por fim, renderiza a animação resultante em um avatar tridimensional de sinalização.

Para cada glosa da sequência de entrada, todas as instâncias do sinal correspondentes armazenadas na base de dados de movimento são recuperadas. Seguindo [18, 15], o problema de seleção é formulado como uma busca pelo caminho mais curto em um grafo em que os nós representam instâncias de sinal candidatas e as arestas representam os custos de transição.

Diferentemente de abordagens anteriores, o método proposto considera tanto a similaridade de pose quanto a dinâmica do movimento. Além da diferença de quatérnios entre fragmentos consecutivos, a função de custo incorpora diferenças de velocidade, favorecendo a escolha de unidades que melhor preservam a continuidade do movimento.

Uma vez identificada a sequência de fragmentos ideal, as trajetórias de quatérnios correspondentes são recuperadas da base de dados e concatenadas em uma sequência de movimento contínuo. Essa sequência serve de entrada para a etapa de suavização de transição.

Para reduzir as discontinuidades entre fragmentos gravados de forma independente, são gerados quadros intermediários por meio da aplicação de Interpolação Linear Esférica (SLERP) [19]. Um fator de ajuste dinâmico baseado em diferenças de velocidade local é empregado adicionalmente, preservando o momento angular para melhorar a continuidade temporal, mantendo as características expressivas da performance original.

A etapa final aplica a sequência de movimento sintetizada a um avatar tridimensional. Os valores dos quatérnios são mapeados continuamente para o esqueleto do avatar, gerando a animação final em Libras. O Anexo 6 também discute a síntese concatenativa.

- A10 Conversão Glossa-para-Vídeo (*Gloss2Sign*) e Síntese de Avatar Sinalizante Videorrealista:** O início das atividades de desenvolvimento do avatar sinalizante videorrealista baseado em geração de vídeo sintético foi adiado devido às dificuldades para ampliar a equipe com novos bolsistas de pós-graduação. Os principais fatores foram a escassez de candidatos com a qualificação técnica e acadêmica necessária e as restrições dos calendários dos programas de pós-graduação, que concentram o ingresso de novos alunos no início de cada semestre letivo. Em consequência, não foi possível constituir, no período previsto, a equipe necessária para iniciar essa linha de pesquisa.
- A11 Desenvolvimento de Aplicativos:** Foi iniciado o desenvolvimento de aplicativo para a apresentação em Libras de conteúdo de páginas Web, com ênfase na apresentação de cardápio dos restaurantes universitários da UNICAMP. O Anexo 6 apresenta uma visão geral do aplicativo em desenvolvimento.
- A12 Avaliação de Abordagens de Reconhecimento/Tradução de Libras:** Essa atividade foi desenvolvida parcialmente no contexto da avaliação das implementações das atividades 5, 6 e 7.
- A13 Avaliação de Abordagens de Tradução de Texto-para-Glosa e vice-versa:** Essa atividade foi desenvolvida parcialmente no contexto da avaliação das implementações das atividades 8 e 9.
- A14 Avaliação Avatares:** Foram realizadas avaliações pontuais do avatar por membros da equipe fluentes em Libras. As contribuições obtidas nessas avaliações resultaram em melhorias na qualidade visual da animação, especialmente na articulação manual e nas expressões faciais.
- Adicionalmente, o estudo apresentado no Anexo 4 sintetiza uma análise inicial que comparou o intérprete humano com dois recursos de tradução automática do mercado. Esta análise inicial servirá para estabelecer os critérios a serem aplicados na análise do avatar do CCD-TAAL.
- Uma avaliação sistemática mais geral foi postergada e será iniciada após a consolidação de provas de conceito que permitam testes mais abrangentes e controlados.
- A15 Avaliação Aplicativos:** Não foram desenvolvidas atividades para a avaliação sistemática de aplicativos. Essa atividade deve ser iniciada, conforme originalmente planejada, ao final do quarto ano do projeto.

Os anexos 9 a 15 apresentam os relatórios dos bolsistas envolvidos na execução das tarefas. Consultar os anexos para mais detalhes.

5 Apoio Institucional

Para além da manutenção da estrutura física do CCD-TAAL, localizada no Laboratório Galileu, a Universidade Estadual de Campinas vem oferecendo suporte ao Centro por meio de outras iniciativas. O Escritório de Apoio Institucional ao Pesquisador da Faculdade de Engenharia Elétrica e de Computação (EAIP/FEEC) tem contribuído ativamente para questões operacionais e de gestão do projeto, incluindo a elaboração da prestação de contas e a interlocução com a FAPESP para a resolução de dúvidas e o encaminhamento de questões. A Pró-Reitoria de Pesquisa (PRP) da UNICAMP, por meio do Programa de Pós-Doutorado em Gestão da Pesquisa (PPDG), diretamente voltado aos grandes centros temáticos de pesquisa da universidade, vem contribuindo com o CCD-TAAL oferecendo duas bolsas de pós-doutorado: a primeira voltada à gestão executiva de projetos e a segunda dedicada à gestão de transferência de tecnologia e inovação. No momento, duas doutoras bolsistas atuam diretamente no CCD-TAAL, contribuindo com as atividades do Centro.

Por meio da Diretoria Executiva de Apoio e Permanência Estudantil (DEAPE/UNICAMP), a universidade possibilita que o Centro conte hoje com seis bolsistas de graduação que, a um só tempo, aprendem sobre o projeto e o tema enquanto facilitam sua permanência na cidade de Campinas por meio da bolsa oferecida pela Universidade.

Para mais, a Agência de Inovação da UNICAMP (INOVA) vem colaborando com o Centro na organização documental e facilitação do estabelecimento de parcerias entre o CCD-TAAL e as instituições públicas que o compõem (USP, IPT e SEDPcD), assim como com instituições interessadas em estabelecer parcerias com o Centro. Além do suporte institucional mencionado, duas unidades da UNICAMP – a Faculdade de Engenharia Elétrica e de Computação (FEEC) e o Instituto de Computação (IC) – integram diretamente o projeto e fornecem recursos complementares de infraestrutura para o pleno funcionamento do projeto.

A participação da Secretaria de Estado dos Direitos da Pessoa com Deficiência no CCD-TAAL está concentrada na articulação institucional e governamental, promovendo a aproximação entre o Centro, os órgãos da administração pública e as entidades representativas das pessoas com deficiência. Essa atuação tem contribuído para fortalecer o diálogo interinstitucional, ampliar as possibilidades de cooperação técnica e favorecer a construção de estratégias conjuntas voltadas à promoção da acessibilidade, da inclusão e da garantia de direitos. Como suporte institucional, a Secretaria atua na interlocução com diferentes atores governamentais e da sociedade civil, apoiando a consolidação de parcerias e a integração de iniciativas alinhadas aos objetivos do Centro.

O Professor Doutor Felipe Venâncio Barbosa (Departamento de Linguística da Faculdade de Filosofia, Letras e Ciências Humanas da Universidade de São Paulo) manteve participação ativa nas atividades científicas e estratégicas do CCD-TAAL durante o período de referência. No âmbito do desenvolvimento do projeto, participou das reuniões de acompanhamento e planejamento, contribuindo para as discussões técnico-científicas relacionadas às atividades de tradução automática entre a Língua Portuguesa e a Libras atualmente em desenvolvimento. Também desempenhou papel relevante na articulação institucional com organizações das áreas de educação e saúde, visando à consolidação de parcerias para as futuras etapas de avaliação, validação e implementação da ferramenta tecnológica desenvolvida pelo Centro em diferentes contextos de uso. No eixo de internacionalização, coordenou o planejamento de sua participação no congresso MMSYM2026, a ser realizado na Bélgica, onde apresentará dois trabalhos científicos (Anexo 3 e Anexo 4) diretamente vinculados às pesquisas conduzidas no âmbito do CCD-TAAL, contribuindo para a disseminação internacional dos resultados do Centro. Adicionalmente,

organizou visitas técnico-científicas que serão realizadas em setembro, à Universidade de Leiden (Países Baixos) e à Universidade de Hamburgo (Alemanha), com o objetivo de discutir aspectos relacionados às linhas de pesquisa do Centro, prospectar oportunidades de cooperação internacional e estabelecer potenciais parcerias para o desenvolvimento de projetos conjuntos. Paralelamente, coordenou a concepção e a elaboração de um curso de formação e de uma oficina de treinamento, com início previsto para agosto, destinados à capacitação de profissionais e à difusão das metodologias, tecnologias assistivas e conhecimentos produzidos pelo CCD-TAAL, fortalecendo as ações de formação, transferência de conhecimento e impacto social do Centro.

Por meio da participação ativa de uma pesquisadora associada, a Faculdade de Educação da USP atua junto ao CCD-TAAL. O envolvimento nas reuniões, a colaboração com a equipe e com intérpretes, a interação com surdos para discutir a importância dos sinais na comunicação são algumas das principais atividades desenvolvidas. O apoio da Faculdade de Educação da USP tem sido fundamental, não apenas em termos de recursos, mas também na promoção de um ambiente inclusivo que valoriza a diversidade e a acessibilidade no contexto educacional.

O Instituto de Pesquisas Tecnológicas (IPT) é uma instituição de pesquisa aplicada, cujos pilares são: inovação, suporte industrial e políticas públicas. Vinculado à Secretaria de Desenvolvimento Econômico do Estado de São Paulo, o instituto conta com uma infraestrutura robusta de 39 laboratórios especializados. Suas principais frentes de vanguarda em P&D incluem: Materiais Avançados e Estruturas Leves, Bionanomanufatura, Transição Energética e Inovação Aberta e Tecnologias Digitais (TD). Em Inteligência Artificial (IA), o IPT desenvolve Manutenção e Operações Inteligentes, Gêmeos Digitais (*Digital Twins*), *Edge e Cloud Computing*, *Big Data Analytics*, Sistemas Autônomos/Robótica, entre outros. No projeto do CCD-TAAL, o IPT trabalha com uma equipe de quatro técnicos especializados em IA, sendo três mestres e um doutor, dando suporte em soluções de IA para as etapas de vídeo/texto (*gloss-free*) e glosa multicamadas/texto. Em breve, também será possível a utilização de um *cluster* de alto desempenho que poderá ser utilizado para implementar os modelos necessários ao projeto.

6 Planejamento para o Próximo Período

- A1 **Reuniões dos Pesquisadores Principais.** As reuniões semanais com todos os pesquisadores do projeto serão mantidas. Essas reuniões permitem o acompanhamento sistemático das atividades e contribuem para a gestão do projeto. Tais reuniões também são um momento importante para a difusão de informações entre os membros do projeto, bem como para o levantamento das dificuldades encontradas no desenvolvimento. Além das reuniões semanais, reuniões técnicas continuaram a ser realizadas sob demanda e em função das atividades específicas a serem desenvolvidas.
- A2 **Oficinas de Trabalho.** As oficinas de trabalho presenciais com a participação de convidados estrangeiros serão adaptadas à modalidade remota. O planejamento inicial contempla a discussão do formalismo de anotação (ver Anexo 1) com pesquisadores da IGDS. São planejados esforços para o contato com outros pesquisadores da área para a apresentação do projeto e coleta de sugestões para o seu desenvolvimento e aprimoramento.
- A3 **Estabelecimento de Formalismo de Anotação por Glosas.** Para o início de agosto, está previsto o treinamento dos membros do projeto para a anotação por glosas, utilizando o programa ELAN, dos vídeos que compõem os conjuntos de dados. Também estão previstas a revisão e a evolução

do formalismo de anotação, com a incorporação de melhorias identificadas durante o treinamento e a anotação dos dados. Nesse processo, será buscada a colaboração do IGDS, em especial da pesquisadora Maria Kopf, para apoiar a avaliação e o aperfeiçoamento do formalismo. Contato inicial já foi estabelecido, com sinalização positiva da disponibilidade para interagir de maneira remota com membros do projeto.

- A4 **Construção de Base de Dados.** Será dada continuidade à construção da base de dados do projeto, envolvendo a tradução de material escrito para Libras, a gravação de vídeos, o registro de dados de MoCap e a anotação por glosa dos dados.

Em função do acordo de parceria com a AME (<https://www.ame-sp.org.br/>), que se encontra atualmente em tramitação na UNICAMP e instituições associadas, está prevista a disponibilização para o CCD-TAAL de vídeos gravados pela plataforma iCom (<https://www.ame-sp.org.br/iniciativas-icom/>). Esses vídeos apresentam intérpretes de Libras interagindo com usuários em diversas situações. Tais vídeos serão utilizados para compor a base de dados do CCD-TAAL e estender o domínio linguístico dos dados a serem analisados.

- A5 **Reconhecimento de Libras Vídeo-para-Glosa (*Sign2Gloss*).** Para o próximo período, são planejadas a adaptação e a extensão da abordagem implementada até o momento para contemplar multimodalidade, com a inclusão de dados de esqueleto do sinalizador extraídos dos vídeos e de anotações multicamadas do formalismo. Espera-se que a combinação da aparência visual do vídeo com a informação estrutural da pose possa superar algumas das limitações dos modelos atuais de reconhecimento de língua de sinais. Pretende-se também manter o monitoramento das publicações científicas, a fim de incorporar eventuais propostas consideradas promissoras.

- A6 **Tradução Glosa-para-Texto (*Gloss2Text*).** Para o próximo período, são planejadas a adaptação e a extensão da abordagem implementada até o momento. O modelo implementado será exposto a múltiplas variações linguísticas para melhorar sua robustez. Vários experimentos serão conduzidos com diferentes arquiteturas, comparando o desempenho e a eficiência de cada abordagem. Para verificar a qualidade da tradução gerada, serão empregadas diferentes medidas de avaliação, tais como as métricas BLEU, ROUGE e METEOR, que permitem uma análise mais abrangente da fluência e adequação semântica do texto produzido.

Com relação às glosas de múltiplas camadas, será dada continuidade às etapas seguintes dos experimentos baseados em [8, 9], incluindo o uso dos arquivos gerados para o treinamento de modelos neurais de tradução automática e a análise de desempenho dos diferentes formatos sugeridos pelos dois artigos. Também está prevista a pesquisa de trabalhos atualizados focados em traduções de múltiplas camadas.

- A7 **Tradução de Libras Vídeo-para-Texto (*Sign2Text*).** Para esta atividade, a adaptação e extensão da abordagem atual devem considerar a evolução das pesquisas na área, que buscam sistemas que traduzem diretamente o vídeo para texto sem depender de glosas como representação intermediária. Dessa forma, pretende-se explorar estratégias de alinhamento *cross-modal* para aproximar as representações visuais e textuais, eliminando a necessidade de anotações manuais de glosas. Com isso, será possível não apenas reduzir o custo de anotação de dados, mas também alcançar resultados competitivos que se aproximam do estado da arte obtido por métodos que utilizam glosas.

Assim, artigos como [20, 10, 21] introduzem uma estratégia de pré-treinamento baseada em *auto-encoders* com o uso de *encoders* (de vídeo e de texto) que processam os dados de entrada e geram resultados numéricos com significado semântico, e *decoders* (também de vídeo e de texto) que partem desses resultados para a reconstrução dos dados previamente processados.

O uso desse tipo de arquitetura viabiliza o aprendizado não supervisionado. O modelo é alimentado com grandes volumes de dados de língua de sinais em vídeo e de texto de língua oral, e o objetivo da rede é aprender padrões desses dados e comprimir a entrada em um espaço latente semântico para reconstruir esses dados na saída com a menor perda possível.

O levantamento bibliográfico complementar confirma que essa é uma tendência consolidada no estado da arte: múltiplos artigos recentes utilizam estruturas de *encoders* e *decoders* acoplados (tanto para a modalidade de vídeo quanto para texto) para alinhar as representações semânticas em um espaço vetorial comum antes da etapa final de ajuste fino da tradução.

- A8 **Tradução Texto-para-Glosa (*Text2Gloss*)**. Para esta tarefa estão planejados a implementação e o refinamento de um modelo tradutor, previamente treinado em português, para a conversão Texto-para-Glosa dos conjuntos de dados do projeto. Além disso, pretende-se incorporar glosas multicamadas definidas no formalismo de anotação. As glosas multicamadas carregam informações extras que vão além das palavras lexicais e podem incluir marcadores não manuais, apontamentos, classificadores, entre outros. O emprego de glosas multicamadas ajuda o modelo renderizador (Glosa-para-Vídeo) a receber informações mais detalhadas e contextualizadas, podendo, assim, gerar sinalizações com maior nível de precisão.
- A9 **Conversão Glosa-para-Vídeo (*Gloss2Sign*) e Síntese de Avatar Sinalizante 3D**. Será dado seguimento a essa atividade com a depuração da implementação e testes mais exaustivos da abordagem baseada em síntese concatenativa de Libras.
- A10 **Conversão Glosa-para-Vídeo (*Gloss2Sign*) e Síntese de Avatar Sinalizante Videorrealista**. Está planejado o estudo aprofundado de soluções generativas para a geração automática de vídeos sintéticos, com ou sem uso de glosas. A proposta consiste na geração de vídeos fotorrealistas de sinalizantes via modelos generativos. Essa abordagem ganhou força com o desenvolvimento, relativamente recente, das redes generativas (GANs) e dos modelos de difusão. O mérito dessa estratégia está no fato de que o modelo aprende diretamente dos vídeos reais, herdando o fotorrealismo do domínio de origem. Dessa forma, a representação visual é mais natural, contém marcadores não manuais e busca superar o fenômeno do "Vale da Estranheza"[22]. A tarefa é desafiadora, visto que, apesar dos avanços na área, a síntese fotorrealista ainda sofre com problemas de instabilidade, principalmente para a geração de sentenças mais longas devido ao efeito de derretimento (*drift*) causado pela propagação de erros na geração autorregressiva das poses.
- A11 **Desenvolvimento de Aplicativos**. Pretende-se evoluir e aperfeiçoar o aplicativo para a apresentação em Libras de conteúdo escrito de páginas da Web, com a progressiva substituição da renderização das animações em vídeo por publicação em mecanismo interativo 3D, seja um motor de jogos ou um *framework* tipo WebGL. A evolução focará em questões associadas à robustez, eficiência e segurança da comunicação entre cliente (navegador Web) e servidor (tradutor).
- A12 **Avaliação de Abordagens de Reconhecimento/Tradução de Libras**. Acompanhando os desenvolvimentos, é planejada, para um primeiro momento, a avaliação com métricas automáticas, como

WER e BLEU. A atividade é voltada à definição e aplicação de protocolos e ferramentas para avaliar e comparar a qualidade e generalidade das abordagens de reconhecimento/tradução da Libras a partir de vídeos/imagens desenvolvidos. As avaliações e comparações a serem realizadas envolvem as abordagens Vídeo-para-Glosa acoplada à tradução Glosa-para-Texto e Vídeo-para-Texto que serão exploradas.

Como etapa complementar, será realizada uma análise semântica dos textos produzidos pelas diferentes abordagens, a fim de verificar em que medida o conteúdo preserva informações essenciais à compreensão da mensagem. Essa avaliação permitirá identificar a manutenção de aspectos semânticos relevantes, complementando as métricas automáticas e oferecendo uma análise qualitativa da adequação linguística das traduções geradas.

- A13 Avaliação de Abordagens de Tradução de Texto-para-Glosa e vice-versa.** Acompanhando os desenvolvimentos, é planejada, para um primeiro momento, a avaliação com métricas automáticas, como WER e BLEU. O foco da atividade é a definição e aplicação de protocolos e ferramentas para avaliar e comparar a qualidade e generalidade das abordagens de tradução automática de texto em português para representação por glosa e vice-versa. As avaliações e comparações envolvem as abordagens de tradução Texto-para-Glosa e Glosa-para-Texto que serão estudadas.

Na etapa subsequente, será empregado o formalismo de representação desenvolvido neste relatório como base para uma avaliação qualitativa da tradução. O foco será a análise semântica dos conteúdos gerados, verificando a preservação de informações e relações de significado essenciais para a compreensão do texto, complementando os resultados obtidos pelas métricas automáticas com uma avaliação linguística da qualidade semântica das traduções.

- A14 Avaliação de Avatares.** Definição e aplicação de protocolo para avaliar e comparar a qualidade do avatar 3D e avatar videorealista. Nesta atividade será desenvolvida também uma avaliação comparativa da interação entre usuário e avatar versus intérprete humano, através de técnicas de rastreamento ocular. Os dados dessa comparação trarão informações sobre a percepção e esforço cognitivo de partes específicas do avatar, como as configurações de mãos, expressões não manuais e amplitude da permanência do contato. Ainda nesta atividade, será desenvolvida a avaliação humana, com foco na fluência e na adequação do resultado da tradução. Serão desenvolvidos instrumentos de medida para mensurar a percepção dos usuários sobre usabilidade, inteligibilidade e acessibilidade.

- A15 Avaliação de Aplicativos.** Definição e aplicação de protocolo para avaliar e comparar a qualidade do avatar 3D e do avatar videorealista. Nesta atividade, também será desenvolvida uma avaliação comparativa da interação entre usuário e avatar versus intérprete humano, por meio de técnicas de rastreamento ocular. Os dados dessa comparação trarão informações sobre a percepção e esforço cognitivo de partes específicas do avatar, com a análise de dilatação das pupilas mediante os diferentes estímulos e análise de taxa de fixação e de movimentos sacádicos em aspectos linguísticos específicos, como as configurações de mãos, expressões não manuais e amplitude da permanência dos movimentos. Ainda nesta atividade será desenvolvida a avaliação humana focalizando a fluência e adequação do resultado da tradução com a análise linguística de compreensibilidade dos conteúdos por parte dos usuários. Serão desenvolvidos instrumentos de mensuração da percepção dos usuários sobre usabilidade, inteligibilidade e acessibilidade.

7 Gestão de Dados

O projeto CCD-TAAL possui caráter interdisciplinar, integrando áreas como linguística, visão computacional, aprendizado de máquina, educação e tecnologias assistivas. Um dos objetivos do projeto CCD-TAAL é a construção de uma base de dados ampla e aberta, destinada não apenas a subsidiar as pesquisas desenvolvidas no âmbito do Centro, mas também a fomentar investigações conduzidas por grupos de pesquisa de outros grupos do país e do exterior.

Durante o desenvolvimento do projeto, prevê-se a produção, o armazenamento, a organização e o gerenciamento dos seguintes tipos de dados:

- Conjunto de sentenças em língua portuguesa, contemplando variados domínios linguísticos e contextos interativos, como anamnese, interação em veículos e legendagem Web.
- Vídeos com conteúdo em Libras.
- Dados de MoCap corporais, manuais e faciais de conteúdo associados aos sinais produzidos em Libras.
- Arquivos de anotação ELAN de vídeos/animações com conteúdo em Libras.

Os dados coletados estão sendo organizados em uma base de dados única, com anotação ELAN nos vídeos gerados e associação a metadados, incluindo dados de captura de movimentos. A integração de metadados e a anotação dos vídeos facilita a análise e o uso dos dados coletados.

Além dos conjuntos de dados, o Centro produz e produzirá códigos-fonte, bibliotecas computacionais, modelos de aprendizado de máquina, algoritmos de processamento de sinais, sistemas computacionais e aplicativos voltados para tarefas específicas relacionadas à tradução automática, reconhecimento de sinais, geração de sinais e tecnologias assistivas para pessoas surdas.

Durante a fase de desenvolvimento das pesquisas, conforme previsto no projeto de criação do Centro, o acesso aos dados ficará restrito aos pesquisadores principais, pesquisadores associados, estudantes e bolsistas vinculados ao CCD-TAAL. Essa restrição temporária visa garantir a integridade dos dados, a adequada condução das pesquisas e o cumprimento dos cronogramas científicos estabelecidos.

Após a publicação dos resultados científicos previstos, os códigos-fonte, modelos computacionais, aplicativos e a documentação técnica associada serão disponibilizados publicamente em repositórios apropriados, observando princípios de transparência, reprodutibilidade e ciência aberta.

A disponibilização pública integral dependerá da aprovação dos órgãos competentes e das diretrizes estabelecidas pelo Comitê de Ética em Pesquisa da Instituição Sede, respeitando os termos de consentimento firmados com os participantes e a legislação vigente sobre proteção de dados pessoais.

Para que a base de dados, em sua integralidade, possa ser tornada aberta e disponível livremente, será necessário o consentimento do Comitê de Ética em Pesquisa da Instituição Sede. Quando permitido pelos aspectos éticos e legais aplicáveis, pretende-se disponibilizar os conjuntos de dados, sob licenças abertas do tipo CC-BY, possibilitando seu uso, compartilhamento e adaptação por terceiros, desde que seja devidamente atribuída a autoria original dos dados e recursos produzidos pelo Centro.

8 Participação em Eventos Científicos e Tecnológicos

Resultados parciais do projeto foram apresentados no seguinte evento científico:

- 12th Workshop on the Representation and Processing of Sign Languages - LREC 2026. Títulos do trabalho apresentado: *The In-Car Sign Language Corpus (ICSL): A Multi-Modal Resource for Constrained-Space Sign Language Recognition*. 16 May 2026. ©ELRA Language Resources Association (ELRA), 2026. (Ver Seção 9)

Adicionalmente, os objetivos e metas do CCD-TAAL foram divulgados nos seguintes eventos:

- **Hacktown 2025:** Por convite da AME, o CCD-TAAL foi apresentado no Hacktown 2025, realizado de 21 de julho a 02 de agosto, em Santa Rita do Sapucaí. A AME é uma Organização da Sociedade Civil sem fins lucrativos que atua para promover a inclusão de pessoas com deficiência.
- **Reatech:** Atendendo a convite da Secretaria de Estado dos Direitos da Pessoa com Deficiência de São Paulo (SEDPcD/SP), o CCD-TAAL foi apresentado na feira Reatech 2025 no dia 08 de novembro de 2026. No evento, os objetivos e metas do CCD-TAAL foram apresentados, acompanhados de uma demonstração de resultados parciais alcançados. Na demonstração, participantes surdos presentes no evento interagiram com o avatar desenvolvido no âmbito do projeto.
- **Virada Inclusiva:** Também em função de convite da SEDPcD/SP, o CCD-TAAL participou do evento Virada Inclusiva 2025 que ocorreu entre os dias 1 e 7 de dezembro, celebrando os 10 anos da Lei Brasileira de Inclusão (LBI). Na ocasião, foram divulgados os objetivos e metas do CCD-TAAL e realizada uma demonstração interativa com participantes surdos.

9 Publicações

Artigo publicado:

- Boddu et al. The In-Car Sign Language Corpus (ICSL): A Multi-Modal Resource for Constrained-Space Sign Language Recognition. *Proceedings of the 12th Workshop on the Representation and Processing of Sign Languages*, pages 31–41 16 May 2026. ©ELRA Language Resources Association (ELRA), 2026. (Ver Anexo 2)

Resumos submetidos e aceitos para publicação:

- Felipe Venâncio Barbosa, José Mario De Martino, Thyago Santos, Sylvia Lia Grespan Neves, Isabela Barbieri, Natália Najyme de Melo Afonso, Edilson de Andrade. Multimodality and Semantics in a Sign Language Visuospatial Grounded Annotation Framework *Symposium Series on Multimodal Communication - MMSYM 2026*, 9-11 September 2026, University of Leuven, Belgium. (Ver Anexo 3)
- Juliane Farah Arnone, Felipe Venâncio Barbosa, Patrícia Araújo Vieira. Linguistic Processing of Deaf People in the Perception of Automatic Translators from Brazilian Portuguese to Libras: A Study with Eye Tracking. *Symposium Series on Multimodal Communication - MMSYM 2026*, 9-11 September 2026, University of Leuven, Belgium. (Ver Anexo 4)

Capítulo de livro submetido e em apreciação:

- José Mario De Martino, Vinícius Nascimento, Felipe Venâncio Barbosa, Thyago Santos. Formalismo, Anotação e Tradução Automática em Línguas de Sinais *Sinal Vivo vs Sinal Programado: ética, corpo e autoria na tradução de línguas de sinais*, Clarissa Guerreta e Heloíse Gripp (Orgs), Editora Editora Pimenta Cultural. 1-26, 2026. (Ver Anexo 5)

Artigos submetidos e em apreciação:

- Gustavo Borba da Silva, Ângelo Brandão Benetti, José Mario De Martino. Concatenative Synthesis for Brazilian Sign Language. *XI Workshop de Iniciação Científica em Tecnologia da Informação e da Linguagem Humana - TILic 2026*, 19 a 22 de outubro de 2026 - Cuiabá, Mato Grosso. (Ver Anexo 6)
- Guilherme Galvão de Oliveira, Guilherme Vieira Leite, Hélio Pedrini, José Mario De Martino. Explorando a Integração de Múltiplas Modalidades Visuais no Reconhecimento Contínuo de Libras. *XI Workshop de Iniciação Científica em Tecnologia da Informação e da Linguagem Humana - TILic 2026*, 19 a 22 de outubro de 2026 - Cuiabá, Mato Grosso. (Ver Anexo 7)
- Gabriel de Sousa Pereira, Guilherme Vieira Leite, Ângelo Brandão Benetti, Isabela Cristina Barbieri, Natalia Najyme de Melo Afonso, Thyago de Souza Santos, Hélio Pedrini, José Mario De Martino. Subtitling Restaurant Menus on Web Pages in Brazilian Sign Language. *3º. Workshop Accesibilidad e Inclusión - 3WAI*. 10 a 12 de novembro de 2026, Talca, Chile. (Ver Anexo 8)

10 Dificuldades Enfrentadas e Medidas de Mitigação Adotadas

As principais dificuldades encontradas podem ser organizadas nos seguintes tópicos:

- **Aquisição de Equipamentos:** Para viabilizar a implantação da infraestrutura computacional necessária ao desenvolvimento das soluções de tradução automática baseadas em redes neurais profundas, foi planejada a aquisição de computadores com configurações compatíveis com as demandas do projeto e com os limites orçamentários do edital. No início de dezembro de 2025, foi solicitada a liberação dos recursos para a compra dos equipamentos, juntamente com toda a documentação exigida, incluindo as cotações dos fornecedores. Entretanto, após a virada do ano, o fornecedor informou que não poderia mais manter os preços originalmente apresentados, em razão do aumento dos custos de componentes eletrônicos no mercado internacional, especialmente de memória.

Diante dessa situação, foi encaminhada à FAPESP uma solicitação de complementação orçamentária para viabilizar a aquisição dos equipamentos. A solicitação foi aprovada, e a documentação atualizada, incluindo novo orçamento, foi submetida à Fundação. Contudo, durante o processo de aquisição, o fornecedor comunicou um novo reajuste nos preços. Em consequência, uma segunda solicitação de complementação de recursos foi encaminhada à FAPESP, novamente acompanhada da documentação atualizada. Essa solicitação também foi deferida.

Caso não ocorram novos imprevistos, a entrega dos equipamentos está prevista para setembro. Entretanto, a indisponibilidade de infraestrutura computacional adequada tem restringido a realização de experimentos de maior porte e complexidade. Até o momento, têm sido conduzidos apenas experimentos exploratórios com conjuntos de dados reduzidos, enquanto se aguarda a disponibilização dos equipamentos previstos.

- **Formação e Manutenção da Equipe:** Os desenvolvimentos do CCD-TAAL dependem fortemente da atuação de bolsistas acadêmicos — alunos de iniciação científica, mestrado, doutorado e pós-doutorado — e de bolsistas de treinamento técnico. Entretanto, as bolsas acadêmicas de mestrado e doutorado estão vinculadas aos calendários de ingresso dos programas de pós-graduação das instituições participantes, o que limita a substituição de bolsistas aos períodos regulares de admissão, normalmente no início de cada semestre letivo. Dessa forma, eventuais desligamentos geram impactos significativos no andamento do projeto.

No período em análise, dois bolsistas — um de mestrado e outro de doutorado — solicitaram desligamento do CCD-TAAL por motivos pessoais. Essas saídas interromperam atividades em andamento e resultaram na perda dos esforços previamente investidos em treinamento e capacitação. Embora tenha sido realizado um processo de reestruturação das equipes e de redistribuição das atividades, os impactos decorrentes dos desligamentos não puderam ser integralmente compensados, causando atrasos e reduzindo a velocidade de execução de algumas frentes de trabalho do projeto.

Em razão da redução do número de bolsas TT inicialmente previstas, o projeto adotou como estratégia utilizar bolsas TT-4A para suprir a demanda por profissionais fluentes em Libras, além de um profissional com ampla experiência em captura de movimento e computação gráfica. Entretanto, o recrutamento e seleção desses profissionais envolvem desafios significativos. Por serem especialistas, buscou-se encontrar os melhores profissionais para integrar o projeto, o que, embora tenha exigido esforço, vem gerando bons resultados para o Centro.

O processo seletivo mais recente para uma bolsa TT-4A destinada a um colaborador fluente em Libras demandou aproximadamente sete meses de trabalho e envolveu a avaliação de cerca de 240 candidaturas. Ao final, apenas três candidatos apresentaram perfil compatível com os requisitos do projeto. Essa experiência evidencia a escassez de profissionais que, além da fluência em Libras, possuam a formação e as competências necessárias para atuar em um ambiente de pesquisa científica. Nesse contexto, a manutenção dos colaboradores já capacitados e integrados às atividades do CCD-TAAL é fundamental para a continuidade e a eficiência dos trabalhos, tornando especialmente importante a renovação das bolsas TT-4A atualmente em vigor ao término de sua vigência.

- **Manutenção não Prevista de Equipamento:** Uma atividade estratégica do CCD-TAAL é a captura de movimentos corporais e faciais por meio de sistemas de Motion Capture (MoCap). A instituição-sede do Centro dispõe de uma infraestrutura dedicada a essas atividades, com uso exclusivo pelo projeto. Entretanto, parte das câmeras infravermelhas que compõem o sistema apresentou falhas de funcionamento, comprometendo parcialmente a operação da infraestrutura.

Para solucionar o problema, foi solicitada à FAPESP a liberação de recursos para o envio dos equipamentos à manutenção especializada. A solicitação foi aprovada. No entanto, questões burocráticas relacionadas ao processo de manutenção internacional — incluindo a emissão da autorização de retorno do fabricante (RMA – *Return Merchandise Authorization*), a obtenção de orçamentos para os serviços de manutenção e para o transporte dos equipamentos — têm retardado a implementação da solução. Apesar do apoio da empresa fornecedora e de seu representante no Brasil, bem como dos setores responsáveis da FAPESP e da UNICAMP, o envio dos equipamentos para manutenção ainda não foi viabilizado, embora o processo tenha sido iniciado há mais de seis meses.

Como medida de mitigação, as câmeras que permanecem operacionais foram redistribuídas no ambiente de captura. Essa estratégia permitiu a continuidade das atividades de coleta de dados, ainda que com redução da robustez e da cobertura do sistema de MoCap. Como consequência, tornou-se necessário um esforço adicional nas etapas de calibração, validação e pós-processamento dos dados capturados, aumentando o tempo e a complexidade das atividades de processamento.

- **Armazenamento dos Dados:** As atividades do CCD-TAAL dependem intensivamente da coleta, armazenamento e processamento de grandes volumes de dados. Os conjuntos de dados produzidos pelo projeto incluem textos, vídeos, animações e anotações linguísticas. Em particular, os dados em vídeo e animações demandam elevada capacidade de armazenamento devido ao seu volume e complexidade.

Atualmente, o acervo de dados do CCD-TAAL já ultrapassa dois terabytes, embora as atividades de coleta ainda estejam em andamento. Diante da perspectiva de crescimento contínuo desse volume, tornou-se necessária a avaliação de soluções que garantam armazenamento seguro, acesso eficiente e preservação dos dados produzidos pelo projeto.

Como medida de mitigação, está sendo estudada a aquisição de um sistema NAS (Network Attached Storage) para armazenamento local compartilhado entre os membros do projeto, bem como a contratação de um serviço de backup em nuvem para aumentar a segurança e a disponibilidade dos dados. Essas necessidades não foram previstas na proposta original do CCD-TAAL, uma vez que o volume efetivamente gerado superou as estimativas iniciais.

Em razão dessa demanda, será submetida à FAPESP uma solicitação de recursos para viabilizar a implantação dessas soluções de armazenamento e backup, consideradas essenciais para a continuidade e a sustentabilidade das atividades do Centro.

- **Gestão Compartilhada da Bibliografia:** O compartilhamento de artigos científicos e de suas respectivas fichas bibliográficas entre os membros do CCD-TAAL tem se tornado um desafio crescente. A inexistência de um ambiente centralizado para armazenamento e gerenciamento dessas informações resulta em ineficiências operacionais, duplicação de esforços e inconsistências na catalogação das referências utilizadas pelo projeto.

Para enfrentar esse problema, o CCD-TAAL adotará o Zotero como ferramenta padrão de gerenciamento e compartilhamento de referências bibliográficas. A utilização de uma plataforma comum permitirá organizar, armazenar e compartilhar de forma estruturada a literatura científica relevante ao projeto, além de facilitar a colaboração entre os pesquisadores e a padronização das referências bibliográficas.

Para viabilizar o uso adequado da ferramenta por toda a equipe e garantir capacidade de armazenamento compatível com o volume de documentos compartilhados, será submetida à FAPESP uma solicitação de recursos para a contratação da versão com armazenamento ampliado (*Unlimited Storage*) do Zotero.

- **Internacionalização:** No planejamento inicial do projeto, estavam previstas oficinas presenciais com a participação de pesquisadores internacionais, com o objetivo de fortalecer a inserção internacional do CCD-TAAL e alinhar suas atividades de pesquisa às tendências da área. No entanto, não foi possível viabilizar a participação presencial dos pesquisadores convidados, principalmente devido a compromissos acadêmicos e profissionais previamente assumidos.

Como alternativa, foram realizadas reuniões remotas de curta duração com pesquisadores internacionais. Embora esse formato limite a profundidade das discussões em comparação com oficinas presenciais e imersivas, ele permitiu manter a interação científica e contribuir para o processo de internacionalização do Centro.

Outra estratégia adotada foi a realização de visitas de pesquisadores do CCD-TAAL ao IGDS, no âmbito do projeto de colaboração Brasil–Alemanha financiado pela FAPESP (Processo 2024/23068-4). Essas visitas possibilitaram o estabelecimento de contatos diretos e o fortalecimento das parcerias institucionais.

Considerando que a interação presencial favorece a construção de vínculos de colaboração mais sólidos e duradouros, pretende-se solicitar apoio da FAPESP para viabilizar futuras visitas de pesquisadores do CCD-TAAL a instituições de referência internacional na área.

11 Considerações sobre o Parecer Anterior

O relatório atual reflete a evolução do CCD-TAAL em relação ao período anterior, passando de uma fase predominantemente de estruturação para uma etapa de desenvolvimento científico e tecnológico efetivo. Houve avanço na definição do formalismo multicamada de anotação por glosas, na construção de três conjuntos de dados voltados a diferentes domínios de aplicação, na implementação e validação de modelos neurais para as tarefas de Vídeo-para-Glosa (*Sign2Gloss*, Glosa-para-Texto *Gloss2Text*, Vídeo-para-Texto *Sign2Text* e Texto-para-Glosa *Text2Gloss*, bem como no desenvolvimento da síntese de avatares sinalizantes tridimensionais e de aplicações voltadas à acessibilidade. O relatório também apresenta resultados experimentais quantitativos e comparações com trabalhos de referência da literatura.

Em comparação com o relatório anterior, observa-se que as recomendações do parecerista foram incorporadas. Em particular, o relatório atual apresenta uma ênfase muito maior nas atividades de pesquisa e desenvolvimento, reduzindo o espaço dedicado a aspectos administrativos. Também amplia a descrição da fundamentação técnica e dos resultados alcançados, apresentando a evolução do formalismo de anotação, da construção dos conjuntos de dados e da implementação das abordagens de tradução automática.

Outra observação importante do parecer anterior dizia respeito ao desenvolvimento paralelo da construção das bases de dados e dos modelos computacionais, evitando que o reconhecimento automático dependesse exclusivamente da conclusão da coleta de dados própria do projeto. Essa recomendação foi adequadamente atendida. O relatório demonstra que a equipe implementou e validou modelos utilizando bases públicas consolidadas, como o RWTH-PHOENIX-Weather 2014T e o VLibrasBD, obtendo resultados compatíveis com os reportados na literatura, ao mesmo tempo em que avançou na construção dos conjuntos de dados do CCD-TAAL. Essa estratégia reduz riscos, permite comparações com o estado da arte e estabelece uma base sólida para a futura adaptação dos modelos à Libras.

O relatório também responde à recomendação de apresentar uma análise mais clara da execução do cronograma, descrevendo as atividades realizadas, justificando eventuais postergações e explicando as medidas adotadas para mitigar seus impactos. As justificativas apresentadas para o adiamento de algumas atividades, como o desenvolvimento do avatar videorrealista e a avaliação sistemática dos avatares, são compatíveis com o estágio atual do projeto.

Permanecem, naturalmente, alguns desafios esperados para esta fase de desenvolvimento, especialmente o início da anotação sistemática dos conjuntos de dados produzidos e a realização de avaliações

formais dos modelos treinados com dados próprios e dos avatares desenvolvidos. Tais atividades dependem diretamente da consolidação das etapas de coleta de dados e da disponibilização de versões mais estáveis dos protótipos.

Cabe registrar que as observações apresentadas pelo parecerista no relatório anterior foram pertinentes e contribuíram positivamente para o projeto. As recomendações relativas ao fortalecimento da fundamentação científica, ao desenvolvimento paralelo das diferentes frentes de pesquisa, ao uso de bases públicas para a validação das abordagens e à apresentação de uma análise mais crítica do andamento das atividades foram consideradas pela equipe e incorporadas neste relatório.

Bibliografia

- [1] F. Veiga and A. B. Souza, *Manual de Exame Físico*. Elsevier Health Sciences, 2019.
- [2] P. Wittenburg, H. Brugman, A. Russel, A. Klassmann, and H. Sloetjes, “Elan: a professional framework for multimodality research,” in *Fifth International Conference on Language Resources and Evaluation*, (Genova, Italy), pp. 1556–1559, May 2006.
- [3] J. M. De Martino and E. T. Poeta, “Método para a síntese concatenativa de línguas de sinais para a geração de avatares sinalizadores tridimensionais realistas.” Patente BR102019028311A2, 2021. Depósito: 31 dez. 2019. Publicação: 13 jul. 2021.
- [4] N. C. Camgöz, O. Koller, S. Hadfield, and R. Bowden, “Sign language transformers: Joint end-to-end sign language recognition and translation,” in *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, (Seattle, WA, USA), pp. 10023–10033, IEEE, 2020.
- [5] D. Jurafsky and J. H. Martin, *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*. Upper Saddle River, NJ: Prentice Hall, 2 ed., 2009.
- [6] K. Papineni, S. Roukos, T. Ward, and W.-J. Zhu, “Bleu: A method for automatic evaluation of machine translation,” in *40th Annual Meeting on Association for Computational Linguistics, ACL ’02*, (USA), p. 311–318, Association for Computational Linguistics, 2002.
- [7] N. C. Camgoz, O. Koller, S. Hadfield, and R. Bowden, “Sign Language Transformers: Joint End-to-End Sign Language Recognition and Translation,” in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, (Los Alamitos, CA, USA), pp. 10020–10030, IEEE Computer Society, June 2020.
- [8] J.-H. Kim, M. Huerta-Enochian, C. Ko, and D. H. Lee, “Signbleu: Automatic evaluation of multi-channel sign language translation,” in *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pp. 14796–14811, 2024.
- [9] V. Vandeghinste, M. De Sisto, S. E. Gómez, and M. De Coster, *Challenges with Sign Language Datasets*, pp. 117–139. Cham: Springer Nature Switzerland, 2024.
- [10] Z. Li, W. Zhou, W. Zhao, K. Wu, H. Hu, and H. Li, “Uni-Sign: Toward Unified Sign Language Understanding at Scale,” Mar. 2025. arXiv:2501.15187 [cs].

- [11] Y. Tang, X. Li, P.-J. Chen, N. Goyal, V. Chaudhary, J. Gu, and A. Fan, “Multilingual translation with extensible multilingual pretraining and finetuning,” in ., 08 2020.
- [12] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. u. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in Neural Information Processing Systems* (I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, eds.), vol. 30, pp. 5998–6008, Curran Associates, Inc., 2017.
- [13] M. Lewis, Y. Liu, N. Goyal, M. Ghazvininejad, A. Mohamed, O. Levy, V. Stoyanov, and L. Zettlemoyer, “BART: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension,” in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* (D. Jurafsky, J. Chai, N. Schluter, and J. Tetreault, eds.), (Online), pp. 7871–7880, Association for Computational Linguistics, July 2020.
- [14] M. A. Lima, D. Cruz, D. R. Silva, D. D. Albuquerque, D. F. Lacerda, R. Costa, G. L. de Souza Filho, and T. M. de Araújo, “Vlibrasbd: A brazilian portuguese–brazilian sign language (libras) bilingual text dataset designed to support neural machine translation,” *Data in Brief*, vol. 62, p. 111911, 2025.
- [15] J. M. De Martino and E. T. Poeta, “Método para a síntese concatenativa de línguas de sinais para a geração de avatares sinalizadores tridimensionais realistas.” Patente BR102019028311A2, 2021. Depósito em 31 dez. 2019; publicação em 13 jul. 2021.
- [16] A. Hunt and A. Black, “Unit selection in a concatenative speech synthesis system using a large speech database,” in *1996 IEEE International Conference on Acoustics, Speech, and Signal Processing Conference Proceedings*, vol. 1, pp. 373–376 vol. 1, 1996.
- [17] D. Schwarz, “Current research in concatenative sound synthesis,” in *Proceedings of the International Computer Music Conference (ICMC)*, (Barcelona, Spain), pp. 1–4, International Computer Music Association, Sept. 2005.
- [18] E. Poeta, “Síntese concatenativa de línguas sinais,” msc thesis, Universidade Estadual de Campinas(UNICAMP), 2025.
- [19] K. Shoemake, “Animating rotation with quaternion curves,” in *Proceedings of the 12th Annual Conference on Computer Graphics and Interactive Techniques (SIGGRAPH ’85)*, pp. 245–254, ACM, 1985.
- [20] B. Zhou, Z. Chen, A. Clapés, J. Wan, Y. Liang, S. Escalera, Z. Lei, and D. Zhang, “Gloss-free Sign Language Translation: Improving from Visual-Language Pretraining,” in *2023 IEEE/CVF International Conference on Computer Vision (ICCV)*, (Paris, France), pp. 20814–20824, IEEE, Oct. 2023.
- [21] W. Zhou, W. Zhao, H. Hu, Z. Li, and H. Li, “Scaling up Multimodal Pre-training for Sign Language Understanding,” Aug. 2024. arXiv:2408.08544 [cs].
- [22] M. Mori, K. F. MacDorman, and N. Kageki, “The uncanny valley [from the field],” *IEEE Robotics & Automation Magazine*, vol. 19, no. 2, pp. 98–100, 2012.

Anexo 1

Formalismo de Anotação por Glosa



Centro de Ciência para o Desenvolvimento
Tecnologia Assistiva e Acessibilidade em Libras

Processo Fapesp 2024/00914-7

Formalismo de Anotação por Glosa Versão 2.0

28 de junho de 2026

José Mario De Martino - FEEC/UNICAMP

Guilherme Vieira Leite - FEEC/UNICAMP

José Carlos Ferreira - FEEC/UNICAMP

Hélio Pedrini - IC/UNICAMP

Edilson de Andrade - SEDPcD

Felipe Venâncio Barbosa - FFLCH/USP

Sylvia Lia Grespan Neves - FE/USP

Vagner Luiz Vaga - IPT

Angelina da Silva Inacio - IPT

Felipe Augusto Frazão Kleine - IPT

Fábio Rogerio Lins Pereira de Souza - IPT

Thyago de Souza Santos - CCD-TAAL

Isabela Cristina Barbieri - CCD-TAAL

Natália Najyme de Melo Afonso - CCD-TAAL

Ângelo Brandão Benetti - CCD-TAAL



Secretaria dos
Direitos da Pessoa com Deficiência



RESUMO

Este documento apresenta a versão 2.0 do formalismo de anotação por glosas, consolidada no primeiro semestre de 2026. O formalismo será utilizado na anotação de vídeos em Língua Brasileira de Sinais (Libras), apoiando a construção de bases de dados destinadas ao desenvolvimento de abordagens de tradução automática entre Libras e português no âmbito do Centro de Ciência para o Desenvolvimento – Tecnologia Assistiva e Acessibilidade em Libras (CCD-TAAL). O CCD-TAAL é um projeto financiado pela Fundação de Amparo à Pesquisa do Estado de São Paulo (FAPESP). Como resultado da evolução das atividades de pesquisa e do aprofundamento dos estudos conduzidos pelo CCD-TAAL, o formalismo aqui descrito poderá ser revisado e aprimorado para incorporar novos conhecimentos, necessidades e requisitos identificados ao longo do projeto.

Palavras-chave: Tradução Neural de Língua de Sinais, Produção de Língua de Sinais, Reconhecimento de Língua de Sinais, Língua Brasileira de Sinais, Avatar Sinalizante.

ABSTRACT

This document presents Version 2.0 of the gloss annotation formalism, consolidated in the first semester of 2026. The formalism will be used to annotate Brazilian Sign Language (Libras) videos, supporting the development of datasets for the creation of machine translation approaches between Libras and Portuguese within the framework of the Center for Science for Development – Assistive Technology and Accessibility in Libras (CCD-TAAL). The CCD-TAAL is a project funded by the São Paulo Research Foundation (FAPESP). As research activities evolve and studies conducted within CCD-TAAL advance, the formalism described in this document may be revised and refined to incorporate new knowledge, requirements, and insights identified throughout the project.

Keywords: Sign Language Neural Translation, Sign Language Production, Sign Language Recognition, Brazilian Sign Language, Signing Avatar.

Sumário

1	Introdução	1
2	Conceitos	2
2.1	Anáfora	2
2.2	Ancoragem	2
2.3	Banco de Glosas	2
2.4	Banco Lexical	2
2.5	Catáfora	3
2.6	Dêitico	3
2.7	Dêixis	3
2.8	Dicionário	3
2.9	Glosa	4
2.10	Lema	4
2.11	Lexema	4
2.12	Léxico	4
2.13	Multicanal	4
2.14	Processamento Multifluxo (<i>multistream</i>) e Multimodal	5
2.15	Vocabulário	5
3	Convenções	6
3.1	Glosa	6
3.2	Trilhas	7
3.3	Ancoragem	7
4	Protocolo de Anotação	8
4.1	Regras gerais de anotação	9
4.2	Anotação das Trilhas	10
4.2.1	Trilha Tradução_Português	10
4.2.2	Trilha Tradução_Inglês	10
4.2.3	Trilhas Sinal_Lexical_MD e Sinal_Lexical_ME	10
4.2.4	Trilhas Datilologia_MD e Datilologia_ME	10
4.2.5	Trilhas Depicção_MD e Depicção_ME	10
4.2.6	Trilhas Boia_MD e Boia_ME	10
4.2.7	Trilhas Apontamento_MD e Apontamento_ME	11
4.2.8	Trilha Olhar	11
4.2.9	Trilha Face	11
4.2.10	Trilha Boca	11
4.2.11	Trilhas Gesto_MD e Gesto_ME	11
4.2.12	Ancoragem Espacial	11
	Referências	12

1 Introdução

A construção de um conjunto de dados (*dataset*) paralelo Libras–português é um elemento central para o desenvolvimento de sistemas de tradução automática entre essas línguas. Com esse objetivo, o CCD-TAAL iniciou, em setembro de 2024, uma série de discussões voltadas à definição de um formalismo de anotação adequado ao treinamento de modelos de aprendizado de máquina.

Essas discussões abrangeram os princípios fundamentais da anotação, o estabelecimento de convenções, a definição dos elementos necessários para representar a natureza multiarticulatória da Libras — envolvendo mãos, corpo, face, boca e olhos — e as estratégias de tradução automática a serem adotadas. Como resultado, foi desenvolvido um formalismo de anotação por glosas destinado a orientar a tradução e a anotação de vídeos em Libras.

O corpus paralelo Libras–português será constituído por vídeos em Libras, que servirão de base para a construção de conjuntos de dados destinados ao treinamento, validação, teste e avaliação de modelos de tradução automática. A anotação dos vídeos será realizada no software ELAN (WITTENBURG et al., 2006; MPI, 2025), amplamente utilizado para anotação linguística.

O formalismo de anotação proposto busca superar limitações frequentemente observadas em abordagens tradicionais de anotação por glosas, originalmente concebidas para a descrição de fenômenos linguísticos com forte enfoque fonético e fonológico. Embora adequadas para análise linguística, essas abordagens nem sempre atendem às necessidades de representação estruturada exigidas por métodos de aprendizado de máquina.

A anotação apresentada nesse documento é organizada em múltiplas camadas (*tiers*), nas quais diferentes tipos de informações linguísticas serão registrados ao longo de uma linha temporal comum. O formalismo fundamenta-se em uma representação capaz de acomodar as características multicamada e multicanal das línguas de sinais.

A anotação multicamada refere-se à organização das informações em diferentes camadas, cada uma dedicada a um tipo específico de dado linguístico. Já a anotação multicanal representa os diferentes canais articulatórios envolvidos na produção da língua de sinais, tais como mãos, expressões faciais, movimentos corporais e componentes orais.

O formalismo do CCD-TAAL adota uma abordagem simultaneamente multicamada e multicanal, permitindo representar componentes manuais, não manuais, espaciais e discursivos da Libras de forma integrada.

Apesar das limitações apontadas na literatura quanto ao uso de glosas para a representação detalhada das línguas de sinais (PIZZUTO; ROSSINI; RUSSO, 2006), elas continuam sendo amplamente utilizadas em corpora e sistemas de tradução automática (HANKE et al., 2023). De modo geral, uma glosa consiste em um rótulo textual associado a uma unidade linguística observada na sinalização. Dependendo da convenção adotada, uma glosa pode representar uma tradução aproximada, um identificador lexical, um fenômeno produtivo ou uma função linguística específica.

Não existe consenso sobre um padrão único de anotação por glosas. Diferentes comunidades e projetos utilizam convenções distintas, adequadas aos seus objetivos de pesquisa e de aplicação. Entre os principais tipos de glosas encontrados na literatura destacam-se:

- Glosa de Tradução: representa aproximadamente o significado de um sinal por meio de uma palavra ou expressão de uma língua oral.
- Glosa-ID (ID-Gloss): identifica de forma única um item lexical da língua de sinais.

- Glosa de Lema: representa uma unidade lexical abstrata, independentemente de suas realizações visíveis.
- Glosa Fonológica: descreve aspectos da forma do sinal.
- Glosa Funcional: representa funções gramaticais, discursivas ou referenciais.
- Glosa Produtiva: representa construções produtivas geradas dinamicamente durante a sinalização.

2 Conceitos

Nesta seção, são apresentadas definições de conceitos utilizados no contexto do projeto CCD-TAAL. Essas definições visam estabelecer um referencial e uma base comum para o entendimento e facilitar a comunicação entre os membros do projeto, que inclui membros de áreas diversas como linguística, estudo de língua de sinais, tradução, educação e ciência da computação.

2.1 Anáfora

Anáfora é um mecanismo de referência pelo qual um elemento linguístico retoma um referente previamente introduzido no discurso.

Em línguas de sinais, a anáfora frequentemente é realizada por apontamentos direcionados a posições espaciais previamente associadas a entidades discursivas.

Exemplo em português: João é meu irmão. Ele (anáfora) chegou de viagem.

Veja também: Catáfora e Dêixis.

2.2 Ancoragem

O termo ancoragem designa o processo de fixação de uma referência no espaço de sinalização, criando um ponto estável ao qual o sinalizador pode retornar ao longo do discurso (BARBERA; ZWETS, 2013; LIDDELL, 2003). Esse mecanismo permite associar entidades discursivas a locais espaciais específicos que funcionam como base para apontamentos, classificadores, olhares ou outros gestos de retomada. Em termos gramaticais e discursivos, a ancoragem opera como um recurso de coesão espacial e referencial, possibilitando que as relações sintáticas e semânticas sejam representadas por meio da localização e da orientação corporal. Assim, qualquer elemento sinalizado pode atuar como âncora, servindo de suporte para a continuidade do significado e para a organização da estrutura informacional no espaço de sinalização.

2.3 Banco de Glosas

Um Banco de Glosa é uma base de dados que organiza, de forma estruturada, glosas, suas realizações, informações linguísticas e metadados associados, permitindo o armazenamento, a consulta e a reutilização consistentes de informações glosadas.

2.4 Banco Lexical

Banco lexical é uma base de dados que organiza, de forma estruturada, lexemas, seus identificadores, suas realizações, informações linguísticas e metadados associados, permitindo o armazenamento, a consulta e a reutilização consistentes de informações lexicais.

2.5 Catáfora

A catáfora ocorre quando um elemento linguístico aponta para um referente que ainda será mencionado.

Exemplo em português. Quando ele (catáfora) chegou, João sentou.

Veja também Anáfora e Dêixis.

2.6 Dêitico

Dêitico é aquilo que aponta para algum contexto da fala — pessoa, tempo, espaço ou discurso — e só pode ser interpretado em relação a esse contexto.

Veja também Anáfora, Catáfora e Dêixis.

Observação: Dêixis é o fenômeno linguístico de referência contextual; dêitico é o item linguístico que realiza essa referência.

Observação: Anáfora retoma o que já foi dito; dêitico aponta para a situação de fala. Exemplos em português: i) João é meu irmão. Ele (anáfora) chegou de viagem; ii) Eu (dêitico) cheguei agora.

2.7 Dêixis

É o mecanismo linguístico pelo qual o significado depende do contexto de enunciação (quem fala, quando fala, onde fala, em que discurso).

Tipos clássicos de dêixis:

- Dêixis pessoal: Depende de quem fala e com quem se fala. Em português: eu, você, nós, meu, teu. Em Libras: apontamento para o corpo ou para o interlocutor.
- Dêixis espacial: Depende de onde está o referente. Em português: aqui, aí, ali, lá, este, esse, aquele. Em Libras: uso do espaço à frente do corpo.
- Dêixis temporal: Depende de quando o enunciado é produzido. Em português: agora, ontem, amanhã, hoje, este ano.
- Dêixis discursiva: Depende do próprio discurso. Em português: isto, isso, aquilo (referindo-se a partes do texto ou da fala), “como dito acima”, “a seguir”.

A dêixis é central nas línguas de sinais, pois os apontamentos funcionam como pronomes dêiticos; o espaço de sinalização cria referentes ancorados no discurso; e os verbos direcionais usam dêixis espacial para marcar papéis.

Veja também Dêitico.

Observação: Dêixis é o fenômeno linguístico de referência contextual; dêitico é o item linguístico que realiza essa referência.

2.8 Dicionário

Um dicionário é uma obra de referência que descreve e explica unidades lexicais de uma língua (palavras ou sinais) para consulta humana, organizando informações linguísticas de forma acessível.

2.9 Glosa

Glosa é um rótulo textual associado a uma unidade linguística observada na sinalização. Dependendo da convenção adotada, uma glosa pode representar uma tradução aproximada, um identificador lexical, um fenômeno produtivo ou uma função linguística específica.

2.10 Lema

Forma canônica escolhida para representar o lexema em dicionários/bancos lexicais.

Por exemplo, tradicionalmente, no português, todas as flexões verbais são catalogadas no dicionário no infinitivo. Por exemplo, "comer".

2.11 Lexema

Lexema é a unidade lexical abstrata que agrupa todas as formas flexionadas, variantes e ocorrências contextuais reconhecidas como um único item lexical.

Na língua portuguesa, por exemplo, o lexema "comer" inclui diferentes formas: como, comeu, comendo, comerá. Todas essas formas pertencem ao mesmo lexema.

Em língua de sinais, o lexema agrupa variações fonológicas (velocidade, amplitude), flexões gramaticais (direção, aspecto) e variações contextuais ou estilísticas, desde que os sinalizantes reconheçam todas essas formas como “o mesmo sinal”. O lexema não é uma execução específica em vídeo; é a identidade lexical abstrata subjacente.

2.12 Léxico

Léxico é o conjunto abstrato de unidades lexicais (lexemas) de uma língua — isto é, o inventário de itens de vocabulário que a língua disponibiliza aos seus falantes.

2.13 Multicanal

As línguas de sinais podem ser caracterizadas como sendo multicanais, na medida em que transmitem informação linguística simultaneamente por meio de componentes manuais e não manuais.

Canais são os diferentes meios articulatórios e perceptivos pelos quais a informação linguística é produzida e percebida, podendo operar simultaneamente na construção do significado.

Embora o termo multicanal seja mais frequente na literatura recente (KIM et al., 2024; SAUNDERS; CAMGÖZ; BOWDEN, 2020), o termo descreve adequadamente a estrutura simultânea das línguas de sinais, alinhando-se a abordagens formalistas, como a de Sandler e Lillo-Martin (2006), e a análises cognitivo-funcionais, como a de Liddell (2003).

Diferentes concepções teóricas de multicanalidade nas línguas de sinais implicam decisões distintas de anotação em corpora e de arquitetura de modelos para o processamento desses corpora. Abordagens formalistas tendem a representar canais como camadas linguísticas independentes, enquanto abordagens cognitivo-funcionais privilegiam representações integradas, nas quais o significado emerge da interação dinâmica entre gesto, espaço e sinal. A abordagem do projeto CCD-TAAL privilegia a perspectiva cognitivo-funcional.

Para a anotação dos corpora do projeto CCD-TAAL, é utilizada uma representação multicanal, instanciada em camadas de anotação por glosa, cada uma associada a um meio articulatório, perceptivo ou estrutural da Libras.

As camadas ou trilhas de anotação por glosa, no âmbito do CCD-TAAL, serão implementadas por meio do software de anotação multimídia ELAN (MPI, 2025)

2.14 Processamento Multifluxo (*multistream*) e Multimodal

Multifluxo refere-se à arquitetura de processamento computacional, na qual múltiplos fluxos de um mesmo tipo de dados são processados em paralelo por uma rede neural.

Uma rede neural é multimodal quando utiliza mais de uma modalidade de informação (texto, vídeo, esqueleto, etc.)

Combinação das características multifluxo e multimodais é comum no processamento de língua de sinais

Tratando-se de abordagens de processamento computacional de língua de sinais baseadas em estratégias de aprendizado de máquina, o fluxo de dados pode ser separado, a partir de vídeo, para o tratamento especializado das configurações de mãos, face, corpo etc.

No âmbito do CCD-TAAL, a característica multifluxo/multimodalidade das abordagens de reconhecimento e tradução pode contemplar também, além de diferentes tipos de dados (vídeo, texto, esqueleto, etc.) as informações expressas nas diferentes camadas de anotação. As camadas poderão ser agrupadas para a realização de experimentos envolvendo as abordagens em desenvolvimento. Diferentes estratégias de fusão (precoces, tardias ou híbridas) dos fluxos de dados também serão exploradas nos experimentos

Na Fusão Precoces (*early fusion*), os dados de diferentes fluxos são combinados logo na entrada do modelo, antes de qualquer processamento.

Na Fusão Tardia (*late fusion*), cada fluxo de dados é processado separadamente, e as saídas (representações ou decisões) são combinadas apenas no final.

Na Fusão Híbrida, ou Fusão Intermediária, (*hybrid / intermediate fusion*), a fusão ocorre em profundidades intermediárias da rede neural, buscando combinar as vantagens das fusões precoces e tardias.

No contexto da multimodalidade, é importante destacar que Um sistema linguístico é multimodal quando utiliza mais de uma modalidade sensorial (visual, auditiva, tátil etc.) para a comunicação ou processamento de informação. Nesse sentido, as línguas de sinais, assim como as línguas orais, são unimodais.

As línguas de sinais são da modalidade visuoespacial (ou gesto-visual). A informação é produzida pelo corpo (mãos, expressões faciais/corporais) e recebida pelos olhos, utilizando o espaço físico para construir significados.

A modalidade das línguas orais é oral-auditiva, ou seja, a produção da mensagem ocorre por meio da fala e a recepção é feita pelos ouvidos (audição).

2.15 Vocabulário

Vocabulário é o conjunto de palavras ou sinais efetivamente usados por um falante ou por um grupo de falantes em um texto ou em um domínio específico, em contraste com o léxico, que é abstrato e engloba todas as unidades lexicais da língua.

Essa distinção é importante em tradução automática, reconhecimento de sinais e modelagem neural, pois o tamanho do vocabulário do corpus afeta diretamente a complexidade do treinamento, enquanto o léxico da língua é muito mais amplo e aberto à incorporação de novos itens.

3 Convenções

3.1 Glosa

A glosa é a unidade básica de anotação adotada neste formalismo. Consiste em um rótulo textual atribuído a uma unidade linguística identificada na sinalização. As glosas são registradas em CAIXA ALTA, utilizando palavras do português conforme a ortografia padrão, incluindo acentos e cedilha.

Uma glosa pode representar um item lexical, um fenômeno produtivo ou uma função linguística. No âmbito do CCD-TAAL, as glosas não têm como objetivo descrever a forma articulatória dos sinais. Em vez disso, priorizam a representação de seu valor semântico ou funcional.

Essa abordagem favorece a interpretação linguística dos dados e permite que as glosas sejam utilizadas como etiquetas textuais adequadas ao processamento computacional, especialmente em aplicações de tradução automática e análise linguística. Dessa forma, a glosa estabelece uma ponte entre a representação visual da língua de sinais e os modelos computacionais, preservando, na medida do possível, o conteúdo semântico do enunciado sem buscar representar explicitamente toda a complexidade multicanal da sinalização.

No formalismo adotado pelo CCD-TAAL, a anotação utiliza três categorias principais de glosas: Glosas-ID, Glosas Funcionais e Glosas Produtivas.

- **Glosa-ID** (*ID-Gloss*): É um rótulo lexical associado a um determinado sinal. Sua função é referenciar consistentemente um item lexical específico em um banco de glosas. A Glosa-ID é utilizada para rotular sinais lexicalizados, ou seja, sinais que fazem parte do léxico convencional de uma língua de sinais, reconhecida e compartilhada pela comunidade de usuários da língua. Um sinal lexicalizado tem forma estabelecida e amplamente reconhecida pelos sinalizantes.
- **Glosa Funcional**: É utilizada para representar funções gramaticais, discursivas ou referenciais sem associação obrigatória a um sinal lexicalizado específico. Exemplos incluem apontamentos, elementos dêiticos, marcadores interrogativos, marcadores de negação e outros elementos cuja interpretação depende predominantemente de sua função no enunciado.
- **Glosa Produtiva**: É utilizada para representar construções geradas dinamicamente durante a sinalização, cuja forma e interpretação dependem do contexto discursivo e espacial. Diferentemente das Glosas-ID, as glosas produtivas não correspondem a sinais lexicalizados, mas a fenômenos como depicções (classificadores), ações construídas (representação de personagem em um discurso) e outras estruturas produtivas das línguas de sinais.

Independentemente da categoria utilizada, cada glosa deve estar associada a uma única realização de sinal ou gesto. Para fins de rastreabilidade, validação e reutilização dos dados, cada ocorrência deverá estar vinculada aos respectivos registros em vídeo e aos dados de captura de movimento no banco de glosas do projeto. Sempre que variações distintas de produção forem identificadas, elas deverão ser anotadas por meio de glosas diferentes.

As variações possíveis da forma do sinal (articulação do sinal) e do significado atribuído ao sinal, a atribuição de uma glosa a uma forma específica, devem observar as seguintes convenções:

- mesma forma de realização do sinal com mesmo significado $\Rightarrow$ mesma glosa (mesmo sinal);

- mesma forma do sinal com significados diferentes $\Rightarrow$ glosas diferentes (exemplo LARANJA e SÁBADO);
- formas diferentes com o mesmo significado $\Rightarrow$ glosas diferentes (variações de mesmo sinal). Utilizar, se apropriado, sinônimos na definição das diferentes glosas. Se não for possível, utilizar um sufixo numérico para diferenciar as variações;
- formas diferentes com significados diferentes $\Rightarrow$ glosas diferentes (sinais diferentes).

É importante frisar que uma determinada realização de um sinal deve ser associada a uma única glosa. Entretanto, glosas diferentes podem ser associadas a uma mesma realização de sinal, como, por exemplo, na sinalização de LARANJA e SÁBADO.

As palavras de uma glosa formada por mais do que uma palavra devem ser separadas pelo caractere sublinhado (exemplo: DUAS_PALAVRAS)

3.2 Trilhas

Considerando a natureza não linear, simultânea e espacialmente distribuída da sinalização em Libras, o presente formalismo adota um sistema de anotação multicamada, composto por trilhas de anotação, capaz de capturar as diversas dimensões envolvidas na construção do significado. Cada trilha representa uma dimensão específica da sinalização e a combinação dessas trilhas permite descrever a complexidade do evento comunicativo de forma sincronizada. A Tabela 1 apresenta as trilhas adotadas nesta versão do formalismo.

As trilhas mantêm alinhamento temporal, assegurando a coerência entre os diferentes canais da produção sinalizada. Quando, por exemplo, o sinalizador realiza uma boia de listagem, a trilha correspondente a “Boia” deve permanecer marcada durante todo o intervalo em que essa estrutura discursiva está sendo realizada. Nesse mesmo período, as trilhas de Apontamento e de Sinal Lexical registram, cada uma em seu respectivo canal, as ações que interagem com a boia — suas ocorrências devem ser delimitadas temporalmente dentro do intervalo da boia, respeitando as relações de inclusão e dependência entre as trilhas. Essa estrutura de trilhas torna possível representar, a simultaneidade, a sobreposição e a articulação espacial características da modalidade visuoespacial da libras.

3.3 Ancoragem

O termo ancoragem designa o processo de fixação de uma referência no espaço de sinalização, criando um ponto estável ao qual o sinalizador pode retornar ao longo do discurso ((LIDDELL, 2003; BARBERÀ; ZWETS, 2013). Esse mecanismo permite associar entidades discursivas a locais espaciais específicos que servem de base para apontamentos, classificadores, olhares ou outros gestos de retomada. Em termos gramaticais e discursivos, a ancoragem opera como um recurso de coesão espacial e referencial, possibilitando que as relações sintáticas e semânticas sejam representadas por meio da localização e da orientação corporal. Assim, qualquer elemento sinalizado pode atuar como âncora, servindo de suporte à continuidade do significado e à organização da estrutura informacional no espaço de sinalização.

Tabela 1 – Trilhas de Anotação.

Trilha	Função Principal
Tradução_Português	Tradução discursiva para o português do trecho sinalizado
Tradução_Inglês	Tradução discursiva para o inglês do trecho sinalizado
Sinal_Lexical_MD	Elementos lexicais da Libras. Anotação separada para cada mão. Esta é a trilha da Mão Direita (MD)
Sinal_Lexical_ME	Elementos lexicais da Libras. Anotação separada para cada mão - trilha Mão Esquerda (ME)
Datilologia_MD	Sinalização utilizando o alfabeto manual. Anotação separada para cada mão - Mão Direita (MD)
Datilologia_ME	Sinalização utilizando o alfabeto manual. Anotação separada para cada mão - Mão Esquerda (ME)
Depicção_MD	Representações icônicas e espaciais. Anotação separada para cada mão - Mão Direita (MD)
Depicção_ME	Representações icônicas e espaciais. Anotação separada para cada mão - Mão Esquerda (ME)
Boia_MD	Estabelecimento de referentes no espaço de sinalização - Mão Direita (MD)
Boia_ME	Estabelecimento de referentes no espaço de sinalização - Mão Esquerda (ME)
Apontamento_MD	Retomadas dêiticas de referentes. Anotação separada para cada mão - Mão Direita (MD)
Apontamento_ME	Retomadas dêiticas de referentes. Anotação separada para cada mão - Mão Esquerda (ME)
Olhar	Direcionamento do olhar para concordância, retomada ou foco
Face	Expressões não manuais
Boca	Ações bucais produzidas que desempenham um papel significativo na realização do texto sinalizado.
Gesto_MD	Gestos discursivos/dêiticos. Anotação separada para cada mão - Mão Direita (MD)
Gesto_ME	Gestos discursivos/dêiticos. Anotação separada para cada mão - Mão Esquerda (ME)

4 Protocolo de Anotação

Este protocolo define a estratégia de anotação linguística da Libras com vistas à criação de um conjunto de dados capaz de alimentar sistemas de processamento de línguas de sinais. O desenvolvimento fundamenta-se no corpus em produção no âmbito do projeto (CCDD TAAL), constituindo um corpus empírico de referência.

O material original a ser anotado e utilizado para o estabelecimento de um corpus paralelo português-Libras, de suporte ao desenvolvimento de abordagens de tradução automática, será constituído de vídeos com conteúdo em Libras. Os vídeos serão anotados conforme o formalismo descrito neste documento. A anotação será efetuada no programa de computador de anotação linguística ELAN (MPI, 2025).

No fluxo de um vídeo sinalizado, toda ação significativa – aquela que produza significado – deve ser delimitada com seu início e fim para que ela possa vir a ser anotada. Entre essas ações estão as ações manuais convencionais relacionadas a sinais lexicalizados, equivalentes às palavras nas línguas orais, mas não só: ações não manuais (como expressões faciais), depicções (também conhecidas como classificadores), gestos, apontamentos, ações de ancoragem, entre outros (LIDDELL, 2003; BARBERÀ; ZWETS, 2013). Em contextos sinalizados, a segmentação

não pode apoiar-se apenas em fronteiras lexicais ou sintáticas, como ocorre nas línguas orais, mas deve considerar a integração dinâmica entre diferentes partes que constituem um todo, podendo ser glosadas de acordo com o sentido que se apresenta nessas construções. Aqui, cada ocorrência significativa é entendida como uma unidade, cuja delimitação depende de critérios fonológicos, prosódicos e discursivos observáveis na materialidade do gesto: pausas, mudanças de expressão facial, direcionamento do olhar, variações rítmicas e transições espaciais. Assim, o que chamamos de “sinal” não corresponde apenas a uma forma lexical isolada, mas a um evento comunicativo situado que articula múltiplos canais do corpo (LEITE, 2008).

Para fins de segmentação, a produção de um sinal ou gesto da língua pode ser dividida em quatro fases (LEITE, 2008): (1) preparação, (2) ataque, (3) manutenção e (4) retração. A fase 1 (preparação) — movimento inicial para a posição articulatória — não é anotada.

A anotação inicia-se na fase 2 (ataque), momento em que a mão já está configurada para o sinal, e estende-se até a fase 3 (manutenção).

A retração serve apenas como limite de encerramento do intervalo anotado.

Entre duas glosas consecutivas em uma mesma trilha deve haver um intervalo temporal mínimo, assegurando que o modelo de tradução consiga segmentar adequadamente as unidades de análise.

4.1 Regras gerais de anotação

As seguintes regras gerais devem ser observadas na anotação das trilhas:

- **Glosas:** devem ser escritas integralmente em CAIXA ALTA, representando o valor semântico do sinal.
- **Verbos:** são registrados no infinitivo (ex.: IR, SABER, FALAR).
- **Gênero:** não deve ser marcado; as glosas serão registradas no masculino, salvo quando houver expressão explícita de gênero no dado sinalizado.
- **Soletreção:** deve ser anotada letra a letra quando cada caractere for produzido individualmente, ou como palavra inteira quando a soletreção for sinalizada de modo contínuo, conforme a realização observada (ver (DINIZ, 2024))
- **Numerais:** quando produzidos de forma isolada, cada número é glosado separadamente; em casos de expressão composta ou sequencial, anota-se o numeral correspondente ao final da ação.
- **Sinais compostos:** devem ser glosados somente quando lexicalizados, formando uma única unidade.
- **Expressões faciais neutras:** não são anotadas, sendo registradas apenas expressões com função linguística ou discursiva.
- **Delimitação temporal:** o início e o fim da glosa devem corresponder, respectivamente, ao início da fase de ataque) e ao término da fase de manutenção.
- **Consistência:** a anotação deve manter consistência terminológica e temporal ao longo de todo o corpus.

4.2 Anotação das Trilhas

4.2.1 Trilha Tradução_Português

Essa trilha de tradução apresenta o conteúdo discursivo do trecho sinalizado em língua portuguesa, sem segmentação palavra a palavra. Seu objetivo é fornecer um sinal de supervisão que permite o aprendizado de relações de correspondência entre produções "equivalentes" em duas línguas.

4.2.2 Trilha Tradução_Inglês

Essa trilha de tradução apresenta o conteúdo discursivo do trecho sinalizado em língua inglesa, sem segmentação palavra a palavra. Seu objetivo é fornecer um sinal de supervisão que permite o aprendizado de relações de correspondência entre produções "equivalentes" em duas línguas.

4.2.3 Trilhas Sinal_Lexical_MD e Sinal_Lexical_ME

Essas trilhas registram a produção manual lexicalizada da Libras. Como a Libras permite articulação simultânea, é fundamental distinguir entre a atuação da mão direita (MD) e da mão esquerda (ME). Quando há sinal bimanual, a glosa é duplicada em ambas as trilhas; quando as mãos realizam ações diferentes, cada trilha registra, independentemente, sua glosa. A anotação deve iniciar quando a configuração manual estiver formada (fase 2) e encerrar ao final da manutenção (fase 3).

4.2.4 Trilhas Datilologia_MD e Datilologia_ME

Nestas trilhas, serão anotadas as palavras soletradas, isto é, produções manuais realizadas letra a letra, por meio do alfabeto manual. Distingue-se aqui entre palavra soletrada e sinal soletrado (DINIZ, 2024): a primeira corresponde à representação sequencial de letras que formam um item lexical do português, enquanto a segunda já se encontra lexicalizada na Libras - devendo essa ser anotada na trilha Sinal Lexical. Assim, a trilha Datilologia registra apenas as ocorrências de soletração alfabética, respeitando o intervalo temporal exato de início e fim da produção de cada palavra.

4.2.5 Trilhas Depicção_MD e Depicção_ME

Estas trilhas apresentam sinais não lexicalizados, de natureza icônica ou espacial, que descrevem forma, posição, movimento ou função de um referente, fundamentalmente realizados com as mãos (outros elementos que compõem a depicção que não as mãos serão anotados nas suas trilhas respectivas). Por serem produtivos e não dicionarizados, os classificadores devem ser glosados com base no valor semântico evocado, ou seja, em toda a sua contração. Eles também podem funcionar como âncoras discursivas para apontamentos e olhares subsequentes.

4.2.6 Trilhas Boia_MD e Boia_ME

As boias têm uma função discursiva fundamental. Elas estabelecem referentes espaciais que poderão ser retomados posteriormente na enunciação. Esses referentes ancoram o espaço sintático-discursivo, permitindo operações como apontamentos e direcionamento do olhar. A escolha de qual mão utilizar depende da produção do sinalizador, e a ancoragem deve ser precisa, já que outras trilhas se referirão a ela.

4.2.7 Trilhas Apontamento_MD e Apontamento_ME

Trilhas que registram operações dêiticas. Um apontamento retoma um referente previamente ancorado — por exemplo, em uma boia — e deve indicar a glosa e a trilha de origem. Isso permite ao sistema de tradução reconhecer relações sintáticas espaciais, como sujeito, objeto ou tópico sinalizado no espaço.

4.2.8 Trilha Olhar

Trilha voltada ao registro da orientação dos olhos como recurso linguístico. O olhar é parte integrante da gramática espacial da Libras, funcionando muitas vezes como retomada de um referente previamente ancorado, ou como forma de marcar tópico, foco ou concordância. A anotação deve indicar sempre a glosa e a trilha da âncora.

4.2.9 Trilha Face

Trilha destinada à anotação de expressões faciais linguísticas — interrogativas, topicalizações, negações ou foco. Expressões emocionais (por exemplo, surpresa, raiva ou alegria) não devem ser anotadas aqui, por não terem função sintática. A ausência de marca facial é interpretada como expressão afirmativa neutra e não requer anotação.

4.2.10 Trilha Boca

Nesta trilha serão anotadas as ações bucais produzidas que desempenham papel significativo na realização do texto sinalizado. Essas ações podem ser aquelas que se assemelham à articulação de palavras de línguas orais, descritas na literatura como articulação bucal de palavras (mouthings), quando usadas para se distinguir um sinal lexical de outro, ou ações bucais que não mantêm relação direta com palavras de línguas orais, mas que participam da significação como protrusão de língua, sopros, sucções, suspensões ou outros movimentos visíveis da boca (SILVA, 2023).

4.2.11 Trilhas Gesto_MD e Gesto_ME

Os gestos, embora não sejam sinais lexicalizados, carregam funções discursivas e sintáticas, podendo indicar foco, modalizações ou reforço enunciativo. Esta trilha registra gestos manuais não lexicais, diferenciados por mão. Gestos prosódicos neutros podem ser omitidos, a critério da equipe de anotação.

4.2.12 Ancoragem Espacial

A ancoragem é um recurso transversal que liga um elemento sinalizado em qualquer trilha a elementos subsequentes da enunciação. O apontamento e o direcionamento do olhar, por exemplo, dependem da ancoragem para que suas referências possam ser interpretadas pela máquina. Cada anotação que retoma um referente deve conter a glosa e a trilha de origem, permitindo a reconstrução da sintaxe espacial. A ancoragem dos elementos realizados é de grande importância para evidenciar as relações sintáticas existentes em uma língua de sintaxe espacial, assim, a notação adotada para expressar essas relações será: SIGNIFICADO[(REFERÊNCIA)TRILHA], sendo o SIGNIFICADO a glosa que designe o significado da produção sinalizada, REFERÊNCIA o local no qual a produção se ancora e TRILHA a trilha onde esse local se encontra.

Referências

- BARBERÀ, G.; ZWETS, M. Pointing and reference in sign language and spoken language: Anchoring vs. identifying. *Sign Language Studies*, Gallaudet University Press, v. 13, n. 4, p. 491–515, 2013. ISSN 03021475, 15336263. Disponível em: <<http://www.jstor.org/stable/26191737>>. 2, 7, 8
- DINIZ, H. G. *Variação fonológica das letras manuais na soletração manual em Libras*. Tese (Doutorado) — Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2024. 9, 10
- HANKE, T. et al. Easier notation – a proposal for a gloss-based scripting language for sign language generation based on lexical data. In: *2023 IEEE International Conference on Acoustics, Speech, and Signal Processing Workshops (ICASSPW)*. [S.l.: s.n.], 2023. p. 1–5. 1
- KIM, J.-H. et al. SignBLEU: Automatic evaluation of multi-channel sign language translation. In: CALZOLARI, N. et al. (Ed.). *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*. Torino, Italia: ELRA and ICCL, 2024. p. 14796–14811. Disponível em: <<https://aclanthology.org/2024.lrec-main.1289/>>. 4
- LEITE, T. de A. *A segmentação da língua de sinais brasileira (Libras): um estudo linguístico descritivo a partir da conversação espontânea entre surdos*. Tese (Doutorado) — Faculdade de Filosofia, Letras e Ciências Humanas, Universidade de São Paulo, 2008. 9
- LIDDELL, S. K. *Grammar, Gesture, and Meaning in American Sign Language*. [S.l.]: Cambridge University Press, 2003. 2, 4, 7, 8
- MPI. *Elan*. 2025. <<https://archive.mpi.nl/tla/elan>>. Multimedia annotation software. 1, 5, 8
- PIZZUTO, E. A.; ROSSINI, P.; RUSSO, T. Representing signed languages in written form: Questions that need to be posed. In: *2nd Workshop on the Representation and Processing of Sign Languages: Lexicographic Matters and Didactic Scenarios*. Genoa: European Language Resources Association (ELRA), 2006. p. 1–6. 1
- SANDLER, W.; LILLO-MARTIN, D. *Sign Language and Linguistic Universals*. [S.l.]: Cambridge University Press, 2006. 4
- SAUNDERS, B.; CAMGÖZ, N. C.; BOWDEN, R. Adversarial training for multi-channel sign language production. *CoRR - A Computing Research Repository*, abs/2008.12405, 2020. Disponível em: <<https://arxiv.org/abs/2008.12405>>. 4
- SILVA, J. P. *As ações bucais como práticas na emergência de entendimentos situados em interação sinalizada*. Tese (Doutorado) — Faculdade de Filosofia, Letras e Ciências Humanas, Universidade de São Paulo, São Paulo, 2023. 11
- WITTENBURG, P. et al. Elan: a professional framework for multimodality research. In: *Fifth International Conference on Language Resources and Evaluation*. Genova, Italy: [s.n.], 2006. p. 1556–1559. 1

Anexo 2

Artigo Publicado

**The In-Car Sign Language Corpus (ICSL): A
Multi-Modal Resource for Constrained-Space Sign
Language Recognition**

**12th Workshop on the Representation and
Processing of Sign Languages**

The In-Car Sign Language Corpus (ICSL): A Multi-Modal Resource for Constrained-Space Sign Language Recognition

Raviteja Boddu*, Guilherme Vieira Leite†, Joed Lopes da Silva*,
Ângelo Benetti†, Isabela Barbieri†, Natália de Melo Afonso†,
Thyago Santos‡, Helio Pedrini†, Felipe Venâncio Barbosa‡,
José Mario De Martino†, Munir Georges*, Alessandro Zimmer*

*Technische Hochschule Ingolstadt (THI), Bayern, Germany

†Universidade Estadual de Campinas (UNICAMP), São Paulo, Brazil

‡Universidade de São Paulo (USP), São Paulo, Brazil

*{raviteja.boddu, joed.lopesdasilva, munir.georges, alessandro.zimmer}@thi.de

†martino@unicamp.br, †guilherme.leite@ic.unicamp.br

Abstract

This paper addresses the challenges of using sign language within shared mobility services, such as taxis, carpools, or ride-sharing platforms. The use of sign language recognition (SLR) in real-world, confined environments, specifically vehicle interiors remains largely unexplored. To motivate research in this area, we present the In-Car Sign Language (ICSL) dataset for Brazilian Sign Language (Libras), with the long-term goal of improving public transport accessibility for the Deaf and Hard-of-Hearing community. The dataset consists of: (1) high-precision laboratory motion capture (MoCap) data to establish an idealized linguistic baseline and (2) real-world multi-modal in-car recordings captured using a 2D camera and 3D Time-of-Flight sensors. The dataset provides a basis for comparative analyses between synthesized signing avatar animations and recorded real signing interpreter videos, which enable future research into robust “in-the-wild” SLR models and domain adaptation. We describe in detail the use cases, the setup, the data collection protocol, and the metadata structure of the corpus. In total, we recorded a multimodal dataset exceeding 1.5 million frames, comprising the synchronized multimodal streams described above featuring Libras users across various in-car scenarios. The corpus is provided with gloss annotation of lexical signs and non-lexical sign language elements specially designed to support the training and evaluation of deep neural networks for constrained space recognition. In-vehicle signing offers a technically significant example of a constrained, occluded, and non-frontal environment. While recognizing the diverse communication strategies already employed by the Deaf community, identifying automotive-specific limitations provides a useful stepping stone for research into enhancing in-car accessibility and passenger quality of life.

Keywords: Brazilian Sign Language (Libras), Shared Mobility Service, Motion Capture (MoCap), In-Car Communication, Constrained Signing Space, Signing Avatars, Multimodal Sensors

1. Introduction

The advancement in natural language processing and computer vision has brought us closer to seamless human-machine interaction. While the Deaf and Hard-of-Hearing (DHH) community has developed effective strategies for “on-the-go” communication, such as the use of mobile devices or visual cues, the interior of vehicles within shared mobility services represents a technically significant and under-researched environment for Sign Language Recognition (SLR).

Specifically, the car cabin serves as a critical case study for constrained, occluded, and non-frontal signing environments, which are often overlooked in traditional laboratory-based datasets. While Brazilian Sign Language (Libras) has an established linguistic foundation, there is currently no specialized resource documenting how signing is produced and processed in the highly constrained physical and visual environments of a car cabin (dos Santos et al., 2025; Lee et al., 2025).

The relevant studies and corpora that exist for Libras are predominantly recorded in laboratory-controlled settings with optimal lighting and neutral backgrounds. In such environments, signers have a full, unobstructed signing space (dos Santos et al., 2025). However, the interior of a vehicle introduces severe constraints, such as seatbelts cutting across the torso, occlusions, dashboard obstruction, and constrained space that limit the range of torso, elbow, and arm movements, and dynamic environmental lighting creates substantial visual noise. These factors represent fundamental challenges for current SLR systems, which often fail to generalize to such “in-the-wild” conditions.

Within the framework of Project UNITY, a collaborative research initiative between the UNICAMP (Brazil) and the THI (Germany), we seek to establish a specialized multimodal dataset that captures real-world constraints while providing a high-fidelity baseline. We aim to enhance the robustness of SLR models by utilizing signing avatars as a controlled reference to evaluate the environmental chal-




Figure 1: Proposed Project UNITY architecture for a conceptual bidirectional loop: (right) Driver-to-Passenger Speech-to-Sign Synthesis and (left) Passenger-to-Driver Sign Language Recognition.

lenges present in real-world in-car video. Led by professional Libras signers and Deaf researchers, who are also co-authors of this study, the data acquisition process seeks to document the authentic challenges of the constrained transport domain by documenting passenger-driver communication within the vehicle cabin.

The long-term vision of this project is to investigate the feasibility of a real-time, bidirectional translation framework, as seen in Figure 1, which serves as the target architecture for our ongoing work. Unlike traditional one-way approaches, our target architecture facilitates a conversational loop between driver speech and passenger signs (Libras). Building such a system requires resources that capture both idealized linguistic baselines and the severe physical restrictions of the vehicle cabin.

Rather than presenting a final recognition solution, this paper describes an initial step toward the In-Car Sign Language (ICSL) corpus, which we hope can serve as a helpful reference for future data collection efforts in the automotive domain. It details the acquisition protocol, use-case design, and setup for in-car recordings; the technical setup of the laboratory MoCap baseline; and the architecture of the signing avatar pipeline. By providing this comparative resource, we hope to contribute to future studies on accessible communication technologies for the DHH community in transportation systems.

2. Related Work

For the Brazilian Sign Language (Libras) community, there is a big gap between lab research and real-world use, especially in ride-hailing and ride-sharing services. The space, movement, and social setting within a vehicle influence how signs are produced. This section provides an overview of existing language resources, the algorithms used, and the real-world challenges involved in building a Libras dataset and tools designed specifically for use in vehicles.

2.1. The Landscape of Brazilian Sign Language (Libras) Resources

The development of language resources for Libras has changed over time. It started mainly with written documentation and later moved to video-based, multimodal data. Libras is recognized as a legal means of communication and expression in Brazil, with its own grammar and linguistic system for transmitting ideas and facts (Presidência da República, 2002).

Early work on documenting Libras mostly focused on creating dictionaries and bilingual corpora to support education and translation (de Quadros and de Sousa, 2021). A comparative summary of prominent Libras datasets and their recording environments is provided in Table 1.

2.1.1. Textual and Bilingual Corpora

One of the important recent resources for Libras is VLibras-DB (Lima et al., 2025). It is a bilingual text dataset with about 127,000 translation pairs between Brazilian Portuguese and Libras. This dataset was mainly created to help neural machine translation systems convert written text into glosses. Broadly defined, glossing is the use of written language to represent primary data, whether signed or spoken. Within SLR, it serves as a symbolic bridge, utilizing labels from a spoken language to represent the manual and non-manual components of a sign.

To build VLibras-DB, a group of 10 professional interpreters worked together to define annotation rules for representing signs using glosses that could leverage neural network training. The gloss convention established includes directional verbs, intensifiers, and negation. The dataset primarily covers manual lexical signs but does not address challenges posed by non-manual markers or timing-related information. Non-manual markers (NMMs) are linguistically meaningful articulations produced by the face, head, torso, and gaze used as part of a sign language’s phonology, morphology, syntax, and prosody (Herrmann, 2014). As a result, the

VLibras-DB is not fully suitable for sign recognition tasks in real-world settings.

2.1.2. Visual and Isolated Sign Recognition Benchmarks

For isolated sign language recognition (ISLR), researchers typically use datasets such as MINDS-Libras (Rezende et al., 2021) and LIBRAS-UFOP (Cerna et al., 2021). These datasets have videos of single signs, mostly recorded in a controlled setup, with a plain background and the signer facing the camera. Recently, researchers have improved recognition performance by utilizing skeleton-based image representations paired with 2D CNN models, achieving accuracies up to 0.93 on MINDS-Libras. This technique involves transforming skeletal sequences comprising body, hand, and facial landmarks into a single spatio-temporal image, allowing a 2D CNN to recognize the sign from this unified input. This image then goes into a classifier to recognize the sign (Alves et al., 2024). However, such datasets do not work well for car environment. Most ISLR benchmarks assume the signer is facing the camera directly, which is very different from the angles you get inside a vehicle (Ranum et al., 2024). While vehicle interiors present unique spatial challenges, they share commonalities with other atypical or constrained-space signing environments. For instance, the PopSign dataset (Starner et al., 2023) explores the complexities of one-handed signing with the narrow field of view of a smartphone camera. Much like PopSign, our ICSL dataset addresses the problem of reduced signing volume, where the signer must adapt the scale of their gestures due to spatial boundaries. Our work extends this by focusing on the specific two-handed constraints, such as seatbelt occlusions and non-frontal camera perspectives, unique to the automotive cabin that are not present in hand-held mobile datasets.

2.1.3. Regional and Documentary Inventories

The LIBRAS-UFSC corpus and the Libras National Inventory are focused on preserving Brazil's Deaf heritage and the language's diversity. They ensure the corpus includes people of different ages, genders, and regions, using careful methods to build it. The LIBRAS-UFSC corpus provides phonetic and phonological details, inspired by the Dutch Signbank model, and classifies signs by hand shape, movement, and location. These resources are relevant for linguistic research, but they are usually recorded in controlled settings, so they do not capture challenges such as visual noise, occlusions, or restricted movement that you would see in a car (de Quadros and de Sousa, 2021) (Lobo-Neto and Pedrini, 2024).

2.2. Sign Language Recognition Architectures and Methodologies

The technological evolution of SLR has transitioned from traditional manual feature extraction to end-to-end deep learning models. This shift is critical for handling the high variability of sign language, which is based on precise hand movements, facial expressions, and body language.

2.2.1. Feature Extraction and Temporal Modeling

Feature extraction focuses on capturing spatial information about hand shape, position, and orientation, as well as facial landmarks. Temporal modeling addresses the multichannel sign language characteristics (hands, facial expression, gaze, torso shift, head movement) presented in continuous stream of video frames (Camgoz et al., 2020; Rastgoo, 2021; Alyami et al., 2024; Taher and Zeebaree, 2025). Common architectures include:

- **CNN-BiLSTM:** Convolutional Neural Networks (CNNs) extract spatial features from individual frames, while Bidirectional Long Short-Term Memory (BiLSTM) networks learn the temporal dependencies over time. This combination is particularly effective for dynamic gestures, where the order of movements is crucial to the meaning (Lu et al., 2023).
- **Graph Convolutional Networks (GCNs):** These consider body landmarks as nodes in a graph, allowing the model to learn the structural interconnections between different joints and body parts (de Amorim et al., 2019).
- **Transformers:** Utilizing spatial and temporal attention mechanisms, Transformers can capture long-range dependencies across frames and correlations between different visual channels (Ma et al., 2024).

2.2.2. Landmark Detection and Efficiency

In real-time automotive applications, computational efficiency is as vital as accuracy. MediaPipe and OpenPose are the two most frequently cited tools for skeletal feature extraction due to their extensive joint coverage. OpenPose is often prone to temporal jitter and high latency, particularly in occluded environments (Alves et al., 2024). In contrast, MediaPipe offers a lightweight alternative that can achieve 5x faster recognition by utilizing an optimized subset of body landmarks (dos Santos et al., 2025). Research has shown that a well-chosen landmark subset (e.g., focusing on the upper body and hands) can maintain state-of-the-art accuracy while significantly reducing inference time. While efficient, MediaPipe's performance can degrade

Table 1: Overview of existing and proposed Brazilian Sign Language (Libras) datasets.

Dataset Name	Modality	Primary Task	Language	Scope	Annotations
VLibrasBD	Text/Gloss	Neural Machine Translation	Libras/BP	127k Pairs	Gloss, Syntax
MINDS-Libras	RGB Video	Isolated Sign Recognition	Libras	1,200+ Samples	Gloss
LIBRAS-UFOP	RGB Video	Isolated Sign Recognition	Libras	2,000+ Samples	Gloss
LIBRAS-UFSC	Video/Bank	Linguistic Documentation	Libras	National Inventory	Phonetics
LSWH100	Synthetic RGB	Handshape Classification	Libras	144k Images	Keypoints
Ours (ICSL)	RGB/Depth/IR /Point Cloud	Constrained Sign Recognition	Libras	1.5M+ Frames, 127 Phrases*	Gloss

*Current subset of a total 1,344 defined phrases.

significantly when parts of the body are blocked or in poorly lit environments, which often happens inside a car (Amalfitano et al., 2023). Consequently, there is a need for models that can handle missing hand or body points or combine information from different sensors to deal with visual noise.

2.3. The Automotive Domain: Physical and Social Constraints

The interior of a vehicle presents a highly restricted physical and visual environment for communication. Unlike laboratory settings, where signers have full, unobstructed signing space, the car cabin introduces several “in-the-wild” constraints that serve as a starting point for specialized SLR research.

2.3.1. Constrained Signing Space and Occlusions

The physical setup inside a car changes how people sign. Seatbelts cross the body and can obscure important parts of a sign and hinder torso movements. The dashboard, headrests, and tight space also limit the movement of the arms and elbows, reducing overall signing space.

2.3.2. Environmental Noise and Dynamic Lighting

Inside a vehicle, visual conditions can change significantly. Lighting can go from bright sunlight to near darkness very quickly. Shadows, reflections from windows, and uneven light can add visual noise, making it harder to clearly see hands and movements. Because of this, sign language recognition systems that work well in lab lighting often struggle to handle these changing real-world conditions (Amalfitano et al., 2023).

2.4. Hardware and Multimodal Sensing

Because single RGB cameras do not work reliably inside a car, researchers are using multiple sensor types to make sign language recognition systems more stable and accurate.

2.4.1. 2D vs. 3D Sensing

While 2D cameras are affordable and widely available in modern vehicles, they lack depth information. Time-of-Flight (TOF)/3D cameras provide 3D skeletal data that can be used to track hand motion trajectories in three dimensions. Depth maps enable the system to segment hands from the background more effectively, especially when the hands are similar in color to the vehicle interior. Depth sensing is critical for sign language because the movement of the hand toward or away from the camera often distinguishes between different signs (Zhang, 2022) (Ranum et al., 2024).

2.4.2. Synthetic Data and Motion Capture (MoCap)

Synthetic data generation has emerged as a key strategy for overcoming the difficulty and high cost of collecting large-scale natural datasets.

Previous studies have successfully utilized motion capture systems to acquire precise three-dimensional point cloud and skeletal data from deaf signers (Kipp et al., 2011; De Martino et al., 2016; Will et al., 2018; Jedlička et al., 2020; Andersen et al., 2025; De Martino et al., 2025). This high-fidelity spatiotemporal data, capturing both manual and non-manual signals, serves as a critical training corpus for neural networks, such as CNNs and RNNs, enabling them to learn the mapping from continuous sign language kinematics to written language translation.

Shterionov et al. (2024) discuss about the types of synthetic work, two of the main trends in synthesis are: (i) the more traditional 3D animation-based which resolves in generating a 3D animated character, commonly referred to as an avatar; and (ii) a video of a virtual human that can be synthesized with generative AI methods based on real human video/image data

3. Motivation for the Set-up

The synthesis of the existing literature reveals the primary motivations for developing our specialized Libras resource. This work distinguishes itself by starting from a stable, fundamental baseline, which is currently missing in the field of automotive sign language recognition.

- **Establishing a Multimodal In-Car Baseline:** There is currently no resource documenting Libras production within the physical and visual constraints of a car cabin. Our setup provides the very first multimodal baseline (RGB + 3D TOF) recorded inside a vehicle. By starting with a simplified, stable environment, we establish the necessary scientific foundation before introducing more complex parameters in future iterations, and it provides the first comparative benchmark between idealized laboratory MoCap and these constrained “in-the-wild” conditions.
- **Comparative Analysis of Constrained Space:** This resource is motivated by the need to quantify the linguistic and physical differences between idealized laboratory signing and signing within the confined space of a car cabin. This dataset allows for a direct comparison between high-precision MoCap and real-world cabin constraints.
- **Facilitating Initial Domain Adaptation:** By providing a synchronized real-world baseline and a corresponding synthetic dataset, we enable researchers to begin exploring domain adaptation for cars using expressive 3D avatars.

3.1. Potential Research Directions

To address these motivations, the ICSL dataset provides the necessary multimodal data to investigate several key research questions in future studies, such as the following:

- **Camera Placement Optimization:** Determining the optimal camera positions within a vehicle cabin to maximize the visibility of facial expressions and head movements in Libras, despite the spatial constraints.

- **Physical Baseline Comparison:** Analyzing how sign production (hand configuration and path movement) differs when comparing a high-precision laboratory MoCap baseline to the constrained physical space of a vehicle.
- **Multimodal Stability Evaluation:** Assess to what extent multimodal sensor fusion improves the stability of landmark detection in a confined interior compared to traditional monocular systems.
- **Perspective Gap Assessment:** Evaluating whether signing avatars, generated from idealized MoCap, can effectively simulate the non-frontal viewing angles required for in-car Human-Machine Interfaces (HMI).
- **Linguistic Adaptation Analysis:** Investigating how physical restrictions, such as the car seat and seatbelt, impact the duration and spatial volume of signs compared to laboratory-recorded data.
- **Model Robustness Testing:** Quantifying the performance drop when models trained on stable in-car data are tested against other driving-related micro-gestures or environmental noise.

By establishing this baseline, we provide the scientific community with a foundation for building inclusive, real-time assistive technologies that bridge the communication gap in shared mobility services.

4. Corpus Design

The design of the In-Car Sign Language (ICSL) corpus is driven by the need for accessible passenger-driver communication within shared mobility services. Unlike general-purpose sign language datasets, this resource focuses exclusively on the constrained signing space of vehicle interiors to analyze how physical constraints impact LIBRAS language.

4.1. Scenario Selection and Use Cases

In collaboration with our Deaf researchers and professional Libras interpreters, we defined 1,344 essential communication scenarios for shared mobility services. To date, we have recorded 127 essential cases that reflect the immediate needs of DHH passengers. These are categorized into five functional groups:

- **Navigation and Routing**
 - “Qual o destino?” (Where to?)
 - “Melhor evitar o centro.” (It is best to avoid downtown.)
 - “Já passamos o ponto.” (We are past my drop-off.)

- etc.

- **Safety and Regulations**

- “Reduzindo por segurança.” (Reducing for safety reasons.)
- “Pode ir devagar?” (Can you slow down?)
- etc.

- **Passenger Comfort and Interaction**

- “Preciso descer urgente.” (I need to stop urgently.)
- “Posso ligar o ar-condicionado?” (May I turn on the air conditioning?)
- etc.

- **Assistance**

- “Pode ajudar com a cadeira de rodas?” (Can you help with the wheelchair?)
- “Tem troco para R\$ 25,00?” (Do you have change for R\$ 25,00?)
- “Tenho uma mala pesada.” (My luggage is heavy.)
- etc.

- **Alphabet Spelling**

- A, B, C, etc.

4.1.1. Subject Recruitment and Diversity

The corpus was recorded by one hearing and two deaf signers, all proficient in Libras, which were instructed to dress as usual for the capture session. They also served as annotators to our data. To ensure that our data captures a wide range of physical constraints, recordings were conducted across three different vehicle models with varying cabin geometries: a Jeep Compass, a Nissan March, and a Renault Megane. All sessions were performed under clear daylight conditions to minimize extreme external lighting noise while preserving the natural dynamic shadows of the vehicle interior as seen in Figure 2.




Figure 2: Illustration of the three signers and challenges within vehicle cabin: (a) FLIR camera, (b) ToF camera, and (c) recording tablet point of views.

5. Data Acquisition and Technical Setup

Our data collection followed a two-stage approach. We first established a laboratory baseline using high-precision motion capture to define the “gold standard” for each sign. This was followed by an acquisition phase inside a vehicle cabin, using a multimodal sensor setup to capture the natural constraints for in-car communication.

5.1. Laboratory MoCap Baseline

Our ICSL MoCap corpus was built to simulate in-vehicle body positioning and its effects on Libras sign production. To do so, we employed several sensors, including RGB cameras and a motion capture suit (MoCap), to record joint movements with detail and precision during sign language communication. The setup made use of several professionals, including:

- Two Libras signers who were fluent in Libras and performed the signs.
- One system operator to up-keep the quality of the MoCap data being recorded.
- Two hardware operators to ensure frame synchronization and camera operation, and lastly.
- One content facilitator to assist with translation and language production evaluation.

Regarding our frame composition for this task, the laboratory has a green-screen background and a mock-up car seat. The Libras' signers are recorded while seated, wearing a special MoCap suit that covers most of their bodies. The suit is made from black cloth and allows the attachment of reflective beads (or spherical markers) with velcro, which are detectable by the infrared cameras as seen in Figure 3a. In total, there are 73 beads distributed across the main signer's joints.




Figure 3: MoCap setup illustrating the (a) capturing suit, (b) the markerset and skeleton from the Vicon tracking software, and (c) the rendered avatar (Clara).

We also distributed fourteen Vicon (Vicon, 2026) cameras radially around the signer. These cameras are equipped with near-IR sensor that detect

the spherical markers attached to the MoCap suit. Later on the markers will be digitalized to move the character skeleton in the capture software as illustrated in Figure 3b, which in turn will animate the avatar as shown in Figure 3c. Moreover, two Canon EOS T6i Rebel (Canon, 2026) are also employed for RGB capture, alongside the FLIR 2D (Teledyne FLIR, 2026), and the Vicon Vue cameras.

5.2. In-Car Data Acquisition

The in-car component of the ICSL corpus was designed to capture the linguistic and environmental challenges of a transport system setting. We employed a multi-sensor approach to provide both standard video and high-fidelity 3D spatial data.

5.2.1. Hardware and Sensor Setup

We utilized multi-modal sensors as seen in Figure 4 and the setup as seen in Figure 5b was deployed across three distinct test vehicles: a Jeep Compass (illustrated in Figure 5a), a Nissan March, and a Renault Megane, providing variability in cabin dimensions, window size, lightning, color, texture, seat shape, and interior geometry.




Figure 4: The multi-modal sensor suite including (a) the FLIR 2D camera, (b) Orbbec ToF sensor, and (c) the Lenovo Tablet.

- **2D Imaging:** A FLIR Blackfly S (Teledyne FLIR, 2026) was utilized to capture the primary 2D visual stream at a resolution of 1440×1080 , operating at 60 fps as seen in Figure 4a. To accommodate the confined vehicle interior, we utilized fisheye lenses to maximize the field of view as seen in Figure 2a.
- **3D Time-of-Flight (ToF):** An Orbbec Femto Bolt (Orbbec, 2026) was utilized to capture spatial information as seen in Figure 4b. The sensor was configured to capture synchronized RGB, Depth, Infrared (IR), and Point Cloud streams at a resolution of 1024×1024 pixels, operating at 30 fps, allowing for precise tracking of hand movements in 3D space as seen in Figures 2b and 6a-d.
- **Recording Tablet:** A Lenovo Tab P12 (Lenovo, 2026) was utilized as an additional perspective, as seen in Figure 4c.



(a)



(b)

Figure 5: (a) test vehicle, and (b) full technical installation inside the Jeep Compass cabin, illustrating sensor placement and the passenger signing space.




Figure 6: Multimodal perspectives of Libras communication within a vehicle cabin, illustrating the two sensors: (a) ToF depth image shown in color, where blue indicates closer objects and green indicates farther objects. Dark blue areas mean no depth was measured, (b) ToF infrared (IR) image shown in grayscale, where white represents strong IR reflection and black represents weak or no reflection, (c) ToF RGB point cloud, where each 3D point contains spatial coordinates (X, Y, Z) and its corresponding color (R, G, B), and (d) ToF Depth point cloud, where each 3D point contains spatial coordinates (X, Y, Z) derived only from depth measurements, without color information.

Positioned behind the front-seat headrest at a resolution of up to 3840×2160 pixels, it recorded the signer from an elevated, centered viewpoint, providing a third data stream to supplement the mounted sensors as seen in Figure 2c.

- **Prompting Interface (Mobile Phones):** In addition to the main sensors, mobile phones were positioned within the signer’s line of sight specifically to display the selected use cases. These served as a remote prompting system to guide the signer through the recording sequence.

5.3. Acquisition Protocol and Workflow

The recording session followed a strictly controlled protocol managed via a custom web-based control panel, as seen in Figure 7. To ensure the signer remained focused and in the correct posture, we utilized a remote signaling system:

- **Instruction Delivery:** Use cases were published on the mobile phone screens from the central Control Panel.
- **Start/Stop Signals:** The operator sent a “Start” signal (green) to the phone to indicate which sign to perform. Once the gesture was completed, a “Stop” signal (red) was sent, and the system automatically switched to the “Next Case” for the signer.




Figure 7: Web-based remote control interface for Start and Stop signaling.

6. Corpus Analysis and Limitations

Our dataset represents a first step toward a comprehensive in-vehicle Libras resource. To ensure the scientific validity of our comparative analysis, we chose to establish a solid baseline under stable, controlled conditions before introducing more dynamic environmental variables. This approach allows us to demonstrate the causal relationship between the physical layout of the car and signing

production without the interference of visual noise. By focusing on these idealized conditions, we provide a “ground truth” reference that enables the evaluation of technical benchmarks in a confined space. This is critical because sign language representations must reflect 3D awareness to handle the orientations and spatial trajectories inherent in real-world cabins.

The current iteration of the dataset is built upon a theoretical vocabulary of 1,344 Portuguese context-specific phrases for ride-sharing applications. To date, a subset of 127 phrases has been successfully recorded in video, with plans to complete the remaining recordings in the coming months. The data collection and annotation methodology relies on a cohort of three participants (two deaf, one hearing) who perform both the signing and the on-going data annotation.

A significant current limitation is the lack of dynamic lighting conditions, such as sun glare, tunnel transitions, or nighttime driving noise. While these factors are vital for “in-the-wild” robustness, in this initial phase, we theorize that models pre-trained on normal illumination data serve as a superior foundation for subsequent fine-tuning in low-light scenarios. As an early-stage resource within Project UNITY, the dataset currently features a limited number of signers, two deaf signer and one hearing. We acknowledge this as a potential source of signer bias that could limit the generalization of initial AI models. While we capture stationary occlusions (seatbelts, headrests), the dataset does not yet account for dynamic occlusions caused by vehicle movement or secondary passenger interactions.

By acknowledging these constraints, we frame this work not as a final solution but as the essential foundation required to guide our future, more complex data-collection efforts in the automotive sign language domain.

7. Conclusion

This paper introduces the In-Car Sign Language (ICSL) dataset, a novel multimodal resource designed to investigate the technical challenges of sign language recognition across shared mobility services. By focusing specifically on the constrained signing environment of vehicle interiors, we have established the first specialized dataset that systematically documents how Brazilian Sign Language (Libras) is produced within the physical and visual limitations of car cabins. The corpus comprises over 1.5 million synchronized frames across multiple modalities, providing researchers with a comprehensive foundation for investigating sign language recognition in real mobile settings.

Our contribution is split into two parts. First, a comparative benchmark between laboratory and in-car signing that addresses potential research direc-

tions in Section 3 focused on physical, multimodal, and linguistic adaptations. Second, we provide 127 communication scenarios recorded across three vehicle models, reflecting real-world accessibility needs within diverse cabin geometries.

The limitations acknowledged in Section 6 including controlled lighting conditions, and signer diversity, this work establishes a necessary foundation for robust “in-the-wild” SLR systems. As a component of Project UNITY, the ICSL corpus provides an empirical baseline for assistive technologies aiming to reduce communication barriers between hearing drivers and DHH passengers. Available upon request, this resource supports the development of inclusive transportation systems where language barriers no longer hinder DHH access and dignity.

8. Future Work

Moving forward, our next step is to introduce dynamic environmental parameters. We plan to record subsequent datasets under varied lighting conditions. Additionally, future iterations will move from a stationary vehicle to active driving environments to capture dynamic occlusions and noise caused by vehicle vibration, which are known bottlenecks for real-time landmark tracking. Although our dataset focuses on sentence-based communication scenarios, we aim to expand the ICSL corpus to include continuous Libras conversations between passengers, more complex phrases, and a broader range of subjects.

9. Acknowledgement

This project is partially financed by the São Paulo Research Foundation (FAPESP), grants #2024/23068-4 and #2024/00914-7, the Brazilian Federal Agency for Support and Evaluation of Graduate Education (CAPES), grant #88887.091672/2014-01, National Council for Scientific and Technological Development (CNPq), grant #458691/2013-5, and FINEP, grant #2778/20. The authors would also like to thank the Verkehrsverbund Großraum Ingolstadt (VGI) for their support through the VGI newMIND project.

10. Ethical Considerations

The Libras signers in this project are not just participants, they are paid team members and co-authors of this study. Deaf and hard-of-hearing researchers were involved in every stage of the project, from designing the data collection process to writing the paper. This helps us make sure that the linguistic details of Libras are treated with care and that the technology we develop truly reflects the needs of the community. All team members gave their informed consent for the use of their images and biometric data in the corpus. Since the data was created by the research team specifically for this

resource, the project follows the institutional ethical guidelines for collaborative research. To request access to the corpus or for further technical inquiries regarding the acquisition software, annotation tools, or the Project UNITY framework, please contact José Mario De Martino at martino@unicamp.br.

11. Bibliographical References

- Carlos Eduardo GR Alves, Francisco De A Boldt, and Thiago M Paixão. 2024. Enhancing Brazilian Sign Language recognition through skeleton image representation. In *37th SIBGRAPI Conference on Graphics, Patterns and Images*, pages 1–6. IEEE.
- Sarah Alyami, Hamzah Luqman, and Mohammad Hammoudeh. 2024. *Reviewing 25 years of continuous sign language recognition research: Advances, challenges, and prospects*. *Information Processing & Management*, 61(5):103774.
- Domenico Amalfitano, Vincenzo D’Angelo, Antonio Rinaldi, Cristiano Russo, and Cristian Tomasino. 2023. Enhancing gesture recognition for sign language interpretation in challenging environment conditions: A deep learning approach. In *15th International Joint Conference on Knowledge Discovery, Knowledge Engineering and Knowledge Management (IC3K)*, pages 395–402.
- Jari Ivar Andersen, Gomer Otterspeer, Robert Belleman, and Floris Roelofsen. 2025. Designing a marker based motion capture setup for sign language research. In *Adjunct Proceedings of the 25th ACM International Conference on Intelligent Virtual Agents*, pages 1–9.
- Necati Cihan Camgoz, Oscar Koller, Simon Hadfield, and Richard Bowden. 2020. Sign language Transformers: Joint end-to-end sign language recognition and translation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.
- Canon. 2026. EOS Rebel T6i product manual. <https://www.cla.canon.com/en/p/eos-rebel-t6i>. Digital camera technical documentation. Accessed: 2026-02-13.
- Cleison Correia de Amorim, David Macêdo, and Cleber Zanchettin. 2019. Spatial-temporal graph convolutional networks for sign language recognition. In *International Conference on Artificial Neural Networks*, pages 646–657. Springer.
- José Mario De Martino, Paula D Paro Costa, A Benetti, Luciana Aguerá Rosa, Kate Mamhy Oliveira Kumada, and IR Silva. 2016. Building a Brazilian Portuguese–Brazilian Sign

- Language parallel corpus using motion capture data. In *Proceedings of the 12th International Conference on the Computational Processing of the Portuguese Language, Tomar*, pages 56–63.
- José Mario De Martino, Ivani Rodrigues Silva, Janice Gonçalves Temoteo Marques, Antonielle Cantarelli Martins, Enzo Telles Poeta, Dener Stassun Christinele, and João Pedro Araújo Ferreira Campos. 2025. Neural machine translation from text to sign language. *Universal Access in the Information Society*, 24(1):37–50.
- Daniele LV dos Santos, Thiago B Pereira, Carlos Eduardo GR Alves, Richard JMG Tello, Francisco de A Boldt, and Thiago M Paixão. 2025. Proper body landmark subset enables more accurate and 5X faster recognition of isolated signs in LIBRAS. *arXiv preprint arXiv:2510.24887*.
- Annika Herrmann. 2014. *Modal and Focus Particles in Sign Languages: A Cross-Linguistic Study*, volume 2. De Gruyter Mouton, Berlin, Boston.
- Pavel Jedlička, Zdeněk Krňoul, Jakub Kanis, and Miloš Železný. 2020. Sign language motion capture dataset for data-driven synthesis. In *9th Workshop on the Representation and Processing of Sign Languages*, pages 101–106.
- Michael Kipp, Alexis Heloir, and Quan Nguyen. 2011. Sign language avatars: Animation and comprehensibility. In *International Workshop on Intelligent Virtual Agents*, pages 113–126. Springer.
- Marie Lee, Ziming Li, Wendy Dannels, Tae Oh, and Roshan L Peiris. 2025. Exploring one handed signing during driving for interacting with in-vehicle systems for Deaf and hard of hearing drivers. In *Proceedings of the Extended Abstracts of the CHI Conference on Human Factors in Computing Systems*, New York, NY, USA. Association for Computing Machinery.
- Lenovo. 2026. Tab P12: 12.7-inch Storm Grey tablet (8GB/128GB) product manual. https://www.mediamarkt.de/de/product/_lenovo-tab-p12pencil-8gb-128gb-127-zoll-tablet-128-gb-127-zoll-storm-grey-133566330.html. Hardware product specifications. Accessed: 2026-02-12.
- Chenghong Lu, Misaki Kozakai, and Lei Jing. 2023. Sign language recognition with multimodal sensors and deep learning methods. *Electronics*, 12(23):4827.
- Xiaohan Ma, Rize Jin, and Tae-Sun Chung. 2024. Multi-channel spatio-temporal transformer for sign language production. In *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pages 11699–11712.
- Orbbec. 2026. Orbbec: Femto Bolt Time-of-Flight depth camera specifications. <https://www.orbbec.com/products/tof-camera/femto-bolt/>. Product technical datasheet. Accessed: 2026-04-07.
- Presidência da República. 2002. Lei número 10.436. Diário Oficial da União, Imprensa Nacional, n. 79, Seção 1.
- Reza Rastgoo. 2021. Sign language recognition: A deep survey. *Expert Systems with Applications*, 164:113794.
- Dimitar Shterionov, Lorraine Leeson, and Andy Way. 2024. *The pipeline of sign language machine translation*, pages 1–25. Springer.
- Hanan A. Taher and Subhi R. M. Zeebaree. 2025. A critical study of recent deep learning-based continuous sign language recognition. *The Review of Socionetwork Strategies*, 19(1):131–161.
- Teledyne FLIR. 2026. Firefly S technical specifications. <https://www.teledynevisionsolutions.com/products/firefly-s/?segment=iis&vertical=machine+vision>. Machine vision camera documentation. Accessed: 2025-02-12.
- Vicon. 2026. Vicon Valkyrie advanced motion capture (mocap) camera specifications. <https://www.vicon.com/hardware/cameras/valkyrie/>. Hardware technical datasheet. Accessed: 2026-02-13.
- Ackley Dias Will, José Mario De Martino, and Juliano Renato S Bezerra. 2018. An optimized marker layout for 3D facial motion capture. In *Proceedings of the Smart Tools and Apps for Graphics (STAG)*, pages 107–113.
- Wanyu Zhang. 2022. Sign language recognition based on depth image processing. *Highlights in Science, Engineering and Technology*, 23:25–33.

12. Language Resource References

- Luis R. Cerna, E. E. Cardenas, D. G. Miranda, David Menotti, and Guillermo Camara-Chavez. 2021. *A Multimodal Libras-UFOP Brazilian Sign Language Dataset of Minimal Pairs using a Microsoft Kinect Sensor*. Expert Systems with Applications.

Ronice Müller de Quadros and Alexandre Melo de Sousa. 2021. *Corpus da Língua Brasileira de Sinais: Inventário de Libras do Acre*. Revista de Estudos da Linguagem.

M. A. Lima, D. Cruz, D. R. Silva, D. D. Albuquerque, D. F. Lacerda, R. Costa, G. L. de Souza Filho, and T. M. de Araújo. 2025. *VLibrasBD: A Brazilian Portuguese-Brazilian Sign Language (Libras) Bilingual Text Dataset*. Data in Brief.

Vicente Coelho Lobo-Neto and Helio Pedrini. 2024. *LSWH100: A Handshape Dataset for Brazilian Sign Language (Libras) using SignWriting*. Data in Brief.

Oline Ranum, Gomer Otterspeer, Jari I. Andersen, Robert G. Belleman, and Floris Roelofsen. 2024. *3D-LEX v1.0: 3D Lexicons for American Sign Language and Sign Language of the Netherlands*. arXiv preprint arXiv:2409.01901.

Tamires Martins Rezende, Sílvia Grasiella Moreira Almeida, and Frederico Gadelha Guimarães. 2021. *Development and Validation of a Brazilian Sign Language Database for Human Gesture Recognition*. Neural Computing and Applications.

Thad Starner, Sean Forbes, Matthew So, David Martin, Rohit Sridhar, Gururaj Deshpande, Sam Sepah, Sahir Shahryar, Khushi Bhardwaj, Tyler Kwok, Daksh Sehgal, Saad Hassan, Bill Neubauer, Sofia Vempala, Alec Tan, Jocelyn Heath, Unnathi Kumar, Priyanka Mosur, Tavenner Hall, Rajandeep Singh, Christopher Cui, Glenn Cameron, Sohier Dane, and Garrett Tanzer. 2023. *PopSign ASL v1.0: An Isolated American Sign Language Dataset Collected via Smartphones*. Curran Associates, Inc.

Anexo 3
Resumo Aceito para Publicação

**Multimodality and Semantics in a Sign Language
Visuospatial Grounded Annotation Framework
Symposium Series on Multimodal Communication**

Multimodality and Semantics in a Sign Language Visuospatial Grounded Annotation Framework

Authors in Order¹ (leave open for review)

Institutions¹ (leave open for review)

Corresponding author Email (leave open for review)

This abstract summarizes an annotation proposal for Brazilian Portuguese–Brazilian Sign Language (PB–Libras) automatic translation. The proposal introduces a multi-tier, semantically oriented framework designed to overcome the limitations of traditional gloss-based corpora, which tend to reduce the simultaneity and spatial organisation of sign languages to linear representations modelled on spoken-language writing systems [1]. Instead of treating Libras as a sequence of lexical tokens, the framework conceptualizes it as a multi-articulatory and visuospatial system in which meaning emerges from the coordinated activity of hands, face, mouth, eyegaze, and body. The annotation scheme is structured into temporally aligned tiers representing distinct yet interacting components of signing: lexical signs, fingerspelling, facial expressions, depictions and classifiers, buoys, pointing signs, eye gaze and gestures. This architecture preserves simultaneity and overlap, which are intrinsic to Libras grammar, and allows the explicit encoding of spatial reference, anchoring, and non-manual marking. Semantic segmentation is a core principle of the model: annotated units correspond to meaningful actions, delimited primarily by stroke and hold phases of movement, in line with descriptive analyses of Libras segmentation [2]. Glosses are defined as capitalized Portuguese-based labels that encode semantic values rather than phonetic detail, while articulatory realization is linked to video and motion-capture data, forming a multimodal lexical database. Crucially, this framework is not intended as a system for comprehensive linguistic description. Its primary goal is to provide structured information for automatic processing tasks, such as sign language recognition, translation, and production. By decomposing signing into semantically interpretable and temporally aligned components, the proposal aims to offer richer input representations for machine learning models while respecting the visuospatial nature of Libras. This perspective aligns with recent arguments that effective translation cannot rely solely on linear gloss strings, since such representations fail to capture spatial syntax and multimodal coordination [3;4]. A central theoretical issue addressed in the proposal concerns the interface between gesture and sign. Signed discourse integrates categorical linguistic structure with gradient, depictive resources that resemble gesture while remaining grammatically constrained. In Libras, depictive constructions and classifier predicates iconically encode shape, motion, and spatial relations, challenging rigid distinctions between lexical signs and gestures. These forms occupy an interface zone where visual depiction and conventionalised linguistic structure converge. The annotation framework operationalises this interface by assigning such productions to a dedicated Depiction tier, glossed according to semantic construal rather than articulatory detail. Gestures, in turn, are annotated separately as non-lexical manual actions with discourse or pragmatic functions. This distinction is theoretically motivated but methodologically demanding. Translation between Libras and Brazilian Portuguese involves not only cross-linguistic but also cross-modal mapping, since spatial and simultaneous structures must be rendered as linear verbal sequences. The framework addresses this challenge by explicitly encoding spatial reference and alignment relations, enabling translation models to reconstruct aspects of spatial syntax rather than treating them as residual information. In sum, the annotation proposal offers a multimodal and semantically grounded framework for automatic translation. While it does not aim to resolve the theoretical tensions between discreteness and gradient meaning, or between gesture and sign, it renders them operational for intermodal translation and contributes to research at the intersection of modality, multimodality, and computational sign language studies.

References

- [1] L. McCleary, E. Viotti, and T. Leite. Descrição das línguas sinalizadas: a questão da transcrição dos dados. *ALFA: Revista de Linguística*, 2010. 54(1).
- [2] T. Leite. A segmentação da língua de sinais brasileira (Libras): um estudo linguístico descritivo a partir da conversação espontânea entre surdos. Tese de doutorado em letras, Universidade de São Paulo (USP), Faculdade de Filosofia, Letras e Ciências Humanas, São Paulo. 2008.
- [3] M. Müller et al. Considerations for meaningful sign language machine translation based on glosses. In *61st Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pages 682–693, Toronto, Canada. Association for Computational Linguistics. 2023.
- [4] D. Bragg et al. Sign language recognition, generation, and translation: An interdisciplinary perspective. In *21st international ACM SIGACCESS Conference on Computers and Accessibility*, pages 667 16–31. 2019.

Anexo 4
Resumo Aceito para Publicação

**Linguistic Processing of Deaf People in the
Perception of Automatic Translators from
Brazilian Portuguese to Libras: A Study with Eye
Tracking**

Symposium Series on Multimodal Communication

Linguistic Processing of Deaf People in the Perception of Automatic Translators from Brazilian Portuguese to Libras: A Study with Eye Tracking

Authors in Order¹ (leave open for review)

Institutions¹ (leave open for review)

Corresponding author Email (leave open for review)

Automatic translation consists of converting a source language into a target language through computer programming [1]. This process can involve lexical items or complete sentences and texts and can be performed on different digital platforms. The complexity of the automatic translation stems from the need for in-depth linguistic knowledge of the languages involved, as their structures can diverge significantly, making it difficult to obtain adequate translations [2]. Despite this, the process is a fast, efficient, and continually improving resource, particularly relevant for access to information and accessibility, especially in translation between spoken languages and sign languages. These languages are natural languages, with their own phonological, morphological, and syntactic organisation [3], but they present specific challenges, such as the absence of conventional writing and the use of visual resources, such as classifiers and spatialization [4]. Thus, it becomes fundamental to investigate the comprehensibility of these automatic translations for the deaf community. Considering that automatic translation from Brazilian Portuguese to Libras (Brazilian Sign Language) is an important accessibility resource for the deaf community, this study aims to analyse the extent to what extent this resource is truly comprehensible to deaf people, and, with this, we aim to contribute to the development of improvements and enhancements for automatic translation technologies in Libras. The objective of this research is to analyse the linguistic processing of deaf individuals in relation to the automatic translation from Brazilian Portuguese to Libras (Brazilian Sign Language) that occurs through applications with avatars. An experiment was conducted with 27 deaf participants, who watched videos of 30 signed sentences using eye tracking. The sentences were presented in three conditions: two using automatic translation to sign language with avatars (Hand Talk - HT and Vlibras - VL) and one with human translation by a deaf user of Brazilian Sign Language. After the video, two images were presented simultaneously: one representing the target sentence and the other semantically similar. Participants were asked to select the image that corresponded to the observed sentence. The initial results of this research show that the participants' performance in identifying the correct figures corresponding to the sentences was better in situations where these sentences were signed by a human (91.9% correct answers). For the avatars, a higher number of correct answers was observed with the use of the HT (74.8%), followed by the VL (67.4%). Statistically significant differences were found between the responses obtained with the avatars compared to the human translator ($p < 0.001$). No statistically significant difference was observed between the avatars (Figure 1). The analysis of the eye-tracking data is under development. From the tests using the eye tracker, we are observing the number and duration of fixations, as well as visits to the image and pupil dilation. In an initial analysis, it is possible to observe that deaf participants tend to fix their gaze on the face in situations with a human translator and fix their gaze more on the hands in situations with greater processing difficulty. These results require further confirmation, which will be carried out with a more in-depth analysis of the data from this research. Furthermore, the data from the eye tracker will be cross-referenced with the participants' responses from the image stage so that we can monitor and understand the cognitive process during the reception of the Libras translation of the avatars in the analyzed applications, in order to understand and propose points for improvement.




Figure 1: *Mean scores of deaf participants in sign language sentence comprehension using human translator (H) and automatic translators with avatars (HT and VL)*

References

- [1] S Melo. Tradução automática e competência tradutória: repensando interseções. In: Rónai: Revista de Estudos Clássicos e Tradutórios, 2013. V. 1, N. 1, p.60 – 72.
- [2] H. Caseli. Tradução Automática: estratégias e limitações In: Domínios de Lingu@gem, vol. 11, n. 5, 2017. p. 1782-1796.
- [3] R. Quadros and L. Karnopp. Língua de Sinais Brasileira: estudos linguísticos. ArtMed. Porto Alegre. 2004.
- [4] F. Paiva. Tradução Automática de Português Brasileiro para a Libras e Análise de Processos de Intensificação. 142f. Tese (Doutorado em Engenharia Elétrica) – Faculdade de Engenharia Elétrica e da Computação, Universidade Estadual de Campinas, São Paulo. 2019.

Anexo 5
Capítulo de Livro Submetido e em
Avaliação

Formalismo, Anotação e Tradução Automática em
Línguas de Sinais

Sinal Vivo vs Sinal Programado: ética, corpo e
autoria na tradução de línguas de sinais

FORMALISMO, ANOTAÇÃO E TRADUÇÃO AUTOMÁTICA EM LÍNGUAS DE SINAIS

José Mario De Martino
(Universidade Estadual de Campinas - UNICAMP)
Vinícius Nascimento
(Universidade Federal de São Paulo - UNIFESP)
Felipe Venâncio Barbosa
(Universidade de São Paulo - USP)
Thyago Santos
(Universidade de São Paulo -USP)

INTRODUÇÃO

A Tradução Automática (TA) tem se consolidado como uma técnica importante na mediação entre línguas, figurando como um avanço potente para processos de comunicação, acesso à informação e aprendizagem (Nouatin, 2018, 2021). Mais recentemente, o aumento do número de ferramentas de TA com uma profusão de criação de aplicativos e softwares tem exibido essa consolidação, ainda mais chancelada pelo advento de algoritmos baseados em Inteligência Artificial, que revelam uma nova fase do uso desta técnica (Bolacio Filho, 2025).

Tais recursos são amplamente empregados em línguas orais, especialmente nas que possuem sistemas de escrita consolidados. Para línguas que não seguem um padrão de linearidade exibido por grande parte das línguas que recebem maior foco dos trabalhos em TA, como línguas tonais e línguas de sinais, o desafio pode ser ainda maior (Wang et al., 2007; Nguyen et al., 2026).

Este capítulo tem como objetivo discutir sobre os sistemas de formalismo e notação utilizados para a criação de TA em línguas de sinais e é resultado de trabalho colaborativo envolvendo Surdos, linguistas, tradutores, intérpretes, pedagogos, engenheiros, profissionais de modelagem e animação 3D, além de pós-doutorandos, doutorandos, mestrands e alunos de iniciação científica. Esse grupo de profissionais atua no Centro de Ciência para o Desenvolvimento – Tecnologia Assistiva e Acessibilidade em Libras (CCD-TAAL) (<https://site.fee.unicamp.br/ccdtaal/ccdtaal-ptbr>), projeto financiado pela Fundação de Amparo à Pesquisa do Estado de São Paulo (FAPESP - Processo 2024/00914-7). O CCD-TAAL é um centro multidisciplinar que reúne pesquisadores da Universidade Estadual de Campinas (UNICAMP), da Universidade de São Paulo (USP) e do Instituto de Pesquisas Tecnológicas (IPT), em parceria com a Secretaria dos Direitos da Pessoa com Deficiência do Estado de São Paulo (SEDPCD). Além dessas instituições brasileiras, o CCD-TAAL possui acordo de colaboração na temática com um grupo de pesquisadores da Technische Hochschule Ingolstadt, Alemanha.

Propomos adiante uma reflexão teórica sobre o tema e sua ligação com a tradução, tecnologia e línguas de modalidade gesto-visual e apresentamos uma proposta de notação e formalismo utilizado no projeto CCD-TAAL. Discutimos, primeiro, sobre tradução de/para línguas de sinais, na sequência refletimos sobre os registros gráficos de línguas dessa modalidade para depois debatermos sobre a

articulação entre a Linguística, a Tradução e os Estudos de Tecnologia para pensar sobre os modos de exploração da TA. Finalizamos com a apresentação do projeto e com reflexões sobre os desafios impostos e as perspectivas futuras.

1. TRADUÇÃO DE/PARA LÍNGUAS DE SINAIS

Antes de iniciarmos uma discussão sobre TA e línguas de sinais precisamos, primeiramente, refletir sobre a tradução de/para línguas de sinais de forma geral. Para isso, é necessário, primeiro, pensar sobre o conceito de tradução e de suas diferentes operacionalizações. Nos Estudos da Tradução, campo disciplinar que surgiu em meados da segunda metade do século XX, o conceito possui diversas definições a depender do paradigma que o mobiliza (Pym, 2017), mas, de forma geral, pode ser entendido como “um conjunto de processos que conduzem à passagem (de textos, da língua, da cultura) de um lado para outro” (Pym, 2017, p. 18) ou pode, conforme reflete Sobral (2008, p. 32/33), ser definido como um ato de transferência:

traduzir é sempre “transferir”, ou seja, transportar algo de um lugar para outro, mesmo que sejam lugares abstratos. Esse transporte, “trans”, envolve contudo um “ferir”, que entendo como uma alteração/adaptação inevitável do sentido do que é traduzido. Logo, traduzir é um ato que sempre deixa uma marca do processo de alteração daquilo que é transportado - de maneira legítima, ainda que haja casos de transposição ilegítima.

Segundo Souza (1998, p. 51), o “termo tradução é polissêmico e pode significar (a) o produto (ou seja, o texto traduzido); (b) o processo do ato tradutório; (c) o ofício (a atividade de traduzir); ou (d) a disciplina (o estudo interdisciplinar e/ou autônomo)”. Todavia, apesar da diversidade das definições do termo, quase todas convergem na compreensão de que a tradução permite que uma mensagem cruze a chamada “barreira linguística” entre duas comunidades, sendo comum o uso da metáfora “ponte” para designar os profissionais que a realizam (Pagura, 2015, p. 184).

Entretanto, a tradução, do ponto de vista histórico, foi sendo redefinida a partir das mudanças sociais, tecnológicas e científicas e, de forma mais recente, foi sendo compreendida como uma atividade que pode se operacionalizar de duas formas principais: a tradução, em si, e a interpretação, que seria uma forma de tradução oral. Segundo Pagura (2015, p. 183), “a conversão de um texto escrito em uma língua, denominada de partida, para outra, designada língua de chegada” é considerada *tradução* e a “conversão de um discurso oral, de uma língua de partida para uma língua de chegada” é designada de *interpretação*. Essas atividades demandam competências e habilidades distintas, mas podem ser realizadas pelo mesmo sujeito, desde que as desenvolva e as aperfeiçoe.

Apesar de possuírem algumas semelhanças como, por exemplo, a necessidade do tradutor e do intérprete possuírem amplo conhecimento linguístico e cultural das línguas envolvidas no processo, Pagura (2015) defende que também existem diferenças. Segundo a perspectiva clássica defendida pelo autor, enquanto o tradutor atuará com a modalidade escrita, o intérprete trabalhará mais objetivamente

com a modalidade oral, o que gera implicações na recepção e na produção da mensagem. Para ser intérprete, por exemplo, as habilidades expressivas orais das línguas envolvidas no processo são requeridas enquanto que para o tradutor não necessariamente são demandadas, muito embora os tradutores, quase todos, sejam exímios falantes das línguas que trabalham. Outro aspecto é o ritmo e a temporalidade da realização das atividades. Tradutores possuem tempo mais expandido para produzir o texto, revisá-lo e realizar pesquisas terminológicas em diferentes bases de dados como dicionários, *websites* e outras fontes enquanto intérpretes precisam se preparar bem para a realização da tarefa, já que durante a produção da interpretação não há possibilidade, tal como existe para o tradutor, de realizar amplas pesquisas. O enunciado produzido pelo intérprete está geralmente ligado ao tempo de produção de fala do enunciador da língua de partida e, por isso, não há possibilidade de revisão.

Apesar de estarem consolidadas no campo dos Estudos da Tradução, as diferenças e semelhanças entre tradução e interpretação e a distinção entre oral e escrito propostas por Pagura (2015) partem de uma visão um tanto dicotômica que desconsidera outras diferentes possibilidades de materialidade linguístico-discursiva presentes na atualidade. Segundo Rodrigues (2023, p. 4),

Essa perspectiva não está incorreta e, de fato, serve como uma possibilidade inicial de aproximação, compreensão, definição e distinção de processos tradutórios e interpretativos. Por outro lado, ela se torna ineficiente, insuficiente e inadequada quando são levadas em consideração as demais variáveis que interferem em uma diversidade de processos de reformulação interlinguística. Assim, ao analisarmos tais processos, no intuito de categorizá-los e de distingui-los, veremos que a modalidade dos textos e a sua materialidade são apenas alguns dos fatores que precisam ser considerados.

No bojo dessas exclusões estão as línguas de sinais que são de modalidade¹ gesto-visual e apresentam características singulares tanto na produção quanto na recepção e que são, com cada vez mais frequência, mobilizadas nas duas operacionalizações tradutórias. Diferente das línguas vocais-auditivas, as línguas de sinais ancoram-se enunciativamente no corpo do enunciador, o que impõe a necessidade de acessar o falante para acessar o texto produzido. O corpo, nesse caso, é todo articulador da língua sendo impossível, com isso, separar a identidade do falante do texto que ele produz.

A interpretação de/para línguas de sinais é mais antiga e conhecida socialmente no Brasil devido à atuação de intérpretes em contextos comunitários². A tradução de/para línguas de sinais, entretanto, é atividade recente no cenário social e acadêmico e está intimamente ligada ao avanço dos

¹ Modalidade de língua será definida aqui como a forma biofisiológica pela qual uma língua é foneticamente produzida e sensorialmente recebida (Rodrigues, 2023). Considerando essa definição, assumimos que existe a modalidade vocal-auditiva, produzida pelo aparelho fonador e recebida pela audição, e a gesto-visual, produzida pelas mãos, braços, tronco e cabeça e recebida pela visão.

² Denominamos interpretação comunitária aquela que permite que uma comunidade linguisticamente minoritária acesse os bens e serviços da sociedade em que vive, como serviços de saúde, de educação, de justiça, por meio da interpretação (Pöchhacker, 2004; Rodrigues, 2010). Esse tipo de interpretação é comum com comunidades surdas, indígenas, de imigrantes, de refugiados etc.

direitos linguísticos das pessoas surdas e da tecnologia. Com o advento do vídeo, as produções em línguas de sinais passam a contar com uma possibilidade de registro mais alinhada com as características gesto-visuais (Leite, et. al, 2022) permitindo, com isso, a criação de bancos de dados que acompanhem essa dimensão.

No contexto brasileiro, a criação do primeiro curso de Letras Libras (LL) em 2006 na Universidade Federal de Santa Catarina (UFSC), com a proposta de “garantir o acesso e a permanência das pessoas surdas na Universidade” inovou quando propôs que “todos os materiais do curso [...]” fossem “traduzidos para a Libras e disponibilizados em vídeo no Ambiente Virtual de Ensino (AVEA)” (Oliveira e Silva, 2015, p. 93) com uma equipe de tradutores prioritariamente surdos. Essa experiência inaugurou formalmente um novo cenário de tradução envolvendo línguas de sinais no contexto nacional, pois colocou a Libras como língua de instrução em um curso de graduação em uma universidade pública por meio da tradução.

Segundo Nascimento (2021), antes do LL da UFSC havia algumas experiências de tradução de literatura infanto-juvenil para a Libras publicados pela Editora Arara Azul, por exemplo, que teve importante papel no processo de consolidação da Literatura Surda no Brasil, e por algumas instituições religiosas. Todavia, o LL colocou a tradução como atividade central no processo formativo de pessoas surdas garantindo, com isso, acesso, permanência e conclusão de um curso de graduação para pessoas surdas.

Atualmente, 20 anos depois da abertura do primeiro curso LL, a tradução para a Libras ganhou outra dimensão e outros espaços. Um dos destaques foi a realização de vídeo-provas em Libras em vestibulares para ingresso em universidades (Guedes, 2019; Silva, 2019) e o Exame Nacional do Ensino Médio (ENEM) que desde 2017 tem sido oferecido aos candidatos surdos também na versão traduzida para a Libras (Trevisan e Martins, 2020). A tradução para a Libras tem sido adotada também em diferentes concursos públicos, como os da esfera jurídica (Assis, 2024), em materiais didáticos (Saito, Scolari, Felício, 2011), em vídeos-guia de exposições artísticas de museus e instituições culturais (Silva, 2021) e no campo da educação básica (Santos, Diniz, Lacerda, 2016), uma vez que o profissional que atua com surdos na escola interpreta as aulas, mas atua, em alguns cenários, na produção de materiais didáticos com tradução para a Libras a fim de oferecer aos estudantes surdos materiais de apoio para as aulas e para estudo em casa.

Com o avanço da tecnologia, um novo cenário se impõe ao campo da tradução para as línguas de sinais em todo o mundo. O avanço da inteligência artificial (IA) e do uso de tradutores automáticos com reconhecimento de voz, de imagem e de gestos se apresenta como um novo contexto de possibilidades para a tradução de línguas de modalidade gesto-visual gerando, com isso, novas pesquisas e investimentos que poderão impactar o futuro da tradução de/para essas línguas. Entretanto, alguns desafios se impõem como, por exemplo, a forma de registrar graficamente línguas sinalizadas e de alimentar as máquinas que podem produzir a TA delas.

2. O REGISTRO GRÁFICO E AS LÍNGUAS DE SINAIS

Os registros gráficos de línguas naturais constituem uma ferramenta de grande impacto social e científico. Eles possibilitam a preservação, circulação e análise das línguas ao longo do tempo. Para estudiosos de sistemas de escrita como Gelb (1952), Daniels (1996) e Bright (1996), a escrita não apenas registra a língua, mas também se torna um instrumento fundamental para a investigação de seu funcionamento estrutural, para a reconstrução de momentos históricos distintos e para a constituição de patrimônios culturais. Nesse sentido, os sistemas de escrita fornecem evidências empíricas valiosas para áreas como a Linguística Histórica, a Linguística Descritiva, os estudos comparativos sobre as línguas naturais e os Estudos da Tradução.

Há, também, um amplo debate na literatura sobre o grau de fidelidade com que esses registros conseguem representar as línguas que procuram codificar. Desde as reflexões fundadoras de Saussure (1916) sobre a relação entre língua e escrita até análises contemporâneas de pesquisadores como Coulmas (2003) e Olson (1994), discute-se em que medida a escrita constitui uma representação adequada das estruturas e dos usos de uma língua. Tradicionalmente, essas discussões emergiram sobretudo a partir das línguas vocais-auditivas. Nesse contexto, aspectos como da prosódia como a entonação, ritmo e padrões de acentuação, são frequentemente apontados como dimensões de difícil representação nos sistemas gráficos convencionais, uma vez que grande parte das escritas alfabéticas privilegia a codificação de segmentos fonológicos em detrimento de propriedades suprasegmentais ou aquelas que se apresentam fora da linearidade esperada, inclusive pelas visões de língua mais tradicionais.

No caso das línguas de sinais, os desafios de representação gráfica tornam-se ainda mais complexos. Além das questões relacionadas à prosódia, essas línguas apresentam propriedades estruturais específicas, como a simultaneidade na apresentação de signos, a espacialização da gramática e o papel de componentes gestuais e imagéticos na construção do significado. Tais características colocam desafios particulares para qualquer tentativa de anotação ou escrita. Pesquisadores como Stokoe (1960), responsável por uma das primeiras propostas sistemáticas de notação para línguas de sinais, e Adam Kendon (2004), que investigou as relações entre gesto e linguagem, destacam que as possibilidades de múltiplas articulações de sentido dessas línguas exigem modelos de representação capazes de lidar com estruturas simultâneas e com a interação entre diferentes camadas expressivas. Assim, a anotação de línguas de sinais frequentemente precisa acomodar não apenas unidades linguísticas discretas, mas também recursos gestuais e visuo-espaciais que contribuem para a organização da gramática e da expressão comunicativa.

Dessa forma, as discussões sobre registros gráficos de línguas naturais evidenciam que os sistemas de escrita não constituem meras transcrições da fala ou da sinalização, mas sim construções analíticas e culturais que procuram representar, de maneira necessariamente seletiva, a complexidade das práticas linguísticas humanas.

Diversos pesquisadores têm desenvolvido sistemas de transcrição e anotação para línguas de sinais ao longo das últimas décadas. Desde as primeiras propostas de descrição estrutural, como a proposta de Bébien (1825) e a análise fonológica pioneira de Stokoe (1960), que demonstrou que as línguas de sinais possuem unidades estruturais comparáveis às línguas vocais-auditivas, com componentes manuais, como a configuração da mão, sua orientação e seus movimentos, e não manuais, como expressões faciais, direção do olhar e movimentos do tronco, surgiram diferentes tentativas de registrar graficamente ou anotar a produção sinalizada. Entre essas propostas encontram-se sistemas de registro baseados em características fonético-fonológicas, como o Sutton (1974) com o desenvolvimento do *SignWriting* e o HamNoSys (PRILLWITZ, 1989), que buscam descrever como os sinais são produzidos, por meio de arranjos espaciais de símbolos visuais (ícones), bem como sistemas mais recentes de anotação desenvolvidos em diferentes contextos de pesquisa, como o ELiS (Barros, 2015) e a Visografia (Benassi, 2018).

Além desses sistemas, outras propostas foram desenvolvidas com o objetivo específico de possibilitar a criação de corpora linguísticos ou apoiar a descrição e explicação das línguas de sinais em pesquisas linguísticas. Pesquisadores da área de Linguística das Línguas de Sinais, como Liddell (2003), Rathmann (2007) e Johnston (2010), destacam que diferentes sistemas de anotação emergem a partir de necessidades analíticas específicas e de distintos objetivos de pesquisa. Assim, grupos de pesquisa em diversos países têm proposto modelos variados de anotação que procuram dar conta das múltiplas camadas linguísticas presentes na sinalização, incluindo aspectos fonológicos, morfológicos, sintáticos e discursivos.

Os desafios associados a esses sistemas de anotação e transcrição tornam-se particularmente evidentes quando se consideram os objetivos das pesquisas em que são empregados. Alguns sistemas privilegiam a representação detalhada da forma articulatória dos sinais, enquanto outros buscam oferecer instrumentos mais adequados para a análise de estruturas discursivas ou para a organização de bases de dados linguísticos. Nesse contexto, sistemas como o conhecido modelo de transcrição desenvolvido no âmbito do *Berkeley Transcription System*, discutido por pesquisadores como Liddell (2003), permitem a descrição minuciosa de trechos com elevada complexidade morfosintática e com múltiplos articuladores simultâneos. Por outro lado, propostas de anotação multi-linear como a de Johnston (2010), desenvolvidas no contexto de construção de *corpora* de línguas de sinais, oferecem estratégias que procuram representar de maneira mais clara componentes imagéticos e representacionais da sinalização, frequentemente associados a construções classificadoras e estruturas altamente icônicas.

Dessa forma, a diversidade de sistemas de transcrição e anotação para línguas de sinais reflete tanto a complexidade estrutural e a multi-linearidade dessas línguas (Garcia e Sallandre, 2013) quanto a multiplicidade de objetivos analíticos presentes na pesquisa linguística contemporânea. Cada sistema, portanto, enfatiza determinadas dimensões da sinalização, revelando que a representação gráfica ou anotacional das línguas de sinais envolve necessariamente escolhas metodológicas e teóricas

específicas. Neste sentido, passamos a discutir as questões relacionadas sobre a TA e aspectos de aprendizagem de máquina com suas relações com a linguística das línguas de sinais.

3. PROCESSAMENTO COMPUTACIONAL, RECONHECIMENTO, TRADUÇÃO E PRODUÇÃO DE LÍNGUAS DE SINAIS

O processamento computacional de línguas de sinais constitui uma área interdisciplinar que integra linguística, processamento de linguagem natural, aprendizado de máquina, visão computacional e computação gráfica. Essa área abrange três tarefas computacionais: reconhecimento de língua de sinais (SLR - *Sign Language Recognition*), tradução de língua de sinais (SLT - *Sign Language Translation*) e produção de língua de sinais (SLP - *Sign Language Production*) (Bragg, et al, 2019).

A tarefa SLR tem como foco converter conteúdo em língua de sinais, geralmente registrado em vídeo, em uma representação linguística simbólica. SLT, por sua vez, é a tarefa de converter a sinalização presente em vídeo em texto expresso na norma culta de uma língua oral. Já a tarefa SLP objetiva gerar automaticamente representações visuais de uma língua de sinais, como animações ou vídeos, a partir de texto ou de fala de uma língua oral.

Diferentes estratégias têm sido exploradas para o desenvolvimento de soluções voltadas ao reconhecimento (SLR), à tradução (SLT) ou à produção (SLP) de língua de sinais. As propostas se diferem essencialmente pela organização do fluxo de processamento e pela utilização, ou não, de uma representação intermediária simbólica da língua de sinais. As propostas desenvolvidas até aqui, e que foram citadas anteriormente, são representações com forte base fonética e por recorrerem a representações icônicas de difícil processamento por computador, não são as mais adequadas para uso direto em abordagens computacionais. Para apoiar SLR, SLT e SLP, a anotação por glosa tem sido utilizada para representar a sinalização em formato textual e para construir *corpora* paralelos.

Glosa é uma representação simbólica escrita que identifica um sinal específico por meio de um rótulo textual, geralmente baseado em uma palavra de uma língua oral, sem necessariamente representar a estrutura gramatical da língua de sinais (Johston, 2020). Esforços iniciais para o estabelecimento de sistemas de anotação utilizando glosas limitaram-se a considerar apenas os sinais lexicais convencionais, estabelecendo uma sequência linear de glosas. Ao se apoiar em um modelo linear, esse tipo de anotação não consegue representar satisfatoriamente referências espaciais, simultaneidade, estruturas produtivas e construções discursivas das línguas de sinais. Propostas atuais de representação por glosa explicitamente rejeitam esse paradigma linear e adotam modelos multicamadas/multicanais, que reconhecem que a língua de sinais envolve múltiplos articuladores (mãos, face, tronco, olhar, boca) e que a sua anotação deve refletir essa estrutura multidimensional. Embora vários projetos de corpus de língua de sinais proponham diretrizes para a anotação por glosa, ainda não há consenso quanto a um padrão único (Kopf, et al., 2022).

Para a representação dos sinais lexicais convencionalizados, os paradigmas de anotação atuais adotam predominantemente o conceito de Glossa de Identificação (ID-Gloss). ID-Gloss é um identificador simbólico único associado a um lexema da língua de sinais, utilizado para garantir a consistência das anotações e permitir a vinculação dos dados de um corpus a um banco lexical, independentemente de variações fonéticas ou contextuais do sinal (Johnston, 2010).

Avaliar a qualidade de sistemas de processamento de língua de sinais é outro aspecto fundamental para o avanço da área. As estratégias e protocolos de avaliação são fortemente influenciados pelas características e objetivos da tarefa (SLR, SLT ou SLP) em análise, não existindo um protocolo único e padronizado. Não obstante, é possível identificar duas estratégias básicas de abordagem para a avaliação de sistema de processamento de língua de sinais: avaliação humana e avaliação automática. Se combinadas, essas estratégias tendem a resultar em avaliações mais robustas.

Em geral, a avaliação humana envolve a apreciação de dois aspectos principais: a adequação e a fluência do resultado da tradução (Koenh, 2020). A adequação está associada à aderência do significado da tradução à formulação original na língua fonte ou a uma tradução de referência. Já a fluência refere-se ao grau de proximidade entre a tradução e a produção de um falante nativo. Além desses critérios, outros aspectos têm sido empregados para avaliar a legibilidade, a compreensão, a usabilidade e a aceitabilidade das traduções (Castilho et al., 2018). Considerando que, em geral, não existe uma única tradução aceitável/adequada para uma determinada produção da língua fonte, devido à variabilidade inerente às línguas naturais, o julgamento humano acaba por apresentar subjetividade, podendo resultar em discrepâncias interavaliadores e mesmo intraavaliador.

Por sua vez, a avaliação automática objetiva medir a similaridade da tradução gerada em relação a uma tradução de referência produzida por um tradutor humano. Métricas como acurácia, precisão e revocação (Bishop, 2006) são utilizadas em SLR, principalmente no reconhecimento de datilologia e de sinais isolados. Para o reconhecimento contínuo de língua de sinais (CSLR), a WER (*Word Error Rate*) (Jurafsky; Martin, 2009) é frequentemente utilizada. Essa métrica mede a proporção de unidades divergentes entre as sequências reconhecidas/traduzidas e as de referência, calculada a partir do alinhamento ótimo entre ambas, considerando substituições, deleções e inserções. Uma métrica popular para SLT é a BLEU (*Bilingual Evaluation Understudy*) e suas variações (Post, 2018). BLEU é uma medida do grau de similaridade, baseada na análise de n-gramas, entre a tradução produzida por um sistema e uma ou mais traduções de referência produzidas por humanos. É importante destacar que os resultados do desafio *Metrics Shared Task* do WMT 2022 (*Workshop on Machine Translation 2022*), envolvendo métricas automáticas, sugerem que métricas automáticas baseadas em redes neurais, como a métrica COMET (*Crosslingual Optimized Metric for Evaluation of Translation*) (Rei et al., 2020) são mais adequadas para avaliar sistema de tradução automática do que métricas não neurais (Freitag et al., 2022).

Em síntese, há argumentos a favor e contra a avaliação humana e a automática. A avaliação automática exige menor esforço humano, sendo mais objetiva e menos custosa do que a avaliação

humana. Entretanto, deve-se levar em conta que a maioria das métricas automáticas exige traduções de referência criadas por humanos e, em muitos casos, a qualidade dessas traduções é assumida sem verificação, o que pode introduzir subjetividade e variabilidade na avaliação (Castilho et al., 2018). Embora os resultados das métricas humanas sejam considerados mais confiáveis do que os fornecidos por métricas automáticas, as desvantagens daquele método incluem o envolvimento de recursos humanos especializados, nem sempre disponíveis, e o tempo necessário para executar a tarefa. Para garantir a confiabilidade dos resultados, os avaliadores humanos devem atender a critérios específicos, como fluência nas línguas envolvidas e experiência com questões relacionadas ao processo tradutório. Há necessidade de formação, de aderência aos critérios de avaliação e de familiaridade com a área temática dos textos por parte dos avaliadores. Além disso, o procedimento recomendável para a avaliação humana deve incluir mais de um avaliador e ponderar a (dis)concordância interavaliadores (Rivera-Trigueros, 2022).

Considerando as vantagens e desvantagens das avaliações e humanas, a combinação de métricas humanas e automáticas parece ser um dos métodos mais confiáveis para avaliação de sistemas de tradução automática (Chatzikoumi, 2020).

A tarefa de SLR tem como objetivo identificar e classificar automaticamente sinais a partir de dados registrados em vídeo. Observa-se que há outras formas de sensoriamento além de vídeo convencional que têm sido exploradas no contexto SLR, como por exemplo, luvas de dados, sensores inerciais, eletromiográficos e de profundidade. Em geral, o SLR envolve o mapeamento de sequências temporais de observações visuais em vídeo para uma representação linguística simbólica, geralmente expressa por uma sequência de glosas (Bragg et al., 2019).

As propostas de abordagens de SLR podem ser classificadas considerando o escopo do reconhecimento em reconhecimento de datilologia, de sinais isolados ou de sinalização contínua. Além da aquisição de dados para a criação de corpus bilíngue (língua de sinais – língua oral), os sistemas de SLR abrangem o reconhecimento visual propriamente dito e o mapeamento da informação visual em uma representação simbólica. Com a evolução das técnicas de aprendizado profundo (*deep learning*) (Goodfellow; Benguio; Courville, 2016), tornou-se comum o uso de redes neurais para aprender, sem intervenção manual, representações discriminativas a partir do processamento e da análise de conjuntos de dados (*datasets*) de vídeos anotados com glosa. Arquiteturas de aprendizado profundo utilizadas para SLR abrangem Redes Neurais Recorrentes (RNNs), especialmente as do tipo LSTM (*Long Short-Term Memory*), e, mais recentemente, as arquiteturas do tipo *Transformers* (Vaswani et al., 2017). Essas últimas por permitirem modelar dependências temporais complexas com maior eficiência a partir da análise de corpus bilíngues. Entretanto, é importante destacar que o sucesso do SLR com base em estratégias de aprendizado de máquina depende fortemente da disponibilidade de grandes *corpora* bilíngues.

Apesar dos avanços, o SLR enfrenta desafios importantes decorrentes da natureza multicanal/multiarticulatória e altamente variável das línguas de sinais. Um dos principais desafios é a

variabilidade interindividual, uma vez que diferentes sinalizadores podem produzir o mesmo sinal com variações significativas na velocidade, na amplitude e no estilo. Outro desafio importante está relacionado ao fenômeno da coarticulação, decorrente da influência articulatória entre sinais consecutivos, que ocorre no fluxo contínuo da sinalização.

Esses aspectos apresentam impactos significativos para o processo de identificação automática das línguas de sinais, especialmente em três: (i) reconhecimento de datilologia³, (ii) reconhecimento de sinais isolados (ISLR) e (iii) reconhecimento de sinalização contínua (CSLR).

O primeiro objetiva a identificação automática de sequências de letras produzidas no alfabeto manual. O objetivo de um sistema de reconhecimento de datilologia é transformar uma sequência visual do alfabeto manual de língua de sinais em uma sequência de letras ou de palavras da língua oral correspondente. Os experimentos de abordagem SLR, por vezes, além das letras, incluem dígitos numéricos.

O segundo objetiva reconhecer automaticamente um único sinal produzido isoladamente, geralmente gravado em vídeo, classificando-o em uma classe de sinal pré-definida. O ISLR pode ser utilizado para a construção de mecanismos de busca em dicionários eletrônicos de sinais, em ferramentas de ensino de vocabulário e em interfaces com sistemas computacionais baseadas em sinais. Embora ISLR seja uma tarefa útil, ela efetua reconhecimento sem levar em conta o contexto do enunciado, estando, portanto, distante da tarefa de tradução (SLT). É importante não confundir a classificação de rótulos com o reconhecimento linguístico robusto. E o terceiro consiste em reconhecer automaticamente sequências de sinais, em geral em vídeo, gerando uma sequência de glosas ou rótulos lexicais. O CSLR é o cenário de reconhecimento mais realista e, ao mesmo tempo, o mais desafiador, já que a língua de sinais é produzida em fluxo contínuo, sem marcas claras de fronteira entre sinais, com coarticulação, redução articulatória, simultaneidade e sobreposição de canais.

Apesar de sua utilidade, o paradigma baseado em glosas estritamente lexicais apresenta limitações importantes. Em primeiro lugar, as glosas lexicais não capturam plenamente fenômenos como classificadores, expressões não manuais e construções espaciais complexas. Em segundo lugar, a anotação manual de glosas é custosa e demorada, o que dificulta a criação de *corpora* de grande escala.

É interessante observar que os *corpora* PHOENIX (Förster et al., 2014) e CSL-Daily (Zhou et al., 2021), amplamente utilizados em experimentos da área, apresentam anotações por glosa lexicais, feitas manualmente e, assim, relativamente mais robustas, porém com tamanhos limitados. O BSL-1K é outro corpus que merece destaque por seu tamanho, entretanto, apresenta rótulos ruidosos por serem gerados automaticamente (Albanie et al., 2020). Como destacado por Rastgoo, Kiani e Escalera (2021), a maioria dos conjuntos de dados adota glosas como representação intermediária, sem a anotação sistemática de marcadores não manuais, depicção ou ações construídas.

³ A datilologia é usada para sinalizar nomes próprios, termos técnicos ou palavras que não possuem sinal lexical convencionalizado.

Conjuntos de dados de sinalização contínua em Libras ainda são raros, o que é frequentemente apontado como gargalo para CSLR. Há iniciativas direcionadas a CSLR em contextos aplicados, por exemplo, saúde, (Vidalón; De Martino, 2015). O reconhecimento contínuo ainda é um desafio aberto, também para Libras.

Considerando a tarefa de reconhecimento de Libras, é possível destacar dois pontos que merecem especial atenção nas ações de pesquisa e desenvolvimento: (i) Avaliação da capacidade de generalização das abordagens de aprendizado de máquina por meio de estudos de cruzamento de conjuntos de dados (*cross-dataset*). Nesses estudos, um modelo de aprendizado de máquina (*machine learning*) é treinado em um ou mais conjuntos de dados e testado em outro conjunto de dados. O estudo permite avaliar a capacidade de generalização do modelo e verificar se ele funciona em cenários desconhecidos não utilizados no treinamento do modelo computacional; (ii) Extensão da cobertura linguística. Boa parte dos conjuntos de dados contempla apenas sinais lexicais isolados e deixa de lado fenômenos centrais em cenários de uso mais realistas (marcadores não manuais gramaticais, dêixis, boias, depicção, simultaneidade).

Em termos gerais, o reconhecimento contínuo de língua de sinais constitui um dos problemas centrais do processamento computacional das línguas de sinais. As abordagens baseadas em glosas continuam desempenhando um papel fundamental em cenários com corpora linguisticamente anotados, oferecendo uma interface clara entre dados visuais e representações simbólicas. No entanto, apesar dos significativos avanços da CSLR nas últimas décadas, desafios importantes permanecem, especialmente relacionados à modelagem da simultaneidade multicanal das línguas de sinais, à escassez de corpora anotados e à necessidade de sistemas capazes de generalizar para diferentes sinalizantes e contextos de comunicação. O avanço futuro do CSLR dependerá da combinação de recursos linguísticos mais ricos, corpora mais diversos e modelos capazes de representar adequadamente a estrutura visuoespacial dessas línguas.

4. TRADUÇÃO AUTOMÁTICA E PRODUÇÃO AUTOMÁTICA DE LÍNGUAS DE SINAIS

A tradução automática de língua de sinais (SLT) consiste em converter automaticamente enunciados expressos em uma língua de sinais para uma língua oral, geralmente na forma escrita, preservando o significado semântico e a estrutura linguística da mensagem. Essa tarefa constitui uma extensão do reconhecimento de língua de sinais, especificamente do reconhecimento de sinalização contínua (CSLR). Diferentemente da tarefa CSLR, cujo objetivo é produzir uma sequência de unidades lexicais ou glosas, a tradução automática busca gerar sentenças adequadas na língua oral, o que envolve processos adicionais de reorganização sintática, resolução semântica e adaptação discursiva (Rastgoo; Kiani; Escalera, 2021).

Ao longo da evolução da área, dois paradigmas principais de abordagem têm sido explorados: (i) tradução baseada em glosas (*Sign2Gloss2Text*) e (ii) modelos computacionais ponta-a-ponta (*Sign2Text*) que aprendem diretamente a tradução a partir de dados multimodais. Esses paradigmas refletem diferentes concepções sobre o papel das representações intermediárias no processo de tradução.

(i) SLT - Abordagens com uso de glosa (*Sign2Gloss - Gloss2Text*)

As primeiras propostas de SLT baseadas em aprendizado de máquina adotam uma arquitetura em duas etapas baseada em glosas. Nesse paradigma, o sistema SLT primeiro reconhece as sequências de sinais presentes no vídeo, produzindo sequências de glosas (*Sign2Gloss*), que, então, são traduzidas para a língua oral (*Gloss2Text*). Essa organização permite decompor o problema em duas etapas independentes: o reconhecimento CSLR e a tradução textual. Em termos metodológicos, essa separação facilita o uso de técnicas já consolidadas em CSLR, que lida com o reconhecimento visual, e de tradução automática, que foca na tradução de texto de uma representação intermediária escrita para a língua oral alvo. Como vantagem adicional da estratégia, essa última etapa do processamento pode explorar, por meio de técnicas de aprendizado por transferência (*transfer learning*) (De Martino et. al., 2024), soluções consolidadas de tradução neural entre línguas orais para impulsionar os desenvolvimentos.

(ii) SLT - Abordagens ponta-a-ponta (*end-to-end / Sign2Text*)

Nos últimos anos, pesquisadores também têm explorado o desenvolvimento de modelos computacionais ponta-a-ponta (*Sign2Text*), capazes de aprender simultaneamente o reconhecimento visual e a tradução linguística em uma única etapa. Nesses sistemas, o vídeo de língua de sinais é processado diretamente por um modelo neural, ou seja, por uma rede neural treinada para gerar a tradução em texto de língua oral como saída.

Arquiteturas do tipo *Transformer* multimodais têm se mostrado particularmente eficazes nesse contexto. Esses modelos utilizam mecanismos de atenção para capturar dependências de longo alcance na sequência de entrada e associá-las a elementos da sequência textual gerada. Um exemplo influente é o modelo proposto por Camgoz et al. (2020), que integra reconhecimento e tradução em uma arquitetura *Transformer* unificada.

As abordagens ponta-ponta apresentam vantagens potenciais. Em primeiro lugar, eliminam a necessidade de uma etapa intermediária de reconhecimento explícito de glosas, reduzindo a propagação de erros entre etapas. Em segundo lugar, permitem explorar estratégias de aprendizado por transferência a partir do pré-treinamento em grandes bases de dados visuais, o que pode melhorar significativamente a qualidade das representações aprendidas. No entanto, as abordagens ponta-a-ponta também apresentam desafios. O treinamento de modelos ponta-a-ponta requer grandes volumes de dados e recursos computacionais substanciais para o treinamento das redes neurais. Além disso, a ausência de representações intermediárias interpretáveis pode dificultar a análise linguística do comportamento do sistema.

A produção automática de língua de sinais (SLP), refere-se à tarefa de gerar representações visuais de uma língua de sinais a partir de texto em uma língua oral ou de uma representação simbólica intermediária, como glosas. Diferentemente do reconhecimento de língua de sinais, que busca interpretar sinais produzidos por um sinalizante humano, o SLP enfrenta o problema inverso: converter uma representação linguística em movimentos articulatorios compreensíveis para usuários surdos (Bragg et al., 2019).

O desenvolvimento de sistemas de SLP tem grande relevância para aplicações de acessibilidade e mediação linguística, como interfaces de atendimento público, sistemas educacionais e tradução automática entre línguas orais e línguas de sinais. No entanto, a tarefa apresenta desafios substanciais. As línguas de sinais caracterizam-se pela simultaneidade articulatória, envolvendo múltiplos canais — mãos, rosto, orientação do corpo e espaço tridimensional — que devem ser coordenados com precisão para produzir significado linguístico (Sandler; Lillo-Martin, 2006).

Nas últimas décadas, diferentes abordagens foram propostas para enfrentar esse problema. De maneira geral, essas abordagens podem ser organizadas em dois paradigmas principais: (i) modelos baseados em representações simbólicas por glosa (*Text2Gloss2Sign*); (ii) modelos ponta-a-pontas baseados em modelos generativos (*Text2Sign*). Além disso, os sistemas diferem quanto à forma de apresentação da saída visual, que pode ocorrer por meio de avatares tridimensionais animados ou de vídeos sintéticos gerados por modelos generativos.

(i) SLP - Abordagens baseadas em glosas (*Text2Gloss - Gloss2Sign*)

Várias propostas de SLP adotam uma arquitetura com duas etapas baseadas em glosas. Nesse paradigma, o sistema primeiro converte o texto de entrada em uma sequência de glosas e, em seguida, transforma essa sequência em uma apresentação visual, na forma de uma animação.

Aqui também, como no CSLR baseado em glosa, a representação intermediária permite decompor o problema em duas tarefas distintas: tradução linguística (*Text2Gloss*) e síntese visual (*Gloss2Text*). Essa estratégia foi adotada em diversos sistemas de tradução automática de língua de sinais e em ambientes de geração de animações com avatares.

A principal vantagem desse paradigma é a modularidade. A tradução linguística pode ser tratada separadamente da síntese visual, o que facilita o desenvolvimento incremental dos sistemas. Contudo, as abordagens baseadas em glosas, principalmente se forem só lexicais, apresentam limitações, como já mencionado anteriormente. Em primeiro lugar, as glosas são apenas aproximações da estrutura linguística real das línguas de sinais. Elas geralmente não representam adequadamente fenômenos como classificadores, construções espaciais e marcadores não manuais. Em segundo lugar, a conversão de glosas em movimentos articulatorios requer regras complexas, frequentemente desenvolvidas manualmente, o que dificulta a escalabilidade do sistema, especialmente se não forem ancoradas em dados de captura de movimento.

(ii) SLP - Abordagens ponta-a-ponta (*end-to-end* / *Text2Sign*)

Recentemente, a área tem experimentado uma mudança significativa com o surgimento de modelos computacionais generativos, que buscam aprender diretamente a correspondência entre texto e movimentos de sinalização. Esses sistemas utilizam grandes corpora multimodais para treinar redes neurais capazes de gerar vídeo a partir de representações linguísticas.

Um exemplo importante dessa linha de pesquisa é o trabalho de Stoll et al. (2020), que propõe um sistema de geração de língua de sinais a partir de texto utilizando modelos de tradução neural combinados com redes adversariais generativas (GANs - *Generative Adversarial Networks*). Nesse tipo de arquitetura, o modelo aprende a produzir movimentos, observando grandes conjuntos de exemplos de sinalização humana.

A principal vantagem dessas abordagens é a capacidade de aprender padrões complexos diretamente dos dados, reduzindo a necessidade de regras linguísticas explícitas. Além disso, os modelos generativos podem capturar nuances de movimento que seriam difíceis de especificar manualmente. Entretanto, a geração de vídeos realistas exige elevado poder computacional e grandes conjuntos de dados para o controle fino da movimentação articulatória apresentada nos vídeos. Garantir que os movimentos gerados não apenas pareçam realistas, mas também sejam linguisticamente corretos, continua sendo um desafio significativo.

Passaremos, agora, a mostrar as soluções desenvolvidas no âmbito do CCD-TAAL, criado a partir de recurso da Fundação de Amparo à Pesquisa do Estado de São Paulo (FAPESP - Processo 2024/00914-7) e envolvendo a UNICAMP, a USP, o IPT e a Secretaria de Estado dos Direitos da Pessoa com Deficiência do Estado de São Paulo (SEDPCDSP).

5. A PROPOSTA DE ANOTAÇÃO NO ÂMBITO DO CCD-TAAL

O CCD-TAAL visa estabelecer e aprofundar ações colaborativas entre grupos de pesquisa envolvidos no desenvolvimento de tecnologias assistivas para os surdos. Além de promover o avanço do conhecimento na área, o CCD-TAAL também objetiva desenvolver ferramentas tecnológicas e educacionais que atendam às demandas específicas de secretarias estaduais e municipais, especialmente as dos direitos das pessoas com deficiência, da educação e da saúde.

O CCD-TAAL se apoia fortemente no entendimento de que os indivíduos surdos pertencem a uma minoria linguística que se comunica por meio da língua de sinais e vive em condição de bilinguismo, imersa em uma sociedade falante de língua oral/escrita.

As pesquisas e os desenvolvimentos do CCD-TAAL concentram-se em duas grandes linhas conexas, que se complementam para reduzir a barreira de comunicação entre surdos e ouvintes: 1) tradução automática do português para Libras (SLP), e 2) tradução automática de Libras para português (SLT).

A primeira linha de pesquisa foca o desenvolvimento de uma solução de tradução automática do português para Libras, explorando abordagens de aprendizado de máquina baseadas em redes neurais. Nessa solução, a apresentação do conteúdo traduzido será realizada por um avatar sinalizante realista, seja ele um humano virtual, implementado por meio de técnicas de computação gráfica, ou vídeo sintético gerado por abordagem generativa. Avatares realistas buscam, como o nome sugere, ter aparência e movimentação realistas e se contrapõem a avatares estilizados, com aparência e movimentação mais próximas de simplificações típicas de desenhos animados. Para conteúdo, cujas seriedade e credibilidade também precisam ser expressas na forma visual da apresentação, avatares realistas se apresentam como uma alternativa mais adequada.

Atualmente, existem sistemas que se propõem a traduzir automaticamente do português para Libras, integrados a avatares sinalizantes. Tais sistemas, entretanto, utilizam personagens virtuais estilizados e realizam, essencialmente, tradução palavra-para-sinal, sem levar em conta as especificidades dos mecanismos e das regras da produção em Libras. O resultado dessa tradução, em geral, não é Libras, e sim o que é conhecido como português sinalizado. Cabe destacar que ainda não há sistema robusto e preciso para a tradução automática português-Libras, ou mesmo entre outras línguas escritas e de sinais, sendo este grande desafio tema de pesquisa e desenvolvimento em várias partes do mundo.

O desenvolvimento de uma solução de tradução automática português-Libras robusta, confiável e aderente à gramática da língua de sinais é um desafio técnico-científico ainda em aberto. O CCD-TAAL objetiva o desenvolvimento de sistema de tradução automática do português escrito para Libras, apoiado nas mais modernas técnicas de tradução automática. Tais técnicas são baseadas na análise e processamento de corpora paralelos, compostos por uma significativa quantidade de produções pareadas da língua fonte e língua alvo.

O potencial de impacto social e os reflexos econômicos deste desenvolvimento deriva da aplicação dessa tecnologia para melhorar a acessibilidade de alunos e cidadãos surdos a material escrito, aumentando a autonomia e facilitando a aprendizagem e a comunicação entre a sociedade ouvinte e a comunidade surda. Exemplos de aplicação dos resultados dessa linha de pesquisa incluem a tradução para Libras de material didático utilizado em escolas bilíngues, profissionalizantes ou não, e a melhoria da acessibilidade e da qualidade da informação em Libras disponibilizada em sítios e materiais de informação e divulgação governamentais. Empresas privadas também podem se beneficiar da tecnologia para melhorar os mecanismos de comunicação com seus colaboradores, dentre outros, de materiais instrucionais escritos e de manuais técnicos.

A outra linha de pesquisa do projeto busca desenvolver recursos tecnológicos para facilitar a comunicação entre surdos falantes de Libras e a sociedade ouvinte. Essa segunda frente foca no desenvolvimento de solução para a tradução automática de Libras para português, por meio do processamento e da análise de imagens e vídeos. Abordagens baseadas em redes neurais também definem a base para as pesquisas e desenvolvimentos realizados no âmbito do CCD-TAAL. Entre outras

possibilidades, visando sempre à redução de barreiras e à maior autonomia do surdo, essa tecnologia pode ser utilizada como apoio em consultas médicas, teleconsultas, reuniões de trabalho online, além de poder auxiliar surdos em bancos e repartições públicas com o uso de totens de autoatendimento, por exemplo.

As duas linhas de pesquisa, ao explorarem abordagens baseadas em redes neurais, compartilham a necessidade de construir bases de dados (datasets) adequadas para o treinamento e a avaliação de soluções neurais. O CCD-TAAL se propõe a ser uma referência aglutinadora e incentivadora de esforços voltados à construção e integração dessas bases de dados. Os desenvolvimentos previstos para o CCD-TAAL contemplam o estabelecimento de protocolos comuns de aquisição e armazenamento de forma a garantir a compatibilidade e uso compartilhado dos dados entre as equipes de pesquisadores.

Atualmente, o CCD-TAAL envia esforços para construir três bases de dados que abrangem domínios distintos: (i) conjunto de dados de diálogos no âmbito da anamnese; (ii) conjunto de dados de diálogos no interior de meios de transporte de passageiros (Uber, táxi, ônibus, bonde, trem, barco e avião); (iii) conjunto de dados com conteúdo extraído de páginas de internet. As bases de dados em construção são multimodais, contendo vídeo, dados de profundidade, texto e dados de captura de movimento.

Faz parte da construção das bases de dados a definição de um formalismo para a anotação por glosa, a fim de representar a Libras em formato escrito adequado ao treinamento de redes neurais para a tradução português-Libras e Libras-português.

Em um mundo cujo principal meio de comunicação é a linguagem oral e escrita, os surdos enfrentam severas barreiras de comunicação, enfrentando enormes dificuldades de acesso a informações básicas e a serviços públicos. A educação e a execução de tarefas simples como solicitar orientação em um balcão de informações em um centro de saúde, ou mesmo se consultar com um médico, acabam sendo desafios insuperáveis para os cidadãos surdos. Neste contexto, abordagens tecnológicas voltadas à tradução automática entre português e Libras, e vice-versa, podem ajudar a reduzir tais barreiras e promover maior autonomia das pessoas com deficiência auditiva.

O formalismo adotado no projeto CCD-TAAL insere-se em um conjunto de propostas que têm defendido que sistemas de anotação voltados ao processamento computacional devem buscar formas de representar não apenas unidades lexicais, mas também aspectos estruturais da sinalização, como simultaneidade, referência espacial e componentes não manuais, de modo a preservar informações relevantes para tarefas de reconhecimento e tradução automática (Müller et al., 2023).

O sistema foi desenvolvido com o objetivo de produzir uma representação linguística suficientemente estruturada para alimentar modelos computacionais e, ao mesmo tempo, preservar propriedades fundamentais das línguas de sinais. Parte-se do princípio de que a produção linguística em língua de sinais deve ser compreendida como um evento multimodal no qual diferentes articuladores — mãos, face, olhar, boca e corpo — participam simultaneamente da construção do significado.

A anotação é realizada no software ELAN, ferramenta amplamente utilizada na construção de corpora multimodais de línguas de sinais. O ambiente de anotação permite segmentar o vídeo em intervalos temporais e associar diferentes camadas de anotação a um mesmo trecho de sinalização, possibilitando registrar simultaneidade entre diferentes articuladores e recursos semióticos (figura 1).




Figura 1 – Interface do ELAN com organização multicamadas das trilhas de anotação do corpus. Fonte: Elaboração dos autores

Nesse sentido, o formalismo utilizado em nossa proposta pode ser definido como um sistema de anotação multicamadas no qual diferentes dimensões da produção sinalizada são registradas em trilhas temporalmente sincronizadas. Cada trilha corresponde a um canal articulatório ou semiótico específico, permitindo representar simultaneamente diferentes componentes da sinalização. Essa estrutura busca refletir a natureza multicanal das línguas de sinais e evitar a redução da sinalização a uma sequência linear de unidades lexicais.

No sistema de anotação adotado no corpus, essa estrutura multicamadas é operacionalizada por meio de um conjunto de trilhas que registram diferentes dimensões da produção sinalizada. Entre essas trilhas encontram-se aquelas destinadas à anotação de sinais lexicais realizados pelas mãos direita e esquerda, permitindo representar simultaneidade manual; trilhas para depicções ou classificadores, utilizadas na representação de construções produtivas; trilhas de apontamento e de boia, responsáveis pelo registro de mecanismos de referência e organização discursiva no espaço de sinalização; trilhas

dedicadas ao direcionamento do olhar, às expressões faciais e às ações bucais, que registram componentes não manuais relevantes para a construção do significado; trilhas destinadas à anotação de gestos e de datilologia; além de trilhas de tradução para o português e para o inglês. A organização dessas trilhas busca refletir a natureza multimodal da sinalização e permitir que diferentes articuladores sejam representados de forma sincronizada no processo de anotação (figura 2).




Figura 2 – Detalhamento das trilhas de anotação evidenciando simultaneidade entre articuladores e distribuição das glosas. Fonte: Elaboração dos autores

Outro elemento fundamental do formalismo é o registro das relações de ancoragem espacial, mecanismo por meio do qual entidades discursivas podem ser associadas a locais específicos no espaço de sinalização. Esses locais funcionam como pontos de referência que podem ser retomados posteriormente por apontamentos, direcionamento do olhar ou outras construções espaciais. Esse tipo de organização espacial desempenha papel central na construção de relações sintáticas e discursivas nas línguas de sinais (Liddell, 2003; Barberà; Zwets, 2013). O formalismo adotado registra explicitamente essas relações, permitindo indicar quando um elemento produzido na sinalização retoma uma referência previamente estabelecida em outra trilha do corpus.

Além da organização em trilhas, o sistema define critérios para a segmentação temporal das unidades anotadas. Com base na proposta de segmentação da sinalização discutida na literatura sobre Libras, considera-se que a produção gestual pode ser dividida em diferentes fases, incluindo

movimentos preparatórios, a realização do sinal propriamente dito e a retração final do gesto (LEITE, 2008). No processo de anotação adotado no corpus, a unidade linguística corresponde ao intervalo no qual a configuração manual do sinal já está estabelecida e permanece ativa. Movimentos preparatórios não são considerados parte da unidade anotada, uma vez que correspondem apenas ao posicionamento inicial das mãos.

Quadro 1 - Trilhas presentes no formalismo CCD - TAAL

Trilha	Articulador	Função na anotação	Convenção de glosa
Tradução Português	Texto	Tradução interpretativa do trecho sinalizado para o português	Texto em português
Tradução Inglês	Texto	Tradução do trecho sinalizado para o inglês	Texto em inglês
Sinal Lexical MD	Mão direita	Registro de sinais lexicalizados	Glosas em CAIXA ALTA
Sinal Lexical ME	Mão esquerda	Registro de sinais lexicalizados	Glosas em CAIXA ALTA
Datilologia MD	Mão direita	Registro de produções com o alfabeto manual	Letras individuais ou palavra soletrada
Datilologia ME	Mão esquerda	Registro de produções com o alfabeto manual	Letras individuais ou palavra soletrada
Depicção MD	Mão direita	Registro de construções depictivas	Glosa semântica
Depicção ME	Mão esquerda	Registro de construções depictivas	Glosa semântica
Apontamento MD	Mão direita	Registro de apontamentos referenciais	Glosa indicando direção para/ou o referente
Apontamento ME	Mão esquerda	Registro de apontamentos referenciais	Glosa indicando direção para/ou o referente
Boia MD	Mão direita	Registro de estruturas de boia	Glosa do elemento representado
Boia ME	Mão esquerda	Registro de estruturas de boia	Glosa do elemento representado
Gesto MD	Mão direita	Registro de ações não lexicalizadas	Glosa semântica
Gesto ME	Mão esquerda	Registro de ações não lexicalizadas	Glosa semântica
Face	Expressões faciais	Registro das expressões	Tipo de sentença:

		faciais gramaticais	INTERROGATIVA/NEGATIVA...
Boca	Boca	Registro de ações bucais que sejam relevantes	Glosa semântica
Direcionamento do Olhar	Olhos	Registro da orientação do olhar do sinalizador	Glosa indicando direção para/ou o referente

Fonte: elaboração dos autores

A organização das trilhas apresentada na Tabela 1 sintetiza o formalismo de anotação adotado no corpus. O formalismo também contempla a anotação de componentes não manuais relevantes para a construção do significado, como expressões faciais e ações bucais. Estudos recentes têm demonstrado que tais elementos desempenham papel importante na organização da sinalização e na construção de sentidos em interação sinalizada (Silva, 2023). A inclusão dessas dimensões na anotação busca garantir que informações linguísticas relevantes não sejam perdidas no processo de representação dos dados.

Outro componente relevante da anotação é a datilologia, frequentemente utilizada para a introdução de nomes próprios, termos técnicos ou elementos lexicalizados. A variação na realização das letras manuais em Libras tem sido objeto de investigação linguística recente, evidenciando a necessidade de registrar essas ocorrências de forma sistemática nos corpora anotados (Diniz, 2024).

Por fim, o corpus inclui trilhas destinadas à tradução do conteúdo sinalizado para o português e para o inglês. Essas camadas não constituem uma transcrição direta da sinalização, mas funcionam como representações interpretativas do conteúdo produzido. A relação entre sinalização e tradução escrita envolve necessariamente processos de reformulação semântica e discursiva, uma vez que a organização da língua de sinais não corresponde diretamente às estruturas das línguas escritas (Slobin, 2015).

CONSIDERAÇÕES FINAIS

O formalismo aqui apresentado busca oferecer uma representação intermediária capaz de equilibrar duas demandas centrais do desenvolvimento de sistemas de tradução automática de línguas de sinais: a necessidade de dados estruturados para o treinamento de modelos computacionais e a preservação das propriedades linguísticas fundamentais das línguas de modalidade gesto-visual. Ao organizar a anotação em trilhas temporalmente sincronizadas e utilizar glosas como rótulos semânticos associados a eventos da sinalização, o sistema produz um conjunto de dados que pode ser utilizado tanto em análises linguísticas quanto no treinamento de modelos de reconhecimento e tradução automática. Nesse contexto, a anotação multicamadas funciona como uma interface entre a descrição linguística da sinalização e os modelos computacionais utilizados no processamento automático de línguas de sinais.

AGRADECIMENTOS

O presente trabalho reporta resultados parciais de projeto financiado pela FAPESP, por meio dos projetos “Centro de Ciência para o Desenvolvimento - Tecnologia Assistiva e Acessibilidade em Libras”, processo nº 2024/00914-7, e “UNITY - Melhorando a acessibilidade para pessoas surdas em sistemas de transporte multimodais”, processo nº 2024/23068-4, assim como pelo Fundo de Apoio ao Ensino, Pesquisa e Extensão – FAEPEX/Unicamp, processo nº 3321/24 (Editais Especiais (29/2024 - Apoio à Pesquisa em Tecnologias Assistivas) e pelo Programa de Apoio à Gestão de Grandes Centros Temáticos de Pesquisa da Pró-Reitoria de Pesquisa (PRP/Unicamp), Edital PRP 003/2024. Os resultados atuais também são derivados de apoio recebido no passado da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior (CAPES), processo nº 88887.091672/2014-01, CAPES Código de Financiamento 001, Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq), processo nº 458691/2013-5, CAPES e FINEP, processo nº 2778/20.

Os autores também agradecem a todos os participantes dos projetos mencionados acima pelas valiosas contribuições para o avanço da área.

REFERÊNCIAS BIBLIOGRÁFICAS

ALBANIE, Samuel et al. BSL-1K: scaling up co-articulated sign language recognition using mouthing cues. In: *EUROPEAN CONFERENCE ON COMPUTER VISION (ECCV)*, 16., 2020. Proceedings [...]. Cham: Springer, 2020. p. 35–53. DOI: 10.1007/978-3-030-58621-8_3.

ASSIS, Amanda. Quem cabe nos concursos públicos? O discurso de tradutores de provas de concursos públicos da área jurídica do português para a Libras: um olhar do dialogismo e da ciência aberta. 278 fls. (Dissertação). Mestrado em Linguística Aplicada e Estudos da Linguagem. Pontifícia Universidade Católica de São Paulo, São Paulo, 2024.

BARBERÀ, Gemma; ZWETS, Martine. Pointing in sign languages and co-speech gestures: anchoring and identifying functions. 2013.

BARROS, Mariângela Estelita. *ELiS: sistema brasileiro de escrita das línguas de sinais*. Tese (Doutorado em Linguística) – Universidade Federal de Santa Catarina, Florianópolis, 2015.

BÉBIAN, Auguste. *Mimographie, ou essai d'écriture mimique, propre à régulariser le langage des sourds-muets*. Paris: Louis Colas, 1825.

BENASSI, André. *Visografia da língua de sinais: proposta de sistema de representação gráfica para línguas de sinais*. 2018. Dissertação (Mestrado em Linguística) – Universidade Federal de Santa Catarina, Florianópolis, 2018.

BISHOP, Christopher M. *Pattern recognition and machine learning*. New York: Springer, 2006.

BOLACIO FILHO, E. S. et al. Tradução automática, pós-edição e o pronome indefinido “man”. *Pandaemonium Germanicum*, São Paulo, v. 28, p. e240020, 2025.

BRAGG, Danielle et al. Sign language recognition, generation, and translation: an interdisciplinary perspective. In: *INTERNATIONAL ACM SIGACCESS CONFERENCE ON COMPUTERS AND ACCESSIBILITY (ASSETS '19)*, 21., 2019. Proceedings [...]. New York: ACM, 2019. p. 16–31. DOI: 10.1145/3308561.3353774.

BRIGHT, William (ed.). *The world's writing systems*. New York: Oxford University Press, 1996.

CARDOSO, Paloma Braz; LEITE, Tarcísio de Arantes; MIRANDA, Walkíria Maria Duarte. A tirania das glosas: por uma metalinguagem visual da Libras. *Revista da Abralin*, v. 22, n. 2, p. 1–20, 2023.

CASTILHO, Sheila et al. Approaches to human and machine translation quality assessment. In: CASTILHO, Sheila et al. *Translation quality assessment: from principles to practice*. Cham: Springer, 2018. p. 9–38. DOI: 10.1007/978-3-319-91241-7_2.

CHATZIKOUMI, Eirini. How to evaluate machine translation: a review of automated and human metrics. *Natural Language Engineering*, Cambridge, v. 26, n. 2, p. 137–161, 2020. DOI: <https://doi.org/10.1017/S1351324919000469>

COULMAS, Florian. *Writing systems: an introduction to their linguistic analysis*. Cambridge: Cambridge University Press, 2003.

DE MARTINO, José Mario; CHRISTINELE, Dener Stassun. Exploring pre-trained transformers for translating Portuguese text to Brazilian Sign Language. In: *INTERNATIONAL CONFERENCE ON COMPUTATIONAL PROCESSING OF PORTUGUESE (PROPOR)*, 16., 2024, Santiago de Compostela. Proceedings [...]. [S. l.]: Association for Computational Linguistics, 2024. p. 67–75. ISBN 979-8-89176-062-2.

DANIELS, Peter T.; BRIGHT, William (ed.). *The world's writing systems*. New York: Oxford University Press, 1996.

DINIZ, Heloise Gripp. *Variação fonológica das letras manuais na soletração manual em Libras*. 2024. Tese (Doutorado em Linguística) – Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2024.

FÖRSTER, Jens et al. Extensions of the sign language recognition and translation corpus RWTH-PHOENIX-Weather. In: *INTERNATIONAL CONFERENCE ON LANGUAGE RESOURCES AND EVALUATION (LREC)*, 9., 2014, Reykjavik. Proceedings [...]. Reykjavik: ELRA, 2014. p. 1911–1916.

FREITAG, Markus et al. Results of WMT22 metrics shared task: stop using BLEU – neural metrics are better and more robust. In: *CONFERENCE ON MACHINE TRANSLATION (WMT)*, 7., 2022. Proceedings [...]. [S. l.]: Association for Computational Linguistics, 2022. p. 46–68.

GARCIA, Brigitte; SALLANDRE, Marie-Anne. Transcription systems for sign languages: a sketch of the different graphical representations of sign language and their characteristics. In: MÜLLER, Cornelia; CIENKI, Alan; FRICKE, Ellen; LADEWIG, Silva; MCNEILL, David; TESSENDORF, Sedinha (ed.). *Body – Language – Communication: an international handbook on multimodality in human interaction*. Berlin: Mouton de Gruyter, 2013. p. 1125–1138.

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. *Deep learning*. Cambridge, MA: MIT Press, 2016.

GUEDES, Fernando Eustáquio. Tradução de Provas para Libras em Vídeo: mapeamento das videoprovas brasileiras de 2006 a 2019. 148 fls. (Dissertação). Mestrado em Estudos da Tradução, Universidade Federal de Santa Catarina, Florianópolis, 2019.

JURAFSKY, Daniel; MARTIN, James H. *Speech and language processing: an introduction to natural language processing, computational linguistics, and speech recognition*. 2. ed. Upper Saddle River: Prentice Hall, 2009.

KENDON, Adam. *Gesture: visible action as utterance*. Cambridge: Cambridge University Press, 2004.

KOEHN, Philipp. *Neural machine translation*. New York: Cambridge University Press, 2020.
KOPF, Maria et al. *Specification for the harmonization of sign language annotations*. Version 1.0. Hamburg: Universität Hamburg; EASIER Consortium, 2022. DOI: 10.25592/uhhfdm.9842.

LEITE, T. de A.; AMPESSAN, J. P.; BOLDO, J.; TASCA LOHN, J.; AZEVEDO, G. S. de O. Semântica lexical na libras: Libertando-se da tirania das glosas. **Revista da ABRALIN**, [S. l.], v. 20, n. 2, p. 1–23, 2022. Disponível em: <https://revista.abralin.org/index.php/abralin/article/view/1833>. Acesso em: 16 mar. 2026.

LEITE,, Tarcísio de Arantes, AMPESSAN, João Paulo, BOLDO, Jaqueline, LOHN, Juliana Tasca., & Azevedo, G. S. O. (2022). Semântica lexical na libras: libertando-se da tirania das glosas. *Revista da ABRALIN*, 20(2), 1-23. <https://revista.abralin.org/index.php/abralin/article/view/1833> (Acessado 18 de agosto, 2023).

LIDDELL, Scott K. *Grammar, gesture, and meaning in American Sign Language*. Cambridge: Cambridge University Press, 2003.

LUQMAN, Hamzah; MAHMOUD, S. A. Automatic translation of Arabic text-to-Arabic sign language. *Universal Access in the Information Society*, v. 18, p. 939–951, 2019. DOI: 10.1007/s10209-018-0622-8.

MÜLLER, Mathias et al. Considerations for meaningful sign language machine translation based on glosses. In: *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*. 2023.

NASCIMENTO, Vinicius. Alteridades, discursos e saberes na formação de intérpretes de Libras-português experientes. *Belas Infiéis*, Brasília, v. 10, n. 2, p. 01-26, 2021. Disponível em:

<https://periodicos.unb.br/index.php/belasinfieis/article/view/28504?articlesBySimilarityPage=42> Acesso em 9 mar. 2026.

OLSON, David R. *The world on paper: the conceptual and cognitive implications of writing and reading*. Cambridge: Cambridge University Press, 1994.

POST, Matt. A call for clarity in reporting BLEU scores. In: *CONFERENCE ON MACHINE TRANSLATION (WMT)*, 3., 2018, Brussels. Proceedings [...]. [S. l.]: Association for Computational Linguistics, 2018. p. 186–191.

PRILLWITZ, Siegmund et al. *HamNoSys: version 2.0; Hamburg Notation System for Sign Languages*. Hamburg: Universität Hamburg, 1989.

PYM, Anthony. *Explorando teorias da tradução*. São Paulo: Perspectiva, 2017.

RASTGOO, Razieh; KIANI, Kourosh; ESCALERA, Sergio. Sign language recognition: a deep survey. *Expert Systems with Applications*, v. 164, art. 113794, 2021. DOI: 10.1016/j.eswa.2020.113794.

RATHMANN, Christian. *Lexical frequency in sign languages*. Hamburg: Signum Press, 2007.

REI, Ricardo et al. COMET: a neural framework for MT evaluation. In: *CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING (EMNLP)*, 2020. Proceedings [...]. [S. l.]: Association for Computational Linguistics, 2020. p. 2685–2702.

RIVERA-TRIGUEROS, Irene. Machine translation systems and quality assessment: a systematic review. *Language Resources and Evaluation*, v. 56, p. 593–619, 2022. DOI: 10.1007/s10579-021-09537-5.

RODRIGUES, Carlos Henrique. A tradução não escrita envolvendo línguas de sinais: reflexões sobre sua especificidade e características. *Belas Infieis*, Brasília, Brasil, v. 12, n. 1, p. 01–21, 2023. Disponível em: <https://periodicos.unb.br/index.php/belasinfieis/article/view/45612> Acesso em: 18 mar. 2026.

RODRIGUES, Carlos Henrique. Da interpretação comunitária à interpretação de conferência:: desafios para formação de intérpretes de língua de sinais. In: *Anais do Congresso Nacional de Pesquisas em Tradução e Interpretação de Línguas de Sinais*, Universidade Federal de Santa Catarina, Florianópolis, 2010. Disponível em: <https://publicacao.copels.com.br/index.php/tilsp/article/view/578> Acesso em 18 mar. 2026.

SAITO, Daniela Satomi; SCOLARI, Sérgio Henrique Prado; FELÍCIO, Márcia Dilma. O design de material didático e o processo de tradução/interpretação (Libras/Português): uma aproximação possível. In: *BRAZILIAN SYMPOSIUM ON MULTIMEDIA AND THE WEB (WEBMEDIA)*, 17., 2011, Florianópolis. Anais [...]. Porto Alegre: Sociedade Brasileira de Computação, 2011. p. 35–38. Disponível em: <https://sol.sbc.org.br/index.php/webmedia/article/view/5594>

SANDLER, Wendy; LILLO-MARTIN, Diane. *Sign language and linguistic universals*. Cambridge: Cambridge University Press, 2006.

SANTOS, Lara Ferreira; DINIZ, Sarah Leite Lisboa; LACERDA, Cristina Broglia Feitosa de. Práticas de interpretação no espaço educacional: para além dos limites da sala de aula. In: LACERDA, Cristina Broglia Feitosa de; SANTOS, Lara Ferreira; MARTINS, Vanessa Regina de Oliveira. (Org.) Escola e diferença: caminhos para a educação bilíngue de surdos. São Carlos: Edufscar, 2016.

SAUSSURE, Ferdinand de. *Cours de linguistique générale*. Paris: Payot, 1916.

SILVA, João Paulo da. *As ações bucais como práticas na emergência de entendimentos situados em interação sinalizada*. 2023. Tese (Doutorado em Semiótica e Linguística Geral) – Universidade de São Paulo, São Paulo, 2023.

SILVA, Lara Gomes. A mediação dos Educadores Surdos nos Museus de São Paulo: para além da tradução de línguas. 91 fls. (Dissertação). Mestrado em Educação: Currículo. Pontifícia Universidade Católica de São Paulo, São Paulo, 2021.

SILVA, Rodrigo Custódio; OLIVEIRA, Janine Soares. Equipe de tradução do curso de Letras Libras. In: QUADROS, Ronice Muller (Org.) Letras Libras: ontem, hoje e amanhã. Florianópolis: Editora UFSC, 2015.

SLOBIN, Dan Isaac. Quebrando modelos: as línguas de sinais e a natureza da linguagem humana. *Forum Linguistic*, v. 12, n. 3, p. 844–853, 2015.

SOBRAL, Adail Ubirajara. Dizer o ‘mesmo’ a outros: ensaios sobre tradução. São Paulo: SBS Editora, 2008.

STOKOE, William C. *Sign language structure: an outline of the visual communication systems of the American deaf*. Buffalo: University of Buffalo, 1960.

STOLL, Stephanie; CAMGOZ, Necati Cihan; HADFIELD, Simon; BOWDEN, Richard. Text2Sign: towards sign language production using neural machine translation and generative adversarial networks. *International Journal of Computer Vision*, v. 128, p. 891–908, 2020. DOI: 10.1007/s11263-019-01281-2.

SUTTON, Valerie. *Lessons in SignWriting*. La Jolla: Center for Sutton Movement Writing, 1974.

TREVISAN, Sueli Fioramonte; MARTINS, Vanessa Regina de Oliveira. Enem em Libras e a avaliação na educação básica pelo olhar dos surdos. Intellectus. Revista Acadêmica Digital. V. 59, n.1, p. 76-99, 2020. Disponível em: <https://revistasunifajunimax.unieduk.com.br/intellectus/article/view/687> Acesso em 16 mar. 2026.

VASWANI, Ashish et al. Attention is all you need. In: *ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NEURIPS)*, 2017. Proceedings [...]. Red Hook, NY: Curran Associates, 2017. p. 5998–6008.

VIDALÓN, José Elías Yauri; DE MARTINO, José Mario. Continuous sign recognition of Brazilian Sign Language in a healthcare setting. *Journal of Communication and Information Systems*, v. 30, n. 1, p. 82–91, 2015. DOI: <https://doi.org/10.14209/jcis.2015.10>

WANG, L.; AMBIKAIRAJAH, E.; CHOI, E. H. Automatic language recognition with tonal and non-tonal language pre-classification. In: *EUROPEAN SIGNAL PROCESSING CONFERENCE (EUSIPCO)*, 15., 2007. Proceedings [...]. p. 2375–2379.

ZHOU, Hao; ZHOU, Wengang; QI, Weizhen; PU, Junfu; LI, Houqiang. Improving sign language translation with monolingual data by sign back-translation. In: *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. Nashville: IEEE, 2021. p. 1316–1325. DOI: <https://doi.org/10.1109/CVPR46437.2021.00137>

Anexo 6
Artigo Submetido e em Avaliação

**Concatenative Synthesis for Brazilian Sign
Language**

**XI Workshop de Iniciação Científica em Tecnologia
da Informação e da Linguagem Humana**

Concatenative Synthesis for Brazilian Sign Language

Anonymous¹

¹Anonymous

Abstract. *This paper presents an enhanced concatenative synthesis framework for Brazilian Sign Language (Libras) based on motion-capture (MoCap) data. The proposed method extends previous work by incorporating movement dynamics into the unit-selection process, allowing fragment selection to consider both pose similarity and velocity continuity. In addition, a quaternion-based transition smoothing mechanism is introduced to reduce discontinuities between independently recorded sign segments. The framework also employs a compact quaternion-only motion representation and a web-native architecture for real-time synthesis and visualization.*

1. Introduction

Sign language avatars provide a means of presenting signed content in digital environments, supporting accessibility in education, public services, and web communication. Generating movements that faithfully reproduce the dynamics of natural signing remains challenging: current machine learning and generative AI approaches lack the fine-tuning necessary for the language’s nuances, while concatenation-based methods often exhibit discontinuities in posture, velocity, or trajectory, producing unnatural animations that may reduce intelligibility and user acceptance among fluent signers.

Concatenative synthesis offers an alternative approach. Originally developed for speech synthesis, concatenative methods generate new utterances by selecting and concatenating segments from a corpus of pre-recorded data [Hunt and Black 1996, Schwarz 2005]. Applied to sign language, this paradigm replaces speech units with motion-captured (MoCap) sign fragments: given an input gloss sequence, the system retrieves candidate instances from a MoCap database and combines them into a previously unseen animation. Because the output is constructed from authentic human performances, concatenative synthesis can preserve subtle kinematic and temporal characteristics that are often difficult to reproduce using procedural, neural, or manual animation techniques.

The feasibility of this approach for Brazilian Sign Language (Libras) using a gloss-annotated MoCap database is demonstrated in [Poeta 2025]. However, selecting fragments that produce smooth transitions remains a significant challenge. Existing methods rely primarily on pose similarity, which can reduce spatial discontinuities but does not account for movement dynamics, frequently resulting in abrupt velocity changes.

To address this, the paper presents an enhanced concatenative synthesis framework for Libras incorporating movement dynamics into unit selection, an improved quaternion-based transition smoothing mechanism considering angular momentum, and a compact quaternion-only motion representation. The framework targets a web-native architecture for real-time sign synthesis and visualization.

2. Methodology

2.1. Motion Capture Acquisition and Annotation

Motion capture sessions were conducted with fluent Brazilian Sign Language (Libras) signers using a wearable full-body motion capture suit. During each recording session, participants performed complete sentences while the system continuously tracked the orientation and movement of the body at a fixed sampling rate. This process generated a time-synchronized sequence of skeletal poses representing the kinematics of the signing performance.

Facial expressions and non-manual markers were recorded simultaneously using a head-mounted camera rigidly attached to the signer. The recorded video was subsequently processed using computer vision techniques to extract facial features and animation parameters associated with relevant facial movements. Synchronization between the skeletal and facial recordings ensured that manual and non-manual components of the signing performance could be reconstructed consistently.

After acquisition, the captured motion was retargeted to the skeleton of the virtual avatar, establishing a correspondence between the performer’s movements and the avatar rig. The resulting animation data were then converted into a compact representation consisting exclusively of joint rotations expressed as quaternions. By storing only quaternion values for each skeletal joint and frame, the system significantly reduces storage requirements while preserving the information necessary for accurate animation reconstruction and real-time playback.

To establish a correspondence between MoCap recordings and linguistic units, each recording session is rendered as a synchronized avatar video and annotated using the ELAN linguistic annotation tool [Max Planck Institute for Psycholinguistics 2025]. Fluent Libras interpreters identify the temporal boundaries of each sign by marking its start and end frames and assigning the appropriate gloss labels. The resulting annotations are synchronized with the underlying MoCap data, allowing the automatic extraction of sign-specific motion segments from continuous signing sequences. Each extracted segment is then associated with its gloss and stored in a motion database, enabling efficient retrieval and reuse during the concatenative synthesis process.

2.2. Concatenative Synthesis Pipeline

The proposed concatenative synthesis pipeline consists of four stages: unit selection, content generation, transition smoothing, and animation synthesis. Starting from a sequence of glosses, the system retrieves motion fragments from the database, selects the most compatible instances, generates smooth transitions between consecutive fragments, and finally renders the resulting animation on a three-dimensional signing avatar.

2.2.1. Unit Selection

For each gloss in the input sequence, all corresponding sign instances stored in the motion database are retrieved. Following [Poeta 2025], the selection problem is formulated as a shortest-path search on a graph in which nodes represent candidate sign instances, and edges represent transition costs.

Unlike previous approaches, the proposed method considers both pose similarity and movement dynamics. In addition to the quaternion difference between consecutive fragments, the cost function incorporates velocity differences, thereby favoring transitions that better preserve movement continuity.

2.2.2. Content Generation

Once the optimal fragment sequence has been identified, the corresponding quaternion trajectories are retrieved from the database and assembled into a continuous motion sequence. This sequence serves as the input to the transition smoothing stage.

2.2.3. Transition Smoothing

To reduce discontinuities between independently recorded fragments, intermediate frames are generated using Spherical Linear Interpolation (SLERP) [Shoemake 1985]. A dynamic adjustment factor based on local velocity differences is additionally employed by preserving angular momentum to improve temporal continuity while maintaining the expressive characteristics of the original performance.

2.2.4. Animation Synthesis

The final stage applies the synthesized motion sequence to a three-dimensional avatar in real time. Quaternion values are continuously mapped to the avatar skeleton, producing the final Libras animation at interactive frame rates for visualization in a web environment.

3. System Architecture

The proposed framework was designed with web compatibility as the primary requirement. The system was implemented as a TypeScript application using Three.js, an open-source framework for real-time three-dimensional rendering in web browsers. Future versions are expected to support standalone desktop deployment through Tauri, a lightweight Rust-based application framework.

Figure 1 illustrates the overall architecture of the proposed system. Initially, a user selects a textual input through a web interface. The text is then translated into a sequence of glosses by an external text-to-gloss module. Subsequently, the concatenative synthesis engine retrieves the corresponding motion fragments from the motion database, generates the final animation sequence, and renders it in real time using a three-dimensional signing avatar.

The synthesized animations are represented exclusively by quaternion trajectories, enabling efficient transmission and rendering while preserving motion quality.




Figura 1. Architecture of the Synthesizer (Source: The Author)

4. Evaluation Methodology

The proposed framework will be evaluated through qualitative and quantitative analyses.

The qualitative evaluation will involve fluent Libras users who will assess synthesized animations using a five-point Likert scale. Evaluation criteria include naturalness, transition quality, hand articulation, facial expressiveness, intelligibility, and overall quality.

The quantitative evaluation will compare synthesized transitions with corresponding transitions extracted from original motion-capture recordings. Similarity will be measured using Mean Squared Error (MSE) and the coefficient of determination (R^2) computed over quaternion trajectories. These metrics will provide an objective assessment of the fidelity of the synthesized motion.

5. Concluding Remarks

This paper presented an enhanced concatenative synthesis framework for generating Libras animations from motion-capture data. By incorporating movement dynamics into the unit-selection process and in the transition smoothing step, the proposed approach seeks to improve motion continuity and reduce visual discontinuities between concatenated sign fragments.

The framework combines a gloss-annotated motion database, a compact quaternion representation, and a web-native rendering architecture, enabling real-time synthesis and visualization of sign language animations.

Future work will focus on the integration of facial expressions and non-manual markers, as well as the investigation of learned motion representations based on self-supervised learning techniques to further improve fragment selection and transition quality.

Referências

- Hunt, A. and Black, A. (1996). Unit selection in a concatenative speech synthesis system using a large speech database. In *1996 IEEE International Conference on Acoustics, Speech, and Signal Processing Conference Proceedings*, volume 1, pages 373–376 vol. 1.
- Max Planck Institute for Psycholinguistics (2025). Elan (version 7.1) [computer software]. Accessed: 2026-06-04.
- Poeta, E. (2025). *Síntese Concatenativa de Línguas Sinais*. Msc thesis, Universidade Estadual de Campinas(UNICAMP).

- Schwarz, D. (2005). Current research in concatenative sound synthesis. In *Proceedings of the International Computer Music Conference (ICMC)*, pages 1–4, Barcelona, Spain. International Computer Music Association.
- Shoemake, K. (1985). Animating rotation with quaternion curves. In *Proceedings of the 12th Annual Conference on Computer Graphics and Interactive Techniques (SIGGRAPH '85)*, pages 245–254. ACM.

Anexo 7
Artigo Submetido e em Avaliação

**Explorando a Integração de Múltiplas Modalidades
Visuais no Reconhecimento Contínuo de Libras**
**XI Workshop de Iniciação Científica em Tecnologia
da Informação e da Linguagem Humana**

Explorando a Integração de Múltiplas Modalidades Visuais no Reconhecimento Contínuo de Libras

Anonimizado

Abstract. Continuous Brazilian Sign Language (Libras) recognition presents challenges related to the multimodal nature of signing and the modeling of complex spatio-temporal dependencies. This ongoing work investigates the adaptation of neural architectures for continuous Libras recognition using RGB videos, body, facial, and hand keypoints, as well as multi-tier linguistic annotations produced in ELAN. The proposed approach combines visual feature extraction, multimodal integration, and temporal modeling. Evaluation will be conducted using the Word Error Rate (WER) metric and ablation studies. The goal is to analyze the impact of multimodality and multi-layer annotations on the performance of continuous Libras recognition models.

Resumo. O reconhecimento contínuo de Língua Brasileira de Sinais (Libras) apresenta desafios relacionados à natureza multimodal da sinalização e à modelagem de dependências espaço-temporais complexas. Este trabalho em andamento busca investigar a adaptação de arquiteturas neurais para o reconhecimento contínuo de Libras utilizando vídeos RGB, keypoints corporais, faciais e manuais, além de anotações linguísticas multi-tier produzidas no ELAN. O método proposto combina extração de características visuais, integração multimodal e modelagem temporal. A avaliação será realizada por meio da métrica Word Error Rate (WER) e estudos de ablação. Espera-se analisar o impacto da multimodalidade e das anotações multicamadas no desempenho de modelos de reconhecimento contínuo de Libras.

1. Introdução

A Língua Brasileira de Sinais (Libras) constitui o principal meio de comunicação da comunidade surda brasileira e desempenha papel fundamental na promoção da acessibilidade e da inclusão social. Diferentemente da língua portuguesa, a Libras utiliza simultaneamente componentes manuais e não manuais, incluindo configurações de mão, movimentos corporais, expressões faciais, direção do olhar e organização espacial da mensagem. Essa natureza visual-espacial e multimodal torna o desenvolvimento de tecnologias para processamento automático de línguas de sinais um desafio científico relevante e uma importante ferramenta para ampliar a acessibilidade em diferentes contextos sociais, educacionais e institucionais [Bragg et al. 2019].

Apesar da relevância dessas tecnologias, o reconhecimento contínuo da língua de sinais ainda é um desafio [Khan et al. 2025, Najib 2025, Wang et al. 2025]. Diferentemente de sinais isolados, reconhecê-los exige lidar com sequências de sinais de forma contínua, envolvendo fenômenos como coarticulação, transições entre sinais, variações de velocidade e a integração de múltiplos articuladores visuais. Como discutem Koller et al. [Koller et al. 2015], há uma demanda de modelos capazes de capturar dependências espaço-temporais complexas e de operar em condições mais

próximas das situações reais de uso. Nos últimos anos, a literatura tem apresentado diversos métodos que buscam solucionar esses problemas. Por exemplo, Camgöz et al. [Camgoz et al. 2018] propuseram uma formulação neural para a tarefa, enquanto Camgöz et al. [Camgoz et al. 2020b] apresentaram uma arquitetura baseada em *Transformers* para reconhecimento e tradução conjuntos. Além disso, Camgöz et al. [Camgoz et al. 2020a], Yin e Read [Yin and Read 2020] e Yin et al. [Yin et al. 2023] exploraram múltiplos articuladores e novas formas de incorporar informação linguística intermediária aos modelos.

Apesar desses avanços, ainda há muitas questões em aberto, especialmente no contexto da Libras. Este trabalho está inserido em um projeto mais amplo voltado ao reconhecimento e à tradução de língua de sinais, envolvendo o desenvolvimento de um corpus multimodal de Libras contendo vídeos RGB, *keypoints* corporais, faciais e manuais, além de anotações linguísticas *multi-tier* produzidas no ELAN. Este trabalho tem como objetivo principal avaliar e adaptar arquiteturas neurais para o reconhecimento contínuo, investigando o impacto de diferentes modalidades visuais e estratégias de fusão multimodal, de modo a responder à seguinte questão: como integrar, de forma consistente, vídeos RGB, *keypoints* e anotações linguísticas *multi-tier* para melhorar o desempenho de modelos neurais de reconhecimento contínuo de Libras?

2. Metodologia

A metodologia proposta visa investigar o impacto de diferentes modalidades visuais e anotações linguísticas multicamadas no reconhecimento contínuo de Libras. Três tarefas principais compõem a metodologia: construção de corpus multimodal, extração e integração de representações multimodais e modelagem temporal baseada em arquiteturas neurais.

2.1. Construção de Corpus Multimodal de Libras

Os experimentos são conduzidos com um corpus multimodal de Libras, em desenvolvimento no âmbito de um projeto de pesquisa mais amplo. O corpus é composto por sentenças em português traduzidas para Libras por uma equipe de sete intérpretes, incluindo três participantes surdos. As gravações são realizadas em ambiente controlado utilizando quatro câmeras RGB posicionadas em diferentes ângulos. Essa configuração reduz problemas de oclusão e permite a obtenção de múltiplas perspectivas da sinalização. A partir dos vídeos, são extraídas representações complementares, incluindo *keypoints* corporais, faciais e das mãos, possibilitando a construção de diferentes modalidades de entrada para os modelos de reconhecimento.

Além das informações visuais, o corpus incorpora anotações linguísticas produzidas no ELAN [Wittenburg et al. 2006]. Diferentemente de abordagens baseadas em uma única camada de anotação, a estrutura adotada utiliza múltiplos *tiers* sincronizados temporalmente. Além das glosas, são registradas informações sobre apontamentos espaciais, mão dominante, direção do olhar e marcadores não manuais. Essa organização permite uma representação mais detalhada da sinalização e fornece informações adicionais potencialmente úteis para o treinamento de modelos neurais. Atualmente, o corpus abrange diferentes domínios de aplicação, incluindo contextos de saúde, alimentação e mobilidade, o que contribui para uma maior diversidade linguística e contextual dos dados.

2.2. Extração e Integração de representações multimodais

A primeira etapa do processo computacional consiste na conversão de vídeos em representações adequadas ao treinamento de modelos de reconhecimento. Os vídeos RGB são processados por extratores de características visuais, que geram *embeddings* espaciais para cada quadro da sequência. Paralelamente, representações estruturadas derivadas dos vídeos, como *keypoints* corporais, faciais e manuais, são convertidas em vetores numéricos que descrevem explicitamente a configuração espacial dos articuladores envolvidos na sinalização. Dessa forma, o reconhecimento deixa de operar diretamente sobre o vídeo bruto e passa a utilizar sequências de representações compactas que preservam informações relevantes para a modelagem da sinalização.

Um dos objetivos centrais deste trabalho é investigar como diferentes fontes de informação podem ser combinadas para apoiar o reconhecimento contínuo de Libras. Para isso, serão avaliadas diferentes estratégias de fusão multimodal. Na abordagem de fusão antecipada (*early fusion*), as representações provenientes das diferentes modalidades são combinadas antes da modelagem temporal. Já na fusão tardia (*late fusion*), cada modalidade é inicialmente processada por um fluxo independente, sendo integrada apenas em estágios posteriores da rede. A comparação entre essas estratégias permitirá avaliar em que medida as diferentes modalidades contribuem para o desempenho do sistema.

2.3. Modelagem Temporal para Reconhecimento Contínuo

O reconhecimento contínuo está sendo explorado por meio de arquiteturas neurais baseadas em *Transformers*, tomando como referência os modelos propostos por Camgöz et al.(2020) [Camgoz et al. 2020b]. A escolha dessa arquitetura se justifica por seu papel de destaque na literatura da área, tanto pelos resultados reportados quanto por oferecer uma formulação adequada para modelar sequências visuais longas, com dependências espaço-temporais complexas, características centrais do reconhecimento contínuo. A Figura 1 sintetiza as principais etapas da arquitetura, desde a obtenção das representações espaciais até a predição da sequência de glosas e a supervisão do treinamento.




Figura 1. Fluxo computacional para o reconhecimento contínuo de Libras. As setas vermelhas indicam o uso de anotações *multi-tier* na supervisão do treinamento.

Após a etapa de fusão, as sequências de representações multimodais são processadas por mecanismos de atenção capazes de modelar dependências de longo alcance ao longo da sinalização. Essa etapa busca capturar fenômenos característicos do reconhecimento contínuo, incluindo coarticulação, variações entre sinalizantes e relações contextuais entre sinais consecutivos. Como saída, o modelo produz uma sequência de glosas correspondente ao conteúdo linguístico presente no vídeo de entrada.

3. Avaliação Experimental

A avaliação do sistema será conduzida por meio da comparação entre as sequências de glosas produzidas pelo modelo e as anotações de referência presentes no corpus. Como métrica principal, será utilizada a *Word Error Rate* (WER), amplamente empregada em tarefas de reconhecimento contínuo de língua de sinais [Camgoz et al. 2020b]. A WER quantifica a distância de edição entre a sequência predita e a correta, considerando inserções, remoções e substituições. Além da avaliação global, serão realizados estudos de ablação com o objetivo de mensurar a contribuição individual de cada modalidade visual e das anotações multicamadas para o desempenho final do sistema.

4. Desafios Atuais e Próximos Passos

Um dos principais desafios da pesquisa reside na reprodutibilidade técnica das arquiteturas de referência. A adaptação do modelo descrito em [Camgoz et al. 2020b] exige lidar com dependências de códigos, bibliotecas desatualizadas e escolhas de implementação nem sempre totalmente especificadas. Além disso, há um gargalo importante na extração de características espaciais [Alvarez et al. 2022], pois esse tipo de modelo não opera diretamente sobre o vídeo bruto, mas sobre *features* previamente extraídas. Como a arquitetura exata do extrator original não foi disponibilizada integralmente, torna-se necessário investigar alternativas para gerar *embeddings* visuais robustos, etapa central para o restante da tarefa de reconhecimento. Outro desafio diz respeito à generalização do modelo para o cenário de Libras. O sistema de referência foi desenvolvido sobre o conjunto de dados PHOENIX14T, restrito ao domínio de previsões do tempo e à Língua de Sinais Alemã, enquanto o presente trabalho se concentra na Libras e com domínios linguísticos mais variados.

Diante disso, os próximos passos concentram-se na consolidação do módulo de extração de características espaciais, na adaptação do código ao contexto do projeto e na execução sistemática de experimentos com base na métrica WER. Em seguida, pretende-se adaptar o modelo ao contexto de Libras e avaliar empiricamente em que medida a combinação de múltiplas modalidades visuais e de anotações *multi-tier* pode fortalecer o reconhecimento contínuo de sinais.

5. Considerações Finais

O reconhecimento contínuo de Libras constitui um problema computacional desafiador, que requer a integração de informações visuais, temporais e linguísticas. A principal contribuição deste trabalho reside na consolidação de uma base metodológica para a adaptação e avaliação de arquiteturas neurais voltadas a esse problema, com a definição de um fluxo computacional que envolve extração de características espaciais, fusão multimodal, modelagem temporal e avaliação por WER. Embora ainda não haja resultados experimentais finais, o mapeamento dos desafios de reprodutibilidade, a extração de *features* e a generalização para o contexto de Libras já representam etapas relevantes da pesquisa. Espera-se, assim, que os próximos experimentos avancem na compreensão do impacto da multimodalidade e das anotações *multi-tier* no reconhecimento contínuo, contribuindo para o amadurecimento metodológico da área e para o desenvolvimento de tecnologias mais robustas e aplicáveis à comunidade surda brasileira.

Referências

- Alvarez, P. C., Nieto, X. G., and Benet, L. T. (2022). Sign Language Translation Based on Transformers for the How2Sign Dataset. *Image Processing Group Signal Theory and Communications Department Universitat Politècnica de Catalunya*.
- Bragg, D., Koller, O., Bellard, M., Berke, L., Boudreault, P., Braffort, A., Caselli, N., Huenerfauth, M., Kacorri, H., Verhoef, T., et al. (2019). Sign Language Recognition, Generation, and Translation: An Interdisciplinary Perspective. In *Proceedings of the 21st International ACM SIGACCESS Conference on Computers and Accessibility*, pages 16–31.
- Camgoz, N. C., Hadfield, S., Koller, O., Ney, H., and Bowden, R. (2018). Neural Sign Language Translation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 7784–7793.
- Camgoz, N. C., Koller, O., Hadfield, S., and Bowden, R. (2020a). Multi-Channel Transformers for Multi-Articulatory Sign Language Translation. In *European Conference on Computer Vision*, pages 301–319. Springer.
- Camgoz, N. C., Koller, O., Hadfield, S., and Bowden, R. (2020b). Sign Language Transformers: Joint End-To-End Sign Language Recognition and Translation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 10023–10033.
- Khan, A., Jin, S., Lee, G.-H., Arzu, G. E., Dang, L. M., Nguyen, T. N., Choi, W., and Moon, H. (2025). Deep Learning Approaches for Continuous Sign Language Recognition: A Comprehensive Review. *IEEE Access*, 13:55524–55544.
- Koller, O., Forster, J., and Ney, H. (2015). Continuous Sign Language Recognition: Towards Large Vocabulary Statistical Recognition Systems Handling Multiple Signers. *Computer Vision and Image Understanding*, 141:108–125.
- Najib, F. M. (2025). Sign Language Interpretation using Machine Learning and Artificial Intelligence. *Neural Computing and Applications*, 37(2):841–857.
- Wang, Z., Li, D., Jiang, R., and Okumura, M. (2025). Continuous Sign Language Recognition with Multi-Scale Spatial-Temporal Feature Enhancement. *IEEE Access*, 13:5491–5506.
- Wittenburg, P., Brugman, H., Russel, A., Klassmann, A., and Sloetjes, H. (2006). ELAN: A Professional Framework for Multimodality Research. In *5th International Conference on Language Resources and Evaluation*, pages 1556–1559.
- Yin, A., Zhong, T., Tang, L., Jin, W., Jin, T., and Zhao, Z. (2023). Gloss Attention for Floss-Free Sign Language Translation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 2551–2562.
- Yin, K. and Read, J. (2020). Better Sign Language Translation with STMC-Transformer. In *Proceedings of the 28th International Conference on Computational Linguistics*, pages 5975–5989.

Anexo 8
Artigo Submetido e em Avaliação

**Subtitling Restaurant Menus on Web Pages in
Brazilian Sign Language**

3º Workshop Accesibilidad e Inclusión

Subtitling Restaurant Menus on Web Pages in Brazilian Sign Language

No Author Given

No Institute Given

Abstract. This paper presents the development of a robust technological infrastructure designed to facilitate the automated translation of web content into Brazilian Sign Language (Libras). Central to this framework is the construction of a high-fidelity multimodal corpus, comprising approximately 2,400 sentences recorded utilizing advanced motion capture (MoCap) systems. To employ this system, a web injection tool was implemented, featuring a crawler for comprehensive domain mapping and a specialized parser. This parser effectively segments textual information and automatically embeds non-intrusive accessibility interfaces for Libras content. The viability of this solution was validated through its successful application to complex, dynamically loaded web pages, specifically a university restaurant menu. At the user interface level, the system introduces a modular widget that supports the playback of pre-rendered animation of three-dimensional (3D) avatars, a dual approach strategically intended to optimize bandwidth consumption. Ultimately, the proposed architecture establishes a comprehensive ecosystem of data engineering, machine-learning training, and graphical visualization tools, providing a scalable foundation to enhance web accessibility and promote the digital autonomy of the deaf community.

1 Introduction

Although internet information is predominantly textual, assuming it is inherently accessible to deaf individuals is a frequent misconception. While those who experience hearing loss later in life can typically access textual information without difficulty, written material is often significantly less accessible than content presented in sign language for deaf individuals who were deaf before acquiring a spoken/written language. Studies consistently indicate that the reading proficiency of deaf children frequently lags behind that of their hearing peers [8].

Furthermore, because sign language is the primary language for the Deaf community, reading text in a spoken language is cognitively comparable to interpreting a foreign language [10]. Drawing a parallel to spoken languages in Brazil, while there are few native citizens unable to read Portuguese, respecting this unique linguistic community dictates a cultural and legal obligation to provide accessible information in their primary language [19]. According to a 2019 national health survey conducted by the Brazilian Institute of Geography and Statistics (IBGE), approximately 2.5 million citizens over the age of two have severe hearing loss or are deaf, representing 1.1% of the Brazilian population [12].

In Brazil, Brazilian Sign Language (Libras) is recognized as a co-official means of communication and expression for the deaf community under Law No. 10.436/2002 [20], and is regulated by Decree No. 5.626/2005 [5]. Additionally, Law No. 13.146 of July 6, 2015 [6], known as the Statute of the Person with Disabilities, establishes public policies designed to ensure the equal exercise of fundamental rights and freedoms, aiming for full social inclusion and citizenship. Explicitly in Article 63, this legislation mandates accessibility on websites maintained by government agencies or companies that operate in the country. This ensures that individuals with disabilities have access to information in accordance with internationally adopted accessibility best practices and guidelines.

Sign language (SL) perception involves the sensory and cognitive processes by which individuals visually interpret signed information conveyed through hand and body movements, facial expressions, and spatial structure [11]. This perceptual ability is shaped by both linguistic experience and visual motion processing systems [15].

Ensuring accessibility for the deaf community is paramount for both formal education and social inclusion. In scenarios where human interpreters are unavailable, particularly for continuous, round-the-clock communication access, private on-device interactions, and barrier-free content consumption [13], technologies such as signing avatars that automatically translate Portuguese text into Libras (synthesis) present a pressing and viable solution.

The adoption of 3D avatars for sign language synthesis is fundamentally motivated by the need for scalable, uniform, and adaptable digital accessibility solutions. Traditional video-based systems, which rely on recordings of human interpreters, are inherently constrained by challenges related to visual consistency. As the video repository are expanded or updated over time, they inevitably suffer from disruptive variations in lighting, background, attire, or the need to employ different interpreters. An avatar-based approach resolves these issues by separating the movement data from the graphical representation. By capturing raw sign movements via motion capture (MoCap) technology, the system allows all physical characteristics and environmental variables to be strictly altered within a digital environment. Consequently, this paradigm guarantees a cohesive, continuous user experience while allowing a highly sustainable and practical framework for the continuous expansion of accessible web content.

1.1 Related Literature

Avatar generation represents a fundamentally different computational challenge compared to sign-recognition systems. Rather than interpreting video input as text, avatar generation requires synthesizing linguistically coherent and visually natural behavior. Literature shows that the efficacy of realistic signing avatars depends heavily on the integration of both manual and non-manual signals, including torso movement and facial expressions, which are indispensable for sign language comprehension [17]. The simultaneous nature of sign language, with its dynamics of hand configurations, spatial trajectories, and facial expressions,

demands detailed animation and precise synchronization to achieve fluid, continuous communication [2]. Within this framework, facial expressions and lip movements are particularly critical, functioning as primary vehicles for expressing semantic nuance, grammatical marking, and emotional context [14].

Furthermore, presentation and control aspects are increasingly emphasized in accessibility standards. The Web Content Accessibility Guidelines (WCAG) 2.2 [27] recommend core features for web-based sign language avatars, notably the inclusion of pause, stop, and hide commands; mechanisms to control the avatar’s timing; and a minimum contrast ratio of 3:1 between the avatar, its control components, and adjacent background colors [27]. However, the literature, such as [16], identifies critical gaps in standards such as WCAG, including sign writing, the adaptation of captioning technologies, and inclusive captioning for paralinguistic and nonverbal information, and argues for the development of new solutions that move beyond minimum compliance to foster genuine inclusion.

Despite the increasing adoption of assistive technologies, current avatar-based sign language solutions still face substantial limitations. A primary visual challenge lies in selecting the appropriate balance between stylization and realism; consequently, many systems default to non-photorealistic, cartoon-like aesthetics [1]. While these stylized designs may be suitable in specific contexts [14], aiming for hyper-realistic human avatars often risks triggering the “uncanny valley” effect, thereby undermining user acceptance [4]. Furthermore, user studies indicate that while personalization is appreciated, functional customizations that directly enhance comprehensibility, such as adjustable signing speed and avatar scale, are less relevant over purely aesthetic modifications [14,18].

Beyond visual representation, the technical process of converting spoken language text into synthesized animated signed output remains a formidable obstacle. Because sign languages utilize spatial, non-linear grammars that are entirely distinct from written forms, traditional translation paradigms struggle to bridge the linguistic gap. Although intermediate gloss representations and motion capture techniques are widely employed to address this, they introduce their own limitations [28], particularly regarding the rigorous synchronization required across all visual articulators [1,28]. Ultimately, these computational and structural barriers are amplified when developing systems for Portuguese and Libras, as both are classified as low-resource languages within the general landscape of machine translation modeling.

While the development and evaluation of 3D avatars for sign language synthesis have seen considerable progress in recent years, significant computational and design hurdles persist. Surveying the technological landscape, Wolfe et al. [29] observed that avatar synthesis remains largely underexplored, currently characterized by fragmented and inadequate solutions. Reinforcing this perspective, Aziz and Othman [1] reviewed forty years of literature and pinpointed the critical absence of standardized evaluation metrics alongside a severe shortage of annotated datasets, while advocating for the creation of multi-sign language frameworks.

Shifting the focus from the underlying mechanics of synthesis to human-computer interaction, recent studies increasingly highlight the pivotal role of user reception. Soudi et al. [23], for example, explored how both intrinsic avatar traits and extrinsic demographic variables influence the cross-cultural acceptance of these assistive tools. Similarly, Chemnad and Othman [7] demonstrated that subjective user perception is intricately linked to the actual comprehension of the synthesized language. Finally, examining specific visual configurations, Wasserroth et al. [26] concluded that although aesthetic customization enhances the overall user experience and general acceptability, the fundamental intelligibility of the avatar relies almost entirely on the precise execution of handshapes and the presence of facial expressions.

1.2 Our Solution

To overcome the limitations identified in existing systems, this research introduces critical advancements in both the visual fidelity and the computational architecture of signing avatars. A primary objective is to develop a realistic, automatic 3D avatar capable of executing precise movements of the hands, arms, torso, and face. The high degree of movement realism is crucial, not only for ensuring strict grammatical accuracy but also for projecting the credibility and professionalism required for institutional web applications. Beyond the graphical representation, the proposed system addresses the structural complexities of automated synthesis via a comprehensive machine-translation pipeline. This framework translates Brazilian Portuguese text into an intermediate gloss representation, which subsequently drives the continuous synthesis of signs. Given that Portuguese and Libras are low-resource languages in the context of computational translation, developing this architecture is challenging, underscoring the need for robust, high-fidelity data acquisition strategies detailed in this study.

To support this computational pipeline, our work also introduces a novel sign language corpus specifically designed for avatar synthesis and the future training of sign recognition models. This dataset is grounded in the semantic domain of our university restaurant’s menu, focusing on the translation from Portuguese into Libras. Selecting this particular context provides a practical application that directly enhances a digital platform frequently accessed by the deaf academic community. Computationally, restricting the initial corpus to a specialized domain significantly reduces the overall vocabulary size and token variance. This constraint effectively mitigates early-stage modeling complexity, allowing for superior translation accuracy. Ultimately, this focused approach fulfills an immediate campus accessibility need while serving as a crucial proof of concept. A successful deployment within this controlled environment establishes a scalable foundation that can subsequently be adapted to a broader array of institutional web services.

This paper presents an integrated solution to enhance web accessibility by injecting a 3D avatar into HTML environments. The proposed interface gives the user granular control, allowing them to toggle on and off the avatar, position it freely, and adjust its presentation velocity. In parallel, we constructed a novel

corpus based on the linguistic domain of a university restaurant. This dataset currently works on the web system to feed the avatar and is designed to serve as a foundational resource for training future neural machine translation models.

The remainder of this work is structured as follows. Section 2 details the methodology for the web accessibility tool. Section 3 elaborates on the motion-capture acquisition setup and the subsequent data-processing pipeline. Section 4 discusses the limitations and performance of the methodology. Section 5 presents our final remarks.

2 Proposed Method

The proposed methodology is visually outlined in the flowchart presented in Figure 1. This section focuses on explaining the data-driven pipeline that operates during web content translation and drives the generation of the sign language avatar. At a high level, the system architecture actively scrapes and replicates the university restaurant website where the daily menu is published. Following data extraction, the system parses the relevant textual information into an intermediate gloss representation, dynamically embeds the avatar rendering components into the web page, and, upon user request, presents the corresponding sign language animations (detailed in Section 3).




Fig. 1: Overview of the proposed methodology. The orange components denote the scripts responsible for preparing the web page, as well as extracting and filtering relevant textual information. The pink module represents the web injection script that handles rendering our 3D avatar (Clara) on the screen. The element highlighted in blue indicates the kinematic data, which is recorded and post-processed from human motion capture sessions. Finally, the terminal stage illustrates the sign language synthesis, wherein the avatar actively communicates the user-selected text.

2.1 Web Integration

To enable the seamless integration of the machine translation system into web environments, a modular suite of software tools was created to automate the

entire data pipeline—from initial content acquisition to end-user presentation. Python [25] was chosen as the primary implementation language for its highly efficient text-processing capabilities and rich ecosystem of libraries tailored for web scraping and browser automation.

The proposed architectural framework is composed of two main modules: (i) a web crawler dedicated to comprehensive domain mapping; and (ii) a parsing engine responsible for text extraction, sentence segmentation, and the automated injection of the avatar’s accessibility interface. To empirically validate this methodology, a specialized pipeline was implemented to process the dynamically updated menu page of our university restaurants. Serving as a practical proof of concept, this application demonstrates the system’s operational viability and its seamless deployment within a real-world digital environment. The technical specifications and functionalities of these components are elaborated below.

2.2 Crawler

The initial phase of the web integration process involves systematically mapping the target domain. To automate this domain discovery, a dedicated script (`url_collector.py`) was engineered to operate as a specialized web crawler, explicitly tasked with harvesting internal hyperlinks.

Operationally, the algorithm initiates its traversal from a predefined seed URL. Using Python libraries (`Requests`), the script executes an HTTP GET request to fetch the raw HTML source code of the target page. After the retrieval, the system systematically parses the document’s architecture. The algorithm actively navigates the Document Object Model (DOM) tree ([21]) to locate and isolate anchor elements (specifically, `<a>` tags) that denote navigable links.

For every hyperlink identified during this structural traversal, the crawler’s extraction logic sequentially executes the following procedures:

1. **Attribute Extraction:** The algorithm isolates and retrieves the destination paths embedded within the `href` attributes of all identified link tags.
2. **URL Normalization:** To guarantee navigational integrity, the system dynamically resolves and converts all relative paths into fully qualified absolute URLs (`urllib`).
3. **Domain Filtering:** To confine the crawler’s scope and prevent unintended traversal to external websites, a strict verification protocol cross-references the host domain of each resolved link against the original seed URL. Only internal links matching the initial domain are used for further processing.
4. **Duplicate Filtering:** By storing the validated URLs into a `set` data structure, the system eliminates duplicate entries, thereby optimizing computational efficiency and preventing the redundant processing of identical web pages.

Furthermore, to enhance the tool’s flexibility, the script integrates a command-line interface (CLI) (`argparse`), which allows users to dynamically configure both the target seed URL and the designated output directory. The

culmination of this automated crawling process is the generation of a structured text document containing the fully sanitized and filtered list of internal hyperlinks. This comprehensive registry later functions as the foundational data input for the pipeline’s succeeding architectural component: the parser module.

2.3 Parser

Serving as the core computational engine of the proposed architecture, the parser systematically transforms the raw web pages harvested by the crawler into fully accessible, interactive user interfaces. This module is deployed as a single script tailored for the playback of pre-rendered video files (`parser_video.py`).

The parsing workflow commences with the comprehensive rendering of the target webpage. In contrast to traditional static extraction methods, the system instantiates an automated Google Chrome browser session (**Selenium** [22]). This dynamic rendering approach is essential for accurately processing modern web architectures heavily reliant on client-side JavaScript. It guarantees that the fully constructed Document Object Model (DOM), along with all required visual assets, including cascading style sheets (CSS) and dynamically loaded images, is successfully captured before data extraction begins.

Once the fully rendered DOM is acquired, the system initiates a rigorous textual processing phase (**Beautiful Soup** [21]). The algorithm systematically isolates structural text elements, such as headings, paragraphs, and lists. Later, a critical linguistic segmentation protocol is implemented using the Natural Language Toolkit (NLTK) [3]. By tokenizing extended text blocks into discrete, grammatically complete sentences, the algorithm ensures that the produced translation into glosses is executed at a semantic granularity optimal for accurate synthesis and user comprehension.

Following this segmentation, the parser dynamically annotates the underlying HTML markup. Each isolated sentence is structurally wrapped within a newly generated `<span>` tag, which is assigned the `.tracked` class identifier alongside a custom metadata attribute. This attribute explicitly links the text segment to its corresponding kinematic or video asset, thereby generating the finalized, accessibility-enhanced web page, as depicted in Figure 2. Meanwhile, the module aggregates these segmented texts into a structured CSV document, creating a comprehensive transcript that streamlines the ongoing management and production of the Libras translation corpus.

The `parser_video.py` variant is explicitly configured to optimize the web interface for pre-recorded video playback. Specifically, it targets the WebM format, leveraging its native alpha-channel transparency to achieve seamless, background-free rendering across contemporary web browsers.

Interface Front-End: End-user interaction within the enhanced web environment is facilitated by a dedicated player component, engineered as a dynamic widget utilizing the jQuery UI library [24]. This front-end module generates a resizable, floating viewport that seamlessly overlays the primary page content




Fig. 2: The modified web interface of the university restaurant, illustrating the successful structural injection and rendering of the interactive accessibility avatar.

and integrates functional controls that let users adjust the playback speed of the synthesized signing.

The visual and spatial behavior of this interface is governed by custom CSS stylesheets. By employing fixed spatial positioning, the system ensures that the translation viewport remains persistently visible, also during the user's vertical page scrolling. To enhance accessibility and provide immediate visual feedback, translatable textual elements are dynamically highlighted with interactive borders upon mouse hover. This intuitive signaling mechanism effectively guides deaf users toward the machine-translated components of the webpage.

Architecturally, the strict separation of the backend processing logic (Python) from the front-end presentation layers (JavaScript and CSS) provides the system with exceptional modularity. This strategic design choice ensures that the core parsing infrastructure can seamlessly support distinct visualization modalities, whether executing pre-rendered video playback or rendering a real-time 3D avatar, requiring only minimal modifications to the underlying source code.

3 Corpus

The development of robust, data-driven machine translation architectures and the synthesis of realistic sign language depend on rigorous, high-fidelity data acquisition protocols. To satisfy these technical requirements, this study implements the methodology detailed below. A comprehensive architectural overview

of this operational workflow is mapped in Figure 3. The proposed pipeline encapsulates the complete lifecycle of the linguistic data, tracking its progression from the initial processing of source Portuguese text to its materialization as a realistic signing avatar.

The dataset was constructed from the comprehensive annual menu provided by the university restaurant, yielding a preliminary set of raw Portuguese sentences (denoted as the initial stage in Figure 3). Subsequently, a rigorous translation protocol was implemented to review these source sentences, translate them into Libras (representing the second stage in Figure 3). This critical phase was carried out by a specialized team of three project members: one hearing and two deaf interpreters/translators, all with advanced fluency in Libras.




Fig. 3: Methodological flowchart detailing the generation of the restaurant domain corpus. The pipeline initiates with raw Portuguese sentences, advancing through systematic filtering and reference video creation. These videos are then used to guide the production of glosses, which support the accurate acquisition of motion capture (MoCap) data. Finally, the recorded kinematic data undergoes cleanup and processing before functioning as direct input for the web integration script, which ultimately drives the real-time rendering of the sign language avatar.

Translating intrinsically yields a high variance in potential linguistic outputs. Given that the objective of this corpus is to serve as a consistent training dataset for future sign language recognition neural networks and avatar synthesis, this variance poses a methodological challenge. Consequently, strict standardization of the Libras translations was necessary. However, because sign languages lack a writing system to capture complex spatio-temporal articulations, text-based documentation alone proved insufficient. To circumvent this limitation, reference videos were produced, constituting the third step in Figure 3, which will later inform the map-to-glosses process, represented by the fourth step in the flowchart.

As the methodology progresses, the subsequent phase involves motion capture (MoCap) acquisition. As illustrated on the left side of Figure 4, these recording sessions are conducted within a purpose-built laboratory environment. The facility is equipped with specialized hardware engineered to simultaneously track body kinematics and the highly granular, high-resolution positioning of the

hands and individual fingers. Furthermore, corroborating the consensus in the related literature discussed in Section 1.1, facial expressions constitute a fundamental grammatical and semantic component of sign language comprehension; therefore, robust facial motion tracking is seamlessly integrated into the capture protocol.




Fig. 4: Left panel: A Libras interpreter in the controlled green-screen environment of the motion capture laboratory, outfitted with a kinematic tracking suit equipped with reflective optical markers and a head-mounted facial capture apparatus. Right panel: A visualization from the data processing software, displaying the digitally reconstructed skeletal rig and demonstrating the high-fidelity, high-resolution reproduction of the captured human kinematics.

The execution of the motion capture protocol required a specialized, coordinated team comprising a fluent Libras signer to accurately articulate linguistic structures, a system operator dedicated to monitoring the quality and correctness of the generated data, and two hardware technicians responsible for ensuring temporal synchronization and camera operation. As depicted in the left panel of Figure 4, the recording environment utilized a controlled green-screen backdrop with the subject positioned centrally. The signer was outfitted in a purpose-built MoCap suit made of non-reflective black fabric, specifically designed to accommodate the attachment of 73 spherical retroreflective markers. A spatial array of fourteen near-infrared (IR) cameras surrounded the capture volume, continuously tracking these markers to enable algorithmic reconstruction of the subject’s skeletal hierarchy and joint trajectories in 3D space.

Given the fundamental syntactic and semantic role of non-manual expressions in Libras grammar, the body-movement optical tracking system was operated alongside a dedicated facial-capture helmet (Faceware [9]). By using a specialized head-mounted camera (HMC), the system guaranteed absolute temporal synchronization between intricate upper-limb kinematics and nuanced facial articulations. The resulting software-driven digital reconstruction of this captured data is illustrated in Figure 4’s right panel.

During the post-processing phase, the captured 3D spatial coordinates are synchronized with the extracted facial telemetry, spatially scaled, and tempo-

rally resampled at a consistent rate of 60 frames per second (fps). To mitigate mechanical jitter and eliminate unnatural kinematic artifacts, the raw skeletal data is spatially centralized in the software environment, followed by advanced noise-reduction filtering. Furthermore, in instances where hand movements temporarily occluded the HMC's view of the subject's face, disrupting the raw facial capture, algorithmic interpolation was applied afterward. This ensures unbroken temporal coherence and maintains fluid, naturalistic animation throughout the sequence. The culmination of this comprehensive data acquisition and processing pipeline is the finalized rendering of the 3D avatar, Clara, as presented in Figure 5.



Fig. 5: A side-by-side comparison illustrating the kinematic transfer process. The left panel displays the human interpreter outfitted with the specialized motion-capture bodysuit and optical markers. The right panel shows the final rendering of the 3D avatar, Clara, accurately mirroring the precise skeletal posture and synchronized facial expressions captured directly from the source performance.

4 Corpus Processing

The architecture of the university restaurant's web interface, specifically its reliance on dynamic content encapsulation within an `iframe` and JavaScript-driven tab navigation, required the engineering of a highly specialized parsing module. This component was explicitly designed to bypass the limitations of traditional static crawlers, which lack the capacity to execute the complex Document Object Model (DOM) interactions required to unveil dynamically loaded content across different days of the week.

To achieve this, the extraction algorithm leverages an external library to instantiate an automated web browser, thereby simulating human interaction. The operational sequence initiates by localizing the target `iframe` and shifting the automated driver's execution context. Following this contextual switch, the system maps the navigational DOM elements, more specifically, the interactive tabs representing individual days, and triggers a sequence of programmatic click

events. Crucially, the algorithm is programmed to await the complete rendering of the DOM for each respective day prior to harvesting the underlying HTML source code.

Regarding the administration of accessible content, a knowledge-based methodology was adopted, serving as a functional bridge while the AI-driven machine translation pipeline remains under active development. The system creates a CSV file (`text2video.csv`) that functions as a correspondence dictionary, mapping discrete Portuguese linguistic units (e.g., specific dish nomenclature, dietary observations) to their synthesized video or animation counterparts. Upon encountering an undocumented or new sentence in the menu corpus, the parser registers a fallback entry utilizing a unique cryptographic hash identifier. This fail-safe mechanism empowers the production team to seamlessly track, isolate, and generate missing assets without disrupting the system’s continuous runtime operation.

Furthermore, the textual processing also includes specific refinements through the implementation of regular expressions, such as the decomposition of dates (converting “dd/mm” to the full day and month names, to maximize the modular reuse of existing video assets—alongside the systematic segmentation of list elements predicated on HTML `<br>` tag. Ultimately, to safeguard the visual integrity of the interface, the script transposes all relative file paths governing cascading style sheets (CSS) and embedded images into absolute URLs. This critical operation ensures that the locally rendered page preserves the exact aesthetic identity of the original one.

The implementation of the proposed solution, combined with data acquisition methodologies, has yielded results extending far beyond the simple technical deployment of the accessibility utility. Crucially, this effort has enabled the production of invaluable empirical resources, thereby significantly advancing the broader study of Sign Language Machine Translation (SLMT).

The intensive motion capture initiative culminated in the establishment of a robust, high-fidelity Portuguese-Libras parallel corpus. The scale of the processed raw data, totaling approximately 150 GB and encompassing an estimated 2,400 distinct grammatical sentences, represents a relevant advancement over the linguistic resources previously available in the Brazilian academic and technological landscape.

Contextualizing these achievements against the current national state-of-the-art, it is apparent that this newly built corpus works towards solving the limitations of pre-existing databases. Whereas historical datasets have been predominantly constrained to isolated lexical signs or minimal pairs designed expressly for discrete recognition tasks, the kinematic material acquired in this study captures the full complexity of continuous, flowing sentence structures. Furthermore, the acquisition of comprehensive full-body MoCap data alongside high-resolution facial data enriches the dataset. It accurately preserves the prosodic and grammatical non-manual markers that are absolutely indispensable for modeling continuous machine translation, consequently, bridging a critical lacuna in contemporary computational frameworks.

Finally, the engineering of the video-optimized parser (`parser_video.py`) established a rigorous methodological foundation for a comprehensive qualitative evaluation, permitting a critical comparative analysis of its operational trade-offs within the complex context of applied web accessibility. While this video-centric paradigm gives the distinct advantage of visual fidelity to the original human articulation, ensuring naturalness and bypassing the computational complexities of avatar retargeting through a streamlined, native HTML5 implementation, it simultaneously introduces substantial logistical disadvantages. Specifically, this approach imposes a high bandwidth burden due to the need to download relatively large, sentence-specific video files, a limitation further exacerbated by persistent cross-browser rendering inconsistencies with WebM alpha channel transparency, most notably in the Apple ecosystem (Safari and iOS).

5 Conclusions

The study reported in the paper established a foundational technological infrastructure for the automated implementation of Brazilian Sign Language (Libras) captions within web environments. The developed architecture, specifically the crawler and parser modules, demonstrated high efficacy in automating website adaptation through granular textual segmentation and injection of accessibility interfaces. Practical validation conducted on the university restaurant’s portal underscored the solution’s robustness, maintaining the integrity of the original layout while ensuring fluid navigation through dynamic content. Consequently, this approach represents a significant advancement in web content accessibility through automatic 3D avatar signaling.

Furthermore, the development of the new corpus – comprising approximately 2,400 sentences and 150 GB of high-fidelity kinematic and facial data, augmented by the ongoing acquisition of supplementary datasets – establishes a valuable scientific asset that contributes to existing national repositories. Despite these advancements, field validations indicate that the current knowledge-based translation strategy exhibits inherent scalability limitations when processing the linguistic variability characteristic of uncontrolled natural language environments. These findings suggest that while the acquisition and visualization solutions are now established, the transition to other contexts will fundamentally require integrating neural machine translation models trained on the comprehensive corpus developed in this study.

6 Acknowledgement

Removed for blind review

7 Ethical Considerations

The Libras signers in this project are not just participants, they are paid team members and co-authors of this study. Deaf and hard-of-hearing researchers were

involved in every stage of the project, from designing the data collection process to writing the paper. This helps us make sure that the linguistic details of Libras are treated with care and that the technology we develop truly reflects the needs of the community. All team members gave their informed consent for the use of their images and biometric data in the corpus. Since the data was created by the research team specifically for this resource, the project follows the institutional ethical guidelines for collaborative research.

References

1. Aziz, M., Othman, A.: Evolution and Trends in Sign Language Avatar Systems: Unveiling a 40-Year Journey via Systematic Review. *Multimodal Technologies and Interaction* **7**(10), 97 (2023) 3
2. Bernhard, L., Nunnari, F., Unger, A., Bauerdiek, J., Dold, C., Hauck, M., Stricker, A., Baur, T., Heimerl, A., André, E., et al.: Towards Automated Sign Language Production: A Pipeline for Creating Inclusive Virtual Humans. In: *Proceedings of the 15th International Conference on Pervasive Technologies Related to Assistive Environments*. pp. 260–268 (2022) 3
3. Bird, S., Klein, E., Loper, E.: *Natural Language Processing with Python*. O'Reilly Media, Sebastopol, CA (2009) 7
4. Bragg, D., Koller, O., Bellard, M., Berke, L., Boudreault, P., Braffort, A., Caselli, N., Huenerfauth, M., Kacorri, H., Verhoef, T., et al.: Sign Language Recognition, Generation, and Translation: An Interdisciplinary Perspective. In: *21st International ACM SIGACCESS Conference on Computers and Accessibility*. pp. 16–31 (2019) 3
5. BRASIL (Presidência da República): Decreto nº 5.626, de 22 de dezembro de 2005. *Diário Oficial da União* (246, Seção 1) (Dec 2005) 2
6. BRASIL (Presidência da República): Lei nº 13.146, de 6 de julho de 2015. *Diário Oficial da União* (127, Seção 1) (Jul 2015) 2
7. Chemnad, K., Othman, A.: Perception and Monitoring of Sign Language Acquisition for Avatar Technologies: A Rapid Focused Review (2020–2025). *Multimodal Technologies and Interaction* **9**(8), 82 (2025) 4
8. Conrad, R.: *The Deaf Schoolchild*. Harper and Row (1979) 1
9. Faceware Technologies: Faceware Facial Motion Capture System. <https://facewaretech.com/> (2024), accessed in: 2026 apr. 25 10
10. Fernandes, S., Moreira, L.C.: Políticas de Educação Bilingue para Surdos: O Contexto Brasileiro. *Educar em Revista* (spe-2), 51–69 (2014) 1
11. Gimeno-Martínez, M., Costa, A., Baus, C.: Influence of Gesture and Linguistic Experience on Sign Perception. *The Journal of Deaf Studies and Deaf Education* **25**(1), 80–90 (2020) 2
12. IBGE: Pesquisa Nacional da Saúde. <https://agenciadenoticias.ibge.gov.br/agencia-sala-de-imprensa/2013-agencia-de-noticias/releases/31445-pns-2019-pais-tem-17-3-milhoes-de-pessoas-com-algum-tipo-de-deficiencia> (2019), accessed: 2026 apr. 25 1
13. Jaballah, K., Jemni, M.: A Review on 3D Signing Avatars: Benefits, Uses and Challenges. *International Journal of Multimedia Data Engineering and Management* **4**(1), 21–45 (2013) 2

14. Kipp, M., Nguyen, Q., Heloir, A., Matthes, S.: Assessing the Deaf User Perspective on Sign Language Avatars. In: 13th International ACM SIGACCESS Conference on Computers and Accessibility. pp. 107–114 (2011) 3
15. Krebs, J., Wilbur, R.B., Roehm, D., Malaia, E.: Neural Mechanisms of Event Visibility in Sign Languages. *Language, Cognition and Neuroscience* **38**(9), 1282–1301 (2023) 2
16. Loaiza-Ramírez, I., González-Beltrán, B.A.: Digital Accessibility Guidelines for Deaf and Hard of Hearing Persons: A State-of-the-Art Review Article. *Universal Access in the Information Society* **25**(1), 4 (2026) 3
17. Naert, L., Larboulette, C., Gibet, S.: A Survey on the Animation of Signing Avatars: From Sign Representation to Utterance Synthesis. *Computers & Graphics* **92**, 76–98 (2020) 2
18. Nolte, A., Gleißl, B., Heckmann, J., Wallach, D., Jochems, N.: “I Want To Be Able To Change The Speed And Size Of The Avatar”: Assessing User Requirements For Animated Sign Language Translation Interfaces. In: Extended Abstracts of the 2023 CHI Conference on Human Factors in Computing Systems. pp. 1–7 (2023) 3
19. Presidência da República: Lei número 6.001 (Dec 1973), *Diário Oficial da União*, Imprensa Nacional, n. 07, Seção 1 1
20. Presidência da República: Lei número 10.436 (Apr 2002), *Diário Oficial da União*, Imprensa Nacional, n. 79, Seção 1 2
21. Richardson, L.: Beautiful Soup Documentation. www.crummy.com/software/BeautifulSoup (2024), accessed in: 2026 apr. 25 6, 7
22. Selenium Project: Selenium Browser Automation. www.selenium.dev (2024), accessed in: 2026 apr. 25 7
23. Soudi, A., Hakkaoui, M.E., Van Laerhoven, K.: Do Predictability Factors Towards Signing Avatars Hold Across Cultures? *arXiv preprint arXiv:2307.02103* (2023) 4
24. The jQuery Foundation: jQuery UI. www.jqueryui.com (2024), accessed in: 2026 apr. 25 7
25. Van Rossum, G., Drake, F.L.: Python 3 Reference Manual. CreateSpace, Scotts Valley, CA (2009) 6
26. Wasserroth, F., Avramidis, E., Czehmann, V., Kojic, T., Nunnari, F., Möller, S.: Evaluation of a Sign Language Avatar on Comprehensibility, User Experience & Acceptability. In: 25th ACM International Conference on Intelligent Virtual Agents. pp. 1–10 (2025) 4
27. WCGA: Web Content Accessibility Guidelines 2.2. <https://www.w3.org/TR/WCAG22> (2024), accessed: 2026 apr. 25 3
28. Wolfe, R., Braffort, A., Efthimiou, E., Fotinea, E., Hanke, T., Shterionov, D.: Special Issue on Sign Language Translation and Avatar Technology. *Universal Access in the Information Society* **24**(1), 1–3 (2025) 3
29. Wolfe, R., McDonald, J.C., Hanke, T., Ebling, S., Van Landuyt, D., Picron, F., Krausneker, V., Efthimiou, E., Fotinea, E., Braffort, A.: Sign Language Avatars: A Question of Representation. *Information* **13**(4), 206 (2022) 3

Anexo 9

Relatório Bolsista - TT4A

Ângelo Brandão Benetti

Universidade Estadual de Campinas

**Faculdade de Engenharia Elétrica e de Computação da Universidade Estadual de
Campinas**

Relatório individual sintético

Agência de fomento: Fundação de Amparo à Pesquisa do Estado de São Paulo (FAPESP)

Título do projeto: Construção da base de dados do CCD-TAAL e desenvolvimento de avatar 3D.

Processo: 2024/18575-4. Bolsa vinculada ao Centro de Ciência para o Desenvolvimento - Tecnologia Assistiva e Acessibilidade em Libras. Processo Fapesp 2024/00914-7.

Bolsista: Ângelo Brandão Benetti

Responsável: José Mario De Martino

Vínculo Institucional do Processo: Bolsa de Treinamento Técnico Nível 4A

Período usufruído: 19 meses

Campinas, SP
30 de junho de 2026

1. Apresentação

Este relatório descreve as atividades realizadas no período de 01 de julho de 2025 a 30 de junho de 2026, desempenhadas pelo bolsista de treinamento técnico nível 4A, Ângelo Brandão Benetti, processo 2024/18575-4, bolsa vinculada ao Centro de Ciência para o Desenvolvimento - Tecnologia Assistiva e Acessibilidade em Libras. Processo Fapesp 2024/00914-7.

2. Descrição das atividades do bolsista

As atividades principais realizadas no período estão relacionadas à sistematização de sessões de gravações por captura de movimentos. Com o propósito de constituir a base de dados de animações 3D em Libras foram dedicados 70 dias de capturas de movimentos, registrando 5524 tomadas de gravação distribuídas em 9 temas variados. O volume de dados gerado no período é superior a 1TB.

Para fins de organização e usabilidade dos dados gerados, o bolsista realizou estudo das planilhas descritivas das atividades de gravação, com o propósito de proporcionar maior consistência, uniformidade e eficiência de busca por conteúdos filtrados por variados casos de uso, além de viabilizar múltiplos levantamentos estatísticos. A implementação dessa arquitetura da base de dados está em curso e deve ser concluída no próximo período de vigência da bolsa, até outubro de 2026.

No decurso do período, diversos aperfeiçoamentos foram implementados nos procedimentos de gravação, bem como foram incorporados novos recursos de equipamentos e softwares. Em junho de 2025, 2 câmeras Valkyrie, um novo computador e um switch de rede foram incorporados ao sistema do laboratório. Em outubro de 2025 foi adquirido e entrou em operação o sistema Faceware de captura de expressões faciais para animação 3D. O sistema Faceware é um conjunto composto por capacetes com hastes de suporte para câmera estabilizada frontalmente ao rosto do ator, que transmite por cabo ou sistema de rádio as imagens para monitores de vídeo e para a estação de gravação digital. A melhoria proporcionada por esse sistema está relacionada à maior consistência e estabilidade da aquisição de informações de expressões faciais, com significativa redução de oclusões, bem como maior confiabilidade e praticidade na sincronização com dados de captura corporal.

Foi adquirida uma versão atualizada do software Character Creator com recursos mais robustos para a representação geométrica do avatar bem como maior expressividade facial e postural, resultando em um avatar mais moderno, realista e expressivo.

Em atendimento à necessidade do projeto de ampliar a visibilidade e promover o engajamento com a comunidade, o bolsista desenvolveu, junto com a equipe do laboratório, um mecanismo de transmissão ao vivo de conteúdos sinalizados em tempo real, exibidos pelo avatar do projeto em interação com o público de eventos na área de acessibilidade. Em novembro de 2025 esse experimento aconteceu durante a Reatech - Feira Internacional de Inclusão, Acessibilidade e Reabilitação, considerada a principal feira do setor na América

Latina. E em dezembro de 2025 a mesma atividade foi realizada durante a Virada Inclusiva da UNICAMP.

No período deste relatório foram submetidos 3 artigos em que o bolsista contribuiu como co-autor:

- Sign Language Processing on Sign Language Terms:

A Visuospatially Grounded Annotation Framework; (Thyago Santos, Felipe Barbosa Venâncio, Sylvia Lia, Isabela Barbieri, Natália de Melo Afonso, and José Mario De Martino contributed to the development of the annotation framework. Guilherme Leite, José Carlos Ferreira, Yan Moro, and Giovanne Mariano created and recorded the Transportation Dialogues. Vagner Vaga, Felipe Kleine, Angelina Inácio, and Fábio Souza created the anamnesis dialogues. Ângelo Benetti is responsible for the motion capture recordings. Yan Prada Moro, Giovanne Mariano synthesized the discussions and wrote the initial drafts of the paper. Thyago Santos, Felipe Barbosa, Helio Pedrini, Vagner Gava, Guilherme Leite, José Carlos Ferreira, and José Mario De Martino provided critical revision of the manuscript. José Mario De Martino is the lead researcher who coordinated and supervised the writing of the paper.) - submetido, porém não aceito pelo evento PROPOR (International Conference on Computational Processing of Portuguese Language)

- The In-Car Sign Language Corpus (ICSL): A Multi-Modal Resource for Constrained-Space Sign Language Recognition; (Raviteja Boddu, Guilherme Vieira Leite, Joed Lopes da Silva, Ângelo Benetti, Isabela Barbieri, Natália de Melo Afonso, Thyago Santos, Helio Pedrini, Felipe Venâncio Barbosa, José Mario De Martino, Munir Georges, Alessandro Zimmer) - submetido e aceito na conferência LREC 2026 (Language Resources and Evaluation Conference)

- Concatenative Synthesis for Brazilian Sign Language; (Gustavo Borba da Silva, Ângelo Brandão Benetti, José Mario De Martino) - submetido ao TILIC 2026 (XI Workshop de Iniciação Científica em Tecnologia da Informação e da Linguagem Humana)

3. Avaliação do impacto das atividades do bolsista sobre o andamento do projeto

Os resultados parciais, fruto das atividades do bolsista, são relevantes para o conjunto das atividades previstas no projeto por comporem a tecnologia base de apresentação do conteúdo gerado em Libras pelo avatar sinalizador, atendendo ao núcleo da etapa de tradução 'glosa para sinal'. Dessa forma, o estabelecimento do protocolo de animação do avatar com dados de captura de movimentos e seu armazenamento na base de dados são subsídios para a via de exibição de conteúdo a ser sintetizado na tradução de textos em português para Libras.

Na via complementar de pesquisa e desenvolvimento do projeto, que é o reconhecimento de sinais de pessoas sinalizantes em Libras e tradução para o português, os dados gravados por captura de movimentos constituem ativo estruturante da base de dados

que viabilizará a aprendizagem de máquina, e assim a atividade do bolsista tem impacto relevante no conjunto do projeto.

4. Informar e justificar caso tenham ocorrido mudanças e, eventualmente, os ajustes realizados nas atividades de pesquisa do bolsista, em relação ao Plano de Atividades

As atividades estão em conformidade com o planejamento inicial.

5. Se for o caso, especificar:

a) O cronograma da próxima etapa do trabalho do bolsista no projeto;

No período subsequente a este relatório (01/07/2026 até 31/10/2026), as atividades do bolsista serão concentradas em pós-processamento de animações 3D previamente capturadas e estruturação / organização da base de dados de capturas de movimentos para animação do avatar 3D.

Também compõe o escopo desse período uma proposta de formalização do protocolo de armazenamento de dados 3D do projeto, de modo a atender tanto à reprodução de animações, como à iminente recombinação de elementos fracionados, e ainda fornecer dados tridimensionais para modelos de aprendizagem de máquina.

Na perspectiva de ampliação do período de vigência da bolsa para a totalidade da duração do projeto (até julho de 2029), novos conteúdos serão gravados e processados, ampliando a base de dados de animações 3D dentro dos temas: Transporte, Saúde e Alimentação, já iniciados na primeira fase de gravações, obedecendo ao cronograma a seguir:

- julho de 2026 a julho de 2029: gravações e geração de animações 3D;
- janeiro a julho de 2027: prova de conceito de avatar 3D, sinalizador de Libras em páginas web, por reprodução de frases completas;
- julho a dezembro de 2027: prova de conceito de avatar 3D, sinalizador de Libras em páginas web, por recombinação de fragmentos de animação;
- janeiro a dezembro de 2028: exploração de modelos de aprendizagem de máquina com dados 3D para síntese de animações;
- janeiro a julho de 2029: compilação geral dos resultados e apontamentos futuros da pesquisa.

b) Outras observações consideradas relevantes para a análise das atividades do bolsista por parte da FAPESP.

O programa 'Centro de Ciência para o Desenvolvimento', do qual faz parte o projeto CCD TAAL, prevê atividades de pesquisa e desenvolvimento no período de 5 anos, e o planejamento inicial pleiteou bolsas de Treinamento Técnico para o desenvolvimento de atividades durante toda a vigência. Entretanto, a norma para concessão de bolsas do

programa de capacitação técnica estabelece em seu artigo 3.1.1 que a vigência máxima é limitada ao período de 24 meses.

Em sintonia com o objetivo da modalidade de bolsas TT, que é treinar e aperfeiçoar técnicos e alunos de cursos técnicos de nível médio e superior que participem de atividades de apoio a projetos de pesquisa vigentes, financiados pela FAPESP, o bolsista entende que a continuidade de sua participação no projeto é uma oportunidade de aprofundar conhecimentos altamente especializados, junto a uma equipe de pesquisadores de ponta e infraestrutura laboratorial notavelmente avançada para os padrões, mesmo de mercado no Brasil.

Assim, o bolsista manifesta interesse e disponibilidade de avançar e aprofundar o desenvolvimento das atividades no projeto, ampliando suas competências mediante a capacitação técnica adquirida nesta experiência profissional.

6. Apreciação do pesquisador responsável do CCD-TAAL sobre o desempenho da bolsista

O bolsista Ângelo Brandão Benetti apresentou desempenho altamente satisfatório durante o período de vigência deste relatório, cumprindo integralmente o plano de atividades proposto e contribuindo de forma decisiva para o avanço do projeto.

Sua principal atuação concentrou-se na operação, aperfeiçoamento e sistematização da infraestrutura de captura de movimentos utilizada na construção da base de dados do projeto. Um volume importante de material foi gravado com a efetiva participação do bolsista e constitui um dos principais ativos do projeto, servindo de base para o desenvolvimento do avatar sinalizador e para as pesquisas em tradução neural.

Avalio o desempenho do bolsista como excelente, destacando sua competência técnica, comprometimento, autonomia e capacidade de contribuir para atividades de elevada complexidade técnica e científica, características que justificam plenamente a continuidade de sua participação no projeto.

Considerando a natureza da infraestrutura desenvolvida e a continuidade das atividades previstas para o CCD-TAAL, a manutenção da bolsa revela-se estratégica. O conhecimento técnico acumulado pelo bolsista sobre os protocolos de captura, processamento e organização dos dados representa um recurso estratégico para o projeto. A sua substituição demandaria um longo período de treinamento e adaptação. A continuidade de sua atuação permitirá consolidar a base de dados tridimensional, finalizar a estruturação dos protocolos de armazenamento e apoiar as etapas subsequentes de desenvolvimento do avatar sinalizador e dos modelos de inteligência artificial previstos no cronograma do projeto.

Anexo 10

Relatório Bolsista - TT4A

Isabela Cristina Barbieri

CENTRO DE CIÊNCIA PARA O DESENVOLVIMENTO TECNOLOGIA ASSISTIVA E ACESSIBILIDADE EM LIBRAS (CCD-TAAL)

RELATÓRIO INDIVIDUAL SINTÉTICO DE ATIVIDADES BOLSA DE TREINAMENTO TÉCNICO NÍVEL 4A (TT-4A)

Título do projeto: **Tradução e Interpretação de apoio às atividades do CCD-TAAL**

Processo da bolsa: 2025/02642-7

Projeto vinculado: Centro de Ciência para o Desenvolvimento – Tecnologia Assistiva e Acessibilidade em Libras, Processo FAPESP 2024/00914-7

Bolsista: Isabela Cristina Barbieri

Pesquisador Responsável: Prof. Dr. José Mario De Martino

Período reportado: 01/08/2025 a 30/06/2026

Período total de usufruto: 01/08/2025 a 31/07/2027

Próximo período previsto: 01/07/2026 a 30/06/2027

Campinas, SP

Data: 25 de junho de 2026

1. Descrição das atividades desenvolvidas

No período indicado, foi realizada a produção de conteúdos em libras por meio de vídeo, registrando a tradução de português para libras, com e sem a utilização de vestimenta especial de captura de movimento (MoCap) - que permite o rastreamento e a transmissão de expressões e gestos dedicados diretamente para o Avatar computacional. Esta etapa foi seguida da respectiva tradução de libras para o português e da anotação linguística detalhada em glosas. Adicionalmente, houve colaboração ativa na definição do formalismo dessa anotação e na estruturação da base de dados do CCD-TAAL, bem como atuação direta na etapa de avaliação dos resultados e dos artefatos gerados pelo projeto.

Além das atividades listadas acima, a bolsista participou ativamente de reuniões de tradução de sentenças do português para libras e também frequentou semanalmente as reuniões de planejamento e alinhamento, contribuindo com avaliações linguísticas e técnicas relacionadas à tradução, à anotação e ao desenvolvimento das tecnologias do projeto. Vale ainda mencionar que houve participações na Reatech - Feira Internacional de Inclusão, Acessibilidade e Reabilitação, e na Virada Inclusiva - realizada na Unicamp -, eventos nos quais a bolsista atuou durante as apresentações do Centro e na interação com o público.

2. Mudanças ou ajustes em relação ao Plano de Atividades

O cronograma do Plano de Atividades original foi cumprido sem alterações substanciais em seu escopo. O foco das ações direcionou-se de maneira mais intensa no que se refere ao desenvolvimento e à aplicação prática do formalismo metodológico, bem como à tradução de sentenças de português para libras e de libras para a língua portuguesa, bem como para a elaboração de glosas. Adicionalmente, os esforços concentraram-se na validação técnica de dados direcionados à construção do avatar computacional e ao suporte contínuo à comunicação bilíngue entre os integrantes da equipe do projeto.

3. Impacto das atividades sobre o andamento do projeto

As atividades desenvolvidas pela bolsista foram fundamentais para o avanço estrutural do projeto, com impacto direto na criação, consolidação e documentação do banco de dados do CCD-TAAL. O estabelecimento de um formalismo de anotação padronizado colaborou diretamente para fornecer critérios linguísticos rigorosos para a descrição de dados em libras, otimizando o fluxo de trabalho computacional dentro do software ELAN. A produção sistemática de vídeos sinalizados, acompanhada de traduções para o português e da formação de suas respectivas glosas gerou um *corpus* robusto de dados empíricos essenciais para alimentar os modelos de Processamento de Linguagem Natural (PLN).

4. Plano de atividades para o próximo período

No período de 01/07/2026 a 30/06/2027, a bolsista dará continuidade à aplicação, à revisão e à documentação do formalismo de anotação multimodal em ELAN. Prosseguirá com a tradução de sentenças de libras para o português e vice-versa, bem como com a gravação de vídeos traduzindo sentenças de português para libras e com a produção de glosas e anotações, assim como se dedicará ao controle de qualidade dos dados destinados ao processamento automático de linguagem.

Para este período, planeja-se também ministrar um curso de libras aos integrantes do CCD-TAAL e realizar o treinamento dos novos membros da equipe no uso do ELAN.

Cronograma resumido:

Julho de 2026 a junho de 2027: continuidade das traduções, gravações e anotações; consolidação do formalismo; curso de libras; treinamento dos novos integrantes no ELAN.

Novembro de 2026 a junho de 2027: revisão e controle de qualidade dos dados; acompanhamento das anotações realizadas pelos novos integrantes; apoio à preparação do *corpus* de dados empíricos para PLN; avaliação de resultados computacionais e sistematização da documentação produzida.

5. Outras observações relevantes

As atividades desenvolvidas exigem conhecimento especializado de libras, experiência em tradução e interpretação e domínio do ELAN. As contribuições da bolsista são relevantes ao desenvolvimento das atividades planejadas e essenciais ao desenvolvimento do Centro, por isso a continuidade da bolsa é altamente estimulada.

As atividades desenvolvidas propiciaram o amadurecimento técnico em questões associadas à tradução português-libras e à pesquisa de tradução automática, alinhando-se, assim, aos objetivos da bolsa TT4-A.

6. Apreciação do Pesquisador Responsável do CCD-TAAL sobre o desempenho do bolsista

A bolsista demonstrou elevado comprometimento e excelente desempenho no desenvolvimento das atividades previstas para o período, evidenciando domínio técnico, rigor na execução das tarefas e capacidade de atuar em um ambiente multidisciplinar que integra linguística, tecnologia assistiva e inteligência artificial.

Sua participação foi particularmente relevante em atividades que exigem um elevado grau de especialização em Libras, tradução e anotação linguística. A qualidade das contribuições oferecidas teve impacto direto na confiabilidade dos dados produzidos pelo projeto, aspecto essencial para o desenvolvimento das bases de dados e dos modelos computacionais que constituem o núcleo tecnocientífico do CCD-TAAL.

Considero, portanto, que a bolsista apresentou desempenho excelente durante o período avaliado, cumprindo plenamente os objetivos estabelecidos para a bolsa TT-4A e contribuindo de forma significativa para o avanço científico e tecnológico do projeto. Em razão da natureza especializada das atividades desempenhadas e da experiência acumulada, a continuidade da bolsa é altamente recomendável para assegurar o progresso das próximas etapas do CCD-TAAL.

Anexo 11

Relatório Bolsista - TT4A

Natalia Najyme de Melo Afonso

CENTRO DE CIÊNCIA PARA O DESENVOLVIMENTO TECNOLOGIA
ASSISTIVA E ACESSIBILIDADE EM LIBRAS CCD-TAAL

RELATÓRIO INDIVIDUAL SINTÉTICO DE ATIVIDADES BOLSA DE
TREINAMENTO TÉCNICO NÍVEL 4A (TT-4A)

Título do projeto: **Tradução e Interpretação de apoio às atividades do CCD-TAAL**

Processo da bolsa: 25/07354-0

Projeto vinculado: Centro de Ciência para o Desenvolvimento – Tecnologia Assistiva e Acessibilidade em Libras, Processo FAPESP 2024/00914-7

Bolsista: Natalia Najyme de Melo Afonso

Pesquisador Responsável: Prof. Dr. José Mario De Martino

Período reportado: 01/06/2025 a 30/06/2026

Período total de usufruto: 01/06/2025 a 31/05/2027

Próximo período previsto: 01/07/2026 a 31/05/2027

Campinas, SP

Data: 25 de junho de 2026

1. Descrição das atividades desenvolvidas

As atividades desenvolvidas no referido período concentraram-se na produção e organização de dados para as bases do CCD-TAAL. Inicialmente, foram realizadas traduções de sentenças do português para a Libras, seguidas da gravação de vídeos de referência utilizados como base para as sessões de gravação de vídeo e de dados de captura de movimento (Motion Capture – MoCap). Durante as sessões de gravação de vídeo e de dados de MoCap, a bolsista atuou como informante em Libras e como controladora da qualidade da sinalização realizada por outros intérpretes. Os dados gravados são fundamentais para o desenvolvimento do projeto e estão sendo utilizados para a construção e animação do avatar sinalizante, bem como para o treinamento de modelos computacionais de tradução automática baseados em aprendizado de máquina.

Adicionalmente, a bolsista participou do processo de anotação linguística dos vídeos utilizando glosas, colaborando também na definição e no aperfeiçoamento do formalismo de anotação adotado pelo CCD-TAAL. Participou ainda da validação dos dados produzidos e da avaliação dos artefatos desenvolvidos pela equipe de pesquisa.

A bolsista manteve participação assídua nas reuniões de tradução, anotação e planejamento do projeto, contribuindo para o aperfeiçoamento dos processos de tradução, anotação linguística e desenvolvimento das tecnologias assistivas do Centro.

Também participou de atividades de divulgação científica e extensão, atuando em eventos como a Reatech – Feira Internacional de Inclusão, Acessibilidade e Reabilitação – e Virada Inclusiva, apresentando ao público os objetivos do CCD-TAAL e o avatar sinalizante em desenvolvimento.

2. Mudanças ou ajustes em relação ao Plano de Atividades

Não ocorreram mudanças significativas em relação ao Plano de Atividades original. As atividades se concentraram de forma mais intensa no desenvolvimento e aplicação do formalismo, na tradução de sentenças de libras para português (com e sem MoCap), na produção de glosas, na avaliação para produção do avatar e no apoio à comunicação bilíngue da equipe.

3. Impacto das atividades sobre o andamento do projeto

As atividades desenvolvidas contribuíram diretamente para o avanço das pesquisas do CCD-TAAL, especialmente na consolidação da base de dados utilizada no desenvolvimento das tecnologias de tradução automática entre português e Libras.

A produção sistemática de vídeos em Libras, acompanhada da tradução para o português e da anotação por glosas, resultou na ampliação de um corpus linguístico consistente, utilizado no treinamento, validação e avaliação de modelos de Processamento de Linguagem Natural e de tradução automática.

Além disso, a definição e aplicação de um formalismo padronizado de anotação proporcionaram maior consistência linguística aos dados produzidos, aumentando a qualidade das anotações realizadas no software ELAN e tornando mais eficiente o fluxo de processamento e organização da base de dados. Os dados produzidos também constituem a base para a geração das animações do avatar sinalizante em desenvolvimento e treinamento dos modelos neurais de tradução automática.

4. Plano de atividades para o próximo período

No período de 01/06/2026 a 30/06/2027, a bolsista dará continuidade à aplicação, à revisão e à documentação do formalismo de anotação multimodal em ELAN. Prosseguirá com a tradução de sentenças de português para libras e de libras para o português por meio de vídeos e glosagem, com a produção de glosas e anotações e com o controle de qualidade dos dados destinados ao processamento automático de linguagem.

Para este período, a bolsista planeja ainda ministrar um curso de libras aos integrantes do CCD-TAAL e realizar o treinamento dos novos membros da equipe no uso do ELAN .

Cronograma resumido:

Julho de 2026 a maio de 2027: continuidade das traduções, gravações e anotações; consolidação do formalismo; curso de libras; treinamento dos novos integrantes no ELAN.

Janeiro de 2027 a maio de 2027: revisão e controle de qualidade dos dados; acompanhamento das anotações realizadas pelos novos integrantes; apoio à preparação do *corpus* de dados empíricos para PLN; avaliação de resultados computacionais e sistematização da documentação produzida.

5. Outras observações relevantes

As atividades desenvolvidas exigem conhecimento especializado em Libras, experiência em tradução e interpretação, domínio do software ELAN e familiaridade com o formalismo de anotação adotado pelo CCD-TAAL.

A continuidade da bolsa permitirá a manutenção dessas atividades, essenciais à construção das bases de dados, ao desenvolvimento do avatar sinalizante e ao avanço das pesquisas conduzidas pelo Centro.

O aperfeiçoamento da bolsista e seu treinamento para apoiar as atividades de pesquisa do CCD-TAAL são compatíveis com os objetivos da bolsa TT-4A.

6. Apreciação do Pesquisador Responsável do CCD-TAAL sobre o desempenho do bolsista

A bolsista apresentou desempenho exemplar durante o período de vigência da bolsa, executando as atividades previstas no Plano de Atividades com elevado comprometimento, qualidade técnica e participação contínua nas ações do CCD-TAAL.

Sua atuação foi fundamental na produção e organização das bases de dados do projeto, especialmente nas atividades de tradução entre português e Libras, gravação de vídeos e sessões de captura de movimento (MoCap), nas quais atuou tanto como informante em Libras quanto no controle da qualidade linguística da sinalização produzida. Essas atividades são essenciais para a construção das bases de dados utilizadas no desenvolvimento do avatar sinalizante e dos modelos neurais de tradução automática.

As atividades desenvolvidas evidenciam a aquisição e o aprimoramento de competências técnicas e científicas compatíveis com os objetivos da bolsa TT-4A. A bolsista vem demonstrando evolução profissional, capacidade de trabalho em equipe, responsabilidade na execução das atividades e domínio crescente

dos procedimentos de tradução, anotação e organização de bases de dados em Libras.

Considerando a relevância de sua contribuição para o andamento do projeto e a qualidade do trabalho desenvolvido, considero o desempenho da bolsista mais do que satisfatório. A continuidade da bolsa permitirá consolidar as competências adquiridas e assegurar a continuidade de atividades essenciais para a construção das bases de dados, o desenvolvimento do avatar sinalizante e o avanço das pesquisas conduzidas pelo CCD-TAAL.

Anexo 12

Relatório Bolsista - TT4A

Thyago de Souza Santos

CENTRO DE CIÊNCIA PARA O DESENVOLVIMENTO TECNOLOGIA
ASSISTIVA E ACESSIBILIDADE EM LIBRAS CCD-TAAL

RELATÓRIO INDIVIDUAL SINTÉTICO DE ATIVIDADES BOLSA DE
TREINAMENTO TÉCNICO NÍVEL 4A (TT-4A)

Título do projeto: Construção da base de dados do CCD-TAAL, processos de
tradução e interpretação do par linguístico libras-português e estudos de captura
de movimento e rastreamento ocular

Processo da bolsa: 2025/01019-4

Projeto vinculado: Centro de Ciência para o Desenvolvimento – Tecnologia
Assistiva e Acessibilidade em Libras, Processo FAPESP 2024/00914-7

Bolsista: Thyago de Souza Santos

Pesquisador Responsável: Prof. Dr. José Mario De Martino

Período reportado: 01/07/2025 a 30/06/2026

Período total de usufruto: 01/03/2025 a 30/06/2026

Próximo período previsto: 01/07/2026 a 28/02/2027

Campinas, SP

Data: 25 de junho de 2026

1. Descrição das atividades desenvolvidas

No período reportado, o bolsista participou do desenvolvimento, do refinamento e da aplicação do formalismo de anotação multicamada no ELAN. O formalismo, concebido e desenvolvido pelo bolsista em colaboração com outros integrantes do CCD-TAAL, reúne critérios para segmentar, organizar, glosar e descrever dados em libras. Inclui trilhas de anotação para sinais realizados pelas mãos direita e esquerda, apontamentos, boias, datilologia, gestos, ações faciais e bucais e direcionamento do olhar.

O bolsista realizou anotações-teste no ELAN para verificar a aplicabilidade do formalismo, identificar ambiguidades e ajustar os critérios de segmentação e descrição. Essas atividades contribuíram para a produção e o controle de qualidade do corpus paralelo e multimodal português-libras.

Também traduziu sentenças do português para libras e, em seguida, glosou e descreveu as produções sinalizadas no ELAN, contribuindo com a referida fase de testes. Essa atividade provê dados paralelos e anotados para o processamento automático de linguagem, especialmente para o desenvolvimento e a avaliação de modelos de tradução automática e reconhecimento de libras.

Nas reuniões semanais do projeto, atuou como intérprete do par linguístico libras-português, assegurando a comunicação entre participantes surdos e ouvintes. Participou ainda das avaliações de inteligibilidade e adequação linguística do avatar, considerando a clareza das formas manuais, o uso do espaço, a organização temporal dos sinais, as expressões não manuais e a inteligibilidade geral.

O bolsista acompanhou as reuniões semanais de planejamento e alinhamento, contribuindo com avaliações linguísticas e técnicas relacionadas à tradução, à anotação e ao desenvolvimento das tecnologias do projeto. Para mais, participou da Reatech - Feira Internacional de Inclusão, Acessibilidade e Reabilitação, uma das maiores feiras da América Latina, junto à equipe do CCD-TAAL.

2. Mudanças ou ajustes em relação ao Plano de Atividades

Não ocorreram mudanças significativas em relação ao Plano de Atividades original. Houve maior concentração nas atividades de desenvolvimento e aplicação do formalismo, tradução de sentenças do português para libras, produção de glosas, avaliação do avatar e apoio à comunicação bilíngue da equipe.

Esses ajustes decorreram das necessidades do projeto e permaneceram compatíveis com os objetivos da bolsa TT-4A.

3. Impacto das atividades sobre o andamento do projeto

As atividades do bolsista contribuíram diretamente para a construção e a documentação da base de dados do CCD-TAAL. O formalismo de anotação fornece critérios comuns para a descrição dos dados em libras e orienta sua aplicação no ELAN.

A tradução de sentenças do português para libras, seguida da produção de glosas e anotações, provê dados para as atividades de processamento automático de linguagem. A interpretação das reuniões favoreceu a participação dos integrantes surdos, e as avaliações do avatar contribuíram para a identificação de problemas de inteligibilidade e adequação linguística.

A experiência do bolsista em tradução e interpretação de libras e sua formação em linguística contribuíram para aproximar as necessidades linguísticas das atividades computacionais do projeto.

4. Plano de atividades para o próximo período

No período de 01/07/2026 a 28/02/2027, o bolsista dará continuidade à aplicação, à revisão e à documentação do formalismo de anotação multimodal em ELAN. Prosseguirá com a tradução de sentenças do português para libras, a produção de glosas e anotações e o controle de qualidade dos dados destinados ao processamento automático de linguagem.

Ministrará também um curso de libras aos integrantes do CCD-TAAL e realizará o treinamento dos novos membros da equipe no uso do ELAN e na aplicação do formalismo de anotação.

Entre 9 e 17 de setembro de 2026, planeja realizar missão acadêmica internacional vinculada ao projeto. A programação incluirá apresentação de trabalho no MMSYM 2026, na Bélgica, visita técnica à Universidade de Leiden, nos Países Baixos, e visita à Universidade de Hamburgo e ao IDGS, na Alemanha. As atividades estarão relacionadas à anotação multimodal, às línguas de sinais, à tradução automática, às bases de dados e ao rastreamento ocular.

Cronograma resumido:

Julho a outubro de 2026: continuidade das traduções e anotações; consolidação do formalismo; curso de libras; treinamento dos novos integrantes; realização da missão acadêmica internacional.

Novembro de 2026 a fevereiro de 2027: revisão e controle de qualidade dos dados; acompanhamento das anotações realizadas pelos novos integrantes; apoio à preparação do corpus; avaliação de resultados computacionais e sistematização da documentação produzida.

5. Outras observações relevantes

A atuação do bolsista exige conhecimento especializado de libras, experiência em tradução e interpretação, domínio do ELAN e capacidade de aplicar e transmitir procedimentos de anotação linguística.

A continuidade do bolsista é muito relevante para a produção e a revisão dos dados, para a formação dos atuais e de novos integrantes, para viabilizar a tradução do par libras-português e para a aplicação consistente do formalismo no corpus do CCD-TAAL.

O suporte às atividades de pesquisa do Centro e a experiência adquirida pelo bolsista em um projeto multidisciplinar alinham-se aos objetivos da Bolsa TT-4A.

6. Apreciação do Pesquisador Responsável do CCD-TAAL sobre o desempenho do bolsista

O bolsista apresentou desempenho excelente durante o período de vigência deste relatório, cumprindo integralmente as atividades previstas no Plano de Trabalho e contribuindo de forma significativa para o avanço dos objetivos científicos e tecnológicos do CCD-TAAL.

Sua atuação foi fundamental no desenvolvimento, refinamento e validação da versão atual do formalismo de anotação multicamada utilizado pelo projeto. A participação ativa na concepção, aplicação e revisão do formalismo permitiu identificar inconsistências, aperfeiçoar critérios de segmentação e descrição linguística e consolidar procedimentos de anotação que serão adotados na

construção do corpus multimodal Libras–português. Trata-se de uma contribuição estruturante para o projeto, uma vez que a qualidade e a padronização das anotações são fatores determinantes para o desenvolvimento e a avaliação de modelos computacionais de reconhecimento e tradução automática de Libras.

Dessa forma, avalio o desempenho do bolsista como excelente, destacando seu elevado comprometimento, competência técnica e científica, capacidade de trabalho colaborativo e contribuição decisiva para a integração entre os aspectos linguísticos e computacionais do projeto, justificando plenamente a continuidade da bolsa.

Sua experiência como tradutor e intérprete de libras, sua formação em linguística e sua participação na formação dos novos integrantes têm contribuído para o desenvolvimento das atividades do CCD-TAAL.

Anexo 13

Relatório Bolsista - PD

Guilherme Vieira Leite

FAPESP
Relatório Científico
Bolsa Pós-Doutorado

Guilherme Vieira Leite

Junho 2026

Processo FAPESP: 2025/12630-6

Título: Centro de Ciência para o Desenvolvimento - Tecnologia Assistiva e Acessibilidade em Libras (CCD-TAAL)

Pesquisador Responsável: Prof. Dr. José Mario De Martino (FEEC/UNICAMP)

Bolsista: Dr. Guilherme Vieira Leite (PD - FAPESP)

Período do Relatório: 1º de agosto de 2025 a 30 de junho de 2026

Data de Início da Bolsa: 1º de agosto de 2025

Data de Término do Projeto: 31 de julho de 2028

1 Resumo do Projeto Proposto

O Centro de Ciência para o Desenvolvimento - Tecnologia Assistiva e Acessibilidade em Libras (CCD-TAAL) constitui uma iniciativa multidisciplinar que congrega pesquisadores da Universidade Estadual de Campinas (UNICAMP), Universidade de São Paulo (USP) e do Instituto de Pesquisas Tecnológicas (IPT), operando em cooperação estreita com a Secretaria Estadual dos Direitos da Pessoa com Deficiência. A missão central do CCD-TAAL reside na concepção e no avanço de soluções voltadas à atenuação das barreiras comunicacionais existentes entre as comunidades surda e ouvinte. Inserido nesse panorama institucional amplo, meu plano de pesquisa de Pós-Doutorado direciona-se a mitigar essa problemática mediante o desenvolvimento de metodologias para a tradução automática bidirecional entre a Língua Brasileira de Sinais (Libras) e o português. Para tanto, investigo e aplico técnicas avançadas de aprendizado de máquina fundamentadas em arquiteturas de redes neurais profundas. Essa proposta científica encontra-se estritamente alinhada às diretrizes estratégicas estabelecidas pela Chamada da FAPESP, que preconiza o fomento a pesquisas em inteligência artificial aplicadas à acessibilidade.

2 Realizações no Período

2.1 Desenvolvimento e Avaliação de Modelos (Tradução e Reconhecimento SLT)

Nesta que é a frente principal do meu plano de trabalho, dediquei-me à codificação e à experimentação em Reconhecimento Contínuo de Língua de Sinais (CSLR - *Continuous Sign Language Recognition*). Reproduzi o código disponível pelos autores [1] (SLT) e executei os primeiros experimentos computacionais utilizando o cluster de alto desempenho da THI e comparei com as métricas obtidas nas máquinas do Brasil. Minhas principais realizações técnicas incluem:

- **Reconhecimento de Libras Vídeo-para-Glosa (*Sign2Gloss*):** Realizei a reprodução e implementação de uma abordagem baseada na arquitetura *Transformer* [1]. Configurei o treinamento multitarefa, utilizando o conjunto de dados em arquitetura *Sign2Gloss* e *Sign2Text* visando permitir que o aprendizado das características de reconhecimento contribua diretamente para a otimização da tradução. Tenho me dedicado, continuamente e paralelamente, à construção e validação de uma arquitetura de Rede Neural Convolucional 3D (I3D) voltada à extração otimizada de *features* visuais, que comporão a entrada de dados para o *encoder* da rede de reconhecimento e tradução.

Conduzi os testes preliminares do modelo localmente no *dataset* RWTH-PHOENIX-Weather 2014T, computando cerca de 16 horas de treinamento ao longo de 31 épocas, alcançando uma Taxa de Erro de Palavra (WER) de 42,92 na tarefa de reconhecimento (*sign2gloss*). A fim de avaliar o ganho computacional, repliquei esse mesmo experimento no *cluster* HPC da THI. Observou-se uma redução drástica no tempo de execução, atingindo 35 épocas em um tempo total de apenas 40 minutos, mantendo resultados compatíveis (WER 45,08).

Consolidada na literatura da área, a base de dados RWTH-PHOENIX-Weather 2014T fornece registros em vídeo da Língua de Sinais Alemã (DGS) alinhados a anotações estruturadas em glosas e suas respectivas traduções para o alemão escrito. As avaliações mostraram uma melhora da abordagem implementada frente a métodos anteriores, com impactos positivos em ambas as tarefas. No reconhecimento contínuo de sinais, o modelo obteve uma redução considerável na métrica WER, e também, na tarefa de tradução, obteve ganhos expressivos nas métricas de avaliação, o BLEU e suas variantes.

Ainda no ambiente do *cluster* da instituição alemã, enfrentei desafios técnicos operacionais na integração de um outro código desenvolvido paralelamente no Brasil. A alta complexidade na árvore de dependências das bibliotecas fez com que o gerenciador de pacotes (*pip*) demandasse um tempo de resolução de conflitos superior ao tempo limite de alocação permitido pelo *job* do *cluster*, resultando no encerramento forçado do processo. Apesar das tentativas sistemáticas de mitigação, como a redução dos requerimentos ao estritamente essencial, a infraestrutura limitava o tempo necessário para a configuração do ambiente. A superação desse gargalo na resolução de dependências continuará sendo tratada na próxima fase.

- **Tradução de Libras Vídeo-para-Texto (*Sign2Text*):** O mesmo modelo citado anteriormente também produz uma tradução vídeo-para-texto e o experimento foi realizado sobre as mesmas condições

descritas no item anterior. Os resultados obtidos na tarefa de tradução foram de BLEU-1 48,90, BLEU-2 36,88, BLEU-3 29,45 e BLEU-4 24,54, que são significativamente superiores aos trabalhos anteriores ao [1]. Após essa etapa, novamente executei esse mesmo experimento no *cluster* HPC, que obteve resultados similares, porém, obtidos em tempo muito inferior, BLEU-1 45,60, BLEU-2 31,80, BLEU-3 24,18, BLEU-4 19,46.

2.2 Infraestrutura, Coordenação e Capacitação

Durante o período avaliado, participei ativamente de diversas atividades de cunho administrativo, de infraestrutura, alinhamento da equipe e pesquisa. Integrei as reuniões semanais estabelecidas com os pesquisadores do projeto, as quais foram essenciais para a difusão de informações entre os membros da equipe e para o levantamento e discussão das dificuldades encontradas no desenvolvimento de minhas pesquisas. Também participei de reuniões estratégicas com a empresa Associação Amigos Metroviários dos Excepcionais (AME) e com os pesquisadores da Technische Hochschule Ingolstadt (THI).

Tive a oportunidade de obter expressivo ganho de conhecimento por meio de um intercâmbio internacional. Acompanhei de perto a visita dos pesquisadores da Technische Hochschule Ingolstadt (THI), Joed Lopes da Silva e Raviteja Boddu (18 a 28 de agosto de 2025), bem como a visita do Prof. Munir (23 a 27 de agosto de 2025) à UNICAMP, colaborando no alinhamento de protocolos de pesquisa, apresentação de infraestrutura e suporte às atividades de aquisição de dados. Também realizei visita técnica à Alemanha para alinhamento contínuo dos protocolos internacionais.

Do ponto de vista de infraestrutura e processamento de dados sob minha responsabilidade, auxiliei na especificação e acompanhei a compra das máquinas dedicadas ao projeto. Adicionalmente, durante minha visita técnica de 13 dias à THI realizada entre 7 e 19 de junho de 2026, dada minha participação como pesquisador associado do projeto Unity (processo Fapesp 24/23068-4), que detalharei na Seção 2.4 deste relatório.

2.3 Estabelecimento de Protocolos de Aquisição

Para garantir a qualidade na aquisição dos dados em vídeo essenciais para o treinamento de meus modelos, participei da elaboração e na padronização de protocolos de captura. Durante as atividades de visita do grupo da THI, atuei em conjunto com a equipe estrangeira na preparação da infraestrutura necessária para a aquisição de dados, envolvendo aquisição de scripts de software, disposição de câmeras no ambiente veicular e acesso à recursos computacionais. Auxiliei no estabelecimento do protocolo de gravação em veículos (desenvolvido na THI) e de um protocolo de captura RGB geral na UNICAMP. Participei também da implementação do sistema de armazenamento dos vídeos e atuei no desenvolvimento/coordenação do código computacional de controle unificado para captura sincronizada das câmeras.

2.4 Visita Técnica à Technische Hochschule Ingolstadt (THI)

Entre os dias 7 e 19 de junho de 2026, realizei uma visita técnica à *Technische Hochschule Ingolstadt* (THI), na Alemanha. Essa missão teve como objetivo fortalecer a parceria institucional entre os laboratórios, promover o intercâmbio tecnológico e acelerar o desenvolvimento das frentes de modelagem e aquisição de dados do projeto.

Durante a estadia, obtive acesso ao *cluster* de Computação de Alto Desempenho (HPC) da instituição. Nesse ambiente, reproduzi experimentos computacionais realizados no Brasil, a fim de me familiarizar com o ambiente de submissão de tarefas ao cluster. Os testes foram executados utilizando a base de dados RWTH-PHOENIX-Weather 2014T, amplamente adotada na literatura de reconhecimento e tradução de sinais, e os resultados obtidos foram avaliados quantitativamente com base nas métricas de desempenho *Word Error Rate* (WER) [3] e BLEU [2] e suas variantes. Como um desdobramento dessa visita, a equipe alemã viabilizou o caminho necessário para que eu possa continuar submetendo e executando meus experimentos remotamente no *cluster* da THI a partir do Brasil.

No que tange à infraestrutura de captura de dados, inspecionei presencialmente o ambiente de gravações no interior dos veículos experimentais da universidade. Realizei o registro fotográfico e a observação detalhada do posicionamento e disposição das câmeras, além do design dos suportes delas desenvolvidos internamente via manufatura aditiva (impressão 3D). Como resultado prático para o projeto no Brasil, obtive a cópia dos arquivos CAD necessários para a reprodução física idêntica desses suportes na UNICAMP, bem como

os *scripts* e códigos-fonte utilizados para o controle, captura e sincronização das câmeras, assegurando o alinhamento de nossos protocolos de aquisição multimodais com a infraestrutura internacional.

2.5 Apoio na Construção da Base de Dados

Como a qualidade dos meus modelos neurais depende diretamente dos dados consumidos, tenho apoiado intensamente a construção de bases de dados (*datasets*) do CCD-TAAL. O processo engloba desde a tradução de material escrito para Libras até a gravação de vídeos e anotação por glosa. Junto a um aluno de doutorado, também membro do CCD-TAAL, tenho participado da coordenação e das gravações dos dados em RGB. Nós montamos um protocolo de gravação ao final de 2025, que é utilizado para obter dados padronizados. Nas gravações nós contamos com a ajuda de alunos Bolsa Auxílio Social (BAS) e consistem em trabalhar junto aos intérpretes de libras, direcionando as frases que serão gravadas e nos atentando a qualidade das gravações.

Tendo em vista que o desempenho e a precisão dos modelos neurais desenvolvidos dependem estritamente da qualidade dos dados de treinamento, tenho me dedicado à construção das bases de dados (*datasets*) do projeto CCD-TAAL. O processo abrange desde a tradução do material textual para Libras até a captura de vídeos e a anotação por glosas. Em colaboração com um doutorando, atuo na coordenação e na execução técnica das coletas de dados em vídeo RGB. Para assegurar a padronização e a validade científica do material, elaboramos e implementamos, no final de 2025, um protocolo de gravação. Durante as sessões de captura, coordeno o suporte operacional de alunos de Bolsa Auxílio Social (BAS) e atuo junto aos intérpretes de Libras, conduzindo a orientação das sentenças a serem sinalizadas e realizando o controle da qualidade técnica e visual dos dados.

Ainda sobre às atividades de gravação de dados para as bases de dados do projeto, tenho atuado no desenvolvimento técnico e orientando a prática de alunos BAS para a criação de *scripts* dedicados à operação das novas câmeras adquiridas no final de 2025. Esses códigos foram projetados para automatizar a captura sincronizada, o processamento e o armazenamento adequado de fluxos de dados multimodais (vídeo RGB, nuvens de pontos e imagens no espectro infravermelho), garantindo a padronização dos dados estruturados que alimentarão o treinamento dos modelos neurais.

No âmbito do CCD-TAAL, atuei prestando suporte à modelagem dos seguintes conjuntos de dados:

Anamnese Médica: Acompanhei o processo onde sentenças em português são traduzidas para Libras e gravadas por quatro câmeras RGB e sistema MoCap. Auxiliei na organização estrutural para que os dados sejam anotados no software ELAN pela equipe de Libras e sejam prontamente integrados aos *pipelines* de treinamento das minhas e outras redes neurais do projeto.

Interação Veículo: Durante a visita dos pesquisadores da THI (agosto de 2025), trabalhei conjuntamente com as equipes da THI e UNICAMP para definir o conjunto inicial de sentenças em Português/Libras. Acompanhei e participei do suporte técnico da aquisição dos vídeos, utilizando três veículos (Jeep Compass, Nissan March e Renault Megane) com três sinalizantes. Após esse esforço inicial, participei do processo de expansão da base na UNICAMP (ampliada para 1.357 sentenças), integrando os dados de Captura de Movimento (*MoCap*) corporal e facial. Esse trabalho de aquisição e estruturação culminou na nossa publicação conjunta na conferência LREC 2026.

Parceria Estratégica AME/iCom: Tenho participado das discussões técnicas envolvendo o acordo de parceria com a AME (<https://www.ame-sp.org.br/>). A disponibilização dos vídeos gravados pela plataforma iCom permitirá que eu utilize um material rico em interações reais com intérpretes de Libras para entender significativamente o domínio linguístico dos dados que alimento em meus modelos.

Tenho me dedicado também ao desenvolvimento e à especificação de um protocolo de armazenamento e gerenciamento de dados, em colaboração com um bolsista técnico do projeto. Essa infraestrutura foi projetada para garantir uma organização e um acesso simplificado aos arquivos digitais, implementando mecanismos de filtragem baseados em metadados condizentes com os requisitos de pesquisa do CCD-TAAL (por exemplo, recuperação de sequências de vídeo indexadas por ângulo de captura frontal, identificação do intérprete, sentença específica e ambiente veicular correspondente). Adicionalmente, estamos conduzindo um estudo de viabilidade técnica e financeira para a implementação e configuração de um sistema de armazenamento em rede do tipo *Network Attached Storage* (NAS), visando estabelecer uma infraestrutura resiliente, segura e de alta escalabilidade para salvaguardar dados de grande volume.

3 Execução do Plano de Gestão de Dados

Em relação às atividades sob minha responsabilidade, tenho seguido o Plano de Gestão de Dados do CCD-TAAL. Os modelos computacionais, *scripts* de treinamento e *pipelines* de extração de características que venho desenvolvendo estão sendo devidamente documentados, versionados e discutidos entre a equipe. Os dados que processo (vídeos em RGB, profundidade e infra-vermelho) encontram-se estruturados em uma base de dados da equipe com metadados, visando facilitar as consultas e transferência durante o treinamento das redes neurais. Conforme previsto, os códigos e aplicativos sob minha autoria serão abertos à comunidade científica após a publicação dos resultados obtidos.

4 Plano de Atividades para o Próximo Período

Para o próximo período, meu cronograma de trabalho engloba:

- **Reconhecimento de Libras (*Sign2Gloss*):** Adaptação e extensão da abordagem arquitetural atual que reproduzi, visando contemplar multimodalidade (inclusão de dados de esqueleto extraídos e anotações multicamadas). Mantereirei também o monitoramento e replicação das inovações recentes na literatura de reconhecimento de língua de sinais.
- **Extração de Características I3D:** Tenho como planejamento a implementação de um *feature extractor* baseado na rede convolucional tridimensional CNN I3D, utilizando uma arquitetura ResNet-50 como *backbone*. Este modelo será inicialmente pré-treinado na base de dados ImageNet e, posteriormente, submetido a um processo de ajuste fino (*fine-tuning*) no *dataset* Kinetics para tarefas de reconhecimento de ações. Na sequência, conduzirei um novo estágio de *fine-tuning* direcionado a múltiplos *corpora* de larga escala de línguas de sinais (nominalmente How2Sign, PHOENIX-14T e OpenASL), além de outras bases públicas relevantes. O objetivo desta etapa é permitir que a rede aprenda representações e características espaço-temporais basais das línguas de sinais, consolidando ela como um extrator de características (*feature extractor*) robusto para os dados do CCD-TAAL. Visto que os modelos profundos dependem estritamente da qualidade dessas representações latentes como dados de entrada, a obtenção de um extrator especializado garante que as informações visuais mais relevantes dos vídeos sejam preservadas, otimizando o treinamento fim-a-fim das redes neurais na etapa seguinte.
- **Construção de Base de Dados:** Continuarei prestando apoio técnico nas traduções e gravações. O meu foco será integrar aos pipelines de treinamento os novos vídeos advindos da parceria com a AME/iCom, além da implantação dos *scripts* produzidos para captura de dados dentro de veículos e no laboratório.
- **Oficinas de Trabalho:** Participarei das oficinas de trabalho que estão contempladas no projeto mãe, essas oficinas remotas dizem respeito ao formalismo que utilizaremos para as anotações da nossa base de dados e o entendimento desse processo é fundamental para o entendimento completo de como utilizar os dados durante o treinamento dos modelos.

5 Participação em Eventos Científicos e Tecnológicos

Como reflexo dos esforços descritos, tive a oportunidade de atuar como coautor em trabalho submetido e aprovado no seguinte evento científico:

- 12th Workshop on the Representation and Processing of Sign Languages - LREC 2026. Título do trabalho apresentado: *The In-Car Sign Language Corpus (ICSL): A Multi-Modal Resource for Constrained-Space Sign Language Recognition*. 16 May 2026. ©ELRA Language Resources Association (ELRA), 2026.

6 Lista de Publicações

6.1 Artigo Publicado

- Ravi Teja Boddu, Guilherme Vieira Leite, Joed Lopes da Silva, Ângelo Benetti, Isabela Barbieri, Natália de Melo Afonso, Thyago Santos, Hélio Pedrini, Felipe Venâncio Barbosa, José Mario De Martino, Munir Georges and Alessandro Zimmer. The In-Car Sign Language Corpus (ICSL): A Multi-Modal Resource for Constrained-Space Sign Language Recognition. *Proceedings of the 12th Workshop on the Representation and Processing of Sign Languages*, pages 31–41. 16 May 2026. ©ELRA Language Resources Association (ELRA), 2026. (Ver Anexo 1)

6.2 Artigos Submetidos e em Avaliação

- Guilherme Galvão de Oliveira, Guilherme Vieira Leite, Hélio Pedrini, José Mario De Martino. Explorando a Integração de Múltiplas Modalidades Visuais no Reconhecimento Contínuo de Libras. *XI Workshop de Iniciação Científica em Tecnologia da Informação e da Linguagem Humana - TILic 2026*, 19 a 22 de outubro de 2026 - Cuiabá, Mato Grosso. (Ver Anexo 2)
- Gabriel de Sousa Pereira, Guilherme Vieira Leite, Ângelo Brandão Benetti, Isabela Cristina Barbieri, Natalia Najyme de Melo Afonso, Thyago de Souza Santos, Hélio Pedrini, José Mario De Martino. Subtitling Restaurant Menus on Web Pages in Brazilian Sign Language. *3º. Workshop Accesibilidad e Inclusión - 3WAI*. 10 a 12 de novembro de 2026, Talca, Chile. (Ver Anexo 3)

Bibliografia

- [1] N. C. Camgöz, O. Koller, S. Hadfield, and R. Bowden, “Sign language transformers: Joint end-to-end sign language recognition and translation,” in *CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 10023–10033, IEEE, 2020.
- [2] K. Papineni, S. Roukos, T. Ward, and W.-J. Zhu, “Bleu: A method for automatic evaluation of machine translation,” in *40th Annual Meeting on Association for Computational Linguistics*, p. 311–318, Association for Computational Linguistics, 2002.
- [3] D. Jurafsky and J. H. Martin, *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*. Prentice Hall, 2 ed., 2009.
- [4] J.-H. Kim, M. Huerta-Enochian, C. Ko, and D. H. Lee, “Signbleu: Automatic evaluation of multi-channel sign language translation,” in *Proceedings of the Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING)*, pp. 14796–14811, 2024.
- [5] V. Vandeghinste, M. De Sisto, S. E. Gómez, and M. De Coster, *Challenges with Sign Language Datasets*, pp. 117–139. Cham: Springer Nature Switzerland, 2024.
- [6] Y. Tang, C. Tran, X. Li, P.-J. Chen, N. Goyal, V. Chaudhary, J. Gu, and A. Fan, “Multilingual translation with extensible multilingual pretraining and finetuning,” *arXiv preprint arXiv:2008.00401*, 2020.
- [7] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. u. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in Neural Information Processing Systems*, vol. 30, pp. 5998–6008, Curran Associates, Inc., 2017.
- [8] B. Zhou, Z. Chen, A. Clapés, J. Wan, Y. Liang, S. Escalera, Z. Lei, and D. Zhang, “Gloss-free Sign Language Translation: Improving from Visual-Language Pretraining,” in *CVF International Conference on Computer Vision (ICCV)*, pp. 20814–20824, IEEE, Oct. 2023.

Anexo 1
Artigo Publicado

The In-Car Sign Language Corpus (ICSL): A
Multi-Modal Resource for Constrained-Space
Sign Language Recognition

12th Workshop on the Representation and
Processing of Sign Languages

The In-Car Sign Language Corpus (ICSL): A Multi-Modal Resource for Constrained-Space Sign Language Recognition

Raviteja Boddu*, Guilherme Vieira Leite†, Joed Lopes da Silva*,
Ângelo Benetti‡, Isabela Barbieri‡, Natália de Melo Afonso†,
Thyago Santos‡, Helio Pedrini†, Felipe Venâncio Barbosa‡,
José Mario De Martino†, Munir Georges*, Alessandro Zimmer*

*Technische Hochschule Ingolstadt (THI), Bayern, Germany

†Universidade Estadual de Campinas (UNICAMP), São Paulo, Brazil

‡Universidade de São Paulo (USP), São Paulo, Brazil

*{raviteja.boddu, joed.lopesdasilva, munir.georges, alessandro.zimmer}@thi.de

†martino@unicamp.br, ‡guilherme.leite@ic.unicamp.br

Abstract

This paper addresses the challenges of using sign language within shared mobility services, such as taxis, carpools, or ride-sharing platforms. The use of sign language recognition (SLR) in real-world, confined environments, specifically vehicle interiors remains largely unexplored. To motivate research in this area, we present the In-Car Sign Language (ICSL) dataset for Brazilian Sign Language (Libras), with the long-term goal of improving public transport accessibility for the Deaf and Hard-of-Hearing community. The dataset consists of: (1) high-precision laboratory motion capture (MoCap) data to establish an idealized linguistic baseline and (2) real-world multi-modal in-car recordings captured using a 2D camera and 3D Time-of-Flight sensors. The dataset provides a basis for comparative analyses between synthesized signing avatar animations and recorded real signing interpreter videos, which enable future research into robust “in-the-wild” SLR models and domain adaptation. We describe in detail the use cases, the setup, the data collection protocol, and the metadata structure of the corpus. In total, we recorded a multimodal dataset exceeding 1.5 million frames, comprising the synchronized multimodal streams described above featuring Libras users across various in-car scenarios. The corpus is provided with gloss annotation of lexical signs and non-lexical sign language elements specially designed to support the training and evaluation of deep neural networks for constrained space recognition. In-vehicle signing offers a technically significant example of a constrained, occluded, and non-frontal environment. While recognizing the diverse communication strategies already employed by the Deaf community, identifying automotive-specific limitations provides a useful stepping stone for research into enhancing in-car accessibility and passenger quality of life.

Keywords: Brazilian Sign Language (Libras), Shared Mobility Service, Motion Capture (MoCap), In-Car Communication, Constrained Signing Space, Signing Avatars, Multimodal Sensors

1. Introduction

The advancement in natural language processing and computer vision has brought us closer to seamless human-machine interaction. While the Deaf and Hard-of-Hearing (DHH) community has developed effective strategies for “on-the-go” communication, such as the use of mobile devices or visual cues, the interior of vehicles within shared mobility services represents a technically significant and under-researched environment for Sign Language Recognition (SLR).

Specifically, the car cabin serves as a critical case study for constrained, occluded, and non-frontal signing environments, which are often overlooked in traditional laboratory-based datasets. While Brazilian Sign Language (Libras) has an established linguistic foundation, there is currently no specialized resource documenting how signing is produced and processed in the highly constrained physical and visual environments of a car cabin (dos Santos et al., 2025; Lee et al., 2025).

The relevant studies and corpora that exist for Libras are predominantly recorded in laboratory-controlled settings with optimal lighting and neutral backgrounds. In such environments, signers have a full, unobstructed signing space (dos Santos et al., 2025). However, the interior of a vehicle introduces severe constraints, such as seatbelts cutting across the torso, occlusions, dashboard obstruction, and constrained space that limit the range of torso, elbow, and arm movements, and dynamic environmental lighting creates substantial visual noise. These factors represent fundamental challenges for current SLR systems, which often fail to generalize to such “in-the-wild” conditions.

Within the framework of Project UNITY, a collaborative research initiative between the UNICAMP (Brazil) and the THI (Germany), we seek to establish a specialized multimodal dataset that captures real-world constraints while providing a high-fidelity baseline. We aim to enhance the robustness of SLR models by utilizing signing avatars as a controlled reference to evaluate the environmental chal-




Figure 1: Proposed Project UNITY architecture for a conceptual bidirectional loop: (right) Driver-to-Passenger Speech-to-Sign Synthesis and (left) Passenger-to-Driver Sign Language Recognition.

allenges present in real-world in-car video. Led by professional Libras signers and Deaf researchers, who are also co-authors of this study, the data acquisition process seeks to document the authentic challenges of the constrained transport domain by documenting passenger-driver communication within the vehicle cabin.

The long-term vision of this project is to investigate the feasibility of a real-time, bidirectional translation framework, as seen in Figure 1, which serves as the target architecture for our ongoing work. Unlike traditional one-way approaches, our target architecture facilitates a conversational loop between driver speech and passenger signs (Libras). Building such a system requires resources that capture both idealized linguistic baselines and the severe physical restrictions of the vehicle cabin.

Rather than presenting a final recognition solution, this paper describes an initial step toward the In-Car Sign Language (ICSL) corpus, which we hope can serve as a helpful reference for future data collection efforts in the automotive domain. It details the acquisition protocol, use-case design, and setup for in-car recordings; the technical setup of the laboratory MoCap baseline; and the architecture of the signing avatar pipeline. By providing this comparative resource, we hope to contribute to future studies on accessible communication technologies for the DHH community in transportation systems.

2. Related Work

For the Brazilian Sign Language (Libras) community, there is a big gap between lab research and real-world use, especially in ride-hailing and ride-sharing services. The space, movement, and social setting within a vehicle influence how signs are produced. This section provides an overview of existing language resources, the algorithms used, and the real-world challenges involved in building a Libras dataset and tools designed specifically for use in vehicles.

2.1. The Landscape of Brazilian Sign Language (Libras) Resources

The development of language resources for Libras has changed over time. It started mainly with written documentation and later moved to video-based, multimodal data. Libras is recognized as a legal means of communication and expression in Brazil, with its own grammar and linguistic system for transmitting ideas and facts (*Presidência da República, 2002*).

Early work on documenting Libras mostly focused on creating dictionaries and bilingual corpora to support education and translation (*de Quadros and de Sousa, 2021*). A comparative summary of prominent Libras datasets and their recording environments is provided in Table 1.

2.1.1. Textual and Bilingual Corpora

One of the important recent resources for Libras is VLibras-DB (*Lima et al., 2025*). It is a bilingual text dataset with about 127,000 translation pairs between Brazilian Portuguese and Libras. This dataset was mainly created to help neural machine translation systems convert written text into glosses. Broadly defined, glossing is the use of written language to represent primary data, whether signed or spoken. Within SLR, it serves as a symbolic bridge, utilizing labels from a spoken language to represent the manual and non-manual components of a sign.

To build VLibras-DB, a group of 10 professional interpreters worked together to define annotation rules for representing signs using glosses that could leverage neural network training. The gloss convention established includes directional verbs, intensifiers, and negation. The dataset primarily covers manual lexical signs but does not address challenges posed by non-manual markers or timing-related information. Non-manual markers (NMMs) are linguistically meaningful articulations produced by the face, head, torso, and gaze used as part of a sign language’s phonology, morphology, syntax, and prosody (*Herrmann, 2014*). As a result, the

VLibras-DB is not fully suitable for sign recognition tasks in real-world settings.

2.1.2. Visual and Isolated Sign Recognition Benchmarks

For isolated sign language recognition (ISLR), researchers typically use datasets such as MINDS-Libras (Rezende et al., 2021) and LIBRAS-UFOP (Cerna et al., 2021). These datasets have videos of single signs, mostly recorded in a controlled setup, with a plain background and the signer facing the camera. Recently, researchers have improved recognition performance by utilizing skeleton-based image representations paired with 2D CNN models, achieving accuracies up to 0.93 on MINDS-Libras. This technique involves transforming skeletal sequences comprising body, hand, and facial landmarks into a single spatio-temporal image, allowing a 2D CNN to recognize the sign from this unified input. This image then goes into a classifier to recognize the sign (Alves et al., 2024). However, such datasets do not work well for car environment. Most ISLR benchmarks assume the signer is facing the camera directly, which is very different from the angles you get inside a vehicle (Ranum et al., 2024). While vehicle interiors present unique spatial challenges, they share commonalities with other atypical or constrained-space signing environments. For instance, the PopSign dataset (Stanner et al., 2023) explores the complexities of one-handed signing with the narrow field of view of a smartphone camera. Much like PopSign, our ICSL dataset addresses the problem of reduced signing volume, where the signer must adapt the scale of their gestures due to spatial boundaries. Our work extends this by focusing on the specific two-handed constraints, such as seatbelt occlusions and non-frontal camera perspectives, unique to the automotive cabin that are not present in hand-held mobile datasets.

2.1.3. Regional and Documentary Inventories

The LIBRAS-UFSC corpus and the Libras National Inventory are focused on preserving Brazil's Deaf heritage and the language's diversity. They ensure the corpus includes people of different ages, genders, and regions, using careful methods to build it. The LIBRAS-UFSC corpus provides phonetic and phonological details, inspired by the Dutch Signbank model, and classifies signs by hand shape, movement, and location. These resources are relevant for linguistic research, but they are usually recorded in controlled settings, so they do not capture challenges such as visual noise, occlusions, or restricted movement that you would see in a car (de Quadros and de Sousa, 2021) (Lobo-Neto and Pedrini, 2024).

2.2. Sign Language Recognition Architectures and Methodologies

The technological evolution of SLR has transitioned from traditional manual feature extraction to end-to-end deep learning models. This shift is critical for handling the high variability of sign language, which is based on precise hand movements, facial expressions, and body language.

2.2.1. Feature Extraction and Temporal Modeling

Feature extraction focuses on capturing spatial information about hand shape, position, and orientation, as well as facial landmarks. Temporal modeling addresses the multichannel sign language characteristics (hands, facial expression, gaze, torso shift, head movement) presented in continuous stream of video frames (Camgoz et al., 2020; Rastgoo, 2021; Alyami et al., 2024; Taher and Zeebaree, 2025). Common architectures include:

- **CNN-BiLSTM:** Convolutional Neural Networks (CNNs) extract spatial features from individual frames, while Bidirectional Long Short-Term Memory (BiLSTM) networks learn the temporal dependencies over time. This combination is particularly effective for dynamic gestures, where the order of movements is crucial to the meaning (Lu et al., 2023).
- **Graph Convolutional Networks (GCNs):** These consider body landmarks as nodes in a graph, allowing the model to learn the structural interconnections between different joints and body parts (de Amorim et al., 2019).
- **Transformers:** Utilizing spatial and temporal attention mechanisms, Transformers can capture long-range dependencies across frames and correlations between different visual channels (Ma et al., 2024).

2.2.2. Landmark Detection and Efficiency

In real-time automotive applications, computational efficiency is as vital as accuracy. MediaPipe and OpenPose are the two most frequently cited tools for skeletal feature extraction due to their extensive joint coverage. OpenPose is often prone to temporal jitter and high latency, particularly in occluded environments (Alves et al., 2024). In contrast, MediaPipe offers a lightweight alternative that can achieve 5x faster recognition by utilizing an optimized subset of body landmarks (dos Santos et al., 2025). Research has shown that a well-chosen landmark subset (e.g., focusing on the upper body and hands) can maintain state-of-the-art accuracy while significantly reducing inference time. While efficient, MediaPipe's performance can degrade

Table 1: Overview of existing and proposed Brazilian Sign Language (Libras) datasets.

Dataset Name	Modality	Primary Task	Language	Scope	Annotations
VLibrasBD	Text/Gloss	Neural Machine Translation	Libras/BP	127k Pairs	Gloss, Syntax
MINDS-Libras	RGB Video	Isolated Sign Recognition	Libras	1,200+ Samples	Gloss
LIBRAS-UFOP	RGB Video	Isolated Sign Recognition	Libras	2,000+ Samples	Gloss
LIBRAS-UFSC	Video/Bank	Linguistic Documentation	Libras	National Inventory	Phonetics
LSWH100	Synthetic RGB	Handshape Classification	Libras	144k Images	Keypoints
Ours (ICSL)	RGB/Depth/IR/Point Cloud	Constrained Sign Recognition	Libras	1.5M+ Frames, 127 Phrases*	Gloss

*Current subset of a total 1,344 defined phrases.

significantly when parts of the body are blocked or in poorly lit environments, which often happens inside a car (Amalfitano et al., 2023). Consequently, there is a need for models that can handle missing hand or body points or combine information from different sensors to deal with visual noise.

2.3. The Automotive Domain: Physical and Social Constraints

The interior of a vehicle presents a highly restricted physical and visual environment for communication. Unlike laboratory settings, where signers have full, unobstructed signing space, the car cabin introduces several “in-the-wild” constraints that serve as a starting point for specialized SLR research.

2.3.1. Constrained Signing Space and Occlusions

The physical setup inside a car changes how people sign. Seatbelts cross the body and can obscure important parts of a sign and hinder torso movements. The dashboard, headrests, and tight space also limit the movement of the arms and elbows, reducing overall signing space.

2.3.2. Environmental Noise and Dynamic Lighting

Inside a vehicle, visual conditions can change significantly. Lighting can go from bright sunlight to near darkness very quickly. Shadows, reflections from windows, and uneven light can add visual noise, making it harder to clearly see hands and movements. Because of this, sign language recognition systems that work well in lab lighting often struggle to handle these changing real-world conditions (Amalfitano et al., 2023).

2.4. Hardware and Multimodal Sensing

Because single RGB cameras do not work reliably inside a car, researchers are using multiple sensor types to make sign language recognition systems more stable and accurate.

2.4.1. 2D vs. 3D Sensing

While 2D cameras are affordable and widely available in modern vehicles, they lack depth information. Time-of-Flight (TOF)/3D cameras provide 3D skeletal data that can be used to track hand motion trajectories in three dimensions. Depth maps enable the system to segment hands from the background more effectively, especially when the hands are similar in color to the vehicle interior. Depth sensing is critical for sign language because the movement of the hand toward or away from the camera often distinguishes between different signs (Zhang, 2022) (Ranum et al., 2024).

2.4.2. Synthetic Data and Motion Capture (MoCap)

Synthetic data generation has emerged as a key strategy for overcoming the difficulty and high cost of collecting large-scale natural datasets.

Previous studies have successfully utilized motion capture systems to acquire precise three-dimensional point cloud and skeletal data from deaf signers (Kipp et al., 2011; De Martino et al., 2016; Will et al., 2018; Jedlička et al., 2020; Andersen et al., 2025; De Martino et al., 2025). This high-fidelity spatiotemporal data, capturing both manual and non-manual signals, serves as a critical training corpus for neural networks, such as CNNs and RNNs, enabling them to learn the mapping from continuous sign language kinematics to written language translation.

Shterionov et al. (2024) discuss about the types of synthetic work, two of the main trends in synthesis are: (i) the more traditional 3D animation-based which resolves in generating a 3D animated character, commonly referred to as an avatar; and (ii) a video of a virtual human that can be synthesized with generative AI methods based on real human video/image data

3. Motivation for the Set-up

The synthesis of the existing literature reveals the primary motivations for developing our specialized Libras resource. This work distinguishes itself by starting from a stable, fundamental baseline, which is currently missing in the field of automotive sign language recognition.

- **Establishing a Multimodal In-Car Baseline:** There is currently no resource documenting Libras production within the physical and visual constraints of a car cabin. Our setup provides the very first multimodal baseline (RGB + 3D TOF) recorded inside a vehicle. By starting with a simplified, stable environment, we establish the necessary scientific foundation before introducing more complex parameters in future iterations, and it provides the first comparative benchmark between idealized laboratory MoCap and these constrained "in-the-wild" conditions.
- **Comparative Analysis of Constrained Space:** This resource is motivated by the need to quantify the linguistic and physical differences between idealized laboratory signing and signing within the confined space of a car cabin. This dataset allows for a direct comparison between high-precision MoCap and real-world cabin constraints.
- **Facilitating Initial Domain Adaptation:** By providing a synchronized real-world baseline and a corresponding synthetic dataset, we enable researchers to begin exploring domain adaptation for cars using expressive 3D avatars.

3.1. Potential Research Directions

To address these motivations, the ICSL dataset provides the necessary multimodal data to investigate several key research questions in future studies, such as the following:

- **Camera Placement Optimization:** Determining the optimal camera positions within a vehicle cabin to maximize the visibility of facial expressions and head movements in Libras, despite the spatial constraints.

- **Physical Baseline Comparison:** Analyzing how sign production (hand configuration and path movement) differs when comparing a high-precision laboratory MoCap baseline to the constrained physical space of a vehicle.
- **Multimodal Stability Evaluation:** Assess to what extent multimodal sensor fusion improves the stability of landmark detection in a confined interior compared to traditional monocular systems.
- **Perspective Gap Assessment:** Evaluating whether signing avatars, generated from idealized MoCap, can effectively simulate the non-frontal viewing angles required for in-car Human-Machine Interfaces (HMI).
- **Linguistic Adaptation Analysis:** Investigating how physical restrictions, such as the car seat and seatbelt, impact the duration and spatial volume of signs compared to laboratory-recorded data.
- **Model Robustness Testing:** Quantifying the performance drop when models trained on stable in-car data are tested against other driving-related micro-gestures or environmental noise.

By establishing this baseline, we provide the scientific community with a foundation for building inclusive, real-time assistive technologies that bridge the communication gap in shared mobility services.

4. Corpus Design

The design of the In-Car Sign Language (ICSL) corpus is driven by the need for accessible passenger-driver communication within shared mobility services. Unlike general-purpose sign language datasets, this resource focuses exclusively on the constrained signing space of vehicle interiors to analyze how physical constraints impact LIBRAS language.

4.1. Scenario Selection and Use Cases

In collaboration with our Deaf researchers and professional Libras interpreters, we defined 1,344 essential communication scenarios for shared mobility services. To date, we have recorded 127 essential cases that reflect the immediate needs of DHH passengers. These are categorized into five functional groups:

- **Navigation and Routing**
 - "Qual o destino?" (Where to?)
 - "Melhor evitar o centro." (It is best to avoid downtown.)
 - "Já passamos o ponto." (We are past my drop-off.)

– etc.

- **Safety and Regulations**

- “Reduzindo por segurança.” (Reducing for safety reasons.)
- “Pode ir devagar?” (Can you slow down?)
- etc.

- **Passenger Comfort and Interaction**

- “Preciso descer urgente.” (I need to stop urgently.)
- “Posso ligar o ar-condicionado?” (May I turn on the air conditioning?)
- etc.

- **Assistance**

- “Pode ajudar com a cadeira de rodas?” (Can you help with the wheelchair?)
- “Tem troco para R\$ 25,00?” (Do you have change for R\$ 25,00?)
- “Tenho uma mala pesada.” (My luggage is heavy.)
- etc.

- **Alphabet Spelling**

- A, B, C, etc.

4.1.1. Subject Recruitment and Diversity

The corpus was recorded by one hearing and two deaf signers, all proficient in Libras, which were instructed to dress as usual for the capture session. They also served as annotators to our data. To ensure that our data captures a wide range of physical constraints, recordings were conducted across three different vehicle models with varying cabin geometries: a Jeep Compass, a Nissan March, and a Renault Megane. All sessions were performed under clear daylight conditions to minimize extreme external lighting noise while preserving the natural dynamic shadows of the vehicle interior as seen in Figure 2.



Figure 2: Illustration of the three signers and challenges within vehicle cabin: (a) FLIR camera, (b) ToF camera, and (c) recording tablet point of views.

5. Data Acquisition and Technical Setup

Our data collection followed a two-stage approach. We first established a laboratory baseline using high-precision motion capture to define the “gold standard” for each sign. This was followed by an acquisition phase inside a vehicle cabin, using a multimodal sensor setup to capture the natural constraints for in-car communication.

5.1. Laboratory MoCap Baseline

Our ICSL MoCap corpus was built to simulate in-vehicle body positioning and its effects on Libras sign production. To do so, we employed several sensors, including RGB cameras and a motion capture suit (MoCap), to record joint movements with detail and precision during sign language communication. The setup made use of several professionals, including:

- Two Libras signers who were fluent in Libras and performed the signs.
- One system operator to up-keep the quality of the MoCap data being recorded.
- Two hardware operators to ensure frame synchronization and camera operation, and lastly.
- One content facilitator to assist with translation and language production evaluation.

Regarding our frame composition for this task, the laboratory has a green-screen background and a mock-up car seat. The Libras’ signers are recorded while seated, wearing a special MoCap suit that covers most of their bodies. The suit is made from black cloth and allows the attachment of reflective beads (or spherical markers) with velcro, which are detectable by the infrared cameras as seen in Figure 3a. In total, there are 73 beads distributed across the main signer’s joints.




Figure 3: MoCap setup illustrating the (a) capturing suit, (b) the markerset and skeleton from the Vicon tracking software, and (c) the rendered avatar (Clara).

We also distributed fourteen Vicon (Vicon, 2026) cameras radially around the signer. These cameras are equipped with near-IR sensor that detect

the spherical markers attached to the MoCap suit. Later on the markers will be digitalized to move the character skeleton in the capture software as illustrated in Figure 3b, which in turn will animate the avatar as shown in Figure 3c. Moreover, two Canon EOS T6i Rebel (Canon, 2026) are also employed for RGB capture, alongside the FLIR 2D (Teledyne FLIR, 2026), and the Vicon Vue cameras.

5.2. In-Car Data Acquisition

The in-car component of the ICSL corpus was designed to capture the linguistic and environmental challenges of a transport system setting. We employed a multi-sensor approach to provide both standard video and high-fidelity 3D spatial data.

5.2.1. Hardware and Sensor Setup

We utilized multi-modal sensors as seen in Figure 4 and the setup as seen in Figure 5b was deployed across three distinct test vehicles: a Jeep Compass (illustrated in Figure 5a), a Nissan March, and a Renault Megane, providing variability in cabin dimensions, window size, lightning, color, texture, seat shape, and interior geometry.



Figure 4: The multi-modal sensor suite including (a) the FLIR 2D camera, (b) Orbbec ToF sensor, and (c) the Lenovo Tablet.

- **2D Imaging:** A FLIR Blackfly S (Teledyne FLIR, 2026) was utilized to capture the primary 2D visual stream at a resolution of 1440×1080 , operating at 60 fps as seen in Figure 4a. To accommodate the confined vehicle interior, we utilized fisheye lenses to maximize the field of view as seen in Figure 2a.
- **3D Time-of-Flight (ToF):** An Orbbec Femto Bolt (Orbbec, 2026) was utilized to capture spatial information as seen in Figure 4b. The sensor was configured to capture synchronized RGB, Depth, Infrared (IR), and Point Cloud streams at a resolution of 1024×1024 pixels, operating at 30 fps, allowing for precise tracking of hand movements in 3D space as seen in Figures 2b and 6a-d.
- **Recording Tablet:** A Lenovo Tab P12 (Lenovo, 2026) was utilized as an additional perspective, as seen in Figure 4c.



Figure 5: (a) test vehicle, and (b) full technical installation inside the Jeep Compass cabin, illustrating sensor placement and the passenger signing space.




Figure 6: Multimodal perspectives of Libras communication within a vehicle cabin, illustrating the two sensors: (a) ToF depth image shown in color, where blue indicates closer objects and green indicates farther objects. Dark blue areas mean no depth was measured, (b) ToF infrared (IR) image shown in grayscale, where white represents strong IR reflection and black represents weak or no reflection, (c) ToF RGB point cloud, where each 3D point contains spatial coordinates (X, Y, Z) and its corresponding color (R, G, B), and (d) ToF Depth point cloud, where each 3D point contains spatial coordinates (X, Y, Z) derived only from depth measurements, without color information.

Positioned behind the front-seat headrest at a resolution of up to 3840×2160 pixels, it recorded the signer from an elevated, centered viewpoint, providing a third data stream to supplement the mounted sensors as seen in Figure 2c.

- **Prompting Interface (Mobile Phones):** In addition to the main sensors, mobile phones were positioned within the signer’s line of sight specifically to display the selected use cases. These served as a remote prompting system to guide the signer through the recording sequence.

5.3. Acquisition Protocol and Workflow

The recording session followed a strictly controlled protocol managed via a custom web-based control panel, as seen in Figure 7. To ensure the signer remained focused and in the correct posture, we utilized a remote signaling system:

- **Instruction Delivery:** Use cases were published on the mobile phone screens from the central Control Panel.
- **Start/Stop Signals:** The operator sent a “Start” signal (green) to the phone to indicate which sign to perform. Once the gesture was completed, a “Stop” signal (red) was sent, and the system automatically switched to the “Next Case” for the signer.




Figure 7: Web-based remote control interface for Start and Stop signaling.

6. Corpus Analysis and Limitations

Our dataset represents a first step toward a comprehensive in-vehicle Libras resource. To ensure the scientific validity of our comparative analysis, we chose to establish a solid baseline under stable, controlled conditions before introducing more dynamic environmental variables. This approach allows us to demonstrate the causal relationship between the physical layout of the car and signing

production without the interference of visual noise. By focusing on these idealized conditions, we provide a “ground truth” reference that enables the evaluation of technical benchmarks in a confined space. This is critical because sign language representations must reflect 3D awareness to handle the orientations and spatial trajectories inherent in real-world cabins.

The current iteration of the dataset is built upon a theoretical vocabulary of 1,344 Portuguese context-specific phrases for ride-sharing applications. To date, a subset of 127 phrases has been successfully recorded in video, with plans to complete the remaining recordings in the coming months. The data collection and annotation methodology relies on a cohort of three participants (two deaf, one hearing) who perform both the signing and the ongoing data annotation.

A significant current limitation is the lack of dynamic lighting conditions, such as sun glare, tunnel transitions, or nighttime driving noise. While these factors are vital for “in-the-wild” robustness, in this initial phase, we theorize that models pre-trained on normal illumination data serve as a superior foundation for subsequent fine-tuning in low-light scenarios. As an early-stage resource within Project UNITY, the dataset currently features a limited number of signers, two deaf signer and one hearing. We acknowledge this as a potential source of signer bias that could limit the generalization of initial AI models. While we capture stationary occlusions (seatbelts, headrests), the dataset does not yet account for dynamic occlusions caused by vehicle movement or secondary passenger interactions.

By acknowledging these constraints, we frame this work not as a final solution but as the essential foundation required to guide our future, more complex data-collection efforts in the automotive sign language domain.

7. Conclusion

This paper introduces the In-Car Sign Language (ICSL) dataset, a novel multimodal resource designed to investigate the technical challenges of sign language recognition across shared mobility services. By focusing specifically on the constrained signing environment of vehicle interiors, we have established the first specialized dataset that systematically documents how Brazilian Sign Language (Libras) is produced within the physical and visual limitations of car cabins. The corpus comprises over 1.5 million synchronized frames across multiple modalities, providing researchers with a comprehensive foundation for investigating sign language recognition in real mobile settings.

Our contribution is split into two parts. First, a comparative benchmark between laboratory and in-car signing that addresses potential research direc-

tions in Section 3 focused on physical, multimodal, and linguistic adaptations. Second, we provide 127 communication scenarios recorded across three vehicle models, reflecting real-world accessibility needs within diverse cabin geometries.

The limitations acknowledged in Section 6 including controlled lighting conditions, and signer diversity, this work establishes a necessary foundation for robust “in-the-wild” SLR systems. As a component of Project UNITY, the ICSL corpus provides an empirical baseline for assistive technologies aiming to reduce communication barriers between hearing drivers and DHH passengers. Available upon request, this resource supports the development of inclusive transportation systems where language barriers no longer hinder DHH access and dignity.

8. Future Work

Moving forward, our next step is to introduce dynamic environmental parameters. We plan to record subsequent datasets under varied lighting conditions. Additionally, future iterations will move from a stationary vehicle to active driving environments to capture dynamic occlusions and noise caused by vehicle vibration, which are known bottlenecks for real-time landmark tracking. Although our dataset focuses on sentence-based communication scenarios, we aim to expand the ICSL corpus to include continuous Libras conversations between passengers, more complex phrases, and a broader range of subjects.

9. Acknowledgement

This project is partially financed by the São Paulo Research Foundation (FAPESP), grants #2024/23068-4 and #2024/00914-7, the Brazilian Federal Agency for Support and Evaluation of Graduate Education (CAPES), grant #88887.091672/2014-01, National Council for Scientific and Technological Development (CNPq), grant #458691/2013-5, and FINEP, grant #2778/20. The authors would also like to thank the Verkehrsverbund Großraum Ingolstadt (VGI) for their support through the VGI newMIND project.

10. Ethical Considerations

The Libras signers in this project are not just participants, they are paid team members and co-authors of this study. Deaf and hard-of-hearing researchers were involved in every stage of the project, from designing the data collection process to writing the paper. This helps us make sure that the linguistic details of Libras are treated with care and that the technology we develop truly reflects the needs of the community. All team members gave their informed consent for the use of their images and biometric data in the corpus. Since the data was created by the research team specifically for this

resource, the project follows the institutional ethical guidelines for collaborative research. To request access to the corpus or for further technical inquiries regarding the acquisition software, annotation tools, or the Project UNITY framework, please contact José Mario De Martino at martino@unicamp.br.

11. Bibliographical References

- Carlos Eduardo GR Alves, Francisco De A Boldt, and Thiago M Paixão. 2024. Enhancing Brazilian Sign Language recognition through skeleton image representation. In *37th SIBGRAPI Conference on Graphics, Patterns and Images*, pages 1–6. IEEE.
- Sarah Alyami, Hamzah Luqman, and Mohammad Hammoudeh. 2024. *Reviewing 25 years of continuous sign language recognition research: Advances, challenges, and prospects*. *Information Processing & Management*, 61(5):103774.
- Domenico Amalfitano, Vincenzo D’Angelo, Antonio Rinaldi, Cristiano Russo, and Cristian Tomasino. 2023. Enhancing gesture recognition for sign language interpretation in challenging environment conditions: A deep learning approach. In *15th International Joint Conference on Knowledge Discovery, Knowledge Engineering and Knowledge Management (IC3K)*, pages 395–402.
- Jari Ivar Andersen, Gomer Otterspeer, Robert Belleman, and Floris Roelofsen. 2025. Designing a marker based motion capture setup for sign language research. In *Adjunct Proceedings of the 25th ACM International Conference on Intelligent Virtual Agents*, pages 1–9.
- Necati Cihan Camgoz, Oscar Koller, Simon Hadfield, and Richard Bowden. 2020. Sign language Transformers: Joint end-to-end sign language recognition and translation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.
- Canon. 2026. EOS Rebel T6i product manual. <https://www.cla.canon.com/en/p/eos-rebel-t6i>. Digital camera technical documentation. Accessed: 2026-02-13.
- Cleison Correia de Amorim, David Macêdo, and Cleber Zanchettin. 2019. Spatial-temporal graph convolutional networks for sign language recognition. In *International Conference on Artificial Neural Networks*, pages 646–657. Springer.
- José Mario De Martino, Paula D Paro Costa, A Benetti, Luciana Agueria Rosa, Kate Mamhy Oliveira Kumada, and IR Silva. 2016. Building a Brazilian Portuguese–Brazilian Sign

- Language parallel corpus using motion capture data. In *Proceedings of the 12th International Conference on the Computational Processing of the Portuguese Language, Tomar*, pages 56–63.
- José Mario De Martino, Ivani Rodrigues Silva, Janice Gonçalves Temoteo Marques, Antonielle Cantarelli Martins, Enzo Telles Poeta, Dener Stassun Christinele, and João Pedro Araújo Ferreira Campos. 2025. Neural machine translation from text to sign language. *Universal Access in the Information Society*, 24(1):37–50.
- Daniele LV dos Santos, Thiago B Pereira, Carlos Eduardo GR Alves, Richard JMG Tello, Francisco de A Boldt, and Thiago M Paixão. 2025. Proper body landmark subset enables more accurate and 5X faster recognition of isolated signs in LIBRAS. *arXiv preprint arXiv:2510.24887*.
- Annika Herrmann. 2014. *Modal and Focus Particles in Sign Languages: A Cross-Linguistic Study*, volume 2. De Gruyter Mouton, Berlin, Boston.
- Pavel Jedlička, Zdeněk Krňoul, Jakub Kanis, and Miloš Železný. 2020. Sign language motion capture dataset for data-driven synthesis. In *9th Workshop on the Representation and Processing of Sign Languages*, pages 101–106.
- Michael Kipp, Alexis Heloir, and Quan Nguyen. 2011. Sign language avatars: Animation and comprehensibility. In *International Workshop on Intelligent Virtual Agents*, pages 113–126. Springer.
- Marie Lee, Ziming Li, Wendy Dannels, Tae Oh, and Roshan L Peiris. 2025. Exploring one handed signing during driving for interacting with in-vehicle systems for Deaf and hard of hearing drivers. In *Proceedings of the Extended Abstracts of the CHI Conference on Human Factors in Computing Systems*, New York, NY, USA. Association for Computing Machinery.
- Lenovo. 2026. Tab P12: 12.7-inch Storm Grey tablet (8GB/128GB) product manual. https://www.mediamarkt.de/de/product/_lenovo-tab-p12pencil-8gb-128gb-127-zoll-tablet-128-gb-127-zoll-storm-grey-133566330.html. Hardware product specifications. Accessed: 2026-02-12.
- Chenghong Lu, Misaki Kozakai, and Lei Jing. 2023. Sign language recognition with multimodal sensors and deep learning methods. *Electronics*, 12(23):4827.
- Xiaohan Ma, Rize Jin, and Tae-Sun Chung. 2024. Multi-channel spatio-temporal transformer for sign language production. In *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pages 11699–11712.
- Orbbec. 2026. Orbbec: Femto Bolt Time-of-Flight depth camera specifications. <https://www.orbbec.com/products/tof-camera/femto-bolt/>. Product technical datasheet. Accessed: 2026-04-07.
- Presidência da República. 2002. Lei número 10.436. Diário Oficial da União, Imprensa Nacional, n. 79, Seção 1.
- Reza Rastgoo. 2021. Sign language recognition: A deep survey. *Expert Systems with Applications*, 164:113794.
- Dimitar Shterionov, Lorraine Leeson, and Andy Way. 2024. *The pipeline of sign language machine translation*, pages 1–25. Springer.
- Hanan A. Taher and Subhi R. M. Zeebaree. 2025. A critical study of recent deep learning-based continuous sign language recognition. *The Review of Socionetwork Strategies*, 19(1):131–161.
- Teledyne FLIR. 2026. Firefly S technical specifications. <https://www.teledynevisionsolutions.com/products/firefly-s/?segment=iis&vertical=machine+vision>. Machine vision camera documentation. Accessed: 2025-02-12.
- Vicon. 2026. Vicon Valkyrie advanced motion capture (mocap) camera specifications. <https://www.vicon.com/hardware/cameras/valkyrie/>. Hardware technical datasheet. Accessed: 2026-02-13.
- Ackley Dias Will, José Mario De Martino, and Juliano Renato S Bezerra. 2018. An optimized marker layout for 3D facial motion capture. In *Proceedings of the Smart Tools and Apps for Graphics (STAG)*, pages 107–113.
- Wanyu Zhang. 2022. Sign language recognition based on depth image processing. *Highlights in Science, Engineering and Technology*, 23:25–33.

12. Language Resource References

- Luis R. Cerna, E. E. Cardenas, D. G. Miranda, David Menotti, and Guillermo Camara-Chavez. 2021. *A Multimodal Libras-UFOP Brazilian Sign Language Dataset of Minimal Pairs using a Microsoft Kinect Sensor*. Expert Systems with Applications.

- Ronice Müller de Quadros and Alexandre Melo de Sousa. 2021. *Corpus da Língua Brasileira de Sinais: Inventário de Libras do Acre*. Revista de Estudos da Linguagem.
- M. A. Lima, D. Cruz, D. R. Silva, D. D. Albuquerque, D. F. Lacerda, R. Costa, G. L. de Souza Filho, and T. M. de Araújo. 2025. *VLibrasBD: A Brazilian Portuguese-Brazilian Sign Language (Libras) Bilingual Text Dataset*. Data in Brief.
- Vicente Coelho Lobo-Neto and Helio Pedrini. 2024. *LSWH100: A Handshape Dataset for Brazilian Sign Language (Libras) using SignWriting*. Data in Brief.
- Oline Ranum, Gomer Otterspeer, Jari I. Andersen, Robert G. Belleman, and Floris Roelofs. 2024. *3D-LEX v1.0: 3D Lexicons for American Sign Language and Sign Language of the Netherlands*. arXiv preprint arXiv:2409.01901.
- Tamires Martins Rezende, Sílvia Grasiella Moreira Almeida, and Frederico Gadelha Guimarães. 2021. *Development and Validation of a Brazilian Sign Language Database for Human Gesture Recognition*. Neural Computing and Applications.
- Thad Starner, Sean Forbes, Matthew So, David Martin, Rohit Sridhar, Gururaj Deshpande, Sam Sepah, Sahir Shahryar, Khushi Bhardwaj, Tyler Kwok, Daksh Sehgal, Saad Hassan, Bill Neubauer, Sofia Vempala, Alec Tan, Jocelyn Heath, Unnathi Kumar, Priyanka Mosur, Tavenner Hall, Rajandeep Singh, Christopher Cui, Glenn Cameron, Sohier Dane, and Garrett Tanzer. 2023. *PopSign ASL v1.0: An Isolated American Sign Language Dataset Collected via Smartphones*. Curran Associates, Inc.

Anexo 2

Artigo Submetido e em Avaliação

Explorando a Integração de Múltiplas
Modalidades Visuais no Reconhecimento
Contínuo de Libras

XI Workshop de Iniciação Científica em
Tecnologia da Informação e da Linguagem
Humana

Explorando a Integração de Múltiplas Modalidades Visuais no Reconhecimento Contínuo de Libras

Anonimizado

Abstract. Continuous Brazilian Sign Language (Libras) recognition presents challenges related to the multimodal nature of signing and the modeling of complex spatio-temporal dependencies. This ongoing work investigates the adaptation of neural architectures for continuous Libras recognition using RGB videos, body, facial, and hand keypoints, as well as multi-tier linguistic annotations produced in ELAN. The proposed approach combines visual feature extraction, multimodal integration, and temporal modeling. Evaluation will be conducted using the Word Error Rate (WER) metric and ablation studies. The goal is to analyze the impact of multimodality and multi-layer annotations on the performance of continuous Libras recognition models.

Resumo. O reconhecimento contínuo de Língua Brasileira de Sinais (Libras) apresenta desafios relacionados à natureza multimodal da sinalização e à modelagem de dependências espaço-temporais complexas. Este trabalho em andamento busca investigar a adaptação de arquiteturas neurais para o reconhecimento contínuo de Libras utilizando vídeos RGB, keypoints corporais, faciais e manuais, além de anotações linguísticas multi-tier produzidas no ELAN. O método proposto combina extração de características visuais, integração multimodal e modelagem temporal. A avaliação será realizada por meio da métrica Word Error Rate (WER) e estudos de ablação. Espera-se analisar o impacto da multimodalidade e das anotações multicamadas no desempenho de modelos de reconhecimento contínuo de Libras.

1. Introdução

A Língua Brasileira de Sinais (Libras) constitui o principal meio de comunicação da comunidade surda brasileira e desempenha papel fundamental na promoção da acessibilidade e da inclusão social. Diferentemente da língua portuguesa, a Libras utiliza simultaneamente componentes manuais e não manuais, incluindo configurações de mão, movimentos corporais, expressões faciais, direção do olhar e organização espacial da mensagem. Essa natureza visual-espacial e multimodal torna o desenvolvimento de tecnologias para processamento automático de línguas de sinais um desafio científico relevante e uma importante ferramenta para ampliar a acessibilidade em diferentes contextos sociais, educacionais e institucionais [Bragg et al. 2019].

Apesar da relevância dessas tecnologias, o reconhecimento contínuo da língua de sinais ainda é um desafio [Khan et al. 2025, Najib 2025, Wang et al. 2025]. Diferentemente de sinais isolados, reconhecê-los exige lidar com sequências de sinais de forma contínua, envolvendo fenômenos como coarticulação, transições entre sinais, variações de velocidade e a integração de múltiplos articuladores visuais. Como discutem Koller et al. [Koller et al. 2015], há uma demanda de modelos capazes de capturar dependências espaço-temporais complexas e de operar em condições mais

próximas das situações reais de uso. Nos últimos anos, a literatura tem apresentado diversos métodos que buscam solucionar esses problemas. Por exemplo, Camgöz et al. [Camgoz et al. 2018] propuseram uma formulação neural para a tarefa, enquanto Camgöz et al. [Camgoz et al. 2020b] apresentaram uma arquitetura baseada em *Transformers* para reconhecimento e tradução conjuntos. Além disso, Camgöz et al. [Camgoz et al. 2020a], Yin e Read [Yin and Read 2020] e Yin et al. [Yin et al. 2023] exploraram múltiplos articuladores e novas formas de incorporar informação linguística intermediária aos modelos.

Apesar desses avanços, ainda há muitas questões em aberto, especialmente no contexto da Libras. Este trabalho está inserido em um projeto mais amplo voltado ao reconhecimento e à tradução de língua de sinais, envolvendo o desenvolvimento de um corpus multimodal de Libras contendo vídeos RGB, *keypoints* corporais, faciais e manuais, além de anotações linguísticas *multi-tier* produzidas no ELAN. Este trabalho tem como objetivo principal avaliar e adaptar arquiteturas neurais para o reconhecimento contínuo, investigando o impacto de diferentes modalidades visuais e estratégias de fusão multimodal, de modo a responder à seguinte questão: como integrar, de forma consistente, vídeos RGB, *keypoints* e anotações linguísticas *multi-tier* para melhorar o desempenho de modelos neurais de reconhecimento contínuo de Libras?

2. Metodologia

A metodologia proposta visa investigar o impacto de diferentes modalidades visuais e anotações linguísticas multicamadas no reconhecimento contínuo de Libras. Três tarefas principais compõem a metodologia: construção de corpus multimodal, extração e integração de representações multimodais e modelagem temporal baseada em arquiteturas neurais.

2.1. Construção de Corpus Multimodal de Libras

Os experimentos são conduzidos com um corpus multimodal de Libras, em desenvolvimento no âmbito de um projeto de pesquisa mais amplo. O corpus é composto por sentenças em português traduzidas para Libras por uma equipe de sete intérpretes, incluindo três participantes surdos. As gravações são realizadas em ambiente controlado utilizando quatro câmeras RGB posicionadas em diferentes ângulos. Essa configuração reduz problemas de oclusão e permite a obtenção de múltiplas perspectivas da sinalização. A partir dos vídeos, são extraídas representações complementares, incluindo *keypoints* corporais, faciais e das mãos, possibilitando a construção de diferentes modalidades de entrada para os modelos de reconhecimento.

Além das informações visuais, o corpus incorpora anotações linguísticas produzidas no ELAN [Wittenburg et al. 2006]. Diferentemente de abordagens baseadas em uma única camada de anotação, a estrutura adotada utiliza múltiplos *tiers* sincronizados temporalmente. Além das glosas, são registradas informações sobre apontamentos espaciais, mão dominante, direção do olhar e marcadores não manuais. Essa organização permite uma representação mais detalhada da sinalização e fornece informações adicionais potencialmente úteis para o treinamento de modelos neurais. Atualmente, o corpus abrange diferentes domínios de aplicação, incluindo contextos de saúde, alimentação e mobilidade, o que contribui para uma maior diversidade linguística e contextual dos dados.

2.2. Extração e Integração de representações multimodais

A primeira etapa do processo computacional consiste na conversão de vídeos em representações adequadas ao treinamento de modelos de reconhecimento. Os vídeos RGB são processados por extratores de características visuais, que geram *embeddings* espaciais para cada quadro da sequência. Paralelamente, representações estruturadas derivadas dos vídeos, como *keypoints* corporais, faciais e manuais, são convertidas em vetores numéricos que descrevem explicitamente a configuração espacial dos articuladores envolvidos na sinalização. Dessa forma, o reconhecimento deixa de operar diretamente sobre o vídeo bruto e passa a utilizar sequências de representações compactas que preservam informações relevantes para a modelagem da sinalização.

Um dos objetivos centrais deste trabalho é investigar como diferentes fontes de informação podem ser combinadas para apoiar o reconhecimento contínuo de Libras. Para isso, serão avaliadas diferentes estratégias de fusão multimodal. Na abordagem de fusão antecipada (*early fusion*), as representações provenientes das diferentes modalidades são combinadas antes da modelagem temporal. Já na fusão tardia (*late fusion*), cada modalidade é inicialmente processada por um fluxo independente, sendo integrada apenas em estágios posteriores da rede. A comparação entre essas estratégias permitirá avaliar em que medida as diferentes modalidades contribuem para o desempenho do sistema.

2.3. Modelagem Temporal para Reconhecimento Contínuo

O reconhecimento contínuo está sendo explorado por meio de arquiteturas neurais baseadas em *Transformers*, tomando como referência os modelos propostos por Camgoz et al.(2020) [Camgoz et al. 2020b]. A escolha dessa arquitetura se justifica por seu papel de destaque na literatura da área, tanto pelos resultados reportados quanto por oferecer uma formulação adequada para modelar sequências visuais longas, com dependências espaço-temporais complexas, características centrais do reconhecimento contínuo. A Figura 1 sintetiza as principais etapas da arquitetura, desde a obtenção das representações espaciais até a predição da sequência de glosas e a supervisão do treinamento.




Figura 1. Fluxo computacional para o reconhecimento contínuo de Libras. As setas vermelhas indicam o uso de anotações *multi-tier* na supervisão do treinamento.

Após a etapa de fusão, as sequências de representações multimodais são processadas por mecanismos de atenção capazes de modelar dependências de longo alcance ao longo da sinalização. Essa etapa busca capturar fenômenos característicos do reconhecimento contínuo, incluindo coarticulação, variações entre sinalizantes e relações contextuais entre sinais consecutivos. Como saída, o modelo produz uma sequência de glosas correspondente ao conteúdo linguístico presente no vídeo de entrada.

3. Avaliação Experimental

A avaliação do sistema será conduzida por meio da comparação entre as sequências de glosas produzidas pelo modelo e as anotações de referência presentes no corpus. Como métrica principal, será utilizada a *Word Error Rate* (WER), amplamente empregada em tarefas de reconhecimento contínuo de língua de sinais [Camgoz et al. 2020b]. A WER quantifica a distância de edição entre a sequência predita e a correta, considerando inserções, remoções e substituições. Além da avaliação global, serão realizados estudos de ablação com o objetivo de mensurar a contribuição individual de cada modalidade visual e das anotações multicamadas para o desempenho final do sistema.

4. Desafios Atuais e Próximos Passos

Um dos principais desafios da pesquisa reside na reprodutibilidade técnica das arquiteturas de referência. A adaptação do modelo descrito em [Camgoz et al. 2020b] exige lidar com dependências de códigos, bibliotecas desatualizadas e escolhas de implementação nem sempre totalmente especificadas. Além disso, há um gargalo importante na extração de características espaciais [Alvarez et al. 2022], pois esse tipo de modelo não opera diretamente sobre o vídeo bruto, mas sobre *features* previamente extraídas. Como a arquitetura exata do extrator original não foi disponibilizada integralmente, torna-se necessário investigar alternativas para gerar *embeddings* visuais robustos, etapa central para o restante da tarefa de reconhecimento. Outro desafio diz respeito à generalização do modelo para o cenário de Libras. O sistema de referência foi desenvolvido sobre o conjunto de dados PHOENIX14T, restrito ao domínio de previsões do tempo e à Língua de Sinais Alemã, enquanto o presente trabalho se concentra na Libras e com domínios linguísticos mais variados.

Diante disso, os próximos passos concentram-se na consolidação do módulo de extração de características espaciais, na adaptação do código ao contexto do projeto e na execução sistemática de experimentos com base na métrica WER. Em seguida, pretende-se adaptar o modelo ao contexto de Libras e avaliar empiricamente em que medida a combinação de múltiplas modalidades visuais e de anotações *multi-tier* pode fortalecer o reconhecimento contínuo de sinais.

5. Considerações Finais

O reconhecimento contínuo de Libras constitui um problema computacional desafiador, que requer a integração de informações visuais, temporais e linguísticas. A principal contribuição deste trabalho reside na consolidação de uma base metodológica para a adaptação e avaliação de arquiteturas neurais voltadas a esse problema, com a definição de um fluxo computacional que envolve extração de características espaciais, fusão multimodal, modelagem temporal e avaliação por WER. Embora ainda não haja resultados experimentais finais, o mapeamento dos desafios de reprodutibilidade, a extração de *features* e a generalização para o contexto de Libras já representam etapas relevantes da pesquisa. Espera-se, assim, que os próximos experimentos avancem na compreensão do impacto da multimodalidade e das anotações *multi-tier* no reconhecimento contínuo, contribuindo para o amadurecimento metodológico da área e para o desenvolvimento de tecnologias mais robustas e aplicáveis à comunidade surda brasileira.

Referências

- Alvarez, P. C., Nieto, X. G., and Benet, L. T. (2022). Sign Language Translation Based on Transformers for the How2Sign Dataset. *Image Processing Group Signal Theory and Communications Department Universitat Politècnica de Catalunya*.
- Bragg, D., Koller, O., Bellard, M., Berke, L., Boudreault, P., Braffort, A., Caselli, N., Huenerfauth, M., Kacorri, H., Verhoef, T., et al. (2019). Sign Language Recognition, Generation, and Translation: An Interdisciplinary Perspective. In *Proceedings of the 21st International ACM SIGACCESS Conference on Computers and Accessibility*, pages 16–31.
- Camgoz, N. C., Hadfield, S., Koller, O., Ney, H., and Bowden, R. (2018). Neural Sign Language Translation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 7784–7793.
- Camgoz, N. C., Koller, O., Hadfield, S., and Bowden, R. (2020a). Multi-Channel Transformers for Multi-Articulatory Sign Language Translation. In *European Conference on Computer Vision*, pages 301–319. Springer.
- Camgoz, N. C., Koller, O., Hadfield, S., and Bowden, R. (2020b). Sign Language Transformers: Joint End-To-End Sign Language Recognition and Translation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 10023–10033.
- Khan, A., Jin, S., Lee, G.-H., Arzu, G. E., Dang, L. M., Nguyen, T. N., Choi, W., and Moon, H. (2025). Deep Learning Approaches for Continuous Sign Language Recognition: A Comprehensive Review. *IEEE Access*, 13:55524–55544.
- Koller, O., Forster, J., and Ney, H. (2015). Continuous Sign Language Recognition: Towards Large Vocabulary Statistical Recognition Systems Handling Multiple Signers. *Computer Vision and Image Understanding*, 141:108–125.
- Najib, F. M. (2025). Sign Language Interpretation using Machine Learning and Artificial Intelligence. *Neural Computing and Applications*, 37(2):841–857.
- Wang, Z., Li, D., Jiang, R., and Okumura, M. (2025). Continuous Sign Language Recognition with Multi-Scale Spatial-Temporal Feature Enhancement. *IEEE Access*, 13:5491–5506.
- Wittenburg, P., Brugman, H., Russel, A., Klassmann, A., and Sloetjes, H. (2006). ELAN: A Professional Framework for Multimodality Research. In *5th International Conference on Language Resources and Evaluation*, pages 1556–1559.
- Yin, A., Zhong, T., Tang, L., Jin, W., Jin, T., and Zhao, Z. (2023). Gloss Attention for Floss-Free Sign Language Translation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 2551–2562.
- Yin, K. and Read, J. (2020). Better Sign Language Translation with STMC-Transformer. In *Proceedings of the 28th International Conference on Computational Linguistics*, pages 5975–5989.

Anexo 3
Artigo Submetido e em Avaliação

Subtitling Restaurant Menus on Web Pages in
Brazilian Sign Language

3º Workshop Accesibilidad e Inclusión

Subtitling Restaurant Menus on Web Pages in Brazilian Sign Language

No Author Given

No Institute Given

Abstract. This paper presents the development of a robust technological infrastructure designed to facilitate the automated translation of web content into Brazilian Sign Language (Libras). Central to this framework is the construction of a high-fidelity multimodal corpus, comprising approximately 2,400 sentences recorded utilizing advanced motion capture (MoCap) systems. To employ this system, a web injection tool was implemented, featuring a crawler for comprehensive domain mapping and a specialized parser. This parser effectively segments textual information and automatically embeds non-intrusive accessibility interfaces for Libras content. The viability of this solution was validated through its successful application to complex, dynamically loaded web pages, specifically a university restaurant menu. At the user interface level, the system introduces a modular widget that supports the playback of pre-rendered animation of three-dimensional (3D) avatars, a dual approach strategically intended to optimize bandwidth consumption. Ultimately, the proposed architecture establishes a comprehensive ecosystem of data engineering, machine-learning training, and graphical visualization tools, providing a scalable foundation to enhance web accessibility and promote the digital autonomy of the deaf community.

1 Introduction

Although internet information is predominantly textual, assuming it is inherently accessible to deaf individuals is a frequent misconception. While those who experience hearing loss later in life can typically access textual information without difficulty, written material is often significantly less accessible than content presented in sign language for deaf individuals who were deaf before acquiring a spoken/written language. Studies consistently indicate that the reading proficiency of deaf children frequently lags behind that of their hearing peers [8].

Furthermore, because sign language is the primary language for the Deaf community, reading text in a spoken language is cognitively comparable to interpreting a foreign language [10]. Drawing a parallel to spoken languages in Brazil, while there are few native citizens unable to read Portuguese, respecting this unique linguistic community dictates a cultural and legal obligation to provide accessible information in their primary language [19]. According to a 2019 national health survey conducted by the Brazilian Institute of Geography and Statistics (IBGE), approximately 2.5 million citizens over the age of two have severe hearing loss or are deaf, representing 1.1% of the Brazilian population [12].

In Brazil, Brazilian Sign Language (Libras) is recognized as a co-official means of communication and expression for the deaf community under Law No. 10.436/2002 [20], and is regulated by Decree No. 5.626/2005 [5]. Additionally, Law No. 13.146 of July 6, 2015 [6], known as the Statute of the Person with Disabilities, establishes public policies designed to ensure the equal exercise of fundamental rights and freedoms, aiming for full social inclusion and citizenship. Explicitly in Article 63, this legislation mandates accessibility on websites maintained by government agencies or companies that operate in the country. This ensures that individuals with disabilities have access to information in accordance with internationally adopted accessibility best practices and guidelines.

Sign language (SL) perception involves the sensory and cognitive processes by which individuals visually interpret signed information conveyed through hand and body movements, facial expressions, and spatial structure [11]. This perceptual ability is shaped by both linguistic experience and visual motion processing systems [15].

Ensuring accessibility for the deaf community is paramount for both formal education and social inclusion. In scenarios where human interpreters are unavailable, particularly for continuous, round-the-clock communication access, private on-device interactions, and barrier-free content consumption [13], technologies such as signing avatars that automatically translate Portuguese text into Libras (synthesis) present a pressing and viable solution.

The adoption of 3D avatars for sign language synthesis is fundamentally motivated by the need for scalable, uniform, and adaptable digital accessibility solutions. Traditional video-based systems, which rely on recordings of human interpreters, are inherently constrained by challenges related to visual consistency. As the video repository are expanded or updated over time, they inevitably suffer from disruptive variations in lighting, background, attire, or the need to employ different interpreters. An avatar-based approach resolves these issues by separating the movement data from the graphical representation. By capturing raw sign movements via motion capture (MoCap) technology, the system allows all physical characteristics and environmental variables to be strictly altered within a digital environment. Consequently, this paradigm guarantees a cohesive, continuous user experience while allowing a highly sustainable and practical framework for the continuous expansion of accessible web content.

1.1 Related Literature

Avatar generation represents a fundamentally different computational challenge compared to sign-recognition systems. Rather than interpreting video input as text, avatar generation requires synthesizing linguistically coherent and visually natural behavior. Literature shows that the efficacy of realistic signing avatars depends heavily on the integration of both manual and non-manual signals, including torso movement and facial expressions, which are indispensable for sign language comprehension [17]. The simultaneous nature of sign language, with its dynamics of hand configurations, spatial trajectories, and facial expressions,

demands detailed animation and precise synchronization to achieve fluid, continuous communication [2]. Within this framework, facial expressions and lip movements are particularly critical, functioning as primary vehicles for expressing semantic nuance, grammatical marking, and emotional context [14].

Furthermore, presentation and control aspects are increasingly emphasized in accessibility standards. The Web Content Accessibility Guidelines (WCAG) 2.2 [27] recommend core features for web-based sign language avatars, notably the inclusion of pause, stop, and hide commands; mechanisms to control the avatar’s timing; and a minimum contrast ratio of 3:1 between the avatar, its control components, and adjacent background colors [27]. However, the literature, such as [16], identifies critical gaps in standards such as WCAG, including sign writing, the adaptation of captioning technologies, and inclusive captioning for paralinguistic and nonverbal information, and argues for the development of new solutions that move beyond minimum compliance to foster genuine inclusion.

Despite the increasing adoption of assistive technologies, current avatar-based sign language solutions still face substantial limitations. A primary visual challenge lies in selecting the appropriate balance between stylization and realism; consequently, many systems default to non-photorealistic, cartoon-like aesthetics [1]. While these stylized designs may be suitable in specific contexts [14], aiming for hyper-realistic human avatars often risks triggering the “uncanny valley” effect, thereby undermining user acceptance [4]. Furthermore, user studies indicate that while personalization is appreciated, functional customizations that directly enhance comprehensibility, such as adjustable signing speed and avatar scale, are less relevant over purely aesthetic modifications [14,18].

Beyond visual representation, the technical process of converting spoken language text into synthesized animated signed output remains a formidable obstacle. Because sign languages utilize spatial, non-linear grammars that are entirely distinct from written forms, traditional translation paradigms struggle to bridge the linguistic gap. Although intermediate gloss representations and motion capture techniques are widely employed to address this, they introduce their own limitations [28], particularly regarding the rigorous synchronization required across all visual articulators [1,28]. Ultimately, these computational and structural barriers are amplified when developing systems for Portuguese and Libras, as both are classified as low-resource languages within the general landscape of machine translation modeling.

While the development and evaluation of 3D avatars for sign language synthesis have seen considerable progress in recent years, significant computational and design hurdles persist. Surveying the technological landscape, Wolfe et al. [29] observed that avatar synthesis remains largely underexplored, currently characterized by fragmented and inadequate solutions. Reinforcing this perspective, Aziz and Othman [1] reviewed forty years of literature and pinpointed the critical absence of standardized evaluation metrics alongside a severe shortage of annotated datasets, while advocating for the creation of multi-sign language frameworks.

Shifting the focus from the underlying mechanics of synthesis to human-computer interaction, recent studies increasingly highlight the pivotal role of user reception. Soudi et al. [23], for example, explored how both intrinsic avatar traits and extrinsic demographic variables influence the cross-cultural acceptance of these assistive tools. Similarly, Chemnad and Othman [7] demonstrated that subjective user perception is intricately linked to the actual comprehension of the synthesized language. Finally, examining specific visual configurations, Wasserroth et al. [26] concluded that although aesthetic customization enhances the overall user experience and general acceptability, the fundamental intelligibility of the avatar relies almost entirely on the precise execution of handshapes and the presence of facial expressions.

1.2 Our Solution

To overcome the limitations identified in existing systems, this research introduces critical advancements in both the visual fidelity and the computational architecture of signing avatars. A primary objective is to develop a realistic, automatic 3D avatar capable of executing precise movements of the hands, arms, torso, and face. The high degree of movement realism is crucial, not only for ensuring strict grammatical accuracy but also for projecting the credibility and professionalism required for institutional web applications. Beyond the graphical representation, the proposed system addresses the structural complexities of automated synthesis via a comprehensive machine-translation pipeline. This framework translates Brazilian Portuguese text into an intermediate gloss representation, which subsequently drives the continuous synthesis of signs. Given that Portuguese and Libras are low-resource languages in the context of computational translation, developing this architecture is challenging, underscoring the need for robust, high-fidelity data acquisition strategies detailed in this study.

To support this computational pipeline, our work also introduces a novel sign language corpus specifically designed for avatar synthesis and the future training of sign recognition models. This dataset is grounded in the semantic domain of our university restaurant’s menu, focusing on the translation from Portuguese into Libras. Selecting this particular context provides a practical application that directly enhances a digital platform frequently accessed by the deaf academic community. Computationally, restricting the initial corpus to a specialized domain significantly reduces the overall vocabulary size and token variance. This constraint effectively mitigates early-stage modeling complexity, allowing for superior translation accuracy. Ultimately, this focused approach fulfills an immediate campus accessibility need while serving as a crucial proof of concept. A successful deployment within this controlled environment establishes a scalable foundation that can subsequently be adapted to a broader array of institutional web services.

This paper presents an integrated solution to enhance web accessibility by injecting a 3D avatar into HTML environments. The proposed interface gives the user granular control, allowing them to toggle on and off the avatar, position it freely, and adjust its presentation velocity. In parallel, we constructed a novel

corpus based on the linguistic domain of a university restaurant. This dataset currently works on the web system to feed the avatar and is designed to serve as a foundational resource for training future neural machine translation models.

The remainder of this work is structured as follows. Section 2 details the methodology for the web accessibility tool. Section 3 elaborates on the motion-capture acquisition setup and the subsequent data-processing pipeline. Section 4 discusses the limitations and performance of the methodology. Section 5 presents our final remarks.

2 Proposed Method

The proposed methodology is visually outlined in the flowchart presented in Figure 1. This section focuses on explaining the data-driven pipeline that operates during web content translation and drives the generation of the sign language avatar. At a high level, the system architecture actively scrapes and replicates the university restaurant website where the daily menu is published. Following data extraction, the system parses the relevant textual information into an intermediate gloss representation, dynamically embeds the avatar rendering components into the web page, and, upon user request, presents the corresponding sign language animations (detailed in Section 3).




Fig. 1: Overview of the proposed methodology. The orange components denote the scripts responsible for preparing the web page, as well as extracting and filtering relevant textual information. The pink module represents the web injection script that handles rendering our 3D avatar (Clara) on the screen. The element highlighted in blue indicates the kinematic data, which is recorded and post-processed from human motion capture sessions. Finally, the terminal stage illustrates the sign language synthesis, wherein the avatar actively communicates the user-selected text.

2.1 Web Integration

To enable the seamless integration of the machine translation system into web environments, a modular suite of software tools was created to automate the

entire data pipeline—from initial content acquisition to end-user presentation. Python [25] was chosen as the primary implementation language for its highly efficient text-processing capabilities and rich ecosystem of libraries tailored for web scraping and browser automation.

The proposed architectural framework is composed of two main modules: (i) a web crawler dedicated to comprehensive domain mapping; and (ii) a parsing engine responsible for text extraction, sentence segmentation, and the automated injection of the avatar’s accessibility interface. To empirically validate this methodology, a specialized pipeline was implemented to process the dynamically updated menu page of our university restaurants. Serving as a practical proof of concept, this application demonstrates the system’s operational viability and its seamless deployment within a real-world digital environment. The technical specifications and functionalities of these components are elaborated below.

2.2 Crawler

The initial phase of the web integration process involves systematically mapping the target domain. To automate this domain discovery, a dedicated script (`url_collector.py`) was engineered to operate as a specialized web crawler, explicitly tasked with harvesting internal hyperlinks.

Operationally, the algorithm initiates its traversal from a predefined seed URL. Using Python libraries (`Requests`), the script executes an HTTP GET request to fetch the raw HTML source code of the target page. After the retrieval, the system systematically parses the document’s architecture. The algorithm actively navigates the Document Object Model (DOM) tree ([21]) to locate and isolate anchor elements (specifically, `<a>` tags) that denote navigable links.

For every hyperlink identified during this structural traversal, the crawler’s extraction logic sequentially executes the following procedures:

1. **Attribute Extraction:** The algorithm isolates and retrieves the destination paths embedded within the `href` attributes of all identified link tags.
2. **URL Normalization:** To guarantee navigational integrity, the system dynamically resolves and converts all relative paths into fully qualified absolute URLs (`urllib`).
3. **Domain Filtering:** To confine the crawler’s scope and prevent unintended traversal to external websites, a strict verification protocol cross-references the host domain of each resolved link against the original seed URL. Only internal links matching the initial domain are used for further processing.
4. **Duplicate Filtering:** By storing the validated URLs into a `set` data structure, the system eliminates duplicate entries, thereby optimizing computational efficiency and preventing the redundant processing of identical web pages.

Furthermore, to enhance the tool’s flexibility, the script integrates a command-line interface (CLI) (`argparse`), which allows users to dynamically configure both the target seed URL and the designated output directory. The

culmination of this automated crawling process is the generation of a structured text document containing the fully sanitized and filtered list of internal hyperlinks. This comprehensive registry later functions as the foundational data input for the pipeline’s succeeding architectural component: the parser module.

2.3 Parser

Serving as the core computational engine of the proposed architecture, the parser systematically transforms the raw web pages harvested by the crawler into fully accessible, interactive user interfaces. This module is deployed as a single script tailored for the playback of pre-rendered video files (`parser.video.py`).

The parsing workflow commences with the comprehensive rendering of the target webpage. In contrast to traditional static extraction methods, the system instantiates an automated Google Chrome browser session (`Selenium` [22]). This dynamic rendering approach is essential for accurately processing modern web architectures heavily reliant on client-side JavaScript. It guarantees that the fully constructed Document Object Model (DOM), along with all required visual assets, including cascading style sheets (CSS) and dynamically loaded images, is successfully captured before data extraction begins.

Once the fully rendered DOM is acquired, the system initiates a rigorous textual processing phase (`Beautiful Soup` [21]). The algorithm systematically isolates structural text elements, such as headings, paragraphs, and lists. Later, a critical linguistic segmentation protocol is implemented using the Natural Language Toolkit (NLTK) [3]. By tokenizing extended text blocks into discrete, grammatically complete sentences, the algorithm ensures that the produced translation into glosses is executed at a semantic granularity optimal for accurate synthesis and user comprehension.

Following this segmentation, the parser dynamically annotates the underlying HTML markup. Each isolated sentence is structurally wrapped within a newly generated `<span>` tag, which is assigned the `.tracked` class identifier alongside a custom metadata attribute. This attribute explicitly links the text segment to its corresponding kinematic or video asset, thereby generating the finalized, accessibility-enhanced web page, as depicted in Figure 2. Meanwhile, the module aggregates these segmented texts into a structured CSV document, creating a comprehensive transcript that streamlines the ongoing management and production of the Libras translation corpus.

The `parser.video.py` variant is explicitly configured to optimize the web interface for pre-recorded video playback. Specifically, it targets the WebM format, leveraging its native alpha-channel transparency to achieve seamless, background-free rendering across contemporary web browsers.

Interface Front-End: End-user interaction within the enhanced web environment is facilitated by a dedicated player component, engineered as a dynamic widget utilizing the jQuery UI library [24]. This front-end module generates a resizable, floating viewport that seamlessly overlays the primary page content




Fig. 2: The modified web interface of the university restaurant, illustrating the successful structural injection and rendering of the interactive accessibility avatar.

and integrates functional controls that let users adjust the playback speed of the synthesized signing.

The visual and spatial behavior of this interface is governed by custom CSS stylesheets. By employing fixed spatial positioning, the system ensures that the translation viewport remains persistently visible, also during the user's vertical page scrolling. To enhance accessibility and provide immediate visual feedback, translatable textual elements are dynamically highlighted with interactive borders upon mouse hover. This intuitive signaling mechanism effectively guides deaf users toward the machine-translated components of the webpage.

Architecturally, the strict separation of the backend processing logic (Python) from the front-end presentation layers (JavaScript and CSS) provides the system with exceptional modularity. This strategic design choice ensures that the core parsing infrastructure can seamlessly support distinct visualization modalities, whether executing pre-rendered video playback or rendering a real-time 3D avatar, requiring only minimal modifications to the underlying source code.

3 Corpus

The development of robust, data-driven machine translation architectures and the synthesis of realistic sign language depend on rigorous, high-fidelity data acquisition protocols. To satisfy these technical requirements, this study implements the methodology detailed below. A comprehensive architectural overview

of this operational workflow is mapped in Figure 3. The proposed pipeline encapsulates the complete lifecycle of the linguistic data, tracking its progression from the initial processing of source Portuguese text to its materialization as a realistic signing avatar.

The dataset was constructed from the comprehensive annual menu provided by the university restaurant, yielding a preliminary set of raw Portuguese sentences (denoted as the initial stage in Figure 3). Subsequently, a rigorous translation protocol was implemented to review these source sentences, translate them into Libras (representing the second stage in Figure 3). This critical phase was carried out by a specialized team of three project members: one hearing and two deaf interpreters/translators, all with advanced fluency in Libras.




Fig. 3: Methodological flowchart detailing the generation of the restaurant domain corpus. The pipeline initiates with raw Portuguese sentences, advancing through systematic filtering and reference video creation. These videos are then used to guide the production of glosses, which support the accurate acquisition of motion capture (MoCap) data. Finally, the recorded kinematic data undergoes cleanup and processing before functioning as direct input for the web integration script, which ultimately drives the real-time rendering of the sign language avatar.

Translating intrinsically yields a high variance in potential linguistic outputs. Given that the objective of this corpus is to serve as a consistent training dataset for future sign language recognition neural networks and avatar synthesis, this variance poses a methodological challenge. Consequently, strict standardization of the Libras translations was necessary. However, because sign languages lack a writing system to capture complex spatio-temporal articulations, text-based documentation alone proved insufficient. To circumvent this limitation, reference videos were produced, constituting the third step in Figure 3, which will later inform the map-to-glosses process, represented by the fourth step in the flowchart.

As the methodology progresses, the subsequent phase involves motion capture (MoCap) acquisition. As illustrated on the left side of Figure 4, these recording sessions are conducted within a purpose-built laboratory environment. The facility is equipped with specialized hardware engineered to simultaneously track body kinematics and the highly granular, high-resolution positioning of the

hands and individual fingers. Furthermore, corroborating the consensus in the related literature discussed in Section 1.1, facial expressions constitute a fundamental grammatical and semantic component of sign language comprehension; therefore, robust facial motion tracking is seamlessly integrated into the capture protocol.




Fig. 4: Left panel: A Libras interpreter in the controlled green-screen environment of the motion capture laboratory, outfitted with a kinematic tracking suit equipped with reflective optical markers and a head-mounted facial capture apparatus. Right panel: A visualization from the data processing software, displaying the digitally reconstructed skeletal rig and demonstrating the high-fidelity, high-resolution reproduction of the captured human kinematics.

The execution of the motion capture protocol required a specialized, coordinated team comprising a fluent Libras signer to accurately articulate linguistic structures, a system operator dedicated to monitoring the quality and correctness of the generated data, and two hardware technicians responsible for ensuring temporal synchronization and camera operation. As depicted in the left panel of Figure 4, the recording environment utilized a controlled green-screen backdrop with the subject positioned centrally. The signer was outfitted in a purpose-built MoCap suit made of non-reflective black fabric, specifically designed to accommodate the attachment of 73 spherical retroreflective markers. A spatial array of fourteen near-infrared (IR) cameras surrounded the capture volume, continuously tracking these markers to enable algorithmic reconstruction of the subject’s skeletal hierarchy and joint trajectories in 3D space.

Given the fundamental syntactic and semantic role of non-manual expressions in Libras grammar, the body-movement optical tracking system was operated alongside a dedicated facial-capture helmet (Faceware [9]). By using a specialized head-mounted camera (HMC), the system guaranteed absolute temporal synchronization between intricate upper-limb kinematics and nuanced facial articulations. The resulting software-driven digital reconstruction of this captured data is illustrated in Figure 4’s right panel.

During the post-processing phase, the captured 3D spatial coordinates are synchronized with the extracted facial telemetry, spatially scaled, and tempo-

rally resampled at a consistent rate of 60 frames per second (fps). To mitigate mechanical jitter and eliminate unnatural kinematic artifacts, the raw skeletal data is spatially centralized in the software environment, followed by advanced noise-reduction filtering. Furthermore, in instances where hand movements temporarily occluded the HMC’s view of the subject’s face, disrupting the raw facial capture, algorithmic interpolation was applied afterward. This ensures unbroken temporal coherence and maintains fluid, naturalistic animation throughout the sequence. The culmination of this comprehensive data acquisition and processing pipeline is the finalized rendering of the 3D avatar, Clara, as presented in Figure 5.




Fig. 5: A side-by-side comparison illustrating the kinematic transfer process. The left panel displays the human interpreter outfitted with the specialized motion-capture bodysuit and optical markers. The right panel shows the final rendering of the 3D avatar, Clara, accurately mirroring the precise skeletal posture and synchronized facial expressions captured directly from the source performance.

4 Corpus Processing

The architecture of the university restaurant’s web interface, specifically its reliance on dynamic content encapsulation within an `iframe` and JavaScript-driven tab navigation, required the engineering of a highly specialized parsing module. This component was explicitly designed to bypass the limitations of traditional static crawlers, which lack the capacity to execute the complex Document Object Model (DOM) interactions required to unveil dynamically loaded content across different days of the week.

To achieve this, the extraction algorithm leverages an external library to instantiate an automated web browser, thereby simulating human interaction. The operational sequence initiates by localizing the target `iframe` and shifting the automated driver’s execution context. Following this contextual switch, the system maps the navigational DOM elements, more specifically, the interactive tabs representing individual days, and triggers a sequence of programmatic click

events. Crucially, the algorithm is programmed to await the complete rendering of the DOM for each respective day prior to harvesting the underlying HTML source code.

Regarding the administration of accessible content, a knowledge-based methodology was adopted, serving as a functional bridge while the AI-driven machine translation pipeline remains under active development. The system creates a CSV file (`text2video.csv`) that functions as a correspondence dictionary, mapping discrete Portuguese linguistic units (e.g., specific dish nomenclature, dietary observations) to their synthesized video or animation counterparts. Upon encountering an undocumented or new sentence in the menu corpus, the parser registers a fallback entry utilizing a unique cryptographic hash identifier. This fail-safe mechanism empowers the production team to seamlessly track, isolate, and generate missing assets without disrupting the system’s continuous runtime operation.

Furthermore, the textual processing also includes specific refinements through the implementation of regular expressions, such as the decomposition of dates (converting “dd/mm” to the full day and month names, to maximize the modular reuse of existing video assets—alongside the systematic segmentation of list elements predicated on HTML `<br>` tag. Ultimately, to safeguard the visual integrity of the interface, the script transposes all relative file paths governing cascading style sheets (CSS) and embedded images into absolute URLs. This critical operation ensures that the locally rendered page preserves the exact aesthetic identity of the original one.

The implementation of the proposed solution, combined with data acquisition methodologies, has yielded results extending far beyond the simple technical deployment of the accessibility utility. Crucially, this effort has enabled the production of invaluable empirical resources, thereby significantly advancing the broader study of Sign Language Machine Translation (SLMT).

The intensive motion capture initiative culminated in the establishment of a robust, high-fidelity Portuguese-Libras parallel corpus. The scale of the processed raw data, totaling approximately 150 GB and encompassing an estimated 2,400 distinct grammatical sentences, represents a relevant advancement over the linguistic resources previously available in the Brazilian academic and technological landscape.

Contextualizing these achievements against the current national state-of-the-art, it is apparent that this newly built corpus works towards solving the limitations of pre-existing databases. Whereas historical datasets have been predominantly constrained to isolated lexical signs or minimal pairs designed expressly for discrete recognition tasks, the kinematic material acquired in this study captures the full complexity of continuous, flowing sentence structures. Furthermore, the acquisition of comprehensive full-body MoCap data alongside high-resolution facial data enriches the dataset. It accurately preserves the prosodic and grammatical non-manual markers that are absolutely indispensable for modeling continuous machine translation, consequently, bridging a critical lacuna in contemporary computational frameworks.

Finally, the engineering of the video-optimized parser (`parser.video.py`) established a rigorous methodological foundation for a comprehensive qualitative evaluation, permitting a critical comparative analysis of its operational trade-offs within the complex context of applied web accessibility. While this video-centric paradigm gives the distinct advantage of visual fidelity to the original human articulation, ensuring naturalness and bypassing the computational complexities of avatar retargeting through a streamlined, native HTML5 implementation, it simultaneously introduces substantial logistical disadvantages. Specifically, this approach imposes a high bandwidth burden due to the need to download relatively large, sentence-specific video files, a limitation further exacerbated by persistent cross-browser rendering inconsistencies with WebM alpha channel transparency, most notably in the Apple ecosystem (Safari and iOS).

5 Conclusions

The study reported in the paper established a foundational technological infrastructure for the automated implementation of Brazilian Sign Language (Libras) captions within web environments. The developed architecture, specifically the crawler and parser modules, demonstrated high efficacy in automating website adaptation through granular textual segmentation and injection of accessibility interfaces. Practical validation conducted on the university restaurant’s portal underscored the solution’s robustness, maintaining the integrity of the original layout while ensuring fluid navigation through dynamic content. Consequently, this approach represents a significant advancement in web content accessibility through automatic 3D avatar signaling.

Furthermore, the development of the new corpus – comprising approximately 2,400 sentences and 150 GB of high-fidelity kinematic and facial data, augmented by the ongoing acquisition of supplementary datasets – establishes a valuable scientific asset that contributes to existing national repositories. Despite these advancements, field validations indicate that the current knowledge-based translation strategy exhibits inherent scalability limitations when processing the linguistic variability characteristic of uncontrolled natural language environments. These findings suggest that while the acquisition and visualization solutions are now established, the transition to other contexts will fundamentally require integrating neural machine translation models trained on the comprehensive corpus developed in this study.

6 Acknowledgement

Removed for blind review

7 Ethical Considerations

The Libras signers in this project are not just participants, they are paid team members and co-authors of this study. Deaf and hard-of-hearing researchers were

involved in every stage of the project, from designing the data collection process to writing the paper. This helps us make sure that the linguistic details of Libras are treated with care and that the technology we develop truly reflects the needs of the community. All team members gave their informed consent for the use of their images and biometric data in the corpus. Since the data was created by the research team specifically for this resource, the project follows the institutional ethical guidelines for collaborative research.

References

1. Aziz, M., Othman, A.: Evolution and Trends in Sign Language Avatar Systems: Unveiling a 40-Year Journey via Systematic Review. *Multimodal Technologies and Interaction* **7**(10), 97 (2023) 3
2. Bernhard, L., Nunnari, F., Unger, A., Bauerdiek, J., Dold, C., Hauck, M., Stricker, A., Baur, T., Heimerl, A., André, E., et al.: Towards Automated Sign Language Production: A Pipeline for Creating Inclusive Virtual Humans. In: *Proceedings of the 15th International Conference on Pervasive Technologies Related to Assistive Environments*. pp. 260–268 (2022) 3
3. Bird, S., Klein, E., Loper, E.: *Natural Language Processing with Python*. O'Reilly Media, Sebastopol, CA (2009) 7
4. Bragg, D., Koller, O., Bellard, M., Berke, L., Boudreault, P., Braffort, A., Caselli, N., Huenerfauth, M., Kacorri, H., Verhoef, T., et al.: Sign Language Recognition, Generation, and Translation: An Interdisciplinary Perspective. In: *21st International ACM SIGACCESS Conference on Computers and Accessibility*. pp. 16–31 (2019) 3
5. BRASIL (Presidência da República): Decreto n° 5.626, de 22 de dezembro de 2005. *Diário Oficial da União* (246, Seção 1) (Dec 2005) 2
6. BRASIL (Presidência da República): Lei n° 13.146, de 6 de julho de 2015. *Diário Oficial da União* (127, Seção 1) (Jul 2015) 2
7. Chemnad, K., Othman, A.: Perception and Monitoring of Sign Language Acquisition for Avatar Technologies: A Rapid Focused Review (2020–2025). *Multimodal Technologies and Interaction* **9**(8), 82 (2025) 4
8. Conrad, R.: *The Deaf Schoolchild*. Harper and Row (1979) 1
9. Faceware Technologies: Faceware Facial Motion Capture System. <https://facewaretech.com/> (2024), accessed in: 2026 apr. 25 10
10. Fernandes, S., Moreira, L.C.: Políticas de Educação Bilíngue para Surdos: O Contexto Brasileiro. *Educar em Revista* (spe-2), 51–69 (2014) 1
11. Gimeno-Martínez, M., Costa, A., Baus, C.: Influence of Gesture and Linguistic Experience on Sign Perception. *The Journal of Deaf Studies and Deaf Education* **25**(1), 80–90 (2020) 2
12. IBGE: Pesquisa Nacional da Saúde. <https://agenciadenoticias.ibge.gov.br/agencia-sala-de-imprensa/2013-agencia-de-noticias/releases/31445-pns-2019-pais-tem-17-3-milhoes-de-pessoas-com-algum-tipo-de-deficiencia> (2019), accessed: 2026 apr. 25 1
13. Jaballah, K., Jenni, M.: A Review on 3D Signing Avatars: Benefits, Uses and Challenges. *International Journal of Multimedia Data Engineering and Management* **4**(1), 21–45 (2013) 2

14. Kipp, M., Nguyen, Q., Heloir, A., Matthes, S.: Assessing the Deaf User Perspective on Sign Language Avatars. In: 13th International ACM SIGACCESS Conference on Computers and Accessibility. pp. 107–114 (2011) 3
15. Krebs, J., Wilbur, R.B., Roehm, D., Malaia, E.: Neural Mechanisms of Event Visibility in Sign Languages. *Language, Cognition and Neuroscience* **38**(9), 1282–1301 (2023) 2
16. Loaiza-Ramírez, I., González-Beltrán, B.A.: Digital Accessibility Guidelines for Deaf and Hard of Hearing Persons: A State-of-the-Art Review Article. *Universal Access in the Information Society* **25**(1), 4 (2026) 3
17. Naert, L., Larboulette, C., Gibet, S.: A Survey on the Animation of Signing Avatars: From Sign Representation to Utterance Synthesis. *Computers & Graphics* **92**, 76–98 (2020) 2
18. Nolte, A., Gleißl, B., Heckmann, J., Wallach, D., Jochems, N.: “I Want To Be Able To Change The Speed And Size Of The Avatar”: Assessing User Requirements For Animated Sign Language Translation Interfaces. In: Extended Abstracts of the 2023 CHI Conference on Human Factors in Computing Systems. pp. 1–7 (2023) 3
19. Presidência da República: Lei número 6.001 (Dec 1973), *Diário Oficial da União*, Imprensa Nacional, n. 07, Seção 1 1
20. Presidência da República: Lei número 10.436 (Apr 2002), *Diário Oficial da União*, Imprensa Nacional, n. 79, Seção 1 2
21. Richardson, L.: Beautiful Soup Documentation. www.crummy.com/software/BeautifulSoup (2024), accessed in: 2026 apr. 25 6, 7
22. Selenium Project: Selenium Browser Automation. www.selenium.dev (2024), accessed in: 2026 apr. 25 7
23. Soudi, A., Hakkaoui, M.E., Van Laerhoven, K.: Do Predictability Factors Towards Signing Avatars Hold Across Cultures? arXiv preprint arXiv:2307.02103 (2023) 4
24. The jQuery Foundation: jQuery UI. www.jqueryui.com (2024), accessed in: 2026 apr. 25 7
25. Van Rossum, G., Drake, F.L.: Python 3 Reference Manual. CreateSpace, Scotts Valley, CA (2009) 6
26. Wasserroth, F., Avramidis, E., Czehmann, V., Kojic, T., Nunnari, F., Möller, S.: Evaluation of a Sign Language Avatar on Comprehensibility, User Experience & Acceptability. In: 25th ACM International Conference on Intelligent Virtual Agents. pp. 1–10 (2025) 4
27. WCGA: Web Content Accessibility Guidelines 2.2. <https://www.w3.org/TR/WCAG22> (2024), accessed: 2026 apr. 25 3
28. Wolfe, R., Braffort, A., Efthimiou, E., Fotinea, E., Hanke, T., Shterionov, D.: Special Issue on Sign Language Translation and Avatar Technology. *Universal Access in the Information Society* **24**(1), 1–3 (2025) 3
29. Wolfe, R., McDonald, J.C., Hanke, T., Ebling, S., Van Landuyt, D., Picron, F., Krausneker, V., Efthimiou, E., Fotinea, E., Braffort, A.: Sign Language Avatars: A Question of Representation. *Information* **13**(4), 206 (2022) 3

Anexo 14

Relatório Bolsista - DR

José Carlos Ferreira



Fundação de Amparo à Pesquisa do Estado de São Paulo (FAPESP)

RELATÓRIO CIENTÍFICO

José Carlos Ferreira

Título do projeto: Tradução Automática Texto-Glosa

Número do Processo FAPESP: 2025/03814-6

Período de vigência: 01/05/2025 a 30/04/2029

Período coberto pelo Relatório Científico em questão: 01/05/2025 a 30/06/2026

1 Formulário de acompanhamento de atividades do Bolsista

Em anexo.

2 Relatório Científico

2.1 Resumo do projeto proposto

Este projeto tem como objetivo desenvolver métodos de aprendizado de máquina voltados para a Produção de Língua de Sinais (*Sign Language Production*, SLP). O foco principal é o desenvolvimento de modelos capazes de executar uma tradução automática robusta de sentenças em português para sinalizações contínuas da Língua Brasileira de Sinais (Libras).

As línguas de sinais (LS) são o principal meio de comunicação da comunidade surda. Diferente das línguas orais, elas operam de forma visual-espacial. Isso significa que combinam movimentos das mãos, expressões faciais e postura corporal simultaneamente para construir o sentido e a gramática da frase. No entanto, o desconhecimento dessas línguas por parte da maioria da população ouvinte ainda cria barreiras profundas de comunicação e inclusão.

Ao contrário da percepção comum, a língua de sinais não é uma simples tradução literal ou palavra por palavra da língua falada, uma vez que ela possui uma estrutura sintática e gramatical totalmente independente (SAUNDERS; CAMGÖZ; BOWDEN, 2020). Diversas pesquisas têm sido realizadas na área de tradução automática de língua de sinais, sendo que esse campo pode ser dividido em três frentes: (i) reconhecimento (*Sign Language Recognition*), focado na análise de vídeos de sinalizantes e identificação dos sinais (contínuos ou isolados); (ii) tradução (*Sign Language Translation*), focada no mapeamento gramatical da língua de sinais para a língua falada; (iii) produção (*Sign Language Production*), concentrada na etapa de síntese de sinais a partir de sentenças em língua oral ou glosas.

Com a evolução recente das técnicas de aprendizado de máquina, impulsionadas pela introdução dos mecanismos de autoatenção em substituição aos processamentos recorrentes, pelo advento dos Grandes Modelos de Linguagem (LLMs) e dos modelos generativos (como os de Difusão), houve uma forte popularização de trabalhos de SLP baseados nessas novas arquiteturas (ZUO; POTAMIAS et al., 2024). Apoiado por tais métodos, este projeto tem como objetivo central a síntese gráfica contínua de sinais em Libras a partir de textos em português, utilizando glosas como representações intermediárias. O emprego das glosas é útil no *pipeline* de síntese contínua de sinais, pois em vez de tentar mapear o português diretamente para os *pixels* do vídeo, as glosas simplificam o problema ao atuarem como representações textuais que absorvem a complexidade do idioma oral através de lematizações, reordenam sintaticamente as sentenças para garantir um alinhamento cronológico entre o texto e os sinais gráficos, além de carregarem, dependendo do formalismo adotado, informações complementares para a sinalização (e.g., indicação de que a palavra deve ser soletrada manualmente). Adicionalmente, o uso de glosas permite separar a etapa de processamento de linguagem natural da etapa de renderização gráfica ao dividir o processo em duas fases independentes e com redes neurais distintas: etapa *Text-to-Gloss*, em que uma rede neural é treinada para mapear sentenças escritas em língua oral (e.g., língua portuguesa) para sequências de glosas e a etapa *Gloss-to-Sign*, em que métodos clássicos de computação gráfica ou redes generativas são utilizados para a síntese dos sinais a partir das glosas. Neste primeiro

ano de projeto, foi dada ênfase ao desenvolvimento, implementação e refinamento de modelos *Text-to-Gloss*.

O projeto está vinculado à linha de fomento dos Programas Especiais / PCD - Programa Ciência para o Desenvolvimento / PCD - CCD - Centros de Ciências para o Desenvolvimento. O trabalho em questão está associado ao Centro de Ciência para o Desenvolvimento - Tecnologia Assistiva e Acessibilidade em Libras (CCD-TAAL), que é uma articulação de caráter multidisciplinar envolvendo pesquisadores da Universidade Estadual de Campinas (UNICAMP), da Universidade de São Paulo (USP) e do Instituto de Pesquisas Tecnológicas (IPT), em parceria com a Secretaria Estadual dos Direitos da Pessoa com Deficiência. O CCD-TAAL busca avançar no desenvolvimento de soluções que diminuam os obstáculos de comunicação entre a comunidade surda e a ouvinte. O CCD-TAAL se propõe a enfrentar esse desafio focando no desenvolvimento de abordagens para a tradução automática da Língua Brasileira de Sinais (Libras) para português, e vice-versa, explorando técnicas de aprendizado de máquina baseadas em redes neurais. Essa missão está alinhada com o tema estratégico proposto na Chamada FAPESP, que busca um projeto de pesquisa sobre inteligência artificial para acessibilizar a Libras.

2.2 Realizações no período

2.2.1 Visão Geral

O presente relatório científico compreende o primeiro ano do projeto. Nesse período, destacam-se as seguintes atividades realizadas:

1. Cumprimento de todos os créditos obrigatórios do programa de doutorado da Faculdade de Engenharia Elétrica e de Computação (FEEC) da UNICAMP.
2. Revisão bibliográfica de artigos no campo de SLP, englobando principalmente trabalhos nas subáreas de conversão *Text-to-Gloss* (T2G), *Text-to-Gloss-to-Sign* (T2G2S) e *Text-to-Sign* (T2S);
3. Revisão bibliográfica das principais bases de dados de língua de sinais;
4. Definição e preparação dos dados para o treinamento de modelos T2G;
5. Escolha de modelos pré-treinados mais viáveis para o procedimento de conversão T2G, levando em conta as bases de dados escolhidas, hardware disponível e eficiência da arquitetura para a tarefa;
6. Implementação, adaptação e refinamento dos modelos T2G. As adaptações e refinamentos incluíram estudos de ablação e sensibilidade para diversos mecanismos de regularização (*data augmentation*, *label smoothing*, etc.);
7. Escrita de texto bibliográfico sobre trabalhos nas áreas de T2G, T2G2S, T2S e sobre os *data-sets* das línguas de sinais;
8. Participação e organização de sessões de gravação para a construção de bases de dados em Libras.

2.2.2 Modelo de conversão *Text-to-Gloss*

No primeiro ano do projeto, buscou-se uma melhor compreensão do tema de pesquisa por meio, entre outras atividades, da revisão bibliográfica de trabalhos importantes da área, conforme descrito nos itens 2 e 3 da lista anterior. A revisão também foi importante para o entendimento das principais metodologias adotadas no campo de SLP. Fundamentado por diversos trabalhos na literatura (STOLL et al., 2018; SAUNDERS; CAMGÖZ; BOWDEN, 2020; SAUNDERS; CAMGOZ, N.; BOWDEN, 2022; MARTINO; CHRISTINELE, 2024; ZUO; WEI et al., 2025), pela experiência da equipe de pesquisa e pelas bases de dados disponíveis, decidiu-se que a adoção de um modelo em cascata *Text-to-Gloss-to-Sign* seria o mais viável para o projeto, em oposição a um modelo *end-to-end* (também chamado de modelo *Text-to-Sign*).

A principal motivação para essa escolha está no fato de que as línguas de sinais são definidas como línguas de baixos recursos (MÜLLER et al., 2023), carecendo de bases de dados massivas equivalentes às das línguas orais. Para lidar com essa escassez, a adoção de glosas como língua intermediária no *pipeline* de síntese é conveniente, pois elas absorvem a complexidade gramatical da língua portuguesa, reduzindo a diversidade do domínio de entrada dos modelos sintetizadores de sinais e, consequentemente, facilitando o treinamento das redes neurais. Além disso, elas garantem o alinhamento cronológico entre o sinal e o texto. Por outro lado, modelos *end-to-end* tentam mapear o texto oral diretamente para o espaço visual, exigindo um volume de dados consideravelmente maior para aprender as regras linguísticas e a representação espacial dos movimentos de forma simultânea, visto que utilizam uma única função de perda para lidar com a gramática e a renderização.

Outra decisão adotada neste primeiro ano foi a utilização de um modelo de tradução previamente treinado em línguas orais para a tarefa de conversão *Text-to-Gloss*, em oposição à criação de um modelo de tradução do zero. Essa estratégia baseia-se na ideia de transferência de aprendizado (*transfer learning*). Como os modelos de linguagem atuais são pré-treinados em volumes massivos de texto, eles já possuem uma compreensão sintática e semântica profunda do idioma de origem (português). Além disso, as glosas utilizam o vocabulário da língua oral para representar os sinais, logo, o modelo não precisa reaprender o significado das palavras. Durante o *fine-tuning*, ele concentra-se em aprender o reordenamento sintático, as lematizações e complementações exigidas pelo formalismo adotado. Tentar construir um modelo com conhecimento profundo na língua portuguesa utilizando exclusivamente bases de dados de Libras seria inviável, justamente pela natureza de baixos recursos desses *datasets*.

Após a avaliação de diversos modelos neurais de tradução, decidiu-se, com base na análise do desempenho em *datasets* de língua de sinais e nos recursos computacionais disponíveis, que o modelo multilíngue mBART (TANG et al., 2020) era o mais viável para o projeto.

O mBART, abreviação de *multilingual Bidirectional and Auto-Regressive Transformer*, utiliza a arquitetura Transformer *sequence-to-sequence* padrão proposta por Vaswani et al. (2017). A sua estrutura pode ser vista como uma generalização de duas abordagens populares no campo de processamento de linguagem natural: o emprego de *encoder* bidirecional para compreensão profunda do texto, análogo ao BERT (DEVLIN et al., 2019), e a utilização de um *decoder* autorregressivo para a geração contínua de texto, semelhante ao GPT (RADFORD et al., 2018). As duas arquiteturas são acopladas em uma estrutura *encoder-decoder*. O mBART é uma extensão multilíngue do BART (LEWIS et al., 2020), um *denoising autoencoder* pré-treinado para reconstruir documentos corrompidos. O modelo corrompe os dados de entrada substituindo trechos de tamanho variável por um único elemento [MASK], técnica conhecida como *Text Infilling*, e também através da per-

mutação aleatória de sentenças. Ao tentar reconstruir textos fortemente corrompidos, o modelo é forçado a desenvolver uma compreensão sintática e semântica robusta do idioma. Esse conhecimento linguístico torna o mBART altamente eficaz para o *fine-tuning* em tarefas de tradução automática. A Figura 1 ilustra as etapas do pré-treinamento do mBART, utilizando um texto em português como referência:

1. O texto original, que no exemplo é a frase "Fui a Roma. E voltei.", é passado ao *tokenizador*.
2. A *tokenização* ocorre, gerando o vetor alvo X . Esse vetor incorpora os *tokens* especiais de controle [`</s>`] e [`<pt_BR>`] que indicam o final da sentença e o idioma do texto, respectivamente.
3. O texto original sofre corrupção. A ordem das sentenças é permutada e um subconjunto de *tokens* é substituído por um único *token* [MASK] (no exemplo, o termo "Roma" foi ocultado). Essa função de ruído é representada matematicamente por $g(X)$.
4. O vetor corrompido é processado pelo *encoder* bidirecional. O resultado é a matriz de estados ocultos H_{enc} , uma representação matemática com os principais *features* contextuais extraídos da entrada.
5. O *decoder* autorregressivo recebe a matriz H_{enc} e o vetor X_{dec} , que é o vetor original X com os *tokens* originais deslocados para a direita (*shifted right*), com a posição inicial x_0 ocupada pelo *token* de identificação de idioma [`<pt_BR>`]. Processando essas informações, o *decoder* gera o vetor $\hat{X}$, que representa a distribuição de probabilidades preditivas para o próximo *token* do instante atual, considerando todo o vocabulário da rede.
6. A função de perda compara as previsões $\hat{X}$ com o alvo real X . O modelo é otimizado via Entropia Cruzada (*Cross-Entropy*), em que o objetivo é minimizar a seguinte função:

$$\mathcal{L}(\theta) = - \sum_{t=1}^N \log P(x_t | x_{<t}, g(X); \theta)$$

Em que N é o tamanho da sentença de entrada (número total de *tokens* da sequência de entrada) e θ representa os parâmetros ajustáveis da rede. O mecanismo penaliza o modelo ao calcular o logaritmo negativo da probabilidade condicional de gerar o *token* correto, x_t , dados os *tokens* anteriores, $x_{<t}$, e a representação global do texto corrompido $g(X)$. Os parâmetros θ do *encoder* e *decoder* são atualizados conjuntamente via retropropagação do erro calculado na função objetivo




Figura 1: Exemplo ilustrativo do *pipeline* do pré-treinamento do modelo de tradução mBART.

No contexto específico da conversão *Text-to-Gloss*, o pré-treinamento do mBART em *corpora* multilíngues de larga escala permite ao *encoder* adquirir uma profunda compreensão semântica e sintática da língua oral. Durante o *fine-tuning*, etapa na qual a rede é treinada para converter

sentenças em língua falada em sequências de glosas, o conhecimento adquirido previamente é aproveitado. O fato das glosas serem baseadas no vocabulário da língua oral permite que o modelo aproveite as representações lexicais já aprendidas. Assim, a otimização da rede foca quase que exclusivamente no reordenamento gramatical, supressão de artigos e preposições, predição de marcadores (e.g., apontamentos) e outros elementos, a depender da notação adotada pela base de dados. Além disso, a aplicação de técnicas de regularização durante o treinamento, como o *label smoothing*, *dropout* e o aumento artificial de dados (*data augmentation*), contribui para amenizar os sobreajustes da rede, um problema comum em bases de dados escassas, principalmente ao utilizar grandes modelos de linguagem. A Figura 2 ilustra o processo de *fine-tuning* do modelo.

1. O treinamento é supervisionado. Para cada sentença de entrada em língua oral, existe uma sequência de glosas alvo associada (*ground truth*). A sentença é submetida ao *tokenizador*. No exemplo ilustrativo, a entrada "Você é apenas um garoto." é associada à respectiva sequência de glosas "VOCÊ GAROTO."
2. A *tokenização* ocorre de forma análoga ao pré-treinamento, resultando inicialmente no vetor discreto de *tokens* X , que incorpora os identificadores especiais de controle [$\langle s \rangle$] e [$\langle \text{pt_BR} \rangle$].
3. Os dados são injetados diretamente no *encoder* pré-treinado. Diferentemente do pré-treinamento, a entrada não sofre corrupção. O *encoder* processa o texto limpo e gera a matriz de estados ocultos H_{enc} , que codifica o contexto global da sentença original.
4. O vetor Y_{dec} , que consiste na sequência de glosas alvo com um deslocamento posicional para a direita (*shifted right*) é gerado.
5. O *decoder* recebe a matriz de contexto H_{enc} (via *cross-attention*) e Y_{dec} (via *masked self-attention*). O produto final do processamento é a matriz $\hat{Y}$, que contém as distribuições de probabilidade prevendo a próxima glosa para todos os instantes de tempo simultaneamente.
6. A função de perda, baseada na Entropia Cruzada, compara o gabarito das glosas alvo Y com as predições $\hat{Y}$ da rede. Matematicamente, a perda a ser minimizada é definida como:

$$\mathcal{L}(\theta) = - \sum_{t=1}^N \log P(y_t | y_{<t}, X; \theta)$$

Sendo N o tamanho total da sequência alvo. O objetivo da otimização é maximizar a probabilidade de prever a glosa correta no instante y_t , condicionada às glosas anteriores $y_{<t}$ e à entrada X . Os parâmetros ajustáveis θ do *encoder* e *decoder* são atualizados conjuntamente via retropropagação de erros. No caso específico da conversão T2G, utilizou-se a técnica de *label smoothing* (LI; DASARATHY; BERISHA, 2020) na função de perda, evitando *one-hot encoding* na sequência alvo, Y , através da redistribuição de probabilidades, amenizando, assim, o excesso de confiança da rede e regularizando-a diante dos ruídos do *dataset*.




Figura 2: Exemplo ilustrativo do *pipeline* de treinamento do modelo mBART para a tarefa de conversão T2G.

2.2.3 Resultados obtidos

Para o *fine-tuning* do modelo e avaliação de seu desempenho na tarefa de mapeamento T2G, foram utilizadas duas bases de dados: RWTH-PHOENIX-Weather 2014T (PHOENIX-14T) (KOLLER; FORSTER; NEY, 2015) e o VLibrasBD (LIMA et al., 2025). O *dataset* Phoenix-14T, um dos mais referenciados em trabalhos de tradução automática em língua de sinais, é composto por frases (pares de sentenças em língua oral e glosas) e vídeos extraídos de um noticiário televisivo meteorológico alemão. O VLibras, uma base puramente textual, é composta por sentenças extraídas de artigos da Wikipédia em português, do CETENFolha (um vasto corpus de textos do jornal Folha de S. Paulo) e por sentenças focadas em conteúdos e serviços digitais do Governo Federal do Brasil (extraídas do portal gov.br). As informações sobre o tamanho, o tipo de dados, o domínio e o vocabulário dos *datasets* estão descritas na Tabela 1. Além disso, alguns exemplos de sentenças e as respectivas glosas de cada base estão ilustrados nas Tabelas 2 e 3.

Tabela 1: Comparação dos *datasets* em tradução de Língua de Sinais.

Dataset	Línguas (Oral / Sinais)	Modalidade	Domínio	Tamanho	Vocabulário (Palavras / Glosas)
PHOENIX-14T	Alemão / DGS	Vídeo e Texto	Previsão do Tempo	8.257 sentenças	2.887 / 1.066
VLibrasBD	Português / Libras	Texto	Geral e Governamental	127.349 sentenças	Não reportado

Tabela 2: Exemplos de pares sentenças-glosas do *dataset* VLibrasBD.

Português	Glosas (Libras)
Membros previamente cadastrados podem consultar informações turísticas dos destinos brasileiros.	MEMBRO&GRUPO PRÉVIO CADASTRAR PODER&POSSIBILIDADE CONSULTAR&PESQUISAR INFORMAÇÃO TURÍSTICO DESTINO&BRASIL [PONTO]
Tenho mais um favor para pedir.	TER FAVOR 1S_PEDIR_2S [PONTO]
A Noite Estrelada é um óleo sobre tela do pintor pós-impressionista holandês Vincent van Gogh.	NOITE ESTRELAR ÓLEO SOBRE&ASSUNTO TELA PINTOR PÓS_IMPRESSIONISTA HOLANDA&PAÍS VINCENT_VAN_GOGH&FAMOSO [PONTO]

Tabela 3: Exemplos de pares sentenças-glosas do *dataset* Phoenix-14T.

Alemão	Glosas (DGS)
Im Süden freundliches Wetter (No sul, o tempo está agradável).	SUED REGION BESSER (REGIÃO SUL MELHOR).
Tim Westen ist es freundlich (No oeste, o clima é agradável).	WEST FREUNDLICH (OESTE AGRADÁVEL).
Morgen scheint dann wieder überall die Sonne (Amanhã o sol vai brilhar novamente em todos os lugares).	MORGEN ÜBERWIEGEND SONNE (AMANHÃ PREVALECERÁ SOL).

Para os experimentos no *dataset* Phoenix-14T, diversas estratégias de otimização e regularização foram implementadas com o intuito de melhorar a capacidade de generalização do modelo e amenizar o efeito de *overfitting*, visto que o mBART é um grande modelo de linguagem, composto por cerca de 611 milhões de parâmetros (LIU et al., 2023), e foi adaptado para a tarefa de mapeamento *Text-to-Gloss* em uma base de dados relativamente pequena, com 8.257 sentenças (7.096 para treinamento, 519 para validação e 642 para teste). Entre as abordagens avaliadas para estabilizar o aprendizado, destacam-se:

- O emprego de *Label Smoothing* (LI; DASARATHY; BERISHA, 2020) na função de perda. Essa estratégia suaviza a distribuição de probabilidades do vetor alvo, substituindo a representação rígida do *one-hot encoding* por uma distribuição contínua. Isso impede que os pesos da rede cresçam desproporcionalmente na tentativa de empurrar os *logits* para o infinito, evitando que o modelo se torne excessivamente confiante em suas predições e acabe memorizando ruídos.
- Aplicação de *dropout* tanto nas camadas densas quanto nas matrizes de atenção. O desligamento aleatório dos neurônios, durante a fase de treinamento, força a rede a distribuir o aprendizado por toda sua arquitetura, evitando que apenas um subconjunto específico de neurônios controle a rede. Esse mecanismo contribui para a regularização do modelo.
- A adoção da busca em feixe (*beam search*) (FREITAG; AL-ONAIZAN, 2017) como heurística de inferência, em substituição à busca gulosa (*greedy search*). Essa abordagem é mais flexível, pois permite analisar um número maior de sequências de glosas candidatas, sem se limitar à melhor escolha no instante presente. O mecanismo de busca em feixe eleva a qualidade da conversão, pois avalia um número maior de possíveis soluções.
- O controle dinâmico da taxa de aprendizado por meio de um período inicial de aquecimento (*warm-up*) seguido de decaimento linear. Isso protege os pesos pré-treinados do mBART contra atualizações bruscas e destrutivas nas primeiras épocas e garante uma convergência mais estável no final do treinamento.
- Implementação de um treinamento em duas fases baseado em *data augmentation*. Na primeira fase (generalista), o modelo foi treinado com o *dataset* Phoenix-14T expandido artifi-

cialmente via *backtranslation* (EDUNOV et al., 2018), passando de 7.096 para 14.192 sentenças. Na segunda fase (especialista), o modelo foi refinado ao ser treinado exclusivamente com os dados originais e submetido a uma taxa de aprendizado reduzida, com o intuito de lapidar o conhecimento adquirido previamente.

Após a realização de diversos experimentos e avaliação sistemática das estratégias descritas, o melhor modelo mBART de conversão *Text-to-Gloss* apresentou as seguintes características: treinamento em duas fases com *data augmentation*, *label smoothing* de 10%, *dropout* de 30% nas camadas densas e de 10% nas matrizes de atenção, largura de feixe igual a 5 ($k=5$) para o algoritmo de *beam search*, taxa de aprendizado inicial de $5 \cdot 10^{-5}$ com controle dinâmico para a primeira fase e de $1 \cdot 10^{-4}$ para a segunda fase. O modelo mBART otimizado foi comparado, via métricas BLEU, com os principais modelos T2G reportados na literatura que utilizam o conjunto de teste do Phoenix-14T. Os resultados obtidos estão ilustrados na Tabela 4

Tabela 4: Comparação de desempenho na conversão T2G para o conjunto de teste do Phoenix-14T.

Método	BLEU-1	BLEU-2	BLEU-3	BLEU-4
(STOLL et al., 2018)	50,67	32,25	21,54	15,26
(SAUNDERS; CAMGOZ, N. C.; BOWDEN, 2020)	55,18	37,10	26,24	19,10
(LI; XU et al., 2022)	-	-	25,51	18,89
(WALSH; SAUNDERS; BOWDEN, 2022)	58,74	40,86	30,24	23,19
(WALSH; SAUNDERS; BOWDEN, 2024)	60,13	35,10	22,65	15,60
(OUARGANI; EL KHATTABI, 2025)	63,60	28,50	15,20	9,00
mBART otimizado	63,83	45,14	33,39	25,51

Os trabalhos na área de T2G têm evoluído na busca de arquiteturas e metodologias capazes de lidar com a escassez de dados para a tradução automática em língua de sinais. Abordagens iniciais, como a de Stoll et al. (2018), estabeleceram *baselines* utilizando redes neurais recorrentes, as quais sofrem com problemas de esquecimento, especialmente em palavras com dependências de longo alcance. A metodologia evoluiu com o uso de *Transformers* padrões treinados do zero (SAUNDERS; CAMGOZ, N. C.; BOWDEN, 2020; OUARGANI; EL KHATTABI, 2025) que possuem maior capacidade de atenção global, entretanto, são suscetíveis ao *overfitting* quando treinados em bases de baixo recurso. Outras estratégias, que alteram a formulação do problema, foram abordadas para contornar a ausência de um volume expressivo de dados de treinamento. Li, Xu et al. (2022) substituíram a geração direta por heurísticas de edição (i.e., adição, deleção e cópia de *tokens*). De forma análoga, Walsh, Saunders e Bowden (2024) decompuseram o *pipeline* em etapas independentes de seleção de glosas e reordenamento não autorregressivo, enquanto Walsh, Saunders e Bowden (2022) buscaram otimizar a entrada através de *embeddings* linguísticos e transcrições fonéticas alternativas.

A metodologia proposta neste trabalho utiliza o *fine-tuning* do modelo mBART sob a justificativa de que a transferência de aprendizado, que ocorre para a tarefa de mapeamento *Text-to-Gloss*, é extremamente valiosa e desempenha papel importante na capacidade de generalização do modelo de tradução. Como observado na Tabela 4, o desempenho do mBART foi superior aos outros métodos abordados na literatura. O conhecimento gramatical do modelo adquirido em seu pré-treinamento faz com que ele supere o desempenho de arquiteturas treinadas do zero ou de estratégias mais complexas que adotam heurísticas e decomposições do problema.

Para o *dataset* Phoenix-14T, também foram realizados estudos de ablação e análises de sensibilidade, conforme ilustram as Tabelas 5, 6 e 7.

Tabela 5: Desempenho do mBART em relação ao *dropout*, com todos os outros parâmetros fixos.

Dropout	BLEU-1	BLEU-2	BLEU-3	BLEU-4
0	62,00	42,34	30,59	22,65
0,1	62,93	44,28	32,58	24,74
0,2	63,83	45,14	33,39	25,51

Tabela 6: Desempenho do mBART em relação ao *label smoothing*, com os outros parâmetros fixos.

<i>Label Smoothing</i>	BLEU-1	BLEU-2	BLEU-3	BLEU-4
0	61,39	42,00	30,26	22,64
0,1	63,83	45,14	33,39	25,51
0,2	62,77	43,40	31,44	23,36

Tabela 7: Desempenho do mBART com e sem *data augmentation*.

<i>Data Augmentation</i>	BLEU-1	BLEU-2	BLEU-3	BLEU-4
Sem (treinamento em uma única fase)	63,32	44,65	32,93	25,00
Com (treinamento em duas fases)	63,83	45,14	33,39	25,51

A remoção (ablação) de mecanismos de regularização impactou o desempenho do modelo. A exclusão do *Dropout* (nas camadas densas) e a remoção do *Label Smoothing* resultaram em quedas nas métricas de BLEU, confirmando a premissa de que a rede é propensa ao *overfitting* em domínios de dados escassos como o Phoenix-14T. A técnica de *Label Smoothing*, em particular, provou-se essencial para evitar o excesso de confiança da rede diante de dados ruidosos. De forma análoga, a remoção do treinamento em duas fases com *Data Augmentation* reduziu a capacidade de generalização do modelo, evidenciando a importância de enriquecimento artificial do corpus e treinamento de duas fases.

O modelo mBART também foi avaliado na base VLibrasBD. O *dataset* possui um volume expressivo de dados, de aproximadamente 127 mil sentenças, consideravelmente superior ao de 8 mil sentenças do Phoenix-14T. Dessa forma, a dinâmica de otimização adotada foi diferente, com menor foco em técnicas de regularização, visto que a própria variabilidade inerente ao *dataset* atua como mecanismo de regularização, reduzindo as probabilidades de sobreajustes da rede. Para o *fine-tuning* do mBART, adotou-se um treinamento em duas etapas. A primeira etapa concentrou-se na convergência global do modelo ao utilizar taxas de aprendizado maiores. E na segunda etapa, buscou-se o refinamento local, no qual o *learning rate* foi reduzido para estabilizar a descida do gradiente, e a taxa de *dropout* foi atenuada.

Segundo nosso conhecimento, não há *baselines* na tarefa de tradução *Text-to-Gloss* que empregam o VLibrasBD. Portanto, os resultados obtidos estabelecem a *baseline* desse *dataset* para a conversão T2G. Visto que o VLibrasBD não tem uma divisão oficial dos dados, foi adotada uma partição de 70% para o treinamento, 20% para a validação e o restante para o treinamento. Na primeira etapa do treinamento, empregou-se taxa de aprendizado de $2 \cdot 10^{-5}$, sem *label smoothing*

e *dropouts* de 0,3 e 0,1 nas camadas densas e nas matrizes de atenção, respectivamente. Na segunda etapa, adotou-se taxa de aprendizado de $5 \cdot 10^{-6}$, *label smoothing* de 0,1 e *dropouts* de 0,1 tanto nas camadas quanto nas matrizes. Os resultados estão ilustrados na Tabela 8. A Tabela 9 ilustra algumas sequências de glosas preditas pelo modelo em comparação às sequências alvo.

Tabela 8: Desempenho do modelo mBART para o *dataset* VLibrasBD no conjunto de teste.

Método	BLEU-1	BLEU-2	BLEU-3	BLEU-4
mBART otimizado	81,86	65,10	51,99	41,12

Tabela 9: Sentenças em português do VLibras e suas respectivas sequências de glosas alvo em comparação com as sequências preditas pelo mBART.

Sentença	Glosas Alvo	Glosas Preditas
Eu sou contra a guerra.	contra&contrário guerra [ponto]	contra&contrário guerra [ponto]
Se o denunciado possui débitos inscritos em dívida ativa cobrados pela Procuradoria-Geral da Fazenda Nacional (PGFN).	denunciar possuir débito inscrito dívida ativo cobrar procurado- ria_geral_da_fazenda_nacional [ponto]	se denunciar possuir débito inscrito dívida_ativa cobrar procurado- ria_geral_da_fazenda_nacional [ponto]
Obter aprovação dos Programas de Desativação de Instalações na Fase de Produção (atividades em terra).	obter aprovar programa&projeto desativar instalação fase produção atividade terra&local [ponto]	obter aprovar programa&projeto desativar instalação fase produção atividade terra&local [ponto]
Obter incentivo fiscal para projetos de infraestrutura em irrigação.	obter incentivo_fiscal projeto&documento infraestrutura irrigar [ponto]	obter incentivo_fiscal projeto&documento infraestrutura irrigação [ponto]
O país foi fundado em 1822.	país fundar ano&data 1822 [ponto]	país fundar ano&data 1822 [ponto]
Solicitar atualização cadastral dos dados da Operadora de Planos de Saúde e da Administradora de Benefícios.	1s_pedir_2s atualizar cadastral dado&informação operadora plano&saúde administradora benefício [ponto]	1s_pedir_2s atualizar cadastral dado&informação operador plano&saúde administrar&gerenciar benefício [ponto]

Pela Tabela 8, observamos que o mBART foi capaz de obter bons resultados nas métricas BLEUs, mesmo com baixos mecanismos de regularização (e.g., *label smoothing* nulo na segunda

etapa de treinamento). Isso ocorreu pelo fato da base VLibrasBD possuir um volume expressivo de dados, permitindo que modelos maiores de tradução sejam capazes de aprender as regras gramaticais da geração de glosas sem sobreajustes consideráveis. A Tabela 9 corrobora com a hipótese de aprendizado eficiente do mBART, visto a semelhança entre as sequências alvo e a predita. Mesmo quando elas não são exatamente iguais, as glosas preditas conseguem passar a informação corretamente sem grandes alterações.

3 Plano de atividades para o próximo período

O plano de atividades para o próximo período, de 01/07/2026 até 30/06/2027, está descrito na Tabela 10. Neste período, pretende-se realizar tarefas:

1. Elaboração e submissão de artigo com os resultados obtidos na tarefa de tradução *Text-to-Gloss*;
2. Elaboração e defesa de qualificação de tese do doutorado;
3. Escrita inicial da tese de doutorado;
4. Construção de bases de dados em Libras;
5. Estudo, implementação e refinamento de modelos *Gloss-to-Sign*;
6. Elaboração e submissão de artigos com resultados provenientes de modelos *Gloss-to-Sign* e *Text-to-Gloss-to-Sign*.

Tabela 10: Cronograma de execução das atividades previstas para os próximos 12 meses.

Atividades	Meses											
	1	2	3	4	5	6	7	8	9	10	11	12
(1) Artigo <i>Text-to-Gloss</i>												
(2) Qualificação												
(3) Escrita inicial da tese												
(4) Coleta de dados												
(5) Modelo <i>Gloss-to-Sign</i>												
(6) Artigo <i>Text-to-Gloss-to-Sign</i>												

4 Outras seções

Não há nada a ser declarado sobre as seções: 4) Participação em evento científico, 5) Lista das publicações resultantes da Bolsa no período a que se refere o Relatório Científico, 6) Cópias das primeiras páginas dos trabalhos listados na seção anterior, 7) Lista dos trabalhos preparados ou submetidos para publicação e 8) Cópia do relatório do estágio BEPE e a avaliação do supervisor no exterior.

Referências

- DEVLIN, J. et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In: PROCEEDINGS of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). Minneapolis, Minnesota: Association for Computational Linguistics, jun. 2019. P. 4171-4186. DOI: [10.18653/v1/N19-1423](https://doi.org/10.18653/v1/N19-1423). Disponível em: <https://aclanthology.org/N19-1423/>.
- EDUNOV, S. et al. Understanding Back-Translation at Scale. In: RILOFF, E. et al. (Ed.). *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*. Brussels, Belgium: Association for Computational Linguistics, out. 2018. P. 489-500. DOI: [10.18653/v1/D18-1045](https://doi.org/10.18653/v1/D18-1045). Disponível em: <https://aclanthology.org/D18-1045/>.
- FREITAG, M.; AL-ONAIZAN, Y. Beam Search Strategies for Neural Machine Translation. In: LUONG, T. et al. (Ed.). *Proceedings of the First Workshop on Neural Machine Translation*. Vancouver: Association for Computational Linguistics, ago. 2017. P. 56-60. DOI: [10.18653/v1/W17-3207](https://doi.org/10.18653/v1/W17-3207). Disponível em: <https://aclanthology.org/W17-3207/>.
- KOLLER, O.; FORSTER, J.; NEY, H. Continuous sign language recognition: Towards large vocabulary statistical recognition systems handling multiple signers. *Computer Vision and Image Understanding*, v. 141, p. 108-125, 2015. ISSN 1077-3142. DOI: <https://doi.org/10.1016/j.cviu.2015.09.013>. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1077314215002088>.
- LEWIS, M. et al. BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension. In: JURAFSKY, D. et al. (Ed.). *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Online: Association for Computational Linguistics, jul. 2020. P. 7871-7880. DOI: [10.18653/v1/2020.acl-main.703](https://doi.org/10.18653/v1/2020.acl-main.703). Disponível em: <https://aclanthology.org/2020.acl-main.703/>.
- LI, D.; XU, C. et al. Transcribing Natural Languages for the Deaf via Neural Editing Programs. *The Thirty-Sixth AAAI Conference on Artificial Intelligence (AAAI-22)*, 2022.
- LI, W.; DASARATHY, G.; BERISHA, V. Regularization via Structural Label Smoothing. In: CHIAPPA, S.; CALANDRA, R. (Ed.). *Proceedings of the Twenty Third International Conference on Artificial Intelligence and Statistics*. PMLR, 2020. v. 108. (Proceedings of Machine Learning Research), p. 1453-1463. Disponível em: <https://proceedings.mlr.press/v108/li20e.html>.
- LIMA, M. A. et al. VLibrasBD: A Brazilian Portuguese-Brazilian sign language (Libras) bilingual text dataset designed to support neural machine translation. *Data in Brief*, v. 62, p. 111911, 2025. ISSN 2352-3409. DOI: <https://doi.org/10.1016/j.dib.2025.111911>. Disponível em: <https://www.sciencedirect.com/science/article/pii/S2352340925006353>.
- LIU, Y. et al. Communication Efficient Federated Learning for Multilingual Neural Machine Translation with Adapter. In: ROGERS, A.; BOYD-GRABER, J.; OKAZAKI, N. (Ed.). *Findings of the Association for Computational Linguistics: ACL 2023*. Toronto, Canada: Association for Computational Linguistics, jul. 2023. P. 5315-5328. DOI: [10.18653/v1/2023.findings-acl.327](https://doi.org/10.18653/v1/2023.findings-acl.327). Disponível em: <https://aclanthology.org/2023.findings-acl.327/>.

- MARTINO, J. M. D.; CHRISTINELE, D. S. Exploring Pre-Trained Transformers for Translating Portuguese Text to Brazilian Sign Language. In: PROCEEDINGS of the 16th International Conference on Computational Processing of Portuguese - Vol. 1. Santiago de Compostela, Galicia/Spain: Association for Computational Linguistics, 2024. P. 67–75. Disponível em: <<https://aclanthology.org/2024.propor-1.7/>>.
- MÜLLER, M. et al. Considerations for meaningful sign language machine translation based on glosses. In: ROGERS, A.; BOYD-GRABER, J.; OKAZAKI, N. (Ed.). *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*. Toronto, Canada: Association for Computational Linguistics, jul. 2023. P. 682–693. DOI: [10.18653/v1/2023.acl-short.60](https://doi.org/10.18653/v1/2023.acl-short.60). Disponível em: <<https://aclanthology.org/2023.acl-short.60/>>.
- OUARGANI, Y.; EL KHATTABI, N. Transformer-Based Optimization for Text-to-Gloss in Low-Resource Neural Machine Translation. *ITEGAM-JETIA*, v. 11, n. 51, p. 99–111, jan. 2025. DOI: [10.5935/jetia.v11i51.1423](https://doi.org/10.5935/jetia.v11i51.1423). Disponível em: <<https://itegam-jetia.org/journal/index.php/jetia/article/view/1423>>.
- RADFORD, A. et al. Improving language understanding by generative pre-training. OpenAI, 2018.
- SAUNDERS, B.; CAMGOZ, N.; BOWDEN, R. Signing at Scale: Learning to Co-Articulate Signs for Large-Scale Photo-Realistic Sign Language Production. In: p. 5131–5141. DOI: [10.1109/CVPR52688.2022.00508](https://doi.org/10.1109/CVPR52688.2022.00508).
- SAUNDERS, B.; CAMGOZ, N. C.; BOWDEN, R. Progressive Transformers for End-to-End Sign Language Production. In: VEDALDI, A. et al. (Ed.). *Computer Vision – ECCV 2020*. Springer International Publishing, 2020.
- SAUNDERS, B.; CAMGÖZ, N. C.; BOWDEN, R. Adversarial Training for Multi-Channel Sign Language Production. *ArXiv*, abs/2008.12405, 2020. Disponível em: <<https://api.semanticscholar.org/CorpusID:221370584>>.
- STOLL, S. et al. Text2Sign: Towards Sign Language Production Using Neural Machine Translation and Generative Adversarial Networks. *International Journal of Computer Vision*, 2018.
- TANG, Y. et al. *Multilingual Translation with Extensible Multilingual Pretraining and Finetuning*. Ago. 2020. DOI: [10.48550/arXiv.2008.00401](https://doi.org/10.48550/arXiv.2008.00401).
- VASWANI, A. et al. Attention is all you need. In: *ADVANCES in Neural Information Processing Systems*. 2017. v. 30.
- WALSH, H.; SAUNDERS, B.; BOWDEN, R. Changing the Representation: Examining Language Representation for Neural Sign Language Production. In: EFTHIMIOU, E. et al. (Ed.). *Proceedings of the 7th International Workshop on Sign Language Translation and Avatar Technology: The Junction of the Visual and the Textual: Challenges and Perspectives*. Marseille, France: European Language Resources Association, jun. 2022. P. 117–124. Disponível em: <<https://aclanthology.org/2022.sltat-1.18/>>.
- WALSH, H.; SAUNDERS, B.; BOWDEN, R. Select and Reorder: A Novel Approach for Neural Sign Language Production. In: p. 14531–14542. DOI: [10.63317/362tbumoxwha](https://doi.org/10.63317/362tbumoxwha).
- ZUO, R.; POTAMIAS, R. A. et al. Signs as Tokens: A Retrieval-Enhanced Multilingual Sign Language Generator. In: Disponível em: <<https://api.semanticscholar.org/CorpusID:276903918>>.

ZUO, R.; WEI, F. et al. A Simple Baseline for Spoken Language to Sign Language Translation with 3D Avatars. In: LEONARDIS, A. et al. (Ed.). *Computer Vision – ECCV 2024*. Cham: Springer Nature Switzerland, 2025. P. 36–54.

Anexo 15

Relatório Bolsista - IC

Calebe do Nascimento de Souza

UNIVERSIDADE DE SÃO PAULO
FACULDADE DE FILOSOFIA, LETRAS E CIÊNCIAS HUMANAS
DEPARTAMENTO DE LINGUÍSTICA

RELATÓRIO CIENTÍFICO PARCIAL
Centro de Ciência para o Desenvolvimento - Tecnologia Assistiva e Acessibilidade em
Libras

Fundação de Amparo à Pesquisa do Estado de São Paulo (FAPESP)

Programa de Bolsa de Iniciação Científica

Processo: 2026/07168-4

Vigência: 01/05/2026 a 30/04/2027

Período Relacionado: Maio/2026 até Junho/2026

Beneficiário: Calebe do Nascimento de Souza

Orientador: Prof. Dr. Felipe Venâncio Barbosa

Processo Vinculado: 2024/00914-7

Pesquisador principal: José Mario de Martino

Instituição de Pesquisa: Universidade Estadual de Campinas

SÃO PAULO

2026

O Centro de Ciência para o Desenvolvimento Tecnologia Assistiva e Acessibilidade em Libras (CCD-TAAL) tem por objetivo criar métodos para a tradução automática entre o português brasileiro e a Língua de Sinais Brasileira (Libras) a fim de mitigar as barreiras de comunicação entre a sociedade ouvinte e surda. Isso ocorre através de tecnologias sofisticadas de inteligência artificial, avatares 3D e captadores de movimento. Há de salientar que o projeto contém um caráter multidisciplinar, isto é, integra diversas áreas do conhecimento para que os resultados e objetivos sejam alcançados e potencializados.

Nessa função, a presente iniciação científica, vinculada ao projeto CCD-TAAL, volta-se à área da linguística das línguas de sinais e o uso das Glosas no circuito de produção do conhecimento científico. As glosas vêm sendo utilizadas desde os trabalhos do pesquisador estadunidense William Stokoe na década de 1960 para anotar a *American Sign Language* (ASL) na língua escrita, no entanto, sabe-se que em estudos mais complexos e atuais, a glosa não é uma transcrição direta da língua de sinais, mas sim uma transcrição a nível lexical. Assim, transformam-se as unidades linguísticas, sinais, em suas respectivas representações na língua oral, a palavra. Portanto, propõe-se uma reflexão acerca da viabilidade do uso desse formalismo para notação no aprendizado de máquina.

REALIZAÇÕES NO PERÍODO

Essa seção se debruça sobre as atividades desenvolvidas no período de Maio/2026 a Junho/2026. Dado o período curto e inicial, foram feitas principalmente duas medidas para ambientação e integração ao projeto de pesquisa. A primeira atividade foi a participação em reuniões do CCD-TAAL e de projetos adjacentes, assim iniciou-se o envolvimento no projeto *Unity* — esse possui vínculo de pesquisa com o CCD-TAAL — e o grupo de estudos Língua de Sinais e Cognição (LiSCo) da Faculdade de Filosofia, Letras e Ciências Humanas da Universidade de São Paulo (FFLCH-USP). A segunda envolve principalmente a coletânea de artigos sobre a glosagem e conhecimento do software *EUDICO Linguistic Annotator* (Elan) proposto pelos pesquisadores para realizar um tipo diferente de formalismo para anotação das línguas de sinais.

REUNIÃO DE TRADUÇÃO E CCD-TAAL

Os encontros para tradução ocorridos têm por objetivo reunir um grupo de sinalizantes do CCD-TAAL, composto por surdos e ouvintes. Vale ressaltar que as reuniões inteiras acontecem em língua de sinais. Isso se mostrou importante para o aprofundamento na pesquisa, pois a participação como vidente possibilita o aprimoramento dos conhecimentos linguísticos

sobre a Libras. Haja vista que o desenvolvimento da proficiência em Libras constitui parte importante da formação necessária para a execução da pesquisa.

As reuniões funcionam a partir de dois tipos de sentenças em português, as anamneses e as situações passageiro-motorista — a segunda vinculada ao projeto *Unity* —. Sob esse viés, é papel dos tradutores discutirem entre si sobre os diferentes contextos de interação e garantir uma sinalização natural, ou seja, na qual um surdo nativo em língua de sinais utilizaria.

As reuniões costumam apresentar o seguinte fluxo: há um *corpus* preestabelecido de sentenças do português brasileiro e disponibilizado aos tradutores. Assim que chegarem em um acordo sobre a tradução mais correta, as bolsistas de treinamento técnico surdas — Natália Najyme de Melo Afonso e Isabela Cristina Barbieri — gravam um rascunho da sentença e posteriormente a gravam com o equipamento de captura de movimento (MoCap) do laboratório Galileu da Universidade Estadual de Campinas. Dessa forma, auxilia-se a pesquisa proposta ao analisar a base do processo de tradução.

Há, por fim, as reuniões semanais do CCD-TAAL, em que todas as equipes das diferentes áreas do conhecimento se encontram virtualmente, oferecendo atualizações sobre os projetos em andamento, suas pesquisas e contribuições ao Centro como um todo. Isso auxilia principalmente na compreensão do andamento do projeto e gerar contato entre os grupos de diferentes áreas do conhecimento e contribuir, dessa forma, para o desenvolvimento do CCD-TAAL.

LISCO

A participação no grupo de estudos LiSCo foi uma sugestão feita pelo orientador Prof. Dr. Felipe Venâncio Barbosa para integração profunda ao universo da pesquisa em Línguas de Sinais e cognição. De fato, o grupo tem auxiliado na ampliação e reconhecimento de novos artigos envoltos na língua de sinais. Está em andamento, por exemplo, a leitura do livro *Research Methods in Sign Language Studies: A Practical Guide* (Orfanidou, Woll e Morgan, 2015). Desse modo, o grupo integra ouvintes e surdos oferecendo uma troca linguística entre os falantes nativos de português e Libras por meio da criação de duplas e apresentações de seminários com base nos artigos presentes na coletânea. A partir dessas apresentações possibilita expandir o conhecimento em diversas áreas no que tange a surdez, língua de sinais e linguística, auxiliando a produção científica.

REVISÃO E ELAN

Para além destas atividades, há em andamento a coleta bibliográfica. Não é ainda possível afirmar o que será de fato utilizado, mas se fez uma curadoria de artigos sobre glosagem e seus usos, principalmente as problemáticas em torno dela e o uso do ELAN como software de transcrição. Neste sentido, foi realizado o levantamento dos seguintes artigos:

- Leite, T. A.; Ampessan, J. P.; Boldo, J.; Lohn, J. T.: Oliveira, G. S. A. (2021). Semântica lexical na libras: libertando-se da tirania das glosas. Revista da Abralín, v. 20, n. 2, p. 1-23, 2021.
- OUSHIRO, L. "TRANSCRIÇÃO DE ENTREVISTAS SOCIOLINGÜÍSTICAS COM O ELAN", p.117-132. In Raquel Meister Ko. Freitag (Organizadora). Metodologia de Coleta e Manipulação de Dados em Sociolinguística, São Paulo: Editora Edgard Blücher, 2014. DOI <http://dx.doi.org/10.5151/BlucherOA-MCMDS-9cap>
- QUADROS, R. A transcrição de textos do Corpus de Libras. Revista Leitura, [S. l.], v. 1, n. 57, p. 8–34, 2017. DOI: 10.28998/2317-9945.201657.8-34. Disponível em: <https://periodicos.ufal.br/revistaleitura/article/view/3618>.
- SANTOS, B; FRANÇA, L. Uso de Glosas para Tradução Automática em Libras. In: CONGRESSO LATINO-AMERICANO DE SOFTWARE LIVRE E TECNOLOGIAS ABERTAS (LATINOWARE), 22. , 2025, Foz do Iguaçu/PR. Anais [...]. Porto Alegre: Sociedade Brasileira de Computação, 2025 . p. 708-715. DOI: <https://doi.org/10.5753/latinoware.2025.16608>.

Sobre o uso do Elan, observou-se essencialmente que o uso deste como ferramenta de notação apresenta-se mais vantajoso por tratar-se de uma ferramenta multimodal que analisa vídeo e texto simultaneamente. Em adição, ao considerar que a Língua de Sinais é uma modalidade visuo-espacial, ter-se o vídeo juntamente com a notação se mostra fundamental. Neste sentido, pretende-se começar o treinamento no software ainda na fase inicial.

PLANO DE ATIVIDADE PARA O PRÓXIMO PERÍODO

Assim como segue no plano de trabalho, ainda nos encontramos no início do projeto de iniciação científica. Logo, continuaremos o proposto e seguiremos na participação das atividades que corroboram para a execução da pesquisa. Isso inclui:

Etapa Inicial

- Participação das atividades do projeto CCD-TAAL;

- Participação das reuniões dos projetos adjacentes — LiSCo e *Unity*;
- Coleta e revisão bibliográfica;
- Treinamento no Software Elan.

Etapa Intermediária

- Continuidade das atividades do projeto CCD-TAAL;
- Refinamento do processo de tradução com uso de glosas;
- Treinamento no Software Elan;
- Transcrições com o Software Elan.

Etapa Final

- Continuidade das atividades do projeto CCD-TAAL;
- Elaboração e submissão de artigos científicos;
- Entrega de Relatório Final.

REFERÊNCIAS BIBLIOGRÁFICAS

Leite, T. A.; Ampessan, J. P.; Boldo, J.; Lohn, J. T.; Oliveira, G. S. A. (2021). Semântica lexical na libras: libertando-se da tirania das glosas. Revista da Abralín, v. 20, n. 2, p. 1-23, 2021.

Orfanidou, E; Woll, B e Morgan, G. Research Methods in Sign Language Studies: A Practical Guide, Massachusetts: Wiley-Blackwell, 2015.

OUSHIRO, L. "TRANSCRIÇÃO DE ENTREVISTAS SOCIOLINGÜÍSTICAS COM O ELAN", p.117-132. In Raquel Meister Ko. Freitag (Organizadora). Metodologia de Coleta e Manipulação de Dados em ociolinguística, São Paulo: Editora Edgard Blücher, 2014.DOI <http://dx.doi.org/10.5151/BlucherOA-MCMDS-9cap>.

QUADROS, R. A transcrição de textos do Corpus de Libras. Revista Leitura, [S. l.], v. 1, n. 57, p. 8–34, 2017. DOI: 10.28998/2317-9945.201657.8-34. Disponível em: <https://periodicos.ufal.br/revistaleitura/article/view/3618>.

SANTOS, B; FRANÇA, L. Uso de Glosas para Tradução Automática em Libras. In: CONGRESSO LATINO-AMERICANO DE SOFTWARE LIVRE E TECNOLOGIAS ABERTAS (LATINOWARE), 22. , 2025, Foz do Iguaçu/PR. Anais [...]. Porto Alegre: Sociedade Brasileira de Computação, 2025 . p. 708-715. DOI: <https://doi.org/10.5753/latinoware.2025.16608>.

Anexo 16

Relatório Bolsista - IC

Guilherme Galvão de Oliveira Pinto



Fundação de Amparo à Pesquisa do Estado de São Paulo (FAPESP)

RELATÓRIO CIENTÍFICO

Guilherme Galvão de Oliveira Pinto

Título do projeto: Estudos e Experimentos com Modelos Neurais para Reconhecimento Contínuo da Língua Brasileira de Sinais

Número do Processo FAPESP: 2026/05600-6

Responsável: José Mario De Martino

Período de vigência: 01/04/2026 a 31/03/2027

Período coberto pelo Relatório Científico em questão: 01/04/2026 a 30/06/2026

Sumário

1	Formulário de acompanhamento de atividades do Bolsista	1
2	Relatório Científico	1
2.1	Resumo do Projeto Proposto	1
2.2	Realizações no Período	2
3	Plano de Atividades para o Próximo Período	10
4	Lista dos Trabalhos Preparados ou Submetidos para Publicação	12

1 Formulário de acompanhamento de atividades do Bolsista

2 Relatório Científico

2.1 Resumo do Projeto Proposto

O presente trabalho de Iniciação Científica está inserido na linha de pesquisa de reconhecimento contínuo de língua de sinais em vídeo, com foco na conversão do conteúdo visual da sinalização em sequências de glosas, entendidas como rótulos linguísticos simbólicos associados aos sinais realizados. A pesquisa integra as atividades do Centro de Ciência para o Desenvolvimento – Tecnologias Assistivas e Acessibilidade em Libras (CCD-TAAL) e contribui para o estudo de métodos modernos de aprendizado de máquina, visão computacional e modelagem sequencial aplicados ao reconhecimento automático da Língua Brasileira de Sinais (Libras).

O objetivo geral da IC é estudar, reproduzir, avaliar e adaptar arquiteturas neurais voltadas ao reconhecimento contínuo de língua de sinais, com vistas à sua futura aplicação ao corpus de Libras em desenvolvimento no CCD-TAAL. O foco principal do projeto está na etapa de reconhecimento, isto é, na geração de sequências de glosas a partir de vídeos de sinalização contínua. Ainda que algumas arquiteturas de referência também abordem tarefas de tradução para língua oral, a contribuição central deste plano está na análise do componente de reconhecimento, na compreensão de seu funcionamento computacional e na investigação das condições necessárias para sua adaptação ao contexto da Libras.

O plano de trabalho está organizado em torno de três eixos principais: reprodutibilidade, comparação justa entre métodos e análise das soluções de compromisso envolvidas nas arquiteturas estudadas. A reprodutibilidade envolve a recuperação e execução de experimentos descritos na literatura; a comparação justa busca padronizar métricas, conjuntos de dados, parâmetros e critérios de análise; e a análise das soluções de compromisso considera aspectos como custo computacional, capacidade de generalização, complexidade do modelo, características dos *datasets* e desempenho obtido.

Ao longo do projeto, estão previstas atividades de revisão bibliográfica, seleção de arquiteturas e *datasets* relevantes, preparação e organização de dados, adaptação de código, execução de treinamentos, validações e testes, comparação dos resultados com a literatura, aplicação progressiva dos modelos aos dados de Libras produzidos pelo CCD-TAAL e desenvolvimento de conteúdo técnico-científico. Espera-se que a pesquisa contribua para a consolidação de uma base metodológica e experimental para o reconhecimento contínuo de Libras, além de apoiar a formação científica do bolsista no ciclo completo de desenvolvimento de sistemas neurais para língua de sinais.

Contextualização do projeto

O reconhecimento contínuo de língua de sinais constitui um problema computacional desafiador porque, diferentemente do reconhecimento de sinais isolados, envolve a análise de sequências sinalizadas completas, nas quais há transições entre sinais, variações de ritmo, co-articulação e uso simultâneo de múltiplos articuladores. No caso da Libras, essa complexidade é ampliada pela natureza visual-espacial da língua, que combina informações manuais e não manuais, como movimentos corporais, expressões faciais, configuração das mãos, direção do olhar e uso do espaço. Por esse motivo, a adaptação de modelos neurais para esse contexto exige não apenas a escolha de uma arquitetura adequada, mas também a definição cuidadosa das representações visuais de entrada, da organização dos dados, das anotações linguísticas e dos protocolos de avaliação.

Uma etapa central do projeto consiste na investigação das representações visuais utilizadas pelos modelos. Em muitas arquiteturas de reconhecimento contínuo de língua de sinais, o modelo sequencial não opera diretamente sobre os quadros RGB brutos, mas sobre *features* ou *embeddings* previamente extraídos por redes visuais. Assim, torna-se necessário compreender como vídeos podem ser convertidos em sequências numéricas adequadas ao treinamento, quais dimensões e formatos devem ser preservados, como a informação temporal é organizada e como diferentes modalidades podem ser integradas. No contexto do CCD-TAAL, essa discussão é particularmente importante porque o corpus de Libras em desenvolvimento envolve vídeos RGB, *keypoints* corporais, faciais e manuais, além de anotações linguísticas multicamadas.

A adaptação ao corpus de Libras também exige atenção à estrutura das anotações. O projeto mais amplo prevê o uso de anotações linguísticas *multi-tier*, produzidas em ferramentas específicas de anotação multimodal, permitindo registrar não apenas glosas, mas também informações associadas a apontamentos espaciais, uso de mão dominante, direção do olhar, expressões faciais e outros marcadores relevantes. Essa estrutura oferece a possibilidade de explorar formas mais ricas de supervisão do treinamento, bem como de investigar o impacto de diferentes modalidades e camadas de anotação no desempenho do reconhecimento contínuo.

A avaliação experimental será conduzida por meio de métricas adequadas à comparação entre sequências, especialmente a *Word Error Rate* (WER), amplamente utilizada em tarefas de reconhecimento contínuo. Essa métrica permite comparar a sequência de glosas predita pelo modelo com a sequência de referência, contabilizando erros de inserção, remoção e substituição. Além da avaliação global, o plano prevê a realização de experimentos controlados e, quando aplicável, estudos de ablação, com o objetivo de analisar a contribuição individual de diferentes modalidades visuais, estratégias de fusão e formas de representação linguística.

2.2 Realizações no Período

Período de 01/04 a 22/04

No período inicial de vigência da bolsa, as atividades concentraram-se na inserção do bolsista no contexto científico e técnico do Centro, na compreensão de seus objetivos gerais e na consolidação de uma base conceitual necessária ao desenvolvimento das etapas experimentais subsequentes. Por se tratar de uma Iniciação Científica em fase inicial, as realizações do período estiveram voltadas principalmente à contextualização do problema de pesquisa, à revisão bibliográfica introdutória, ao acompanhamento das atividades da equipe e à preparação do ambiente de trabalho para os estudos e experimentos previstos no plano de atividades.

Nas primeiras semanas, o bolsista foi apresentado à equipe do CCD-TAAL, ao ambiente de atuação e à dinâmica de trabalho do grupo. Nesse período, a participação nas reuniões semanais do laboratório e nas reuniões realizadas em articulação com a equipe do IPT mostrou-se especialmente relevante, pois permitiu contato direto com as frentes de trabalho já em andamento, com as discussões técnicas da equipe e com os objetivos mais amplos do projeto no contexto do CCD-TAAL. Essa etapa inicial foi importante para a integração do bolsista à equipe e para a compreensão do papel da presente Iniciação Científica dentro do conjunto de atividades do Centro.

Paralelamente, teve início o estudo introdutório da literatura da área, com ênfase em reconhecimento contínuo de língua de sinais e no uso de modelos neurais aplicados a tarefas de reconhecimento e tradução sequencial. Essa etapa foi orientada por trabalhos que discutem tanto a relevância interdisciplinar das tecnologias para línguas de sinais, especialmente em contextos de acessibilidade e inclusão (Bragg *et al.*, 2019), quanto os desafios específicos do reconhecimento contínuo, como coarticulação, variação entre sinalizantes, dependências

temporais e modelagem de sequências visuais (Koller; Forster; Ney, 2015). Nesse contexto, foi apresentado e selecionado como referência principal o trabalho de Camgoz et al. (Camgoz; Koller et al., 2020), que passou a orientar a etapa inicial de estudo metodológico. A leitura e análise desse trabalho permitiram ao bolsista compreender com maior clareza a formulação do problema de reconhecimento contínuo de sinais, a relação entre reconhecimento de glosas e tradução para língua oral, bem como a relevância de arquiteturas neurais capazes de integrar representação visual, modelagem temporal e geração de sequência.

Ainda nesse período, foram aprofundadas noções fundamentais sobre o papel dos conjuntos de dados na tarefa de reconhecimento contínuo de língua de sinais, incluindo a importância da qualidade dos dados, da definição de protocolos de avaliação e da escolha de métricas adequadas para comparação entre modelos. Esse movimento inicial de estudo foi importante para evidenciar que o desempenho de modelos neurais nessa área depende não apenas da arquitetura utilizada, mas também da forma de organização dos dados, do tipo de representação visual adotada, das estratégias de treinamento e da consistência dos critérios de avaliação empregados.

Do ponto de vista operacional, esse período também envolveu a preparação das condições necessárias para a continuidade do trabalho, incluindo a configuração inicial do ambiente de atuação e o encaminhamento de licenças, acessos e demais requisitos institucionais necessários ao prosseguimento das atividades. Embora essas ações não constituam resultados experimentais em sentido estrito, foram indispensáveis para viabilizar as etapas posteriores de estudo técnico, reprodução computacional e experimentação previstas no plano de trabalho.

Período de 23/04 a 13/05

Nas semanas subsequentes ao período inicial de ambientação, as atividades passaram a concentrar-se no estudo aprofundado da arquitetura de referência selecionada para a pesquisa, bem como na preparação do ambiente computacional necessário à sua execução e análise. Nesse contexto, o trabalho de Camgoz et al. (Camgoz; Koller et al., 2020) foi adotado como principal referência teórico-metodológica para o desenvolvimento da presente etapa da Iniciação Científica, por reunir características particularmente relevantes aos objetivos do plano de trabalho: trata-se de um artigo de reconhecida relevância na área, com documentação técnica clara, repositório público disponível, foco em reconhecimento e tradução contínuos de língua de sinais e uso de arquitetura baseada em *Transformers*, linha de interesse central para os estudos atualmente conduzidos no projeto.

O artigo propõe uma formulação conjunta para reconhecimento contínuo de glosas e tradução de vídeos de língua de sinais para sentenças em língua oral, superando a lógica puramente sequencial de *pipelines* tradicionais. Em vez de tratar reconhecimento e tradução como etapas independentes, os autores formulam um modelo unificado capaz de aprender simultaneamente as probabilidades condicionais de uma sequência de glosas e de uma sentença em língua oral a partir de um vídeo de sinais. A arquitetura se apoia em mecanismos de atenção característicos dos *Transformers* (Vaswani et al., 2017), aplicados ao reconhecimento e à tradução de língua de sinais em uma formulação conjunta (Camgoz; Koller et al., 2020). Para isso, utiliza um *encoder Transformer*, denominado *Sign Language Recognition Transformer* (SLRT), supervisionado por uma função de perda do tipo CTC, com o objetivo de aprender representações espaço-temporais adequadas ao reconhecimento contínuo de glosas, e um *decoder Transformer* autoregressivo, denominado *Sign Language Translation Transformer* (SLTT), responsável por gerar, palavra a palavra, a sentença correspondente em língua falada. Essa proposta mostrou-se particularmente importante para a presente pesquisa porque combina, em uma mesma arquitetura, um componente fortemente vinculado ao problema de reconhecimento,

eixo mais diretamente relacionado ao plano desta IC, com uma formulação moderna baseada em atenção, compatível com as discussões atuais sobre generalização, reprodutibilidade e adaptação para Libras.

Outro aspecto importante identificado no estudo do artigo foi a natureza da entrada efetiva do modelo. Embora o problema seja formulado em termos de vídeos de língua de sinais, o modelo descrito por Camgoz et al. não opera, no nível do *Transformer*, diretamente sobre os quadros RGB brutos. Em vez disso, ele utiliza representações visuais previamente extraídas por uma rede convolucional, tratadas no artigo como *spatial embeddings*. Essa observação mostrou-se central para a compreensão do *pipeline* experimental, pois deixou claro que a reprodutibilidade do método não depende apenas do código do *Transformer* em si, mas também da disponibilidade dos dados processados e dos artefatos de representação visual adotados no experimento. O *dataset* de referência utilizado no artigo original é o RWTH-PHOENIX-Weather-2014T (PHOENIX14T), um corpus contínuo de língua de sinais com vídeos, glosas e traduções em alemão, amplamente utilizado em estudos de reconhecimento e tradução neural de língua de sinais (Camgoz; Hadfield et al., 2018; Camgoz; Koller et al., 2020) e tomado como base para os estudos de reprodutibilidade conduzidos nesta etapa.

A partir dessa compreensão teórica, iniciou-se a análise detalhada do repositório associado ao trabalho, com o objetivo de compreender como a arquitetura descrita no artigo se materializa em código. Essa etapa envolveu a leitura das principais funções do *pipeline* de teste e inferência, a identificação das classes centrais do modelo e a verificação da forma de organização dos dados ao longo do processamento. Esse estudo evidenciou que o modelo principal se organiza em torno de cinco blocos estruturais: um módulo de *embedding* visual para o sinal, um *encoder Transformer*, uma camada de projeção para glosas, um módulo de *embedding* textual e um *decoder Transformer*. A análise do fluxo de inferência permitiu compreender como esses componentes são articulados para produzir, a partir de uma sequência visual, tanto a sequência de glosas reconhecida quanto a sentença traduzida.

Em paralelo ao estudo conceitual e estrutural do repositório, foi necessária a configuração do ambiente computacional no computador do laboratório. Como o trabalho de referência é datado de 2020, sua execução em ambiente atual apresentou, desde o início, dificuldades de compatibilidade decorrentes da defasagem de versões de bibliotecas, dependências e ferramentas originalmente utilizadas. Em especial, verificou-se que a simples instalação das dependências conforme especificadas originalmente não era suficiente para garantir uma execução funcional em um ambiente moderno. Para contornar esse problema, foi montado um ambiente virtual isolado, com uso de ferramentas atuais de gerenciamento de dependências, incluindo a utilização do *uv* para criação e controle do ambiente Python e para a instalação controlada das bibliotecas necessárias. Essa etapa foi importante não apenas para viabilizar a execução do código, mas também para registrar, na prática, um dos eixos previstos no plano de trabalho: a análise da reprodutibilidade de métodos descritos na literatura e das dificuldades concretas de sua recuperação experimental.

Durante esse processo, tornou-se evidente que a reprodução da inferência não dependia apenas do código-fonte do repositório, mas também da presença local de artefatos essenciais que não estavam imediatamente acessíveis ou utilizáveis a partir da instalação inicial. Por esse motivo, foi necessário recuperar, a partir de outro computador do laboratório que continha os arquivos, duas pastas fundamentais para a continuidade dos experimentos: a pasta PHOENIX2014T e a pasta *sign_sample_model*. A primeira continha os arquivos de referência do *dataset* utilizados pelo *pipeline* local do repositório, correspondentes às partições de treino, validação e teste do PHOENIX14T. A segunda continha os artefatos de um experimento já treinado, incluindo *checkpoint* do modelo, arquivos de vocabulário, referências, logs de trei-

namento, registros de validação e saídas anteriormente geradas. Essa recuperação foi decisiva porque, sem os arquivos do *dataset*, o repositório não conseguia montar corretamente os conjuntos utilizados no modo de teste, e, sem a pasta do experimento treinado, não havia como restaurar um modelo com pesos aprendidos para realizar inferência.

Nesse contexto, tornou-se também necessário compreender o significado e o papel dos *checkpoints*. No âmbito de treinamento de redes neurais, um *checkpoint* corresponde a um estado salvo do modelo em um determinado ponto do processo de otimização, incluindo, principalmente, os pesos aprendidos até aquela etapa. O uso de *checkpoints* é importante porque permite restaurar o modelo em um ponto específico de treinamento, retomá-lo ou avaliá-lo sem a necessidade de repetir integralmente o processo de treino. No caso analisado, o arquivo `5100.ckpt` correspondia ao estado salvo do modelo no passo 5100 de treinamento. A identificação desse *checkpoint* como referência principal não foi arbitrária: os artefatos da pasta do experimento indicavam que ele estava associado ao melhor ponto daquele *run* específico, tanto pela presença de arquivos com a marcação `best.IT_00005100` quanto pelos registros em `validations.txt`, nos quais o passo 5100 aparecia como ponto de melhor desempenho segundo a métrica monitorada naquele experimento.

Uma vez configurado o ambiente, recuperados os arquivos necessários e restaurado o *checkpoint* de referência, foi possível executar a primeira inferência completa no computador do laboratório. Essa etapa teve grande importância metodológica, pois representou a validação prática de que o ambiente montado era capaz de carregar os dados, reconstruir a arquitetura, restaurar os pesos do modelo treinado e produzir saídas quantitativas coerentes. Na execução local realizada com o *checkpoint* 5100, foram obtidos os seguintes resultados: no conjunto de desenvolvimento, WER de 43,23 e BLEU-4 de 19,95; no conjunto de teste, WER de 42,92 e BLEU-4 de 19,69. Esses resultados foram consistentes com os artefatos do experimento recuperado e com a configuração reproduzida, mostrando que o *pipeline* de inferência havia sido corretamente reproduzido no ambiente local.

Além da execução da inferência em si, uma parte importante do trabalho do período consistiu no estudo aprofundado do código por meio de inspeções controladas do *pipeline* interno do modelo. Para isso, foram realizados *backups* temporários dos arquivos relevantes antes de qualquer modificação e, em seguida, inseridos trechos pontuais de inspeção no código com o objetivo de observar formatos, tensores e estruturas intermediárias sem alterar permanentemente o repositório. Essa estratégia permitiu examinar, com segurança, o que entrava e saía de funções centrais do modelo e do processo de inferência. Com isso, foi possível verificar, por exemplo, a composição do objeto de *batch*, a dimensionalidade das entradas visuais, o comportamento dos módulos de *embedding*, a saída do *encoder*, a projeção para glosas, os *embeddings* textuais, a estrutura da saída do *decoder* e o papel da função responsável por amarrar a inferência do *batch*. Esse procedimento teve valor formativo importante, pois aproximou a descrição do artigo da implementação concreta disponível no repositório e criou uma base mais sólida para futuras etapas de adaptação, teste e modificação do código.

De modo geral, esse conjunto de atividades representou um avanço significativo em relação à etapa inicial. Se, no começo do período, o foco estava na inserção do bolsista no projeto e na revisão introdutória do tema, nesta fase houve progresso na seleção e análise da arquitetura de referência, na reconstrução do ambiente computacional, na recuperação dos artefatos necessários para reprodutibilidade experimental, na execução local da inferência e na compreensão detalhada do funcionamento interno do modelo. Esses resultados prepararam o terreno para as próximas etapas previstas no plano de trabalho, que incluem aprofundamento da análise experimental, comparação com a literatura, preparação de novos testes e futura adaptação do *pipeline* ao contexto de Libras e aos dados produzidos no âmbito do CCD-TAAL.

Período de 14/05 a 27/05

Na etapa seguinte, as atividades concentraram-se na reprodução experimental da configuração associada à arquitetura de referência descrita por Camgoz et al. (Camgoz; Koller et al., 2020). Essa etapa foi considerada fundamental para o projeto, pois permitiu passar para uma fase de verificação prática do processo de treinamento, validação e avaliação. Além disso, a reprodução controlada de um modelo previamente publicado constitui uma etapa necessária para que, em momentos posteriores, seja possível adaptar a arquitetura estudada ao contexto do corpus em Libras em desenvolvimento no CCD-TAAL.

Aproveitando o ambiente computacional já configurado e dos artefatos recuperados na etapa anterior, foi realizada uma nova organização dos arquivos necessários à execução dos experimentos, com o objetivo de preservar os dados originais e evitar sobrescrever resultados de referência. Para isso, foram criadas configurações locais e diretórios de saída separados, de modo que os novos testes fossem executados em pastas próprias, sem modificar a pasta `sign_sample_model`. Essa estratégia foi importante para manter a rastreabilidade dos experimentos, distinguir os artefatos recuperados daqueles gerados localmente e garantir maior segurança durante as etapas de treino e avaliação.

Antes do treinamento completo, foram realizados testes adicionais de inspeção do código e do fluxo de dados, com o objetivo de compreender a passagem das informações pelos principais módulos da arquitetura. Para evitar alterações permanentes no repositório, foram criadas cópias de segurança de arquivos modificados temporariamente e inseridos pontos de depuração em partes específicas do código. Esses testes permitiram observar, na prática, que cada lote de entrada era organizado com tensores de sinais no formato aproximado (batch, tempo, dimensão), mais especificamente com entradas do tipo `sgn` de dimensão (32, 165, 1024) no primeiro lote analisado. Em seguida, a camada de incorporação espacial transformava esses vetores de dimensão 1024 em representações internas de dimensão 512, que eram então processadas pelo codificador *Transformer*. A partir dessa representação temporal codificada, o modelo alimentava dois caminhos principais: uma camada linear associada à predição de glosas, usada na tarefa de reconhecimento contínuo, e um decodificador *Transformer* associado à geração da sentença em língua oral.

Essa análise também permitiu relacionar os componentes observados no código com os blocos conceituais descritos no artigo de referência. O modelo construído pelo repositório foi identificado como uma instância composta por `SpatialEmbeddings`, `TransformerEncoder`, `TransformerDecoder`, `embeddings` textuais e uma camada de saída para glosas. Na prática, essa estrutura corresponde à formulação conjunta do problema: o fluxo de reconhecimento aprende a mapear a sequência visual para uma sequência de glosas por meio de uma função de perda CTC, enquanto o fluxo de tradução utiliza a representação codificada do sinal para gerar uma sentença textual. Essa verificação foi importante para consolidar a compreensão de que a arquitetura não trata reconhecimento e tradução como tarefas completamente independentes, mas como problemas sequenciais relacionados, treinados de forma conjunta.

Após os testes de inspeção, foi realizada uma avaliação inicial do *checkpoint* recuperado, correspondente ao passo 5100 de treinamento. Essa avaliação permitiu confirmar que o modelo podia ser carregado corretamente e que o repositório era capaz de gerar hipóteses de glosas e de texto para os conjuntos de desenvolvimento e teste. Durante a primeira tentativa, surgiram erros de compatibilidade relacionados ao carregamento de *checkpoints* em versões recentes do PyTorch, pois a função `torch.load` passou a adotar, por padrão, um modo mais restritivo de carregamento de pesos. A solução adotada foi ajustar localmente o carregamento do *checkpoint* com o argumento `weights_only=False`, procedi-

mento aplicado apenas em um contexto controlado e com arquivos confiáveis gerados ou recuperados pela própria equipe. Também foi necessário restringir a busca durante a avaliação, utilizando `recognition_beam_sizes = [10]`, `translation_beam_sizes = [1]` e `translation_beam_alphas = [-1]`, de modo a evitar incompatibilidades observadas na etapa de busca por feixe em configurações mais amplas.

Com essa configuração de avaliação, o *checkpoint* recuperado produziu resultados consistentes nos conjuntos de desenvolvimento e teste. No conjunto de desenvolvimento, foram observados WER de 43,23, BLEU-4 de 19,95, CHRF de 43,80 e ROUGE de 45,62. No conjunto de teste, foram obtidos WER de 42,92, BLEU-4 de 19,69, CHRF de 43,81 e ROUGE de 44,72. Esses valores serviram como referência para verificar se o ambiente configurado era capaz de reproduzir o comportamento esperado da implementação, bem como para estabelecer uma linha de base experimental antes da execução de novos treinamentos.

Em seguida, foi realizado um treino curto de sanidade, em diretório separado, para verificar se o processo de treinamento funcionava sem comprometer os arquivos recuperados originalmente. Para isso, foi criada uma configuração específica apontando para uma nova pasta de saída, preservando a pasta do modelo de amostra. Esse treino de sanidade teve como objetivo confirmar que o código era capaz de iniciar o treinamento, calcular as perdas de reconhecimento e tradução, executar retropropagação, realizar validações periódicas e salvar *checkpoints*. Durante essa etapa, foi identificada uma segunda incompatibilidade decorrente da versão atual do PyTorch: o argumento `verbose=False`, utilizado na criação do escalonador `ReduceLROnPlateau`, não era mais aceito. A remoção desse argumento resolveu o problema sem alterar a lógica de treinamento. O treino de sanidade foi concluído com sucesso, validando o funcionamento do *pipeline* antes da execução do treinamento completo.

Na sequência, foi executado um treinamento completo da configuração de referência em uma pasta isolada denominada `runs/full_train_001`. O processo foi instrumentado para registrar o tempo de execução, o estado da GPU, o ambiente Python, os arquivos gerados, os *checksums* dos principais artefatos e os *diffs* das alterações de compatibilidade aplicadas ao código. Essa documentação foi importante para garantir a rastreabilidade do experimento, permitindo identificar a configuração utilizada, o estado do ambiente, as modificações realizadas no repositório e os arquivos resultantes do treinamento.

O treinamento foi encerrado automaticamente pelo critério de parada associado à ausência de melhoria no último estágio de redução da taxa de aprendizado. O melhor *checkpoint* foi selecionado no passo 5100, com BLEU-4 de 19,95 no conjunto de desenvolvimento. O tempo total registrado para o treinamento foi de 16 minutos e 7 segundos na estação do laboratório. Após o término do treinamento, verificou-se que o *checkpoint* `best.ckpt` apontava corretamente para o arquivo `5100.ckpt`, confirmando que o melhor modelo havia sido salvo no mesmo passo observado na execução de referência.

A avaliação final desse *checkpoint* produziu os mesmos valores obtidos anteriormente com o modelo recuperado: no conjunto de desenvolvimento, WER de 43,23 e BLEU-4 de 19,95; no conjunto de teste, WER de 42,92 e BLEU-4 de 19,69. Foram também gerados arquivos de hipóteses de glosas e de texto para os conjuntos de desenvolvimento e teste, além de arquivos estruturados de resultados. Com isso, foi possível confirmar a reprodutibilidade operacional da configuração estudada no ambiente do laboratório. Mais precisamente, os resultados obtidos foram consistentes com os artefatos recuperados e com a configuração reproduzida, demonstrando que o *pipeline* local estava funcional para treinamento, validação e avaliação.

Essa etapa representa um marco importante para o andamento da pesquisa, pois demonstrou que a equipe dispõe de um ambiente funcional para treinar, validar e avaliar uma arquitetura de referência baseada em *Transformers* para reconhecimento e tradução de

língua de sinais. Além disso, a reprodução do treinamento e da avaliação forneceu uma base técnica concreta para as próximas fases do projeto. A partir desse ponto, torna-se possível investigar com maior segurança quais componentes precisarão ser adaptados para o contexto de Libras, especialmente no que se refere à geração de características visuais, à organização dos dados do corpus em construção, à representação de glosas e à futura integração de múltiplas modalidades visuais, como vídeo RGB, *keypoints* corporais, mãos, face e anotações linguísticas multicamadas.

Período de 28/05 a 30/06

Paralelamente à reprodução do experimento principal, foi iniciado o estudo de trabalhos correlatos que pudessem orientar a futura adaptação da arquitetura de Camgoz et al. (Camgoz; Koller et al., 2020) para outros conjuntos de dados e, posteriormente, para o corpus de Libras em desenvolvimento no CCD-TAAL. Nesse contexto, foi identificado e estudado o trabalho de Cabot Alvarez, Giró Nieto e Tarrés Benet (Alvarez; Nieto; Benet, 2022), que adapta a arquitetura de Camgoz et al. ao *dataset* How2Sign. Esse artigo mostrou-se particularmente relevante para a presente Iniciação Científica porque parte exatamente da arquitetura adotada como referência neste projeto e investiga sua adaptação para um conjunto de dados com características distintas daquelas do PHOENIX14T. Assim, o trabalho ofereceu um exemplo concreto de como uma arquitetura originalmente validada em um corpus de língua de sinais alemã pode ser transportada para outro contexto linguístico, computacional e experimental.

O estudo desse artigo foi importante por duas razões principais. Em primeiro lugar, ele reforçou a necessidade de tratar a adaptação de modelos neurais de língua de sinais não apenas como uma troca de *dataset*, mas como um processo que envolve ajustes na organização dos dados, nos alinhamentos temporais, nas representações de entrada e nas tarefas de supervisão disponíveis. Em segundo lugar, o trabalho evidenciou problemas práticos semelhantes aos que poderão surgir na adaptação para Libras. Enquanto o PHOENIX14T contém vídeos, glosas e sentenças em língua oral organizados em um formato já compatível com o *pipeline* de Camgoz et al., o How2Sign apresenta uma estrutura mais ampla e multimodal. O How2Sign é um *dataset* multimodal e *multiview* de Língua Americana de Sinais (ASL), composto por vídeos contínuos, transcrições e múltiplas modalidades alinhadas (Duarte et al., 2021). Na configuração utilizada por Cabot Alvarez et al. (Alvarez; Nieto; Benet, 2022), as glosas correspondentes não estavam disponíveis para o treinamento, o que levou os autores a utilizarem as transcrições em inglês como uma solução temporária para preencher a parte de reconhecimento do *pipeline*.

Esse ponto foi especialmente relevante para o projeto, pois mostrou que a ausência, indisponibilidade ou diferença estrutural das anotações linguísticas pode exigir adaptações metodológicas importantes. No caso de Camgoz et al., a supervisão intermediária por glosas desempenha papel central na formulação conjunta entre reconhecimento e tradução, uma vez que o *encoder* é treinado com perda CTC para aprender representações espaço-temporais associadas à sequência de glosas. Quando um novo corpus não possui o mesmo tipo de anotação, ou quando suas anotações são organizadas em outro formato, torna-se necessário decidir como representar essa informação intermediária, como ajustar a função de perda e como manter uma comparação experimental justa. Esse aprendizado contribuiu diretamente para a reflexão sobre o corpus de Libras do projeto, que possui anotações linguísticas *multi-tier* produzidas no ELAN (Wittenburg et al., 2006) e poderá permitir estratégias mais ricas de supervisão do que aquelas baseadas apenas em uma sequência simples de glosas.

Outro aspecto técnico de grande importância identificado no estudo do trabalho de Cabot Alvarez et al. foi a etapa de extração de características visuais. Conforme já observado na reprodução do trabalho de Camgoz et al., o modelo baseado em *Transformers* não recebe

diretamente os quadros RGB brutos do vídeo. Em vez disso, ele recebe sequências de vetores de características visuais, isto é, *embeddings* extraídos previamente por um extrator visual. No trabalho original, a etapa de extração de características visuais está associada a trabalhos anteriores com CNN-LSTM-HMMs para reconhecimento contínuo de língua de sinais (Koller; Camgoz et al., 2020). Entretanto, como observado por Cabot Alvarez et al. (Alvarez; Nieto; Benet, 2022), a arquitetura exata, os pesos e os scripts completos dessa etapa não aparecem disponibilizados de forma direta. Essa ausência cria um gargalo importante para a reprodutibilidade e para a adaptação do método, pois a qualidade e o formato das *features* visuais influenciam diretamente a entrada do *Transformer*.

O trabalho de Cabot Alvarez et al. apresentou uma alternativa prática para esse problema ao utilizar uma arquitetura I3D como extrator de características visuais no contexto do How2Sign (Alvarez; Nieto; Benet, 2022). A I3D, originalmente proposta para reconhecimento de ações em vídeo (Carreira; Zisserman, 2017), constitui uma alternativa promissora para extração de representações espaço-temporais a partir de sequências RGB. A adoção dessa solução é relevante para o presente projeto porque indica um caminho viável para substituir o extrator visual não disponibilizado integralmente no *pipeline* original. Além disso, o uso da I3D em trabalhos relacionados ao How2Sign sugere que essa arquitetura pode capturar aspectos temporais do movimento e gerar *embeddings* adequados para modelos sequenciais posteriores (Duarte et al., 2021; Alvarez; Nieto; Benet, 2022), desde que sejam respeitados os requisitos de formato, dimensão e organização temporal esperados pelo modelo de reconhecimento/tradução.

A partir desse estudo, iniciou-se uma frente específica de investigação sobre como montar um extrator de *features* compatível com o *pipeline* reproduzido no laboratório. Essa frente envolve compreender como vídeos brutos podem ser convertidos em tensores de entrada para o modelo, quais dimensões devem ser preservadas, como organizar a sequência temporal, como lidar com diferentes taxas de quadros e como garantir que os *embeddings* gerados sejam compatíveis com o *feature_size* esperado pela configuração do modelo. Essa etapa é tecnicamente relevante porque eventuais incompatibilidades de formato podem impedir o treinamento ou produzir resultados pouco interpretáveis. Portanto, antes da adaptação ao corpus de Libras, é necessário consolidar um procedimento robusto de extração de características visuais.

Também foi realizado um levantamento preliminar de repositórios e materiais públicos relacionados à I3D e a trabalhos que empregam *features* visuais pré-extraídas em tarefas de língua de sinais. Esse levantamento mostrou que, embora existam implementações públicas da I3D e repositórios relacionados ao reconhecimento de ações, os *pipelines* completos de extração utilizados em trabalhos específicos de língua de sinais nem sempre são disponibilizados integralmente. Em muitos casos, estão disponíveis o código do modelo de tradução/reconhecimento ou *features* já extraídas, mas não necessariamente a combinação completa entre arquitetura visual, pesos treinados, pré-processamento dos vídeos e scripts usados para gerar os *embeddings*. Essa constatação reforça a importância de documentar cuidadosamente as escolhas de implementação no projeto, para que os experimentos futuros com Libras sejam reprodutíveis e comparáveis.

Do ponto de vista metodológico, essa etapa de estudo contribuiu para refinar a compreensão do caminho necessário para a adaptação do modelo ao contexto do CCD-TAAL. A reprodução do *pipeline* de Camgoz et al. forneceu uma base funcional para treinamento e avaliação; o estudo do trabalho de Cabot Alvarez et al. mostrou um exemplo de adaptação para um *dataset* multimodal diferente; e a investigação sobre I3D apontou uma solução possível para a etapa de extração de *features* visuais. Em conjunto, essas atividades se alinham diretamente ao plano de trabalho da IC, especialmente às atividades de revisão bibliográfica, seleção de

arquiteturas e *datasets* relevantes, preparação de dados, adaptação de código, execução de experimentos e validação de resultados com a literatura.

Além das atividades técnicas e experimentais, o período também incluiu a elaboração e submissão de um trabalho acadêmico ao XI Workshop de Iniciação Científica em Tecnologia da Informação e da Linguagem Humana (TILic 2026). O artigo submetido apresenta a proposta de pesquisa do bolsista no contexto do projeto, com foco na adaptação de arquiteturas neurais para o reconhecimento contínuo de Libras. O texto discute a integração de múltiplas modalidades visuais, como vídeos RGB e *keypoints* corporais, faciais e manuais, bem como o uso de anotações linguísticas *multi-tier* produzidas no ELAN. Embora o resultado da submissão ainda não tenha sido divulgado, a elaboração do trabalho constituiu uma atividade formativa importante, pois permitiu organizar de forma sistemática os objetivos, a motivação, a metodologia proposta e os desafios técnicos da pesquisa.

A preparação desse manuscrito envolveu revisão bibliográfica, estruturação da proposta metodológica, redação técnica, adequação ao formato do evento e sucessivas rodadas de revisão. O processo foi conduzido com apoio do Prof. Dr. José Mario De Martino, orientador e Pesquisador Responsável, do Prof. Dr. Hélio Pedrini, Pesquisador Principal, e do bolsista de pós-doutorado Dr. Guilherme Vieira Leite. Essa experiência foi relevante não apenas como exercício de divulgação científica, mas também como forma de amadurecimento da própria pesquisa, pois a necessidade de apresentar o problema de maneira clara para apreciação em um evento acadêmico contribuiu para explicitar as decisões metodológicas, os desafios de reprodutibilidade e as próximas etapas de implementação.

A submissão ao TILic também se alinha ao plano de trabalho da Iniciação Científica, que prevê a elaboração de relatórios técnicos, materiais de divulgação científica e, quando possível, manuscritos acadêmicos. Mesmo antes da obtenção de resultados experimentais finais com o corpus de Libras, a redação do artigo permitiu consolidar uma base conceitual e metodológica para a continuidade do projeto. Dessa forma, as atividades do período combinaram três frentes complementares: a reprodução de uma arquitetura de referência, o estudo de estratégias de adaptação para novos *datasets* e a comunicação científica preliminar dos objetivos e caminhos metodológicos da pesquisa. Esse conjunto de ações contribui para reduzir riscos técnicos nas próximas etapas e prepara o avanço em direção à implementação do extrator visual, à organização dos dados de Libras e à avaliação experimental do modelo no contexto do CCD-TAAL.

3 Plano de Atividades para o Próximo Período

No próximo período, as atividades deverão concentrar-se na transição entre a reprodução operacional da arquitetura de referência e sua adaptação progressiva ao contexto do corpus de Libras em desenvolvimento no CCD-TAAL. Como as etapas anteriores permitiram configurar o ambiente computacional, recuperar os artefatos necessários, executar inferência, realizar treinamentos controlados e compreender o funcionamento interno do *pipeline* baseado em *Transformers*, o foco passará a ser a preparação das condições técnicas para que o modelo possa receber dados produzidos no âmbito do projeto.

A primeira frente de trabalho será a consolidação do módulo de extração de características visuais. Essa etapa é necessária porque a arquitetura estudada não opera diretamente sobre os quadros RGB brutos, mas sobre sequências de *features* ou *embeddings* previamente extraídos. Assim, serão investigadas alternativas para gerar representações visuais compatíveis com o formato de entrada esperado pelo modelo, com atenção especial à organização temporal dos vídeos, à dimensão dos vetores gerados, à taxa de quadros, ao pré-processamento

necessário e à compatibilidade com o parâmetro `feature_size` da configuração do modelo. Essa frente deverá incluir o estudo e teste de extratores visuais baseados em arquiteturas já utilizadas na literatura, bem como a documentação das escolhas adotadas para garantir rastreabilidade e reprodutibilidade.

Pretende-se mapear como as sequências de glosas e as anotações linguísticas *multi-tier* poderão ser convertidas para uma estrutura compatível com os arquivos de entrada utilizados pelo modelo de referência. Essa etapa será importante para definir como representar as unidades linguísticas de saída, como organizar partições de treino, validação e teste e como preservar a correspondência temporal entre vídeos, *features* visuais e anotações.

Outra atividade prevista é a adaptação gradual do código para aceitar dados diferentes do PHOENIX14T. Essa adaptação deverá envolver ajustes em arquivos de configuração, vocabulários, caminhos de dados, tamanhos de entrada, formatos de anotação e rotinas de carregamento. Inicialmente, pretende-se realizar testes com subconjuntos reduzidos de dados, de modo a verificar se o *pipeline* consegue carregar as novas entradas, montar corretamente os *batches*, executar a passagem direta pelo modelo e calcular as perdas associadas à tarefa de reconhecimento. Esses testes serão importantes para identificar incompatibilidades antes da execução de experimentos mais longos.

Após essa etapa de adaptação inicial, deverão ser conduzidos experimentos preliminares de treinamento e avaliação com dados de Libras, quando houver volume e organização suficientes para isso. A avaliação será orientada principalmente pela métrica *Word Error Rate* (WER), comparando as sequências de glosas previstas pelo modelo com as sequências de referência disponíveis no corpus. Sempre que possível, também serão planejados experimentos controlados para analisar a contribuição de diferentes representações visuais, como *features* extraídas de vídeo RGB e descritores derivados de *keypoints* corporais, faciais e manuais.

Também deverá ser aprofundada a investigação sobre estratégias de integração multimodal. A partir da estrutura do corpus de Libras, será estudado como diferentes fontes de informação visual e linguística podem ser incorporadas ao processo de reconhecimento contínuo. Essa investigação poderá incluir comparações entre representações baseadas apenas em vídeo RGB, representações baseadas em *keypoints* e combinações entre modalidades, observando seus impactos no desempenho, no custo computacional e na estabilidade do treinamento. A análise das anotações *multi-tier* também deverá orientar possíveis formas de supervisão mais ricas, especialmente no que se refere à representação de informações linguísticas complementares às glosas.

Além das atividades experimentais, será mantida a documentação sistemática dos procedimentos realizados. Para cada teste ou treinamento relevante, deverão ser registrados a configuração utilizada, o ambiente computacional, os arquivos de entrada, os comandos executados, os resultados obtidos e eventuais alterações aplicadas ao código. Essa documentação será fundamental para permitir a comparação justa entre experimentos, facilitar a reprodução dos resultados pela equipe e apoiar a elaboração dos próximos relatórios técnicos e materiais acadêmicos decorrentes da pesquisa.

Por fim, o próximo período também deverá contemplar a continuidade da revisão bibliográfica e da comunicação e produção científica. A revisão será direcionada principalmente a trabalhos sobre extração de características visuais, reconhecimento contínuo de língua de sinais, uso de múltiplas modalidades e adaptação de modelos para novos conjuntos de dados. Caso o trabalho submetido ao TILic 2026 seja aceito, também serão realizadas as atividades necessárias para preparação da apresentação, revisão do material e participação no evento. Em conjunto, essas ações deverão aproximar a pesquisa de sua etapa central de adaptação ao contexto de Libras, consolidando a base técnica construída no primeiro período e avançando

em direção à avaliação experimental com dados do CCD-TAAL.

4 Lista dos Trabalhos Preparados ou Submetidos para Publicação

O trabalho intitulado *Explorando a Integração de Múltiplas Modalidades Visuais no Reconhecimento Contínuo de Libras*, de autoria de Guilherme Galvão de Oliveira Pinto, Prof. Dr. José Mario De Martino, Prof. Dr. Hélio Pedrini e do bolsista de pós-doutorado Guilherme Vieira Leite, foi preparado e submetido ao XI Workshop de Iniciação Científica em Tecnologia da Informação e da Linguagem Humana (TILic 2026). O manuscrito apresenta a proposta de pesquisa desenvolvida no âmbito desta Iniciação Científica, com foco na adaptação de arquiteturas neurais para o reconhecimento contínuo de Libras, considerando a integração de vídeos RGB, *keypoints* corporais, faciais e manuais, além de anotações linguísticas *multi-tier*. O evento, no qual se planeja realizar a apresentação do trabalho em caso de aceite, tem realização prevista para outubro de 2026.

Referências

- ALVAREZ, P. C.; NIETO, X. G.; BENET, L. T. Sign Language Translation Based on Transformers for the How2Sign Dataset. *Image Processing Group Signal Theory and Communications Department, Universitat Politècnica de Catalunya. BARCELONATECH*, 2022.
- BRAGG, D. *et al.* Sign Language Recognition, Generation, and Translation: An Interdisciplinary Perspective. In: **Proceedings of the 21st International ACM SIGACCESS Conference on Computers and Accessibility**, 2019. p. 16–31.
- CAMGOZ, N. C.; HADFIELD, S. *et al.* Neural Sign Language Translation. In: **Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition**, 2018. p. 7784–7793.
- CAMGOZ, N. C.; KOLLER, O. *et al.* Sign Language Transformers: Joint End-to-End Sign Language Recognition and Translation. In: **Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition**, 2020. p. 10023–10033.
- CARREIRA, J.; ZISSERMAN, A. Quo Vadis, Action Recognition? A New Model and the Kinetics Dataset. In: **Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition**, 2017. p. 6299–6308.
- DUARTE, A. *et al.* How2Sign: A Large-Scale Multimodal Dataset for Continuous American Sign Language. In: **Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition**, 2021. p. 2735–2744.
- KOLLER, O.; CAMGOZ, N. C. *et al.* Weakly Supervised Learning with Multi-Stream CNN-LSTM-HMMs to Discover Sequential Parallelism in Sign Language Videos. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, IEEE, v. 42, n. 9, p. 2306–2320, 2020.

KOLLER, O.; FORSTER, J.; NEY, H. Continuous Sign Language Recognition: Towards Large Vocabulary Statistical Recognition Systems Handling Multiple Signers. *Computer Vision and Image Understanding*, Elsevier, v. 141, p. 108–125, 2015.

VASWANI, A. *et al.* Attention Is All You Need. *Advances in Neural Information Processing Systems*, v. 30, 2017.

WITTENBURG, P. *et al.* ELAN: A Professional Framework for Multimodality Research. In: **Proceedings of the 5th International Conference on Language Resources and Evaluation**, 2006. p. 1556–1559.

Anexo 17

Relatório Bolsista - IC

Gustavo Borba da Silva



RELATÓRIO CIENTÍFICO ANUAL

Gustavo Borba da Silva

PROCESSO FAPESP: 2026/01419-5

TÍTULO DO PROJETO: SÍNTESE CONCATENATIVA PARA LINGUAGEM BRASILEIRA DE SINAIS

PESQUISADOR RESPONSÁVEL: JOSÉ MÁRIO DE MARTINO

LINHA DE FOMENTO: BOLSA NO PAÍS - REGULAR - INICIAÇÃO CIENTÍFICA

VINCULADO AO AUXÍLIO: 2024/00914-7 - CENTRO DE CIÊNCIA PARA O DESENVOLVIMENTO - TECNOLOGIA ASSISTIVA E ACESSIBILIDADE EM LIBRAS (CCD-TAAL)

PERÍODO DE VIGÊNCIA DO PROJETO: 01/03/2026 A 28/02/2027

PERÍODO COBERTO PELO RELATÓRIO CIENTÍFICO: 01/03/2026 A 30/06/2026

Campinas, SP
28 de junho de 2026

Resumo

O referido projeto de iniciação científica “Síntese Concatenativa para Linguagem Brasileira de Sinais” está inserido no contexto do desenvolvimento de tecnologias assistivas voltadas à acessibilidade da comunidade surda por meio da Língua Brasileira de Sinais (Libras) e vinculado ao Centro de Ciência para o Desenvolvimento - Tecnologia Assistiva e Acessibilidade em Libras (CCD-TAAL). Iniciada em março de 2026, a pesquisa tem como objetivo principal implementar e avaliar um mecanismo de síntese de animações para avatares sinalizantes tridimensionais que produza movimentos percebidos como naturais e realistas por usuários fluentes em Libras. Neste sentido, como será detalhado nas seções subsequentes, realizou-se a primeira etapa de revisão bibliográfica e a fundamentação teórica, bem como estudos sobre a abordagem de síntese concatenativa para Libras, a avaliação de tecnologias para sua implementação, o desenvolvimento da estrutura de armazenamento de animações e estudos sobre a implementação de melhorias em etapas da síntese concatenativa. A abordagem estudada baseia-se na técnica de síntese concatenativa, amplamente utilizada na área de síntese de fala. Nessa abordagem, sequências previamente registradas por intérpretes humanos são segmentadas em unidades menores que podem ser posteriormente selecionadas e concatenadas para formar novas sequências de sinalização. Diferentemente de métodos puramente baseados em animação procedural ou modelos generativos, a síntese concatenativa preserva características naturais dos movimentos originais, reduzindo artefatos visuais e o efeito conhecido como uncanny valley [Mori et al., 2012].

Para viabilizar essa estratégia, utiliza-se uma base de dados obtida por captura de movimento (Motion Capture – MoCap), contendo informações corporais e faciais de intérpretes de Libras. Os sinais capturados são anotados linguisticamente utilizando a ferramenta de anotação linguística ELAN [Max Planck Institute for Psycholinguistics, 2025], desenvolvido por especialistas da linguagem de Libras, permitindo a associação entre segmentos de movimento e suas respectivas glosas [Poeta, 2025].

O sistema desenvolvido contempla quatro etapas principais: seleção de unidades, geração de conteúdo, suavização de transições e síntese final da animação. A etapa de seleção busca identificar os fragmentos mais adequados para compor uma sentença, minimizando custos de transição entre sinais consecutivos. Em seguida, os dados correspondentes aos sinais selecionados são carregados e organizados para composição da sequência final. Um mecanismo de suavização baseado em interpolação esférica de quatérnios [Shoemake, 1985] com correções de conservação de momento angular é então aplicado para reduzir discontinuidades entre segmentos capturados em contextos distintos. Finalmente, a animação sintetizada é reproduzida em um avatar tridimensional.

Além do desenvolvimento da metodologia, o projeto prevê a realização de avaliações qualitativas e quantitativas das animações produzidas. A avaliação qualitativa será conduzida junto a usuários fluentes em Libras, enquanto a avaliação quantitativa utilizará métricas calculadas para comparar movimentos sintetizados com movimentos reais capturados.

O trabalho contribui para o avanço das pesquisas em acessibilidade digital, síntese de linguagem de sinais e interação humano-computador, oferecendo uma alternativa promissora para a geração automática de animações de Libras com maior naturalidade e compreensibilidade.

Conteúdo

1	Realizações do Período	1
1.1	Revisão Bibliográfica e Fundamentação Teórica	1
1.2	Estudo da Abordagem de Síntese Concatenativa para Libras	1
1.3	Avaliação de Tecnologias para Implementação	2
1.4	Desenvolvimento da Estrutura de Armazenamento de Animações	2
1.5	Implementação de Melhorias em Etapas da Síntese Concatenativa	3
2	Plano de Atividades para o Próximo Período	3
3	Trabalhos Preparados ou Submetidos	6

1 Realizações do Período

1.1 Revisão Bibliográfica e Fundamentação Teórica

A primeira etapa do projeto consistiu na realização de uma revisão bibliográfica voltada para os temas centrais da pesquisa: síntese concatenativa, síntese automática de línguas de sinais, captura de movimento, animação de personagens tridimensionais e representação computacional de movimentos humanos. O objetivo dessa etapa foi construir uma base teórica sólida que permitisse compreender tanto os fundamentos matemáticos quanto os aspectos práticos envolvidos na geração automática de animações para avatares sinalizantes.

Inicialmente foram estudados trabalhos clássicos sobre síntese concatenativa de fala, área na qual a técnica se encontra consolidada há décadas [Hunt and Black, 1996, Schwarz, 2005]. A análise desses trabalhos permitiu compreender os conceitos de unidade de síntese, critérios de seleção, definição de funções de custo e mecanismos de concatenação empregados para garantir naturalidade na geração da fala [Hunt and Black, 1996].

Em seguida, o foco da revisão foi direcionado para trabalhos relacionados à síntese de línguas de sinais. Foram analisadas abordagens baseadas em regras gramaticais, síntese por interpolação, modelos estatísticos e técnicas concatenativas. Durante esse processo observou-se que a síntese de sinais apresenta desafios significativamente mais complexos do que a síntese de fala, uma vez que múltiplos canais de informação precisam ser coordenados simultaneamente, incluindo movimentos das mãos, braços, tronco, cabeça e expressões faciais, além de nuances como velocidade de sinalizações.

Além de fornecer a fundamentação teórica necessária para o desenvolvimento do projeto, essa etapa permitiu identificar limitações presentes em trabalhos anteriores e oportunidades para o desenvolvimento de melhorias na etapa de síntese.

1.2 Estudo da Abordagem de Síntese Concatenativa para Libras

Após a conclusão da etapa inicial de revisão bibliográfica, foi realizado um estudo aprofundado da metodologia proposta por [Poeta, 2025], que constitui a principal referência técnica utilizada neste projeto.

O trabalho analisado propõe a adaptação dos princípios da síntese concatenativa para a geração automática de animações em Libras a partir de uma base de dados composta por sinais previamente capturados por sistemas de motion capture. O processo consiste em selecionar, dentre múltiplas ocorrências disponíveis para cada sinal, aquelas que minimizam o custo de transição entre movimentos consecutivos.

Durante essa etapa foram estudados algoritmos utilizados para representar os movimentos do avatar, os critérios empregados na comparação entre animações e as técnicas utilizadas para realizar a concatenação dos sinais selecionados.

Também foi realizada uma análise crítica da metodologia, buscando identificar possíveis limitações e oportunidades de aprimoramento. Em particular, observou-se que os critérios de seleção propostos concentram-se predominantemente na minimização das diferenças espaciais entre poses consecutivas, deixando em segundo plano características relacionadas à dinâmica temporal dos movimentos. Além disso, o trabalho não contempla a integração com expressões faciais, e também não lida com transições

precisas ao utilizar B-spline, tampouco leva em consideração conservação de momento angular.

Essas observações serviram como motivação para o desenvolvimento de propostas de melhoria que passaram a integrar os objetivos específicos do projeto.

1.3 Avaliação de Tecnologias para Implementação

Paralelamente ao estudo teórico, foi iniciada a investigação das tecnologias que poderiam ser utilizadas para a implementação da infraestrutura computacional necessária à síntese.

Em um primeiro momento, foi escolhida a engine 3D Godot como plataforma de desenvolvimento. A escolha foi motivada por sua natureza open source, pela disponibilidade de recursos avançados para computação gráfica tridimensional e pela experiência prévia com a ferramenta.

Durante essa fase, foram desenvolvidos protótipos experimentais com o objetivo de avaliar a viabilidade da plataforma para a implementação da síntese concatenativa. Esses protótipos incluíram carregamento de modelos tridimensionais, manipulação de esqueletos articulados, reprodução de animações esqueléticas, aplicações de transições e integração desktop e web.

Os resultados obtidos permitiram concluir que, embora a engine apresente recursos adequados para visualização gráfica, sua utilização introduziria desafios adicionais relacionados à distribuição da aplicação em ambiente web, tornando o produto final volumoso, lento e demandante, o que fere os princípios do projeto. Diante dessas limitações, optou-se por interromper o desenvolvimento baseado em Godot e reavaliar a arquitetura tecnológica do sistema.

Após a análise das limitações encontradas na abordagem inicial, foi definida uma nova arquitetura baseada em tecnologias web. A implementação passou a utilizar a linguagem TypeScript para o desenvolvimento da lógica da síntese e a biblioteca Three.js para renderização tridimensional e reprodução das animações.

A escolha dessa arquitetura foi motivada por diversos fatores. Primeiramente, aplicações desenvolvidas utilizando tecnologias web podem ser executadas diretamente em navegadores modernos sem necessidade de instalação adicional. Isso amplia significativamente o potencial de acessibilidade da solução. Outro fator relevante foi a possibilidade de reutilizar a mesma base de código para aplicações desktop por meio de *wrappers* como Electron e Tauri, reduzindo custos de portabilidade e desenvolvimento. Além disso, a utilização direta da API gráfica oferecida pela biblioteca Three.js proporciona maior controle sobre os dados de animação, facilitando a implementação dos algoritmos de seleção e concatenação estudados durante o projeto.

Durante essa etapa foi construída a infraestrutura inicial para carregamento de modelos tridimensionais, manipulação do esqueleto do avatar e reprodução programática das animações armazenadas na base de dados.

1.4 Desenvolvimento da Estrutura de Armazenamento de Animações

Uma etapa importante do trabalho consistiu no estudo dos formatos tradicionalmente utilizados para armazenamento de animações tridimensionais.

Foram analisados formatos amplamente utilizados na indústria, como FBX, BVH e glTF, buscando compreender suas estruturas internas e identificar quais informações seriam realmente necessárias para

o processo de síntese concatenativa. A partir dessa análise foi desenvolvido um formato simplificado voltado especificamente para as necessidades do projeto.

O formato proposto armazena apenas os quatérnios que representam a rotação de cada osso do esqueleto em cada frame da animação. Informações redundantes ou desnecessárias para o processo de síntese foram removidas. Essa abordagem produz arquivos significativamente menores, reduzindo requisitos de armazenamento e acelerando o carregamento das animações durante a execução do sistema, além de possibilitar a integração com um banco de dados, e eventualmente conseguir realizar requisições e atribuições, incrementando os dados para a síntese.

Além disso, a utilização de quatérnios evita problemas associados a representações baseadas em ângulos de Euler, como o fenômeno conhecido como gimbal lock [Shoemake, 1985].

1.5 Implementação de Melhorias em Etapas da Síntese Concatenativa

Com a infraestrutura inicial definida, foram iniciados estudos voltados para possíveis aprimoramentos de etapas da síntese concatenativa.

A literatura normalmente utiliza métricas baseadas na diferença angular (em quatérnios) entre o final de uma animação e o início da próxima [Poeta, 2025]. Embora eficazes em diversos cenários, essas métricas consideram principalmente aspectos espaciais dos movimentos.

Durante a análise da linguagem com especialistas, observou-se que movimentos humanos apresentam características dinâmicas importantes que não são completamente capturadas por esse tipo de métrica. Em muitos casos, duas poses podem ser espacialmente semelhantes, mas possuírem velocidades significativamente diferentes, para transmitir ênfase, emoções e nuances específicas.

Com base nessa observação foi proposta uma extensão da função de custo utilizada na seleção de unidades. Além das diferenças angulares entre poses consecutivas, a nova abordagem busca incorporar métricas relacionadas à velocidade e à aceleração dos movimentos.

A hipótese investigada é que a inclusão desses fatores permita selecionar sequências de sinais mais compatíveis do ponto de vista biomecânico, resultando em animações mais naturais e reduzindo a estranheza de correções posteriores por interpolação.

Os estudos realizados nessa etapa ainda possuem caráter exploratório e ainda estão em andamento. Eles servirão de base para experimentos quantitativos previstos para as próximas fases do projeto.

2 Plano de Atividades para o Próximo Período

No próximo período, as atividades estarão concentradas na consolidação da implementação da abordagem proposta e na preparação dos experimentos necessários para sua avaliação qualitativa e quantitativa.

Inicialmente, será dada continuidade ao desenvolvimento do mecanismo de seleção de unidades. Nessa etapa, serão implementadas e avaliadas diferentes estratégias para determinar quais instâncias de um mesmo sinal devem ser selecionadas para compor uma sentença. Além da minimização dos custos de transição entre poses, pretende-se investigar a utilização de características relacionadas à dinâmica do movimento, buscando preservar propriedades como fluidez, ritmo e continuidade gestual.

Também será concluída a implementação do módulo de suavização de transições. Esse componente será responsável por reduzir descontinuidades introduzidas durante a concatenação de sinais gravados em contextos distintos. Serão realizados experimentos envolvendo diferentes configurações de interpolação esférica de quatérnios e mecanismos adicionais de conservação de momento, visando minimizar perdas de naturalidade durante a síntese.

Além disso, será feita a integração com expressões faciais não só como composição de sinais, mas de indicativo de modificador da emoção a ser transmitida.

Paralelamente, será ampliada a infraestrutura de armazenamento e gerenciamento da base de dados de captura de movimento. Essa atividade envolve a organização das sequências já disponíveis, a integração dos dados corporais e faciais e a criação de mecanismos eficientes de busca e recuperação das animações associadas a cada glosa.

No âmbito da avaliação quantitativa, serão estudadas e implementadas métricas capazes de medir objetivamente a qualidade das animações sintetizadas. Pretende-se comparar movimentos gerados artificialmente com movimentos reais capturados durante as sessões de MoCap, utilizando medidas como erro quadrático médio (MSE), coeficiente de determinação (R^2), diferenças angulares entre articulações e métricas relacionadas à continuidade temporal dos movimentos. Serão comparados os resultados da nova abordagem, com uma transição linear e com os resultados obtidos com B-spline por [Poeta, 2025].

Também será iniciado o planejamento dos experimentos de avaliação qualitativa. Serão elaborados protocolos experimentais e formulários de coleta de dados destinados à participação de usuários fluentes em Libras. Esses experimentos buscarão avaliar aspectos como naturalidade dos movimentos, inteligibilidade da sinalização, qualidade das expressões faciais, fluidez das transições e aceitação geral da tecnologia desenvolvida.

Adicionalmente, pretende-se aprofundar os estudos relacionados à aplicação de técnicas de aprendizado de máquina sobre dados de movimento. Em particular, serão investigadas abordagens de aprendizado auto-supervisionado capazes de produzir representações vetoriais dos movimentos capturados, inspiradas em estratégias de Masked Autoencoding propostas por [He et al., 2022], permitindo futuramente a substituição ou complementação dos métodos tradicionais de seleção de unidades por mecanismos baseados em similaridade aprendida.

Por fim, os resultados obtidos ao longo do período serão sistematicamente documentados, contribuindo para a elaboração de publicações científicas, relatórios técnicos e materiais de divulgação associados ao projeto. Espera-se que, ao final do próximo período, o sistema possua uma versão funcional capaz de sintetizar sequências de sinais em Libras a partir da concatenação automática de segmentos de captura de movimento, em conjunto com resultados das avaliações experimentais previstas no plano de trabalho.

Referências

- [He et al., 2022] He, K., Chen, X., Xie, S., Li, Y., Dollár, P., and Girshick, R. (2022). Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 16000–16009.
- [Hunt and Black, 1996] Hunt, A. and Black, A. (1996). Unit selection in a concatenative speech synthesis system using a large speech database. In *1996 IEEE International Conference on Acoustics, Speech, and Signal Processing Conference Proceedings*, volume 1, pages 373–376 vol. 1.
- [Max Planck Institute for Psycholinguistics, 2025] Max Planck Institute for Psycholinguistics (2025). Elan (version 7.1) [computer software]. Accessed: 2026-06-04.
- [Mori et al., 2012] Mori, M., MacDorman, K., and Kageki, N. (2012). The uncanny valley [from the field]. *IEEE Robotics & Automation Magazine*, 19:98–100.
- [Poeta, 2025] Poeta, E. (2025). Síntese concatenativa de línguas sinais. Msc thesis, Universidade Estadual de Campinas(UNICAMP).
- [Schwarz, 2005] Schwarz, D. (2005). Current research in concatenative sound synthesis. In *Proceedings of the International Computer Music Conference (ICMC)*, pages 1–4, Barcelona, Spain. International Computer Music Association.
- [Shoemake, 1985] Shoemake, K. (1985). Animating rotation with quaternion curves. In *Proceedings of the 12th Annual Conference on Computer Graphics and Interactive Techniques (SIGGRAPH '85)*, pages 245–254. ACM.



3 Trabalhos Preparados ou Submetidos

Artigo Submetido e em Avaliação Concatenative Synthesis for Brazilian Sign Language

XI Workshop de Iniciação Científica em Tecnologia da Informação e da Linguagem Humana

Concatenative Synthesis for Brazilian Sign Language

Anonymous¹

¹ Anonymous

Abstract. *This paper describes the mechanism of a widely used technique in spoken language processing and sound generation known as Concatenative Synthesis applied, however, to realistic 3D sign language animation generation. This technique generates a new animation sequence based on the concatenation of pre-recorded motion capture signs performed by a group of brazilian sign language interpreters resulting in a smoother and more natural final animation. The goal of this approach is to minimize the uncanniness of current signing 3D avatars and neural model generations that fluent sign language speakers notice.*

Resumo. *Esse artigo descreve o mecanismo de uma técnica bem difundida no processamento de linguagem falada e geração de sons conhecida como Síntese Concatenativa aplicada, no entanto, para a geração de animações 3D realistas de linguagens de sinais. Essa técnica gera novas sequências de animação baseada na concatenação de sinais gravados previamente com tecnologia de captura de movimento conduzida por um grupo de intérpretes de línguas de sinais brasileira, resultando em uma animação final mais suave e natural. O objetivo dessa abordagem é minimizar o estranhamento percebido por sinalizantes da língua de sinais em atuais avatares 3D sinalizantes.*

1. Introduction

Concatenative Synthesis is a technique for generating new instances of a certain medium, be it audio or video, such that it breaks down the original content into small pieces called units and, given an user input, it generates a new and unseen expression preserving the naturalness of the original pre-recorded content. In the context of this paper, this technique is used as a means to generate new Brazilian Sign Language (LIBRAS) animations for a three-dimensional avatar.

This work extends previous research by introducing improvements in the unit selection mechanism, a quaternion-based transition smoothing algorithm that preserves movement dynamics, a compact storage format based exclusively on skeletal quaternion data, a web-native animation synthesis pipeline based on Three.js, an integrated production-oriented architecture capable of performing real-time sign synthesis and visualization, as portrayed by [SLA Project 2024] .

2. Related Work

Concatenative synthesis has its roots in speech processing, where it was first employed to generate natural-sounding audio from pre-recorded units. The technique relies on segmenting a corpus of natural speech into small units — ranging from individual phonemes to entire sentences — and selecting and concatenating them to synthesize new utterances [Hunt and Black 1996, Schwarz 2005].

The application of concatenative synthesis to sign languages was first systematically explored by [Poeta 2025], whose work constitutes the primary inspiration for this paper. In that work, motion capture sequences of Brazilian Sign Language (LIBRAS) interpreters are segmented into gloss-labeled units and stored in a Motion Capture Database (BDCM). In his approach, the unit selection mechanism minimizes transition costs across all available sign fragment instances, while the transition smoother concatenates gaps to produce natural-looking movement, looking to reduce the uncanny valley effect that fluent signers perceive in current avatar solutions. [Mori et al. 2012]

Concatenative Synthesis was originally developed for speech synthesis, where new utterances are generated by selecting and concatenating segments from a database of recorded speech. Inspired by this approach, [Poeta 2025] proposed its adaptation to sign language synthesis, replacing speech units with motion-captured sign segments annotated through glosses and linguistic tools such as ELAN [ELAN 2023].

3. Methodology

3.1. Motion Capture Sessions

Initially, motion capture sessions were conducted using a wearable motion capture suit worn by a fluent Brazilian sign language (LIBRAS) interpreter. The interpreter performed complete phrases while the system recorded skeletal motion at a fixed sampling frequency. Also, facial expressions were captured using a stabilized camera attached to a helmet that was later processed to extract facial features via computer vision. The captured motion was tied to the skeleton of the virtual avatar, ensuring the realism component compatibility between the interpreter and the rendering model.

From this step, the data is exported and filtered so that only quaternion data per bone and per frame is stored, minimizing storage necessity.

3.2. Chosen technologies

Moreover, the logic behind the proposed solution is mainly underpinned by technologies that allow easy and natural web compatibility. As such, a web app was initially developed using a typescript app with the Three.js module, an open-source 3D renderer for web platforms, with plans to allow offline portability via a Rust-based wrapper, Tauri.

With the use of these technologies, a robust system is built upon this foundation, as shown in 1. The user selects a text on a webpage, which then requests from a server the translation from text to gloss, and returns the result of the gloss to sign translation, which is a file containing only the quaternion data for the animation for each bone.




Figura 1. Architecture of the Synthesizer (Source: The Author)

3.3. ELAN annotation

To associate motion capture sequences with their corresponding sign units, all recording sessions generated a signing avatar video for sign recognition. The videos were annotated using the ELAN linguistic annotation tool [ELAN 2023], where specialists identified the start and end frames of each sign. These annotations were aligned with the motion capture data, allowing automatic extraction of sign fragments and generation of a motion database identified by glosses. With this, it's possible to structure the concatenative synthesis mechanism, which can be summarized into 4 steps

3.4. Concatenative Synthesis Steps

3.4.1. Unit Selection

In unit selection, after the gloss to sign retrieval, the algorithm chooses the sign fragments to be used in the synthesis. For that goal, every instance of a sign is considered and filtered based on a search mechanism that prioritizes the minimum transition cost between fragments, minimizing the need for artificial interpolation.

This issue is currently solved based on a shortest path on a graph problem with regards to the cost of the entire sentence [Poeta 2025]. However, in this approach, along with considering the cost of quaternional difference between the last frame of the previous sign and the first frame of the next, the dynamics of the movement are also considered, such that the difference in velocity is a factor in determining the selection to preserve the natural flow of the movement.

3.4.2. Content Generator

As a result of the unit selection, the content generator then requests and loads in the memory the specific sign animation data corresponding to the glosses in the input sentence. The result of this step produces a sequence of mocap quaternion data which is ready to be processed by the transition smoother step.

3.4.3. Transition Smoother

The transition smoother's goal is to attenuate discontinuities associated with the inert difference between two different signs, likely recorded in different contexts. To achieve this goal, this mechanism completes the gaps between each concatenation utilizing a spherical linear interpolation (SLERP), while also preserving the angular momentum of the movement with the inclusion of a parameter that compares both signs and attenuates accordingly, therefore composing a movement with minimum loss of hand and facial expression details.

3.4.4. Animation Synthesizer

Finally, the animation synthesizer constitutes the final step of the concatenative synthesis process, applying the animation into a signing 3D avatar. This is done by composing an

update cycle that reads this data at a fixed minimum frame-rate of 30 frames per second, reading the quaternion data of each joint and applying them to the quaternion of the skeleton, deforming its mesh and producing the final perceptible result of the respective sign from the gloss list.

4. Expected Results

While the work is still in its early stages, it's possible to share the methodology to be used in the results and what is expected. There are two main routes to target, the first being a qualitative analysis, aiming to measure uncaniness and approval by fluent sign language speakers; and the second being a quantitative analysis of compatibility between a reconstructed and the original phrase.

The qualitative analysis consists on a form that sign language speakers will fill out and give grades ranging from 1 (bad) to 5 (identical) in a series of categories, such as finger movement, facial expressions, understandability, among others.

On the other hand, the quantitative analysis will compare synthetic animation curves generated by the transition smoother step and an original recorded transition of the same sign transition, providing the mean squared error (MSE) and R^2 .

5. Next steps

As for next steps in implementation, the inclusion of facial expressions specially for feeling discernment in sign language sentences.

Also, a major change is to be made in the unit selection process. Currently, this process is designed as a single rule-based minimum cost function. However, movement properties are far more complex than what this graph-based approach captures. In an attempt to catch a more rich property data for the movement, such as capturing rhythm and contextual compatibility, a direction that is currently being studied is the implementation of embeddings for quaternions data, and a neural network trained with a self-supervised learning strategy, such as Masked Autoencoding [He et al. 2021] or Temporal Neighborhood Coding, or other non-contrastive approaches.

6. Final remarks

This work described a technique for generating unseen three-dimensional animations utilizing unit fragments of recorded labeled mocap data. The proposed concatenative synthesis pipeline for Brazilian Sign Language (Libras) addresses a key limitation of existing signing avatar systems: the uncanny and robotic quality of synthesized movement that fluent sign language speakers readily notice.

By grounding animation in real interpreter motion captured via mocap suits, and selecting sign fragments through an optimization on a cost function based on context of each sign, the system tends to produce realistic movement and is promising path to preserving the naturalness of the original performance.

While there's arguably lots of room for implementation and improvement, this work has potential to output a groundbreaking brazilian sign language 3D avatar with the most appeal to the sign language speaker and deaf community.

Referências

- ELAN (2023). <https://archive.mpi.nl/tla/elan>.
- He, K., Chen, X., Xie, S., Li, Y., Dollár, P., and Girshick, R. (2021). Masked autoencoders are scalable vision learners. IEEE Computer Society.
- Hunt, A. J. and Black, A. W. (1996). Unit selection in a concatenative speech synthesis system using a large speech database.
- Mori, M., MacDorman, K., and Kageki, N. (2012). The uncanny valley [from the field]. *IEEE Robotics Automation Magazine*, 19:98–100.
- Poeta, E. (2025). *Síntese Concatenativa de Línguas Sinais*. Msc thesis, Universidade Estadual de Campinas(UNICAMP).
- Schwarz, D. (2005). Current research in concatenative sound synthesis. pages 1–1.
- SLA Project (2024). <https://slaproject.com/>.

Anexo 18

Relatório Bolsista - IC

Isabela Gomes Pereira

UNIVERSIDADE DE SÃO PAULO
FACULDADE DE FILOSOFIA, LETRAS E CIÊNCIAS HUMANAS
DEPARTAMENTO DE LINGUÍSTICA

RELATÓRIO CIENTÍFICO PARCIAL
CENTRO DE CIÊNCIA PARA O DESENVOLVIMENTO - TECNOLOGIA ASSISTIVA E
ACESSIBILIDADE EM LIBRAS (CCD-TAAL)

Beneficiário: Isabela Gomes Pereira

Orientador: Felipe Venâncio Barbosa

Período de vigência: 01/06/2026 a 31/12/2026

Período coberto por este Relatório Científico: 01/06/2026 a 25/06/2026

Título do projeto: Construção de base de dados a partir da tradução do português para a
Libras: discussão sobre a viabilidade e o papel das glosas

Número do Processo FAPESP: 2026/11885-3

Processo Vinculado: 2024/00914-7

Pesquisador principal: José Mario de Martino

São Paulo

2026

RESUMO DO PROJETO

O Centro de Ciência para o Desenvolvimento - Tecnologia Assistiva e Acessibilidade em Libras (CCD-TAAL) une professores e graduandos da Universidade Estadual de Campinas, Universidade de São Paulo, Universidade Federal de São Carlos e Instituto de Pesquisas Tecnológicas para pesquisar tecnologias de acessibilidade comunicacional que foquem na Libras. O projeto tem como objetivos o estudo e a difusão da Língua Brasileira de Sinais (Libras) e o desenvolvimento de abordagens e aplicativos para a tradução entre o português e a Libras.

Nesse sentido, torna-se imprescindível a atuação de pesquisadores na área de Linguística Aplicada para contribuir nas etapas de definição do formalismo de anotação por glosas e construção de base de dados. Desde a popularização das glosas a partir do trabalho de William Stokoe, elas têm sido amplamente utilizadas por pesquisadores das línguas de sinais, mas o trabalho feito pelo CCD-TAAL exige melhorias nessa estratégia de notação. A presente bolsista cumpre esse papel por 7 meses (o período de vigência disponibilizado para essa atuação pela FAPESP).

REALIZAÇÕES NO PERÍODO

No breve período de um mês, a bolsista pôde participar de reuniões do Centro de Ciência para o Desenvolvimento - Tecnologia Assistiva e Acessibilidade em Libras e do projeto em que se colaboram um grupo de pesquisa da Technische Hochschule Ingolstadt (THI) e o CCD-TAAL, para tornar mais acessível a comunicação para pessoas Surdas em diferentes meios de transporte. Nas reuniões gerais, a bolsista pôde conhecer a equipe e se informar sobre o andamento do projeto e das realizações de cada membro, enquanto, pôde no segundo tipo de reunião, perceber estratégias de tradução do português escrito para a sinalização na Libras.

O espaço virtual das reuniões se mostra um importante evento na rotina da estudante, uma vez que o contato com as sinalizações de cada participante (Surdo ou ouvinte) enriquece o seu conhecimento sobre a Libras. O segundo tipo de reunião (as de tradução), em especial, são muito valiosas para aprender sobre as especificidades de cada língua e como traduzir entre elas.

Ademais, a bolsista esteve em contato com outro bolsista do projeto, para trocar informações e indicações de referências bibliográficas. Desse modo, ela conheceu o grupo de Estudos Surdos do Laboratório de Estudos em Língua de Sinais e Cognição (LiSCo) e participará dele nas próximas reuniões, algo que se espera agregar em muito à sua pesquisa no CCD-TAAL. Nelas, pretende-se ler o livro *Research Methods in Sign Language Studies: A Practical Guide*, escrito por Orfanidou, Woll e Morgan e publicado em 2015.

Para além disso, a bolsista iniciou a sua revisão bibliográfica sobre o uso de glosas como estratégia de notação e revisão de estratégias de notação em pesquisas no campo da linguística e da tradução com a leitura de dois textos:

- OLIVEIRA SILVA ALMEIDA, Melquisedeque; MEIRA LEITE DE OLIVEIRA, Márcia. A Escrita das Línguas de Sinais: Um pouco da história e do desenvolvimento do Sistema Signwriting. *Língu@ Nostr@*, [S. l.], v. 13, n. 2, p. 100–123, 2026. DOI: 10.22481/lnostr.v.13i2.18604. Disponível em: <https://periodicos2.uesb.br/lnostr/article/view/18604>. Acesso em: 20 jun. 2026.
- QUADROS, Ronice Muller de. A transcrição de textos do Corpus de Libras. *Revista Leitura*, [S. l.], v. 1, n. 57, p. 8–34, 2017. DOI: 10.28998/2317-9945.201657.8-34. Disponível em: <https://periodicos.ufal.br/revistaleitura/article/view/3618>. Acesso em: 24 jun. 2026.

Ambos trazem importantes análises de sistemas de notação para as línguas de sinais, que contribuíram para que a bolsista percebesse a necessidade do refinamento do processo de tradução com uso de glosas.

PLANO DE ATIVIDADES PARA O PRÓXIMO PERÍODO

Pretende-se seguir o plano de atividades a seguir nos próximos seis meses:

Atividades	6 meses					
	1	2	3	4	5	6
Revisão bibliográfica	.	.	.	.		
Revisão de estratégias de notação	.	.	.	.		
Refinamento do processo de tradução com uso de glosas		.	.	.	.	.
Elaboração de artigo				.	.	.
Escrita de relatório técnico				.	.	.
Participação das reuniões dos projetos adjacentes (CCD-TAAL e LiSCo)	.	.	.	.	.	.

REFERÊNCIAS BIBLIOGRÁFICAS:

OLIVEIRA SILVA ALMEIDA, Melquisedeque; MEIRA LEITE DE OLIVEIRA, Márcia. A Escrita das Línguas de Sinais: Um pouco da história e do desenvolvimento do Sistema Signwriting. **Língu@ Nostr@**, [S. l.], v. 13, n. 2, p. 100–123, 2026. DOI: 10.22481/lnostr.v.13i2.18604. Disponível em: <https://periodicos2.uesb.br/lnostr/article/view/18604>. Acesso em: 20 jun. 2026.

ORFANIDOU, Eleni; WOLL, Bencie; MORGAN, Gary. **Research methods in sign language studies: A practical guide**. John Wiley & Sons, 2014.

QUADROS, Ronice Muller de. A transcrição de textos do Corpus de Libras. **Revista Leitura**, [S. l.], v. 1, n. 57, p. 8–34, 2017. DOI: 10.28998/2317-9945.201657.8-34. Disponível em: <https://periodicos.ufal.br/revistaleitura/article/view/3618>. Acesso em: 24 jun. 2026.